



Дуглас Люк

Анализ сетей (графов) в среде R

Руководство пользователя

Дуглас Люк

Анализ сетей (графов) в среде R. Руководство пользователя

Douglas A. Luke

A User's Guide to Network Analysis in R



Дуглас Люк

Анализ сетей (графов) в среде R. Руководство пользователя



УДК 004.73:004.438R

ББК 32.971.35

Л94

Люк Д. А.

Л94 Анализ сетей (графов) в среде R. Руководство пользователя / пер. с англ. А. В. Груздева. – М.: ДМК Пресс, 2017. – 250 с.: ил.

ISBN 978-5-97060-428-1

Данная книга представляет собой практическое руководство по решению основных задач, связанных с анализом сетей, включая управление сетевыми данными, визуализацию сетей, их описание и моделирование. Все примеры, используемые в книге, сопровождаются программным кодом на языке R.

Издание служит отличным справочным ресурсом для изучения науки о сетях.

УДК 004.73:004.438R

ББК 32.971.35

Translation from the English language edition:

A User's Guide to Network Analysis in R

by Douglas A. Luke

Copyright © Springer International Publishing Switzerland 2015

This Springer imprint is published by Springer Nature

The registered company is Springer International Publishing AG

All Rights Reserved

Все права защищены. Любая часть этой книги не может быть воспроизведена в какой бы то ни было форме и какими бы то ни было средствами без письменного разрешения владельцев авторских прав.

Материал, изложенный в данной книге, многоократно проверен. Но поскольку вероятность технических ошибок все равно существует, издательство не может гарантировать абсолютную точность и правильность приводимых сведений. В связи с этим издательство не несет ответственности за возможные ошибки, связанные с использованием книги.

ISBN 978-3-319-23882-1 Copyright © Springer International Publishing Switzerland, 2015

ISBN 978-5-97060-428-1

© Перевод, издание, оформление, ДМК Пресс, 2017

*Моей самой важной социальной сети –
Сью, Алине и Эндрю – посвящается*

Содержание

Предисловие	9
Глава 1. Введение в анализ сетей в R	11
1.1. Что такое сети?	12
1.2. Что такое анализ сетей?	14
1.3. Пять серьезных причин проводить анализ сетей в R	15
1.3.1. Широта возможностей R	15
1.3.2. Свободно распространяемая и открытая природа R	16
1.3.3. Возможности работы с данными и проектами в R	16
1.3.4. Широкий выбор пакетов для анализа сетей в R	17
1.3.5. Возможности моделирования сетей в R	17
1.4. Область применения книги и ресурсы	17
1.4.1. Область применения	17
1.4.2. «Дорожная карта» книги	18
1.4.3. Ресурсы	19
Часть I. ОСНОВЫ АНАЛИЗА СЕТЕЙ	20
Глава 2. «Пятиверстная сводка» для анализа сетей	21
2.1. Анализ в R: с чего начать	22
2.2. Подготовка.....	22
2.3. Простая визуализация.....	23
2.4. Базовое описание	23
2.4.1. Размер	23
2.4.2. Плотность	25
2.4.3. Компоненты	26
2.4.4. Диаметр.....	26
2.5. Коэффициент кластеризации	27
Глава 3. Управление сетевыми данными в R	28
3.1. Основные понятия сетевых данных.....	29
3.1.1. Структуры сетевых данных	29
3.1.2. Информация, хранимая в объектах-сетях.....	32
3.2. Создание объектов-сетей и работа с ними в R	32
3.2.1. Создание объекта-сети в statnet	33
3.2.2. Работа с атрибутами узлов и связей.....	36
3.2.3 Создание объекта-сети в igraph	39
3.2.4. Переключение между statnet и igraph.....	41
3.3. Импорт сетевых данных.....	41
3.4. Общераспространенные задачи при работе с сетевыми данными.....	43
3.4.1. Фильтрация сетевых данных на основе значений атрибутов вершин или ребер	43
3.4.2. Преобразование направленной сети в ненаправленную.....	50
Часть II. ВИЗУАЛИЗАЦИЯ	53
Глава 4. Графическое представление и укладка сети	54
4.1. Проблема визуализации сети.....	55
4.2. Эстетический вид укладок сетей	57
4.3. Основные алгоритмы и методы графического представления.....	59

4.3.1. Более точная настройка укладки сети.....	60
4.3.2. Укладки сетей, построенные с помощью <i>igraph</i>	62
Глава 5. Эффективный графический дизайн сетей	64
5.1. Основные принципы.....	65
5.2. Элементы дизайна	65
5.2.1. Цвет узла	66
5.2.2. Форма узла	71
5.2.3. Размер узла	72
5.2.4. Метка узла	77
5.2.5. Ширина ребра	78
5.2.6. Цвет ребра	79
5.2.7. Тип ребра	80
5.2.8. Легенды	81
Глава 6. Сложные графики сетей	83
6.1. Интерактивные графики сетей	84
6.1.1. Простые интерактивные сети в <i>igraph</i>	84
6.1.2. Публикация интерактивных веб-диаграмм сетей.....	85
6.1.3. Statnet Web: интерактивный <i>statnet</i> с помощью <i>shiny</i>	87
6.2. Специализированные диаграммы сетей.....	88
6.2.1. Дуговые диаграммы	88
6.2.2. Хордовые диаграммы.....	90
6.2.3. Теплокарты для сетевых данных	93
6.3. Создание диаграмм сетей с помощью других пакетов R.....	95
6.3.1. Построение диаграмм сетей с помощью <i>ggplot2</i>	95
Часть III. ОПИСАНИЕ И АНАЛИЗ	99
Глава 7. Важность актора	100
7.1. Введение.....	101
7.2. Центральность – показатель важности для ненаправленных сетей.....	101
7.2.1. Три популярные меры центральности	103
7.2.2. Меры центральности в R	105
7.2.3. Централизация: вычисление индексов центральности для сети в целом	106
7.2.4. Создание отчетов по центральности	107
7.3. Точки сочленения и мосты	111
Глава 8. Подгруппы	114
8.1. Введение.....	115
8.2. Социальная сплоченность	116
8.2.1. Клики	116
8.2.2. К-ядра	120
8.3. Обнаружение сообществ	123
8.3.1. Модульность	125
8.3.2. Алгоритмы обнаружения сообществ	127
Глава 9. Сети аффилированности	134
9.1. Определение сетей аффилированности.....	135
9.1.1. Аффилированность в виде бимодальных сетей	135
9.1.2. Двудольные графы (биграфы)	136
9.2. Основы сетей аффилированности.....	137
9.2.1. Создание сетей аффилированности из матриц инцидентности.....	137
9.2.2. Создание сетей аффилированности из списков ребер.....	138

9.2.3. Графическое представление сетей аффилированности	140
9.2.4. Проекции	140
9.3. Пример: актеры Голливуда как пример сети аффилированности.....	143
9.3.1. Анализ полной сети аффилированности актеров Голливуда.....	143
9.3.2. Анализ проекций актеров и фильмов.....	149
Часть IV. МОДЕЛИРОВАНИЕ	155
Глава 10. Модели случайных сетей	156
10.1. Предназначение моделей сетей	157
10.2. Модели формирования и структуры сети.....	158
10.2.1. Модель случайного графа Эрдеша–Рényи	158
10.2.2. Модель малого мира	162
10.2.3. Свободно масштабируемые модели.....	165
10.3. Сравнение моделей случайных графов с наблюдаемыми сетями	170
Глава 11. Статистические модели сетей	173
11.1. Введение.....	174
11.2. Построение экспоненциальных моделей случайных графов	177
11.2.1. Построение нулевой модели	179
11.2.2. Включение предикторов узлов	181
11.2.3. Включение предикторов диад	183
11.2.4. Включение предикторов ребер	187
11.2.5. Включение предикторов локальных структур (зависимых диадных связей)	189
11.3. Анализ экспоненциальных моделей случайных графов	191
11.3.1. Интерпретация модели	191
11.3.2. Подгонка модели.....	192
11.3.3. Диагностика модели	195
11.3.4. Имитационное моделирование сетей на основе оцененной модели.....	195
Глава 12. Модели динамических сетей	199
12.1. Введение.....	200
12.1.1. Динамические сети	200
12.1.2. RSiena	202
12.2. Подготовка данных	203
12.3. Спецификация и оценивание модели	210
12.3.1. Спецификация модели	210
12.3.2. Оценивание модели	214
12.4. Анализ модели	215
12.4.1. Интерпретация модели	215
12.4.2. Качество подгонки	220
12.4.3. Имитационное моделирование	224
Глава 13. Имитационные модели	228
13.1. Имитационные модели сетевой динамики.....	229
13.1.1. Имитационное моделирование социальной селекции	229
13.1.2. Имитационное моделирование социального влияния	240
Библиография.....	247

Предисловие

В начале 2000 года Стивен Хокинг сказал, что «следующий век будет веком сложности». Если его прогноз верен, то выходит, что нам потребуются новые научные теории, методы сбора данных и аналитические подходы, которые будут использоваться для исследования сложных систем и поведения. Наука о сетях – это подход, рассматривающий мир через призму сетей, в котором физические и социальные системы образованы разнородными акторами, соединенными друг с другом с помощью различных типов связей. Анализ сетей – это набор аналитических инструментов, используемых для изучения таких систем. В течение последних нескольких десятилетий анализ сетей приобретает все большее значение в арсенале аналитических средств, используемых социологами, врачами и физиками.

До недавнего времени для проведения анализа сетей требовалось специализированное программное обеспечение (как для управления сетевыми данными, так и для последующего анализа). Однако начиная примерно с 2000 года инструменты для анализа сетей появились в среде статистического программирования R. Помимо того что благодаря этому методы анализа сетей стали доступны более широкому кругу специалистов по статистике, пакет R предоставил исследователям, занимающимся анализом сетей, обширные возможности по управлению данными, графической визуализации и статистическому моделированию.

Как и предполагает название, эта книга является руководством пользователя по анализу сетей в R. В этой книге приводятся ключевые задачи в области анализа сетей, которые теперь можно выполнить в R. Книга концентрируется на четырех основных задачах, с которыми обычно сталкивается специалист в области анализа сетей: управление сетевыми данными, визуализация сети, описание сети и моделирование сети. Книга включает программный код R, который используется в конкретных примерах анализа сетей. Кроме того, к книге прилагается комплект наборов сетевых данных, использующихся в ней. (См. главу 1 для получения более подробной информации о структуре книги, а также инструкции по поводу того, как получить сетевые данные.) Книга написана для тех, кого интересует проведение анализа сетей в R. Она может использоваться в качестве вспомогательного пособия по анализу сетей или руководства по методам анализа сетей в R.

Появление этой книги было бы невозможным без консультаций, поддержки, рекомендаций и советов, которые я получил за последние 30 лет благодаря своим собственным социальным сетям (личной и профессиональной). В середине 1980-х годов я закончил класс по анализу сетей у Стена Вассермана в Иллинойском университете в Урбане-Шампейне. Я помню, в каком я был восторге от этого нового метода анализа данных, но тогда думал, что вряд ли буду когда-либо использовать его в своей работе. Однако мои коллеги в области психологии и здравоохранения посоветовали мне в моей первоначальной работе рассмотреть тему использования анализа сетей для изучения и оценки данных. Среди них – Джулиан Раппапорт (Julian Rappaport), Эд Сейдман (Ed Seidman), Брюс Рапкин (Bruce Rapkin), Курт Рибисл (Kurt Ribisl), Шерон Хоман (Sharon Homan), Росс Браун-

сон (Ross Brownson) и Мэтт Кройтор (Matt Kreuter). Независимо от того, знают они это или нет, я был вдохновлен замечательным коллективом специалистов в области сетей и систем, в их числе Том Валенте (Tom Valente), Стив Боргатти (Steve Borgatti), Мартина Моррис (Martina Morris), Том Снайдерс (Tom Snijders), Скотт Лейшоу (Scott Leischow), Пэтти Мейбри (Patty Mabry), Стивен Маркус (Stephen Marcus) и Росс Хаммонд (Ross Hammond). Свои главные идеи, связанные с анализом сетей, я почерпнул от моих друзей и коллег в Научном центре общественного здравоохранения, в частности от Бобби Карозерса (Bobbi Carothers), Амара Дхенда (Amar Dhand), Криса Робишо (Chris Robichaux) и Нэнси Мюллер (Nancy Mueller). Особенно я благодарен моим студентам, посещавшим мои занятия и семинары на протяжении этих лет. Они не только улучшили эту книгу, но и расширили мои взгляды касательно анализа сетей. Отдельное большое спасибо Дженин Харрис (Jenine Harris). Дженин была моим первым докторантом, и в данный момент я восхищен строгостью и элегантностью ее работы, посвященной анализу сетей. Я также хотел бы поблагодарить Центры по контролю и профилактике заболеваний США, Национальные институты здравоохранения США и Фонд здоровья в Миссури за поддержку в проведении исследований, что позволило мне разработать и усовершенствовать подход к анализу сетей. Наконец, выражаю глубочайшую признательность членам моей семьи. Они дали мне определенные советы касательно содержания, предоставили место и время для напряженной работы над этой книгой (включая знаменательный подарок на День отца) и поддерживали меня в те моменты, когда я больше всего в этом нуждался. Спасибо вам, Сью, Али и Эндрю.

Сент-Луис, Миссури, США
Июль 2015

Дуглас Люк

Глава 1

Введение в анализ сетей в R

1.1. Что такое сети?	12
1.2. Что такое анализ сетей?	14
1.3. Пять серьезных причин проводить анализ сетей в R	15
1.4. Область применения книги и ресурсы	17

– Начните сначала, – серьезно сказал Король, – и читайте, пока не дойдете до конца: тогда и остановитесь.

Льюис Кэрролл. «Алиса в Стране чудес»

1.1. Что такое сети?

Эта книга является руководством пользователя для проведения анализа сетей в среде статистического программирования R. Сети – это все, что окружает нас. Люди естественным образом организуются в сетевые системы. Наши близкие и друзья формируют персональные социальные сети вокруг каждого из нас. Соседские общины организуются в сетевые объединения для выдвижения тех или иных требований. Компании сотрудничают (или конкурируют) друг с другом в рамках сложных, взаимосвязанных отношений торгового и финансово-го партнерства. Развитие здравоохранения осуществляется путем партнерства правительственные и неправительственные организаций [Luke, Harris, 2007]. Страны связаны друг с другом системами миграции, торговли и договорных обязательств.

Кроме того, практически везде встречаются сети, не связанные с человеческими коммуникациями. Наши гены и белки взаимодействуют друг с другом посредством сложных биологических сетей. Человеческий мозг теперь рассматривается как сложная сеть, или «коннектом» («connectome») [Sporns, 2012]. Аналогично человеческие болезни и их базовые генетические корни можно представить в виде «карты болезни» («diseasome») [Barabasi, 2007]. Виды животных взаимодействуют друг с другом различными сложными способами, один из которых – пищевая сеть, в которой взаимодействия можно описать отношениями «кто кого съедает». Информация уже сама по себе объединена в сеть. Наша правовая система пред-ставляет собой взаимосвязанную сеть ранее принятых юридических решений и прецедентов. Социальный и научный прогресс стимулируется процессом рас-пространения инноваций, в ходе которого информация разносится по взаимосвя-занным социальным системам, будь то фермеры Айовы [Rogers, 2003] или специа-листы в области общественного здравоохранения [Harris, Luke, 2009]. Похоже, что сети являются одним из способов, с помощью которого устроена вселенная.

Так что же такое сеть? На рис. 1.1 и 1.2 показаны две важные и интересные социальные сети. Рисунок 1.1 представляет собой сеть контактов 19 налетчиков, совершивших террористическую атаку на США 11 сентября 2001 года. Она взята из работы [Valdis Krebs, 2002]. Социальная сеть состоит из множества акторов (также называемых узлами), которые соединены друг с другом определенным ти-пом социальных отношений (также называемых связью).

На рисунке узлы показаны кружками, а связи – это линии, соединяющие не-которые узлы. Сеть показывает нам, что налетчики контактировали друг с другом, прежде чем совершить теракт 11 сентября, но количество связей в сети небольшое и, кажется, нет никакого доминирующего участника сети, который был бы связан со всеми налетчиками или с большинством из них.

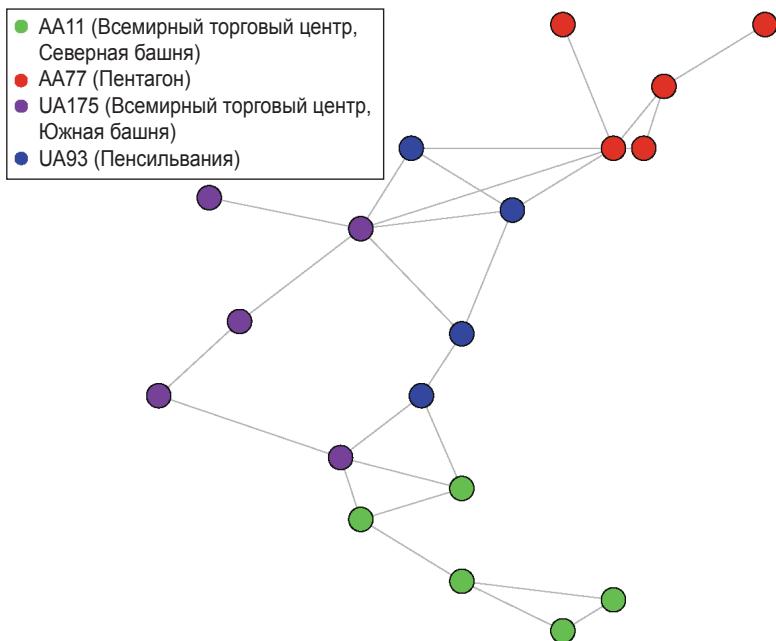


Рис. 1.1. Сеть контактов налетчиков, совершивших террористическую атаку на США 11 сентября 2001 года

Второй пример, приведенный на рис. 1.2, представляет совсем другой вид социальной сети. Здесь узлы – это участники сборной Нидерландов на Чемпионате мира по футболу FIFA 2010 года, которая потерпела поражение в финальном матче с Испанией. Связи – это передачи мяча между различными игроками во время матчей на Чемпионате мира. Стрелки показывают направление передач. Мы видим, что вратарь передавал мяч прежде всего защитникам, а нападающие получали пасы главным образом от полузащитников (за исключением игрока под номером 6, который, в отличие от двух остальных нападающих, похоже, использовал другую манеру передачи мяча).

Может показаться, что между этими двумя примерами мало общего. Однако их объединяет фундаментальное свойство, характерное для всех социальных сетей. Типы социальных взаимосвязей, приведенные на рисунках, не случайны. Они отражают лежащие в их основе социальные процессы, которые можно исследовать с помощью научных теорий и методов, использующихся в рамках анализа сетей. Террористическая сеть не имеет выраженного лидера, и ее члены слабо связаны друг с другом, поскольку именно это и затрудняет обнаружение и ликвидацию такой сети. Связи, представляющие собой паттерны передачи мяча, отражают роли игроков, правила игры и стратегию тренера. Анализ сетей «понятия не имеет» об этих правилах или стратегиях. И тем не менее его можно использовать для определения этих паттернов, которые отражают основные правила и закономерности.

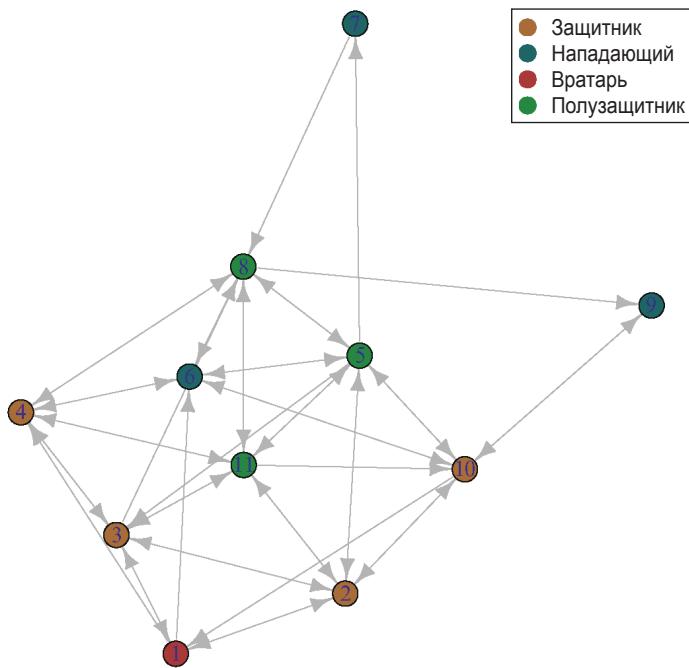


Рис. 1.2. Сеть игроков сборной Нидерландов, участвовавшей в Чемпионате мира по футболу FIFA 2010 года

1.2. Что такое анализ сетей?

Наука о сетях (network science) является широким научным подходом, который использует анализ взаимосвязей для изучения и интерпретации биологических, физических, социальных и информационных систем. Основной инструмент для специалистов по сетям – это анализ сетей, который представляет собой набор методов, использующихся для (1) визуализации сетей, (2) описания определенных характеристик структуры сети в целом, а также получения детальной информации об отдельных узлах, связях и подгруппах внутри сетей, (3) создания математических и статистических моделей сетевых структур и сетевой динамики. Поскольку основной вопрос, интересующий науку о сетях, касается взаимосвязей, большинство методов, используемых в анализе сетей, сильно отличается от более традиционных статистических инструментов, используемых социологами и учеными-медиками.

Анализ сетей (network analysis) – это отдельное научное направление со своими собственными теориями и методами, взятыми из других дисциплин, в частности из теории графов и топологии в математике, анализа систем родственных связей в антропологии, анализа социальных групп и процессов в социологии и психологии. Хотя анализ сетей не был изобретен конкретным человеком в определенном месте и в определенное время, первоначальные наработки того, что мы теперь

называем современным анализом сетей, можно найти в работе Якоба Морено, опубликованной в 1930-х годах. Он стал называть исследования социальных отношений социометрией и основал журнал *Sociometry*, в котором были опубликованы первые работы в этой области. Он также изобрел социограмму, которая была средством визуализации структуры сети. Первая опубликованная социограмма появилась в газете «Нью-Йорк таймс» в 1933 году, и это была сетевая диаграмма дружеских отношений между учениками 4-го класса. (Эта информация входит в набор сетевых данных, который используется в данной книге, см. раздел 1.4.3 ниже.)

Теории и методы анализа сетей разрабатывались на протяжении последних десятилетий XX века, существенный вклад внесли социология, психология, политология, бизнес, здравоохранение и компьютерная наука. Развитие науки о сетях в качестве практической дисциплины было обусловлено разработкой различных программных средств для анализа сетей, включая UCINet, STRUCTURE, Negopy и Rajek. В течение последних 20–30 лет отмечается взрывной рост популярности науки о сетях, обусловленный, по крайней мере, тремя различными факторами. Во-первых, математики, физики и другие исследователи разработали много серьезных теорий, касающихся формирования сетей и их структур, что привлекло внимание к науке о сетях (см. главу 10, в которой рассматриваются эти теории). Во-вторых, рост вычислительной мощности и скорости позволил использовать методы анализа сетей применительно к большим и очень большим сетям, таким как Интернет, население планеты или человеческий мозг. Наконец, новые подходы, появившиеся в рамках статистической теории сетей, впервые позволили аналитикам выйти за рамки простого описания сети, чтобы построить и протестировать статистические модели сетевых структур и процессов (см. главы 11 и 12).

1.3. Пять серьезных причин проводить анализ сетей в R

Как и предполагает название, эта книга является общим руководством для проведения анализа сетей с помощью статистического языка и программной среды R. Почему R является идеальной платформой для разработки и проведения анализа сетей? Существует, по крайней мере, пять серьезных доводов.

1.3.1. Широта возможностей R

Язык и среда статистического программирования R представляют собой обширную интегрированную систему, состоящую из тысяч пакетов и функций, которые позволяют выполнять неисчислимое количество задач по управлению данными, анализу и визуализации. R включает в себя ряд пакетов, которые предназначены для выполнения определенных задач анализа сетей. Выполняя эти задачи в среде R, аналитик может использовать в своих интересах все имеющиеся возможности R. Большинство остальных программ по анализу сетей (например, Rajek, UCINet, Gephi) являются автономными пакетами и поэтому не обладают преимуществами работы в интегрированной среде статистического программирования.

1.3.2. Свободно распространяемая и открытая природа R

Одной из важных причин популярности и успеха R является тот факт, что R – это свободно распространяемый и открытый язык. Официально это подкреплено Открытым лицензионным соглашением GNU, в соответствии с которым распространяется программный код R. Если говорить менее формально, существует огромное сообщество пользователей и разработчиков R, которые постоянно работают над расширением возможностей и улучшением программного кода R и тысячи пакетов R, доступных для свободного скачивания. Инструменты R по анализу социальных сетей, описанные в этой книге, были фактически разработаны пользовательским сообществом R. Открытая природа R способствует более быстрой (и возможно, более внятной и более функциональной) разработке и популяризации новых статистических техник, например инструментов для анализа сетей.

1.3.3. Возможности работы с данными и проектами в R

Несмотря на то что существует много хороших общедоступных программ по анализу сетей, которые могут выполнить самые различные задачи, связанные с исследованием описательных статистик сетей и визуализацией, ни один из программных пакетов, по сравнению с R, не имеет таких же возможностей работы с данными и проектами по изучению крупномасштабных сетей. Во-первых, как уже упоминалось выше, для анализа сетей в R можно использовать внушительные возможности языка R по управлению, очистке, импорту и экспорту данных. Как описано в главе 3, анализ сетей часто начинается с того, что нужно импортировать данные из других источников и преобразовать их в формат, который можно проанализировать с помощью соответствующих инструментов. Все программные пакеты по анализу сетей имеют определенные инструменты управления данными, но ни одна из программ не сравнится с R по широте возможностей и глубине анализа.

Во-вторых, при проведении сложного научного или прикладного анализа сетей важно иметь под рукой подходящие инструменты управления проектами, чтобы упростить хранение и извлечение программного кода, работу с аналитическими выводами (например, со статистическими результатами и графиками), составление отчетов для внутренних и внешних пользователей. В отличие от большинства программ по работе с сетями, традиционные платформы статистического анализа, например SAS и SPSS, имеют подобные инструменты. Используя интегрированную среду разработки для языка R, например RStudio (<http://rstudio.org/>), и вооружившись преимуществами таких пакетов, как `knitr` и `shiny`, пользователь получает возможность управлять проектом сети любой сложности. Фактически легкость разработки и общедоступность этих инструментов были движущими силами направления *воспроизводимое исследование (reproducible research)* [Gentleman, Lang, 2007], которое подчеркивает важность объединения данных, программного кода, результатов и документации в унифицированном и общедоступном формате. В качестве примера, иллюстрирующего возможности инструментов воспроизводимого исследования, имеющихся в R, можно привести эту книгу, которая полностью была создана в RStudio.

1.3.4. Широкий выбор пакетов для анализа сетей в R

Основная причина, по которой R идеально подходит для анализа сетей, – это широкий выбор пакетов, которые в данный момент позволяют управлять сетевыми данными, а также осуществлять визуализацию, интерпретацию и моделирование сетей. Существуют десятки пакетов для анализа сетей, и их становится все больше и больше. Благодаря пакетам *network* и *igraph* с сетевыми данными можно работать как с объектами R, с помощью пакета *intergraph* объекты одного класса можно преобразовать в объекты другого класса. Базовый анализ и визуализацию сетей можно выполнить с помощью пакета *sna*, который входит в более широкий комплект пакетов для анализа сетей *statnet*, а также в *igraph*. Более сложное моделирование сетей можно выполнить с помощью пакета *ergm* и сопутствующих библиотек, модели динамических сетей строятся с помощью пакета *RSiena*. Свободно распространяемые программы анализа сетей имеют много преимуществ (здесь можно упомянуть о возможностях визуализации в Gephi), но ни одна из программ не сравнится с объединенными возможностями пакетов для анализа социальных сетей, имеющихся в R.

1.3.5. Возможности моделирования сетей в R

Наконец, нужно упомянуть о конкретных преимуществах R с точки зрения моделирования сетей. R является единственным общедоступным программным пакетом, который обладает всесторонними возможностями для проведения стохастического моделирования сетей (например, в R можно создавать экспоненциальные модели случайных графов), построения моделей динамических сетей (что позволяет исследовать изменение сети с течением времени) и имитационного моделирования сетей.

1.4. Область применения книги и ресурсы

1.4.1. Область применения

Как следует из названия, цель этой книги состоит в том, чтобы дать вам практическое руководство по анализу сетей в среде статистического программирования R. Книга является практической в том смысле, что в ней приводятся короткие фрагменты программного кода, которые предназначены для проведения анализа сетей и применяются к реальным сетевым данным. Здесь же приводятся результаты исследований. Читатель может скачать примеры программного кода и данные, чтобы легко повторить все то, что показано в книге, поэкспериментировать с собственными данными или программным кодом и таким образом упростить процесс обучения.

Практическая цель книги состоит в том, чтобы продемонстрировать применение методов анализа сетей в R для решения различных исследовательских задач. Речь идет об управлении данными, визуализации сети, вычислении описательных статистик сети и выполнении математического, статистического и динамичного моделирования сетей. Целевая аудитория включает студентов, аналитиков и исследователей различного профиля, конкретно социологов, ученых-медиков, представителей бизнеса и инженеров.

Кроме того, необходимо отметить, что эта книга не является инструкцией по выполнению анализа сетей. Во-первых, в этой книге нет всестороннего рассмотрения теорий, развивавшихся в рамках науки о сетях. Существует много хороших книг, статей, учебных курсов и интернет-ресурсов в свободном доступе, где излагается этот материал. Для составления общего представления все еще подойдет классический текст [Wasserman, Faust, 1994], а в работе [John Scott, 2012] представлен прекрасный и более актуальный обзор теорий и методов науки о сетях. Для более глубокого знакомства с наукой о сетях и статистической теорией см. работу [Newman, 2010] или [Kolaczyk, 2009]. Наконец, упомяну о двух работах, в которых подробно освещена новейшая история науки о сетях, а также прекрасно реализованы научные исследования эмпирических сетей, – работе [Newman et al., 2006], а также работе [Scott, Carrington, 2011].

Во-вторых, эта книга ни в коем случае не является введением в программирование R и статистический анализ. Несмотря на то что были предприняты все попытки сделать примеры программного кода максимально понятными и краткими, начинающий пользователь R обнаружит, что некоторые приемы и синтаксис программного кода сложно понять. В частности, чтобы извлечь максимальную пользу из этого руководства, вам очень пригодится знакомство с возможностями R по управлению данными, графикой и объектно-ориентированным подходом к статистическому моделированию.

Таким образом, книга адресована заинтересованному студенту, аналитику или исследователю, который знаком с R и имеет некоторое представление о теории и методах науки о сетях. Ее можно использовать в качестве вспомогательного пособия по анализу сетей для студентов вузов. Кроме того, опытные аналитики, работающие в R и желающие включить анализ сетей в свой арсенал программно-аналитических средств, могут использовать эту книгу в качестве учебника.

1.4.2. «Дорожная карта» книги

Книга разбита на четыре основные части, которые соответствуют четырем фундаментальным задачам, на выполнение которых специалисты по анализу сетей тратят большую часть своего времени: управление данными, визуализация сетей, описание сетей и моделирование сетей. Первая часть включает две главы, которые представляют собой введение в базовые методы анализа сетей, затем следует более глубокое рассмотрение проблем, связанных с управлением данными в рамках анализа сетей. Три главы, относящиеся к части «Визуализация», посвящены базовым укладкам сетей, выбору графического дизайна сетей, также рассматриваются некоторые продвинутые графики и методы визуализации. Часть «Описание и анализ» состоит из трех глав, которые касаются наиболее распространенных методов, используемых для описания важных характеристик сети, включая важность актора, подгруппы и сообщества внутри сетей, работу с сетями аффилированности. Заключительная часть «Моделирование» включает четыре главы, которые представляют собой продвинутые методы математического моделирования, статистического моделирования, моделирования динамических сетей и имитационного моделирования сетей. В табл. 1.1 приводится «дорожная карта» книги.

Таблица 1.1. «Дорожная карта» руководства пользователя

Глава	Пакеты	Наборы данных
Введение		FIFA_Nether, Krebs
Пятичисловая сводка	statnet, sna	Moreno
Сетевые данные	statnet, network, igraph	DHHS, ICTS
Базовая визуализация	statnet, sna	Moreno, Bali
Графический дизайн	statnet, sna, igraph	Bali
Продвинутая графика	arcdiagram, circlize, visNetwork, networkD3	Simpsons, Bali
Важность	statnet, sna	DHHS, Bali
Подгруппы	igraph	DHHS, Moreno, Bali
Сети аффилированности	igraph	hwd
Математические модели	igraph	Ihds
Стохастические модели	ergm	TCnetworks
Динамические модели	RSiena	Coevolve
Имитационное моделирование	igraph	

1.4.3. Ресурсы

Важнейшим ресурсом для этого руководства является коллекция наборов сетевых данных, специально подобранных и доступных для скачивания. Более десятка наборов сетевых данных включены в пакет R под названием UserNetR. Эти наборы данных используются на протяжении всей книги для иллюстрации примеров программного кода и анализа. Наборы сетевых данных, включенные в пакет UserNetR, преимущественно взяты из опубликованных исследований по анализу сетей, а некоторые созданы специально, чтобы проиллюстрировать решение конкретных аналитических задач. В табл. 1.1 перечисляются названия наборов данных, которые используются в каждой главе.

Пакет UserNetR находится на GitHub. Чтобы получить доступ к сетевым данным, нужно скачать и установить этот пакет. Это можно сделать с помощью программного кода, приведенного ниже. Кроме того, нужно установить пакет devtools, если он у вас отсутствует.

```
library(devtools)
install_github("DougLuke/UserNetR")
```

Как только это сделано, нужно загрузить UserNetR, чтобы получить доступ к различным файлам данных. Как и любой пакет R, его можно загрузить с помощью функции library(). Эта команда не всегда приводится в книге, поэтому, прежде чем выполнить любой приведенный программный код R, удостоверьтесь в том, что загрузили пакет UserNetR.

```
library(UserNetR)
```

С документацией по пакету UserNetR можно ознакомиться с помощью справочной системы R.

```
help(package='UserNetR')
```

ЧАСТЬ I

ОСНОВЫ АНАЛИЗА СЕТЕЙ

Глава 2. «Пятичисловая сводка» для анализа сетей	21
Глава 3. Управление сетевыми данными в R	28

Глава 2

«Пятисловая сводка» для анализа сетей

2.1. Анализ в R: с чего начать.....	22
2.2. Подготовка	22
2.3. Простая визуализация	23
2.4. Базовое описание.....	23
2.5. Коэффициент кластеризации ...	27

Когда ищешь, то обязательно находишь. Спору нет, если ищешь, то всегда что-нибудь найдешь, но совсем не обязательно то, что искал.

Д. Р. Р. Толкин. «Хоббит»

2.1. Анализ в R: с чего начать

С чего нужно начать анализ сетей в R? Разумеется, ответ на этот вопрос зависит от аналитических задач, которые вы надеетесь решить, состояния имеющихся у вас сетевых данных и целевой аудитории, которой будут адресованы результаты этого анализа. Хорошей новостью, связанной с выполнением анализа сетей в R, является тот факт (проиллюстрированный в последующих главах), что R предлагаёт множество инструментов для проведения анализа сетей. Однако принять решение, с какого инструмента начать, – непростая задача.

В 1977 году Джон Тьюки предложил пятичисловую сводку¹ в качестве простого и быстрого способа кратко описать самые важные характеристики одномерного распределения. Сети сложнее отдельных переменных, однако можно провести анализ важных характеристик социальной сети, воспользовавшись небольшим количеством процедур в R.

В этой главе мы сфокусируемся на двух первоначальных шагах, без которых невозможно приступить к анализу сетей: простой визуализации и базовом описании сети с помощью «пятичисловой сводки». Кроме того, эта глава является плавным введением в основы анализа сетей в R и рассказывает о том, как можно быстро выполнить этот анализ.

2.2. Подготовка

Как и в других видах статистического анализа, выполняемого в R, сначала необходимо загрузить соответствующие пакеты (предварительно установив их, если это необходимо) и получить доступ к данным. В данном случае для анализа будет использоваться комплект пакетов `statnet`. Данные, использованные в этой главе (и в остальной части книги), взяты из пакета `UserNetR`, который будет использоваться на протяжении всей книги. Конкретный набор данных, использованный здесь, называется `Moreno` и содержит сеть дружеских отношений между учениками 4-го класса, впервые составленную Якобом Морено в 1930-х годах.

```
library(statnet)
library(UserNetR)
data(Moreno)
```

¹ Пятичисловая сводка Тьюки включала медиану (Q2), первый (Q1) и третий (Q3) квартили, наименьшее (min) и наибольшее (max) значения. – Прим. пер.

2.3. Простая визуализация

Первый шаг в анализе сетей часто заключается в том, чтобы просто посмотреть на сеть. Визуализация сети весьма важна, но, как следует из глав 4, 5 и 6, построение эффективного графика сети требует тщательного планирования и реализации. Вместе с тем информативный график сети можно построить с помощью одного простого вызова функции. Единственная дополнительная сложность заключается в том, что цвет узла определяется полом участника сети. Детали синтаксиса, лежащего в основе этого примера, будут более подробно рассмотрены в главах 3, 4 и 5.

```
gender <- Moreno %v% "gender"  
plot(Moreno, vertex.col = gender + 2, vertex.cex = 1.2)
```

Получившийся график четко показывает, что сеть дружеских контактов состоит из двух довольно четких подгрупп, образованных по половому признаку. Оперативно построенный график сети, аналогичный этому, часто показывает важнейшие структурные паттерны социальной сети.

2.4. Базовое описание

Исходная пятичисловая сводка Тьюки была предназначена для описания важнейших характеристик распределения переменной (включая центральную тенденцию и изменчивость) с помощью статистических показателей. Аналогично, используя лишь несколько функций и строк программного кода R, мы можем построить пятичисловую сводку для сети, которая ответит нам на следующие вопросы: каков *размер* сети, какова *плотность* сети, состоит ли сеть из одной или нескольких отдельных *групп*, насколько сеть *компактна* и как *кластеризованы* участники сети.

2.4.1. Размер

Самая главная характеристика сети – это ее *размер (size)*. Размер – это просто количество *участников (members)*, обычно называемых *узлами (nodes), вершинами (vertices)* или *акторами (actors)*. Самый простой способ получить информацию о размере – воспользоваться функцией `network.size()`. Базовая сводка для объекта-сети `statnet`, полученная с помощью функции `summary`, также предоставляет эту информацию.

Благодаря `network.size` и `summary` узнаем, что сеть Moreno состоит из 33 участников. (Значение `false`, установленное для `print.adj`, подавляет вывод подробной информации о *смежности (adjacency)*, который займет много места.)

```
network.size(Moreno)  
## [1] 33  
  
summary(Moreno, print.adj=FALSE)  
## Network attributes:  
##   vertices = 33
```

```
## directed = FALSE
## hyper = FALSE
## loops = FALSE
## multiple = FALSE
## bipartite = FALSE
## total edges = 46
## missing edges = 0
## non-missing edges = 46
## density = 0.0871
##
## Vertex attributes:
##
## gender:
## numeric valued attribute
## attribute summary:
##   Min. 1st Qu. Median    Mean 3rd Qu.   Max.
##   1.00    1.00    2.00    1.52    2.00    2.00
## vertex.names:
## character valued attribute
## 33 valid vertex names
##
## No edge attributes
```

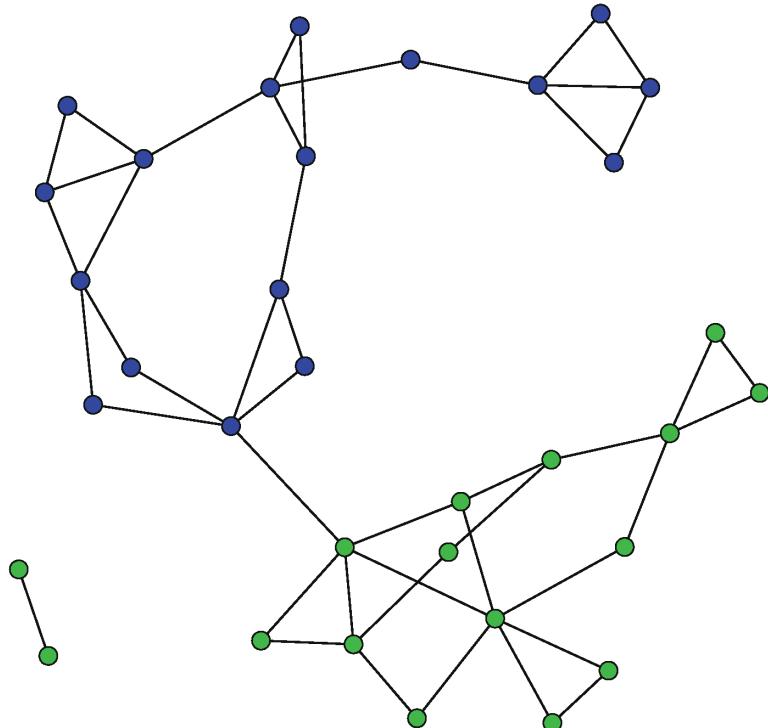


Рис. 2.1. Социограмма Морено

2.4.2. Плотность

Из всех базовых характеристик социальной сети *плотность* (*density*) входит в число наиболее важных и при этом является одним из самых простых показателей с точки зрения интерпретации. Плотность – доля имеющихся *связей* (*ties*)¹ по отношению к максимально возможному количеству связей. Таким образом, плотность является отношением, которое может колебаться от 0 до 1. Чем ближе плотность к 1, тем выше взаимосвязанность сети.

Плотность относительно легко вычислить, несмотря на то что базовое уравнение зависит от характера связей сети, которые бывают *направленными*, или *ориентированными* (*directed*), и *ненаправленными*, или *неориентированными* (*undirected*). Ненаправленная связь – связь, у которой нет направления. Деловое сотрудничество является хорошим примером ненаправленной связи: если А сотрудничает с В, то В также сотрудничает с А. С другой стороны, направленные связи имеют направление. Примером направленной связи является денежный поток. Если А дает деньги В, это не обязательно означает, что В должен ответить взаимностью. Для направленной сети максимальное количество возможных связей между k акторами равно $k * (k - 1)$, поэтому формула плотности выглядит так:

$$\frac{L}{k \times (k - 1)},$$

где L – это количество имеющихся связей. Плотность, как определено здесь, не учитывает связей, соединяющих узел с самим собой. Такие связи называют *петлями* (*loops*).

Для ненаправленной сети максимальное количество связей равно $k \times (k - 1)/2$, потому что ненаправленные связи должны учитываться лишь один раз для каждой диады (т. е. пары узлов). Поэтому плотность для ненаправленной сети равна:

$$\frac{2L}{k \times (k - 1)},$$

Из информации, полученной в предыдущем разделе, мы узнали, что сеть Moreno имеет 33 узла и 46 ненаправленных ребер. Мы можем воспользоваться R, чтобы вычислить это вручную, но проще применить функцию `gden()`.

```
den_hand <- 2*46/(33*32)
den_hand
## [1] 0.0871
gden(Moreno)
## [1] 0.0871
```

¹ Связи (*ties*) также могут называться ребрами (*edges*), дугами (*arcs*) или отношениями (*relations*). – *Прим. пер.*

2.4.3. Компоненты

Социальная сеть иногда может состоять из различных подгрупп. В главе 8 будет рассказано о том, как использовать R для определения различных сетевых групп и сообществ. Однако самым простым типом подгруппы в сети является *компонент* (*component*). Простое определение компоненты звучит так: это подгруппа, в которой все акторы связаны друг с другом прямо или косвенно. Количество компонент в сети можно вычислить с помощью функции `components`. Обратите внимание на то, что для направленных сетей формулировка определения «компоненты» более сложна. См. `help(components)` для получения дополнительной информации.

```
components (Moreno)
```

```
## [1] 2
```

2.4.4. Диаметр

Несмотря на то что информация об общем размере сети может быть интересной, более полезной характеристикой сети является ее компактность с учетом размера и степени взаимосвязанности. *Диаметр* (*diameter*) сети является важным показателем этой компактности. *Путь* (*path*) – это количество шагов, которое нужно пройти, чтобы из узла А попасть в узел В. Кратчайший путь (*shortest path*) – это наименьшее количество требуемых шагов. Диаметр полной сети – это наибольшая длина любого из кратчайших путей между всеми парами узлов. Это показатель компактности или эффективности использования сети, когда диаметр показывает «наихудший вариант» передачи информации (или любых других ресурсов) по сети. Несмотря на то что социальные сети могут иметь очень большой размер, у них могут быть маленькие диаметры в силу их плотности и кластеризации (см. ниже).

Единственная сложность при исследовании диаметра сети заключается в том, что диаметр не имеет четкого определения, когда речь идет о сетях, состоящих из нескольких компонент. Обычный подход выглядит так: если сеть состоит из нескольких компонент, нужно исследовать диаметр самой большой компоненты сети. Сеть Moreno имеет две компоненты (см. рис. 2.1). Наименьшая компонента имеет только два узла. Поэтому мы будем работать с наибольшей компонентой, которая включает 31 связанного друг с другом ученика.

В программном коде, приведенном ниже, диаметр наибольшей компоненты получают по новой матрице. *Геодезические расстояния* (*geodesics*), или кратчайшие пути, вычисляются по каждой паре узлов с помощью функции `geodist()`. Затем вычисляется максимальное геодезическое расстояние, которое является диаметром для этой компоненты. Значение диаметра 11 предполагает, что эта сеть не очень компактна. Необходимо пройти 11 шагов, чтобы соединить два узла, максимально удаленных друг от друга в этой сети дружеских контактов.

```
lgc <- component.largest (Moreno, result="graph")
gd <- geodist(lgc)
max(gd$gdist)

## [1] 11
```

2.5. Коэффициент кластеризации

Одной из фундаментальных характеристик социальных сетей (по сравнению со случайными сетями) является наличие *кластеризации (clustering)*, или тенденции к созданию *закрытых треугольников (closed triangles)*. Процесс замыкания происходит в социальной сети, когда два человека, у которых есть общий друг, сами становятся друзьями. В социальной сети это можно измерить путем исследования ее *транзитивности (transitivity)*. Транзитивность определяется как доля закрытых треугольников (триад, где наблюдаются все три связи) по отношению к общему количеству открытых и закрытых треугольников (триад, где наблюдаются либо две, либо все три связи). Таким образом, как и плотность, транзитивность является отношением, которое может колебаться от 0 до 1. Транзитивность сети можно вычислить с помощью функции `gtrans()`. Транзитивность для учеников 4-го класса равна 0,29, что предполагает умеренный уровень кластеризации в сети.

```
gtrans (Moreno, mode="graph")
```

```
## [1] 0.286
```

В оставшейся части этой книги мы более подробно расскажем, как можно использовать R для изучения и анализа характеристик социальных сетей. Предыдущие примеры показывают, что базовые графики и статистики довольно легко получить. Содержательный смысл этих статистических данных будет всегда зависеть от теорий и гипотез, на которые аналитик опирается при выполнении задачи, а также имеющегося опыта анализа подобных социальных сетей.

Глава 3

Управление сетевыми данными в R

3.1. Основные понятия сетевых данных.....	29
3.2. Создание объектов-сетей и работа с ними в R	32
3.3. Импорт сетевых данных	41
3.4. Общераспространенные задачи при работе с сетевыми данными.....	43

Знание бывает двух видов. Мы сами знаем предмет или же знаем, где найти о нем сведения.

Сэмюэл Джонсон

3.1. Основные понятия сетевых данных

Главное преимущество использования R для проведения анализа сетей – это наличие мощных и гибких инструментов для работы с сетевыми данными. Я часто говорю своим студентам, изучающим количественные методы, что большую часть своего времени они будут обычно тратить, решая задачи и проблемы, связанные с данными. Фактически время, потраченное на анализ и моделирование данных, меркнет на фоне времени, потраченного на подготовку данных. Анализ сетей не является исключением. На самом деле, учитывая специфическую природу сетевых данных, задач, связанных с управлением данными при проведении анализа сетей, становится еще больше. В этой главе мы коснемся трех основных тем. Во-первых, определим и исследуем общую природу сетевых данных. Во-вторых, мы научимся создавать объекты сетевых данных и управлять ими в R. Наконец, несколько типичных задач управления сетевыми данными будут проиллюстрированы на ряде примеров.

3.1.1. Структуры сетевых данных

Как правило, данные, необходимые для анализа, хранятся в прямоугольных структурах данных, где строки – это случаи или наблюдения, а столбцы – отдельные переменные. Электронные таблицы, а также большинство статистических пакетов типа SPSS используют подобный способ организации данных. В R один из основополагающих типов данных – «таблица данных» (*«data frame»*), в которой используется тот же самый прямоугольный формат.

Сети из-за необходимости отображения более сложных взаимосвязей требуют другого типа хранения данных. В прямоугольных структурах данных базовым элементом информации является атрибут (столбец) наблюдения (строки). В анализе сетей базовым элементом информации является отношение (связь) между двумя участниками сети.

Рассмотрим простой пример направленной сети. График сети сам по себе показывает всю информацию о сети. Он состоит из пяти узлов (которым присвоены буквы от *A* до *E*) и содержит в целом шесть направленных связей. Поскольку связи являются направленными, мы можем назвать их *дугами* (*arcs*) в сравнении с не-направленными ребрами. Несмотря на то что диаграмма сети – это эффективный способ представления информации для человека, компьютеры должны использовать другие методы для хранения, чтения и управления сетевыми данными.

3.1.1.1. Социоматрицы

Иной способ представления сетевых данных, который можно использовать для хранения на компьютере, заключается в том, чтобы поместить информацию в мат-

рицу. Данный тип матрицы, содержащий информацию о сети, является *социоматрицей* (*sociomatrix*). Таблица 3.1 содержит социоматрицу, которая соответствует рис. 3.1. Социоматрица является квадратной матрицей, где 1 означает наличие связи между двумя узлами и 0 означает отсутствие связи. В табл. 3.1 мы видим 1 в ячейке 1,2 – это указывает на связь, выходящую из узла А в узел В. Принято, что строка означает стартовый узел, а столбец – конечный узел. Социоматрицу еще иногда вызывают матрицей смежности (*adjacency matrix*), потому что единицы в ячейках указывают, какие узлы смежны друг с другом в сети.

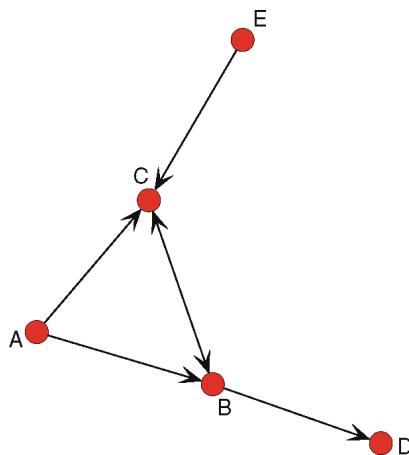


Рис. 3.1. Простая направленная сеть

Таблица 3.1. Социоматрица для направленной сети

	A	B	C	D	E
A	0	1	1	0	0
B	0	0	1	1	0
C	0	1	0	0	0
D	0	0	0	0	0
E	0	0	1	0	0

Если сеть является ненаправленной (только ребра вместо дуг), то социоматрица будет симметричной относительно главной диагонали. Однако в данном случае в ячейке 2,1 записан 0, это указывает на отсутствие дуги, выходящей из узла В обратно к узлу А. В простых сетях петли, когда ребро соединяет узел с самим собой, отсутствуют. Таким образом, в простых сетях все элементы на главной диагонали равны нулю.

3.1.1.2. Список ребер

Социоматрица является изящным способом представления сети, и она является распространенным способом хранения и управления сетевыми данными, который

используются различными программами для анализа сетей. В частности, многие базовые алгоритмы построены на математических или статистических операциях над социоматрицами. Например, для вычисления геодезических расстояний между всеми парами узлов используется перемножение социоматриц [Wasserman, Faust, 1994].

Однако социоматрицы имеют один большой недостаток. Поскольку сети расшут в размерах, социоматрицы становятся очень разреженными. То есть матрица преимущественно будет состоять из пустых ячеек (ячеек с нулями). В табл. 3.2 показано значительное увеличение как размера, так и разреженности социоматрицы по мере роста размера сети при сохранении *средней степени (average degree)*¹, равной 3. Данный факт порождает проблемы, связанные с хранением, управлением и графическим представлением данных.

Таблица 3.2. Пример разреженных матриц

Узлы	Средн. степень	Ребра	Плотность	Пустые ячейки
10	3	15	0,33	70
100	3	150	0,03	9700
1000	3	1500	0,00	997 000

К счастью, существует другой способ представления информации о сети, который позволяет обойти вышеописанную проблему социоматриц. Таблица 3.3 представляет собой *список ребер (edge list)* для сети. Как следует из названия, в списке ребер приводится информация о сети в виде простого перечисления имеющихся связей (ребер). Каждая строка соответствует отдельной связи, которая выходит из узла, указанного в первом столбце, в узел, указанный во втором столбце. Несмотря на то что применительно к этому небольшому примеру (25 ячеек для социоматрицы и 12 ячеек для матрицы списка ребер) социоматрица и список ребер имеют схожий размер, списки ребер гораздо более эффективны для представления больших сетей. Вернувшись к табл. 3.2, можно заключить, что для сети из 1000 узлов социоматрица состояла бы из 1 000 000 ячеек. Список ребер для этой сети со средней степенью узлов 3 включал бы лишь 3000 ячеек (1500 ребер между парами узлов).

Таблица 3.3. Список ребер для направленной сети

Из	В
A	B
A	C
B	C
B	D
C	B
E	C

¹ Речь идет о средней степени узлов – среднем количестве связей, которое приходится на узел. – *Прим. пер.*

3.1.2. Информация, хранимая в объектах-сетях

Несмотря на то что какую-то информацию о сети можно хранить в привычных матрицах, R и другие статистические пакеты для хранения информации об узлах, связях, метаданных и прочих характеристиках используют более сложные структуры данных. В целом объект сетевых данных может содержать до пяти типов информации, как указано в табл. 3.4.

Таблица 3.4. Типы информации, содержащиеся в объектах сетевых данных

Тип	Описание	Обязательность/необязательность
Узлы	Список узлов сети, а также метки узлов	Обязателен
Связи	Список связей сети	Обязателен
Атрибуты узлов	Атрибуты узлов	Не обязательен
Атрибуты связи	Атрибуты связей	Не обязательен
Метаданные	Другая информация о сети в целом	Зависит от других типов информации

Во-первых, объект сетевых данных должен содержать информацию о том, какие элементы принадлежат сети, они обычно называются узлами. В statnet их называют *vertices* (*вершинами*). Второй обязательный компонент объекта-сети – это список связей, которые соединяют узлы друг с другом. Без этих двух типов информации объект данных не является по-настоящему объектом-сетью. Помимо списка узлов и связей, объекты сетевых данных часто хранят характеристики (атрибуты) этих узлов и связей. Например, если узлы сети – это люди, то основная информация о них, например пол или доход, может храниться в объекте данных. Точно так же и сами связи могут иметь характеристики, например, речь может идти о тесноте или валентности связи (например, положительной или отрицательной). Наконец, объекты сетевых данных могут еще содержать метаданные о сети в целом или другую информацию, которая может быть релевантна или полезна при работе с данными и их анализе. Например, statnet хранит глобальную информацию о сети в виде метаданных, включая тип сети (направленная или ненаправленная), информацию о наличии циклов и двудольности.

3.2. Создание объектов-сетей и работа с ними в R

Учитывая объектно-ориентированный дизайн R, неудивительно, что основной способ, с помощью которого R получает доступ к сетевым данным, – это работа с объектами сетевых данных определенного типа. Являясь частью комплекта пакетов statnet, пакет network задает класс *network*, который является структурой объекта, предназначеннной для работы с сетевыми данными. Несмотря на то что statnet может прочитать реляционные данные, которые хранятся в обычных матрицах или таблицах данных, максимальная мощность и гибкость анализа сетей в R раскрываются, когда используются объекты сетевых данных. Для получения более подробной информации об объектах-сетях в statnet см. [Butts, 2008].

3.2.1. Создание объекта-сети в statnet

Чтобы создать объект-сеть, нужно вызвать одноименную функцию `network()`. Эта функция имеет много параметров, но чаще всего ее используют для того, чтобы передать ей реляционные данные – обычно в виде матрицы смежности или списка ребер. Чтобы посмотреть, как она работает, мы воспользуемся все тем же примером направленной сети, показанным на рис. 3.1. Во-первых, мы создадим сеть с помощью матрицы смежности.

```
netmat1 <- rbind(c(0,1,1,0,0),
                  c(0,0,1,1,0),
                  c(0,1,0,0,0),
                  c(0,0,0,0,0),
                  c(0,0,1,0,0))
rownames(netmat1) <- c("A", "B", "C", "D", "E")
colnames(netmat1) <- c("A", "B", "C", "D", "E")
net1 <- network(netmat1, matrix.type="adjacency")
class(net1)

## [1] "network"

summary(net1)

## Network attributes:
##   vertices = 5
##   directed = TRUE
##   hyper = FALSE
##   loops = FALSE
##   multiple = FALSE
##   bipartite = FALSE
##   total edges = 6
##   missing edges = 0
##   non-missing edges = 6
##   density = 0.3
##
## Vertex attributes:
##   vertex.names:
##     character valued attribute
##     5 valid vertex names
##
## No edge attributes
##
## Network adjacency matrix:
##   A B C D E
##   A 0 1 1 0 0
##   B 0 0 1 1 0
##   C 0 1 0 0 0
##   D 0 0 0 0 0
##   E 0 0 1 0 0
```

атрибуты сети количество вершин = 5 ребра интерпретируются как направленные гиперребра не допускаются циклы не допускаются кратные (параллельные) ребра не допускаются сеть не интерпретируется как двудольная (биграф) общее количество ребер = 6 количество пропущенных ребер = 0 количество непропущенных ребер = 6 плотность = 0.3	атрибуты вершин имена вершин атрибут в виде символьных значений 5 действительных имен вершин
атрибуты ребер отсутствуют	матрица смежности

Результаты вызовов `class()` и `summary()` показывают, что мы успешно создали новый объект-сеть. Кроме того, здесь видно, что если строки и столбцы матрицы имеют одинаковые имена, их используют в качестве меток узлов. Еще мы видим, что перед нами та же самая сеть, что и в ранее приведенном примере (рис. 3.2).

```
gplot(net1, vertex.col = 2, displaylabels = TRUE)
```

Ту же самую сеть можно построить с помощью списка ребер. Часто такой способ более удобен, чем использование матриц смежности. Списки ребер меньше по размеру, чем социоматрицы, и, как правило, собирать сетевые данные в таком формате проще. Например, общение по электронной почте можно проанализировать в виде сети, где каждое сообщение соответствует связи между отправителем и получателем. Это позволяет легко получить список ребер между всеми парами узлов.

```
netmat2 <- rbind(c(1,2),
                  c(1,3),
                  c(2,3),
                  c(2,4),
                  c(3,2),
                  c(5,3))
net2 <- network(netmat2, matrix.type="edgelist")
network.vertex.names(net2) <- c("A", "B", "C", "D", "E")
summary(net2)

## Network attributes:
##   vertices = 5
##   directed = TRUE
##   hyper = FALSE
##   loops = FALSE
##   multiple = FALSE
##   bipartite = FALSE
##   total edges = 6
##   missing edges = 0
##   non-missing edges = 6
##   density = 0.3
##
## Vertex attributes:
##   vertex.names:
##     character valued attribute
##     5 valid vertex names
##
## No edge attributes
##
## Network adjacency matrix:
##   A B C D E
## A 0 1 1 0 0
## B 0 0 1 1 0
## C 0 1 0 0 0
## D 0 0 0 0 0
## E 0 0 1 0 0
```

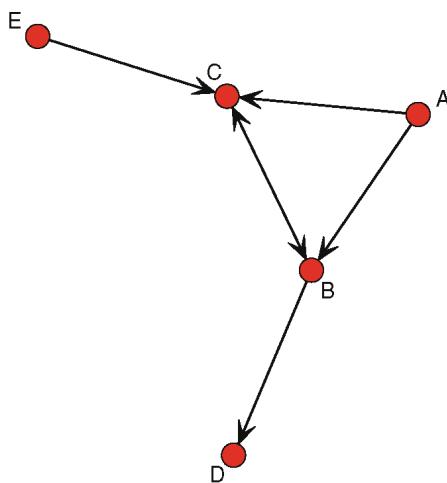


Рис. 3.2. График нового объекта-сети

Этот программный код строит ту же самую сеть, что и прежде. Заметьте, что список ребер был представлен в виде идентификационных номеров узлов. Для маркировки узлов должным образом мы использовали специальный конструктор атрибутов вершин `network.vertex.names`.

Мы только что увидели, что для создания объектов-сетей в R можно воспользоваться рабочим потоком¹, который берет данные в виде матрицы смежности или списка ребер и преобразовывает их в объект класса `network`. Однако, помимо этого, `statnet` имеет массу инструментов, которые позволяют вам инвертировать этот поток, преобразовав сетевые данные в другие форматы матриц.

```
as.sociomatrix(net1)
##   A B C D E
## A 0 1 1 0 0
## B 0 0 1 1 0
## C 0 1 0 0 0
## D 0 0 0 0 0
## E 0 0 1 0 0

class(as.sociomatrix(net1))
## [1] "matrix"
```

Более универсальной функцией преобразования является `as.matrix()`. Ее можно использовать для создания социоматрицы или матрицы списка ребер.

```
all(as.matrix(net1) == as.sociomatrix(net1))
## [1] TRUE
```

¹ Рабочий поток (workflow) – последовательность операций для выполнения той или иной задачи в R. – Прим. пер.

```
as.matrix(net1, matrix.type = "edgelist")
##      [,1] [,2]
## [1,]    1    2
## [2,]    3    2
## [3,]    1    3
## [4,]    2    3
## [5,]    5    3
## [6,]    2    4
## attr(,"n")
## [1] 5
## attr(,"vnames")
## [1] "A" "B" "C" "D" "E"
```

Наличие разных вариантов представления объектов-сетей и различных структур данных (социоматриц и списков ребер) дает аналитику мощные и гибкие возможности управления данными. Мы будем пользоваться преимуществами этих инструментов как в этой главе, так и на протяжении всей книги.

3.2.2. Работа с атрибутами узлов и связей

Одно из главных преимуществ использования объектов-сетей вместо обычных объектов-матриц при выполнении анализа сетей в R – это возможность хранения дополнительной информации об атрибутах узлов и связей в этом же объекте-сети. Как правило, у аналитика гораздо больше информации о сети, нежели просто обычный список узлов и связей. Эти характеристики узлов или связей можно использовать для визуализации сети (см. главу 5), описания и моделирования сети (глава 11).

Применительно к узлам и связям `statnet` предлагает ряд функций, которые можно использовать для создания, удаления, чтения и указания любой необходимой информации об атрибутах. Эти функции имеют массу возможностей, см. `help(attribute.methods)` для получения более подробной информации.

3.2.2.1. Атрибуты узлов

В следующем примере мы воспользуемся двумя различными методами, чтобы задать атрибуты узлов (называемые в `statnet` *атрибутами вершин*, или *vertex attributes*). В первом примере в `net1` мы присваиваем узлам имена F или M в зависимости от пола участника сети. Во втором примере в качестве атрибута задаем числовой вектор. В данном случае мы сохраняем сумму *входящих степеней* (*indegrees*)¹ и *исходящих степеней* (*outdegrees*)² каждого узла в виде нового атрибута вершин.

```
set.vertex.attribute(net1, "gender", c("F", "F", "M",
                                         "F", "M"))
```

¹ Входящая степень узла – количество ребер, входящих в узел. – Прим. пер.

² Исходящая степень узла – количество ребер, выходящих из узла. – Прим. пер.

```

net1 %v% "alldeg" <- degree(net1)
list.vertex.attributes(net1)

## [1] "alldeg" "gender" "na"
## [4] "vertex.names"

summary(net1)

## Network attributes:
##   vertices = 5
##   directed = TRUE
##   hyper = FALSE
##   loops = FALSE
##   multiple = FALSE
##   bipartite = FALSE
##   total edges = 6
##   missing edges = 0
##   non-missing edges = 6
##   density = 0.3
##
## Vertex attributes:
##
##   alldeg:
##     numeric valued attribute
##     attribute summary:
##       Min. 1st Qu. Median Mean 3rd Qu. Max.
##       1.0    1.0    2.0   2.4    4.0    4.0
##
##   gender:
##     character valued attribute
##     attribute summary:
##       F M
##       3 2
##   vertex.names:
##     character valued attribute
##     5 valid vertex names
##
## No edge attributes
##
## Network adjacency matrix:
##   A B C D E
## A 0 1 1 0 0
## B 0 0 1 1 0
## C 0 1 0 0 0
## D 0 0 0 0 0
## E 0 0 1 0 0

```

В этом примере мы видим, что внешнюю информацию (пол) или информацию, полученную из самой сети (степень), можно использовать в качестве атрибутов узла. Как только атрибуты узла заданы, их можно посмотреть с помощью коман-

ды `list.vertex.attributes` (обратите внимание на множественное число). Кроме того, сводка по сети выведет базовую информацию о любых сохраненных атрибутах.

Чтобы посмотреть фактические значения, сохраненные в атрибуте вершин, можно использовать два равнозначных метода, которые приводятся ниже.

```
get.vertex.attribute(net1, "gender")
## [1] "F" "F" "M" "F" "M"
net1 %v% "alldeg"
## [1] 2 4 4 1 1
```

3.2.2.2. Атрибуты связей

Информацию о характеристиках связей можно хранить и обрабатывать в объектах-сетях, используя одноименные функции `set.edge.attributes` и `get.edge.attributes`. В следующем примере мы создаем новый *атрибут ребер* (*edge attribute*), в котором записывается случайно сгенерированное значение для каждого ребра сети, и затем выводим эту информацию.

```
list.edge.attributes(net1)
## [1] "na"

set.edge.attribute(net1,"rndval",
runif(network.size(net1),0,1))
list.edge.attributes(net1)

## [1] "na" "rndval"

summary(net1 %e% "rndval")

##   Min. 1st Qu. Median   Mean 3rd Qu.   Max.
## 0.163   0.165   0.220   0.382   0.476   0.980

summary(get.edge.attribute(net1,"rndval"))

##   Min. 1st Qu. Median   Mean 3rd Qu.   Max.
## 0.163   0.165   0.220   0.382   0.476   0.980
```

Чаще всего новый атрибут ребер вам нужен, когда вы создаете или работаете с сетями, в которых фигурируют определенные значения. Речь идет о сети, где связь имеет определенное числовое значение. Например, сеть обмена ресурсами может включать не только информацию о направлении денежного потока из одного узла в другой, но и фактическую сумму направляемых средств. В `statnet` фактические значения таких связей хранятся в атрибуте ребер. Чтобы увидеть, как это работает, рассмотрим в качестве примера сеть дружеских контактов, в которой пятерых участников попросили выразить свои симпатии друг к другу по шкале от 0 (нет симпатий) до 3 (очень симпатичен). Пример, приведенный ниже, показывает, как мы берем социоматрицу с исходными значениями и сохраняем значения в атрибуте ребер под названием `like`.

```

netval1 <- rbind(c(0,2,3,0,0),
                  c(0,0,3,1,0),
                  c(0,1,0,0,0),
                  c(0,0,0,0,0),
                  c(0,0,2,0,0))
netval1 <- network(netval1,matrix.type="adjacency",
                    ignore.eval=FALSE,names.eval="like")
network.vertex.names(netval1) <- c("A","B","C","D","E")
list.edge.attributes(netval1)

## [1] "like" "na"

get.edge.attribute(netval1, "like")

## [1] 2 1 3 3 2 1

```

Ключевыми здесь являются параметры `ignore.eval` и `names.eval`. Эти два параметра, как показано здесь, сообщают функции `network`, что нужно оценить фактические значения социоматрицы и сохранить эти значения в новом атрибуте ребер `like`. Как только значения сохранены в атрибуте ребер, матрицу с исходными значениями можно восстановить, используя функцию преобразования `as.sociomatrix`.

```

as.sociomatrix(netval1)

##   A B C D E
## A 0 1 1 0 0
## B 0 0 1 1 0
## C 0 1 0 0 0
## D 0 0 0 0 0
## E 0 0 1 0 0

as.sociomatrix(netval1,"like")

##   A B C D E
## A 0 2 3 0 0
## B 0 0 3 1 0
## C 0 1 0 0 0
## D 0 0 0 0 0
## E 0 0 2 0 0

```

3.2.3 Создание объекта-сети в *igraph*

Еще одним важным пакетом R, который можно использовать для хранения и работы с сетевыми данными, является `igraph`. Он представляет собой исчерпывающий набор инструментов для работы и анализа сетевых данных, реализованный в R, Python и C/C++. Более подробную информацию можно получить на сайте igraph.org.

Чтобы начать работу с `igraph`, пакет нужно установить и загрузить. Он включает в себя ряд функций, которые имеют точно такие же названия, как и функции

в комплекте пакетов `statnet`, поэтому правильным будет отсоединить `statnet` прежде, чем загружать `igraph`.

```
detach(package:statnet)
library(igraph)
```

По большей части пакет `igraph`, как и пакет `network`, можно использовать для хранения и обработки информации о сети, узлах и ребрах. В частности, объекты сети `igraph` (называемые *графами*, или *graphs*) можно создать из более простых структур данных, представленных в виде социоматриц или списков ребер.

```
inet1 <- graph.adjacency(netmat1)
class(inet1)
## [1] "igraph"
summary(inet1)
## IGRAPH DN-- 5 6 --
## + attr: name (v/c)

str(inet1)
## IGRAPH DN-- 5 6 --
## + attr: name (v/c)
## + edges (vertex names):
## [1] A->B A->C B->C B->D C->B E->C
```

Сводка по объекту-графу в пакете `igraph` выглядит чуть более загадочно, чем аналогичная сводка по объекту-сети `statnet`. Вслед за тегом `IGRAPH` (который указывает на то, что мы работаем с объектом в пакете `igraph`) приводится ряд обозначений. В данном случае `D` означает направленный граф, а `N` означает, что вершины имеют имена. Возможны и другие обозначения, например они могут указывать на то, является ли граф взвешенным (т. е. каждому ребру соответствует определенное числовое значение – вес) или двудольным. Вслед за этими обозначениями приводится информация о количестве вершин (5) и ребер (6). См. справку, чтобы получить более подробную информацию по `summary.igraph`. Функция `str()` предоставляет чуть больше информации, включая список ребер.

Аналогично объект-граф в пакете `igraph` можно создать из списка ребер.

```
inet2 <- graph.edgelist(netmat2)
summary(inet2)
## IGRAPH D--- 5 6 --
```

Как и в комплекте пакетов `statnet`, в пакете `igraph` атрибуты узлов и связей можно создать, прочитать и преобразовать аналогичными способами. (Фактически работа с атрибутами узлов и связей в `igraph` несколько проще в силу элегантности функций доступа.) Для создания атрибутов узлов и работы с ними используется функция доступа к вершинам `V()`. Точно так же для работы с атрибутами

ребер используется функция доступа к ребрам `E()`. В этом примере мы воспользуемся данными функциями, чтобы задать имена для узлов и числовые значения для имеющихся связей.

```
V/inet2)$name <- c("A", "B", "C", "D", "E")
E/inet2)$val <- c(1:6)
summary/inet2)

## IGRAPH DN-- 5 6 --
## + attr: name (v/c), val (e/n)

str/inet2)

## IGRAPH DN-- 5 6 --
## + attr: name (v/c), val (e/n)
## + edges (vertex names):
## [1] A->B A->C B->C B->D C->B E->C
```

3.2.4. Переключение между `statnet` и `igraph`

Наступит момент, когда вам понадобятся функции комплекта пакетов `statnet` для работы с объектом-графом пакета `igraph`, и наоборот. Для преобразования объектов сетевых данных в эти два формата можно использовать пакет `intergraph`. В примере, приведенном ниже, мы преобразуем данные `net1` в формат `igraph` с помощью функции `asIgraph`. Если бы мы хотели выполнить обратное преобразование, то воспользовались бы функцией `asNetwork`.

```
library(intergraph)
class/net1)

## [1] "network"

net1igraph <- asIgraph/net1)
class/net1igraph)

## [1] "igraph"

str/net1igraph)

## IGRAPH D--- 5 6 --
## + attr: alldeg (v/n), gender (v/c), na
## | (v/l), vertex.names (v/c), na (e/l),
## | rndval (e/n)
## + edges:
## [1] 1->2 3->2 1->3 2->3 5->3 2->4
```

3.3. Импорт сетевых данных

Импорт исходных данных в R для проведения анализа сетей относительно прост при условии, что внешние данные находятся в списке ребер, матрице смежности или социоматрице (или данные легко преобразовать в подобный формат). В при-

мере ниже мы создаем список ребер, который соответствует той же самой сети, приведенной в качестве примера в разделе 3.2.1, и затем сохраняем его как внешний CSV-файл. Затем мы считываем этот файл с помощью `read.csv` и превращаем в объект сетевых данных.

```
detach("package:igraph", unload=TRUE)
library(statnet)

netmat3 <- rbind(c("A", "B"),
                  c("A", "C"),
                  c("B", "C"),
                  c("B", "D"),
                  c("C", "B"),
                  c("E", "C"))

net.df <- data.frame(netmat3)
net.df

##   X1 X2
## 1 A  B
## 2 A  C
## 3 B  C
## 4 B  D
## 5 C  B
## 6 E  C

write.csv(net.df, file = "MyData.csv",
          row.names = FALSE)
net.edge <- read.csv(file="MyData.csv")
net_import <- network(net.edge,
                      matrix.type="edgelist")
summary(net_import)

## Network attributes:
##   vertices = 5
##   directed = TRUE
##   hyper = FALSE
##   loops = FALSE
##   multiple = FALSE
##   bipartite = FALSE
##   total edges = 6
##   missing edges = 0
##   non-missing edges = 6
##   density = 0.3
##
## Vertex attributes:
##   vertex.names:
##     character valued attribute
##     5 valid vertex names
##
## No edge attributes
```

```
##  
## Network adjacency matrix:  
##   A B C D E  
## A 0 1 1 0 0  
## B 0 0 1 1 0  
## C 0 1 0 0 0  
## D 0 0 0 0 0  
## E 0 0 1 0 0  
  
gden(net_import)  
## [1] 0.3
```

Пакет `network`, входящий в комплект пакетов `statnet`, может прочитать внешние сетевые данные в формате Pajek (файлы, создаваемые в программе Pajek с расширением .net или .raj) с помощью функции `read.raj()`. Кроме того, пакет `igraph` может импортировать файлы в формате Pajek и еще нескольких форматах, включая GraphML и UCINet DL.

3.4. Общераспространенные задачи при работе с сетевыми данными

В предыдущих разделах была освещена основная информация, необходимая для создания и управления объектами сетевых данных в R. Однако задачи управления данными, возникающие в рамках анализа сетей, не заканчиваются на этом. В анализе сетей существует целый ряд задач, который потребует применения более сложных методов управления данными и их преобразования. В оставшейся части этой главы будет рассказано о двух таких примерах: создании поднаборов сетевых данных с помощью фильтрации по характеристикам узлов и ребер и преобразовании направленных сетей в ненаправленные.

3.4.1. Фильтрация сетевых данных на основе значений атрибутов вершин или ребер

Часто возникает необходимость исследовать подсеть для беглого визуального анализа и дальнейших исследований. Существует масса способов определить или идентифицировать интересные подсети внутри более крупной сети, и большинство из них освещается в главе 8. Однако базовой задачей при работе с исходными данными является фильтрация сетевых данных на основе значений, записанных либо в атрибутах ребер, либо в атрибутах вершин. В обоих случаях вы удаляете либо узлы, либо ребра, в зависимости от заданного критерия отбора.

3.4.1.1. Фильтрация на основе значений узла

Если объект-сеть содержит характеристики узла, сохраненные в виде атрибутов вершин, эту информацию можно использовать, чтобы задать новую подсеть для

анализа. В нашей сети, взятой в качестве примера, у нас есть атрибут вершин `gender`, поэтому если бы вы хотели взглянуть на подсеть, состоящую из женщин, вы использовали бы следующий программный код (предварительно переключившись обратно с `igraph` на `statnet`).

```
n1F <- get.inducedSubgraph(net1,
  which(net1 %v% "gender" == "F"))
n1F[,]
##   A B D
## A 0 1 0
## B 0 0 1
## D 0 0 0
```

Функция `get.inducedSubgraph()` возвращает новый объект-сеть, который отфильтрован по атрибуту вершин. Программный код успешно выполнен, поскольку оператор `%v%` возвращает список идентификаторов вершин.

```
gplot(n1F, displaylabels=TRUE)
```

Аналогичную операцию можно осуществить с помощью числовых характеристик узла. Программный код, приведенный ниже, построит подсеть, степень которой больше или равна 2. (Однако обратите внимание на то, что узлы в новой подсети, разумеется, не будут иметь тех же самых исходных значений степени!) Аналогично программный код успешно выполняется, но на этот раз используется оператор `%s%`, который является «ярлыком» для функции `get.inducedSubgraph` (рис. 3.3).

```
deg <- net1 %v% "alldeg"
n2 <- net1 %s% which(deg > 1)

gplot(n2, displaylabels=TRUE)
```

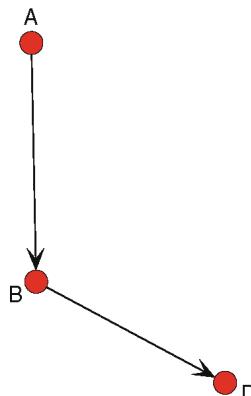


Рис. 3.3. Подсеть, состоящая из женщин

3.4.1.2. Удаление изолированных узлов

Другая общераспространенная задача фильтрации сетевых данных состоит в том, чтобы проанализировать сеть после удаления всех изолированных узлов (т. е. узлов со степенью 0). Можно использовать функцию `get.inducedSubgraph` из предыдущего раздела, но, учитывая, что нам нужно удалить определенные узлы, можно применить более прямой подход (рис. 3.4).

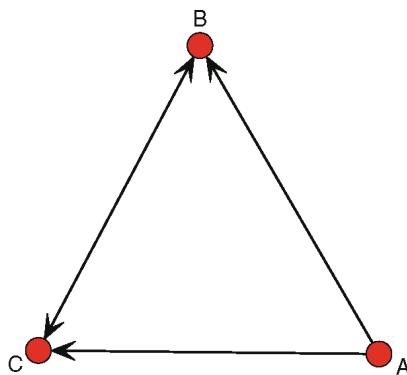


Рис. 3.4. Подсеть высокой степени

Для этого короткого примера мы воспользуемся набором сетевых данных ICTS, который входит в пакет `UserNetR`, широко применяемый в данной книге. Участниками этой сети являются ученые, если они вместе работали над работой, выдвинутой на соискание гранта, то между ними существует связь. Воспользовавшись функцией `isolates()`, мы видим, что данная сеть состоит из достаточно большого количества изолированных узлов.

```

data(ICTS_G10)
gden(ICTS_G10)

## [1] 0.0112

length(isolates(ICTS_G10))

## [1] 96
  
```

Функция `isolates()` возвращает вектор идентификационных номеров вершин. Его можно передать в функцию `delete.vertices()`. Однако, в отличие от большинства функций R, с которыми мы уже работали, `delete.vertices()` не возвращает объект, а напрямую работает с сетью, которая передана ей. Поэтому безопаснее будет работать с копией объекта.

```

n3 <- ICTS_G10
delete.vertices(n3, isolates(n3))
gden(n3)

## [1] 0.0173
  
```

```
length(isolates(n3))
## [1] 0
```

3.4.1.3. Фильтрация на основе значений ребер

Социальная сеть часто содержит связи с определенными числовыми значениями. Например, в сети обмена ресурсами может быть указана информация не только о том, кто обменивается деньгами (или другими ресурсами) друг с другом, но и о сумме денег. Вспомним, что в `statnet` информация о связях хранится в атрибутах ребер (см. раздел 3.2.2). В ситуации, когда сеть содержит такие связи, нет ничего необычного в том, чтобы проанализировать ту часть сети, у которой связи имеют лишь определенные значения. Например, вам, возможно, нужно визуализировать или проанализировать только тех людей в сети, которые отдали или получили определенную сумму денег. Для этого нужно отфильтровать сеть с помощью значений связей, хранящихся в соответствующем атрибуте ребер.

Для следующего примера мы возьмем более реалистичную и крупную социальную сеть. Сеть сотрудничества между экспертами Министерства здравоохранения и социальных служб (`DHHS`) содержит сетевые данные, взятые из исследования взаимосвязей между 54 экспертами, которые специализировались на борьбе против распространения табака и работали в 11 различных агентствах вышеупомянутого министерства в 2005 году. Базовый тип отношений в этом наборе данных – это сотрудничество, между двумя участниками существует связь, если они оба работали вместе. Эта связь имеет числовое значение, чтобы получить оценку тесноты сотрудничества. В частности, связь может получить одно из четырех значений: (1) только обменивались информацией; (2) сотрудничали неофициально; (3) сотрудничали официально в рамках одного проекта; (4) сотрудничали официально по нескольким проектам.

Мы видим, что исходная сеть является относительно плотной, и поэтому график довольно сложно интерпретировать (рис. 3.5).

```
data(DHHS)
d <- DHHS
gden(d)

## [1] 0.312

op <- par(mar = rep(0, 4))
gplot(d, gmode="graph", edge.lwd=d %e% 'collab',
       edge.col="grey50", vertex.col="lightblue",
       vertex.cex=1.0, vertex.sides=20)
par(op)
```

Отчасти диаграмму трудно интерпретировать из-за высокой плотности и большой толщины некоторых ребер (толщина ребер вычисляется на основе значений атрибута `collab`). Мы можем построить более интересный и понятный график сети, если будем учитывать только официальное сотрудничество. То есть мы мо-

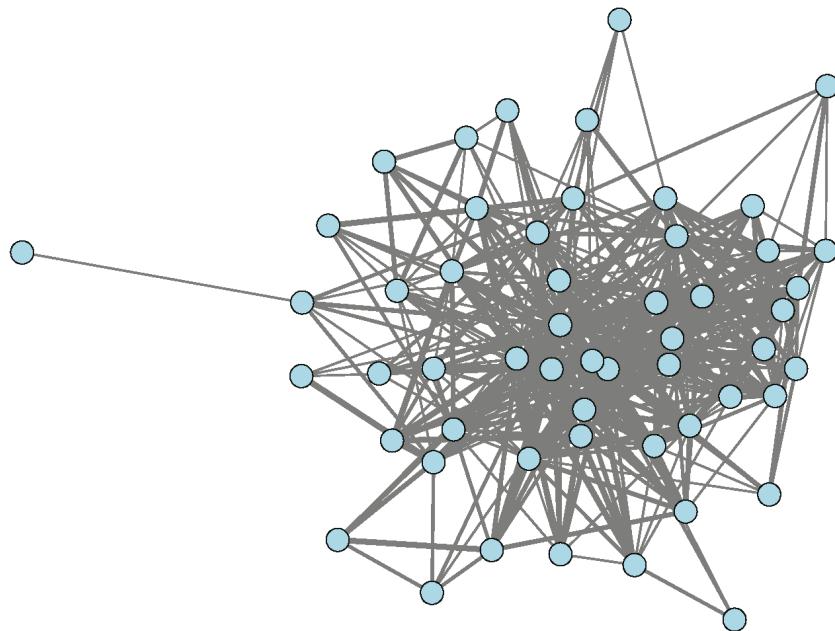


Рис. 3.5. Сеть DHHS, различные формы сотрудничества

жем отфильтровать исходную сеть и показать только те связи, которые получили оценки 3 и 4 по шкале. Чтобы понять, как работает фильтрация ребер, важно помнить, как связи с определенными значениями хранятся в объекте-сети. Сами связи хранятся в виде бинарного индикатора в объекте-сети, тогда как значения этих связей хранятся в атрибуте ребер. Мы можем посмотреть, как это работает, на примере сети сотрудничества между экспертами Министерства здравоохранения и социальных служб. Сначала мы просто посмотрим связи для первых шести участников сети. Затем мы определим, где хранятся значения связей, и используем эту информацию, чтобы вывести значения связей для этих же шести акторов.

```
as.sociomatrix(d)[1:6,1:6]

##      ACF-1 ACF-2 AHRQ-1 AHRQ-2 AHRQ-3 AHRQ-4
## ACF-1    0    1    0    0    0    0
## ACF-2    1    0    0    0    0    0
## AHRQ-1   0    0    0    1    1    1
## AHRQ-2   0    0    1    0    1    1
## AHRQ-3   0    0    1    1    0    1
## AHRQ-4   0    0    1    1    1    0
```

```
list.edge.attributes(d)

## [1] "collab" "na"

as.sociomatrix(d,attrname="collab")[1:6,1:6]
```

```
##      ACF-1 ACF-2 AHRQ-1 AHRQ-2 AHRQ-3 AHRQ-4
## ACF-1    0     1     0     0     0     0
## ACF-2    1     0     0     0     0     0
## AHRQ-1   0     0     0     3     3     3
## AHRQ-2   0     0     3     0     3     2
## AHRQ-3   0     0     3     3     0     3
## AHRQ-4   0     0     3     2     3     0
```

Сводка по объекту-сети сообщает нам, что сеть состоит из 447 связей. Мы можем легко посмотреть распределение значений связей.

```
table(d %>% "collab")

##
##   1   2   3   4
## 163 111  94  79
```

Эта таблица показывает, что из 447 связей 163 – это неофициальный обмен информацией (1), 111 – неофициальное сотрудничество (2), 94 – официальное сотрудничество в рамках одного проекта (3) и, наконец, 79 – официальное сотрудничество по нескольким проектам (4). Теперь мы можем отфильтровать ребра, чтобы включить в анализ лишь связи, охарактеризованные как официальное сотрудничество. Делается это в три этапа. Во-первых, создается социоматрица со значениями связей, сохраняемыми в атрибуте ребер collab. Затем мы исключаем связи, которые нам не нужны. В данном случае связи, которые закодированы 1 и 2, заменяются нулями. Потом мы создаем новую сеть на основе отфильтрованной социоматрицы. Ключевой момент здесь заключается в том, что связи могут создаваться между любыми узлами, если в d.val найдено ненулевое значение. Кроме того, с помощью параметров ignore.eval и names.eval мы сохраняем удержаные значения ребер в атрибуте ребер collab.

```
d.val <- as.sociomatrix(d, attrname="collab")
d.val[d.val < 3] <- 0
dfilt <- as.network(d.val, directed=FALSE,
                      matrix.type="a", ignore.eval=FALSE,
                      names.eval="collab")
```

Мы видим, что новая сеть включает такое же количество участников, но лишь 173 связи (соответствующие оценкам 3 и 4 в атрибуте collab). Неудивительно, что теперь сеть стала гораздо менее плотной.

```
summary(dfilt, print.adj=FALSE)

## Network attributes:
##   vertices = 54
##   directed = FALSE
##   hyper = FALSE
##   loops = FALSE
```

```

##   multiple = FALSE
##   bipartite = FALSE
##   total edges = 173
##   missing edges = 0
##   non-missing edges = 173
##   density = 0.121
##
## Vertex attributes:
##   vertex.names:
##     character valued attribute
##     54 valid vertex names
##
## Edge attributes:
## 
##   collab:
##     numeric valued attribute
##     attribute summary:
##       Min. 1st Qu. Median Mean 3rd Qu. Max.
##       3.00    3.00    3.00   3.46    4.00   4.00

gden(d.filt)
## [1] 0.121

```

Теперь, когда график построен, мы можем исследовать меньшее количество связей для получения важной информации о структуре сети (рис. 3.6).

```

op <- par(mar = rep(0, 4))
gplot(d.filt,gmode="graph",displaylabels=TRUE,
      vertex.col="lightblue",vertex.cex=1.3,
      label.cex=0.4,label.pos=5,
      displayisolates=FALSE)
par(op)

```

Обратите внимание на то, что если задан параметр `thresh`, функция `gplot()` выведет на экран лишь те связи, значения которых превышают определенный порог. Эта команда выведет на экран ту же самую сеть, что и предыдущий программный код, при этом отпадает необходимость в трех вышеупомянутых этапах, чтобы построить новую отфильтрованную сеть (результаты здесь не показаны). Обратите внимание на то, что функции `gplot` должна быть передана социоматрица со значениями, а не фактический объект `network`.

```

op <- par(mar = rep(0, 4))
d.val <- as.sociomatrix(d,attrname="collab")
gplot(d.val,gmode="graph",thresh=2,
      vertex.col="lightblue",vertex.cex=1.3,
      label.cex=0.4,label.pos=5,
      displayisolates=FALSE)
par(op)

```

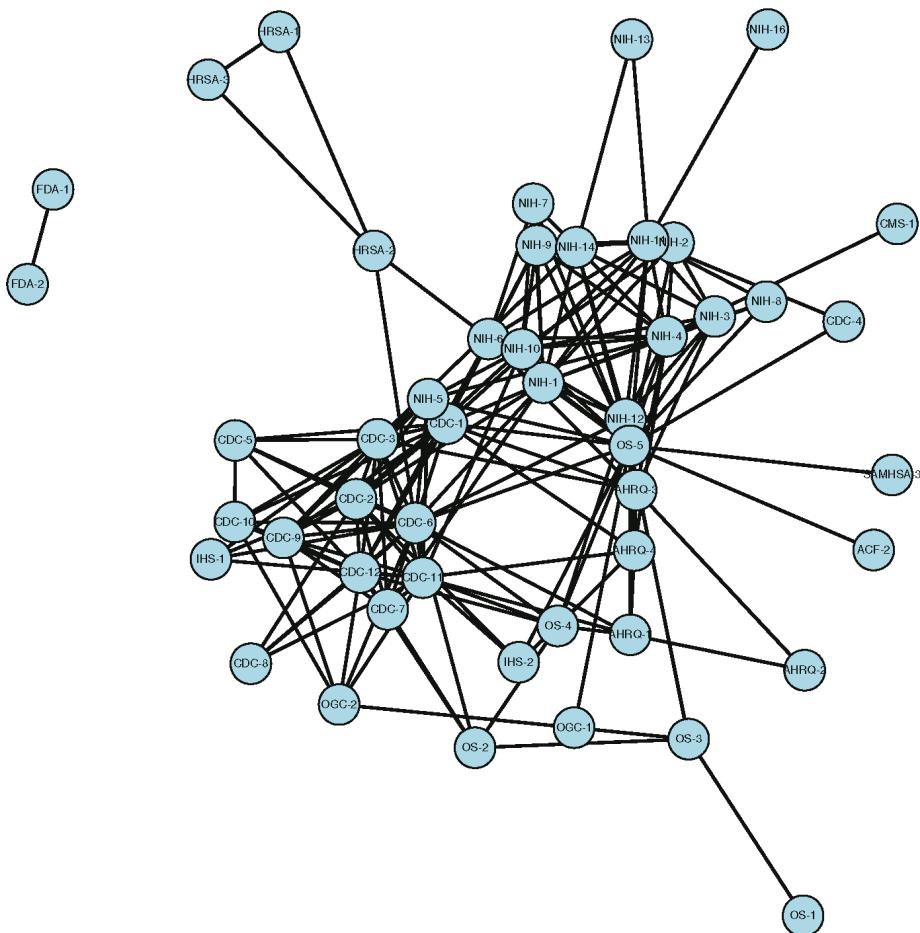


Рис. 3.6. Сеть DHHS, учитывается только официальное сотрудничество

3.4.2. Преобразование направленной сети в ненаправленную

Часто бывает, что даже когда исходные данные в анализе сетей состоят из направленных связей, аналитик хочет проанализировать их как ненаправленные. Это может быть обусловлено несколькими причинами. Во-первых, несмотря на то что сеть является ненаправленной, в процессе сбора данных могут появиться направленные связи. Например, в исследовании сотрудничества между экспертами даже с учетом того, что это сотрудничество является ненаправленным (если агентство А сотрудничает с агентством В, то В также сотрудничает с А), матрицы исходных данных вряд ли будут полностью симметричными. То есть в данные, которые заполняются самостоятельно, может закрасться ошибка, или два респондента не могут прийти к единому мнению по поводу статуса сотрудничества. Респондент

А полагает, что агентство А сотрудничает с агентством В, однако респондент В не считает, что между двумя агентствами есть сотрудничество. Так или иначе, вы в итоге получаете направленную сеть, которую вы хотите «исправить», преобразовав ее в ненаправленную сеть.

Кроме того, вы, возможно, захотите преобразовать направленные связи в ненаправленные по концептуальным причинам, а не просто для того, чтобы устранить разногласия в данных. Например, изучая отношения доверия, вы собираете их в виде направленных связей. В данном случае связь между А и В указывает на то, что А доверяет В. Связь является направленной в том смысле, что если А доверяет В, это не означает, что В доверяет А в ответ. Однако вы, возможно, захотите проанализировать ее как ненаправленную, когда два актора соединены ребром при условии, что между ними существуют хоть какие-то отношения доверия. Таким образом, независимо от того, доверяет ли респондент А респонденту В, или респондент В доверяет респонденту А, или даже если между А и В установлены взаимные доверительные отношения, вы рассматриваете А и В так, словно между ними есть доверительные отношения, и игнорируете направление доверия.

В силу этих причин R упрощает преобразование направленной сети в ненаправленную. Чтобы выполнить преобразование, вы можете использовать функцию `symmetrize()`. Название функции должно напомнить вам, что если данные в социоматрице симметричны по главной диагонали, связи являются ненаправленными.

```
net1mat <- symmetrize(net1, rule="weak")
net1mat

##      [,1] [,2] [,3] [,4] [,5]
## [1,]     0   1   1   0   0
## [2,]     1   0   1   1   0
## [3,]     1   1   0   0   1
## [4,]     0   1   0   0   0
## [5,]     0   0   1   0   0

net1symm <- network(net1mat, matrix.type="adjacency")
network.vertex.names(net1symm) <- c("A", "B", "C", "D", "E")
summary(net1symm)

## Network attributes:
##   vertices = 5
##   directed = TRUE
##   hyper = FALSE
##   loops = FALSE
##   multiple = FALSE
##   bipartite = FALSE
##   total edges = 10
##   missing edges = 0
##   non-missing edges = 10
##   density = 0.5
```

```
##  
## Vertex attributes:  
##   vertex.names:  
##     character valued attribute  
##     5 valid vertex names  
##  
## No edge attributes  
##  
## Network adjacency matrix:  
##   A B C D E  
## A 0 1 1 0 0  
## B 1 0 1 1 0  
## C 1 1 0 0 1  
## D 0 1 0 0 0  
## E 0 0 1 0 0
```

Процедура симметризации является относительно простой, за исключением того, что возвращает социоматрицу (или, в зависимости от настроек, список ребер). Таким образом, мы должны преобразовать ее в объект-сеть, как уже делали это ранее. Параметр `rule` предлагает вам четыре различных способа симметризации связи. Правило `weak` соответствует логическому выражению «OR», когда связь создается между узлами i и j , если есть связь, направленная от узла i к узлу j или от узла j к узлу i . Правило `strong` соответствует логическому выражению «AND», когда связь создается между узлами i и j только тогда, когда есть связи, направленные от узла i к узлу j и от узла j к узлу i . Оно создает симметричную сеть, где единственным видом связей являются полностью взаимные связи.

ЧАСТЬ II

ВИЗУАЛИЗАЦИЯ

Глава 4. Графическое представление и укладка сети	54
Глава 5. Эффективный графический дизайн сетей	64
Глава 6. Сложные графики сетей	83

Глава 4

Графическое представление и укладка сети

4.1. Проблема визуализации сети	55
4.2. Эстетический вид укладок сетей	57
4.3. Основные алгоритмы и методы графического представления.....	59

Прежде всего покажите данные.

Эдвард Тафти.
«Наглядное представление количественной информации».

4.1. Проблема визуализации сети

Как уже было сказано в главе 2, анализ сетей начинается с построения и исследования графика сети. Главное предназначение графика сети (как и любой графической информации) состоит в том, чтобы выделить важную информацию, содержащуюся в исходных данных. Однако существует множество способов скомпоновать узлы и связи сети в двумерном пространстве, а также использовать графические элементы (например, размер узла, цвет линии, легенду и т. д.) для представления сетевых данных. В следующих трех главах мы рассмотрим основные принципы эффективного графического дизайна сетей, а также расскажем, как создавать эффективные визуализации сетей в R.

Эффективный график сети показывает важную информацию о социальной сети, например об общей структуре, расположении ключевых акторов, наличии отдельных подгрупп и т. д. Одновременно с этим график должен максимально минимизировать присутствие нерелевантной информации. Например, длина связи в диаграмме сети является произвольной в том смысле, что она не значима. Эффективный рисунок сети должен быть спроектирован и выведен так, чтобы свести к минимуму вероятность того, что зритель неправильно истолкует значения длины связей.

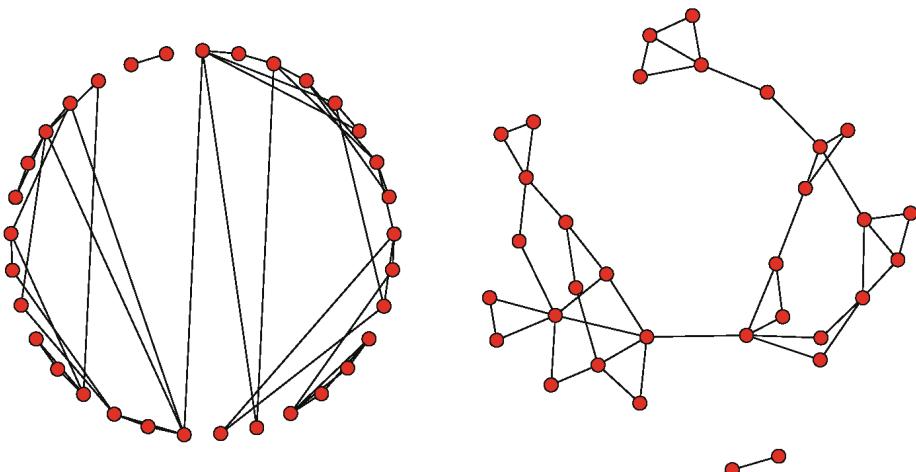


Рис. 4.1. Одна и та же сеть, различные укладки

Цель этой главы состоит в том, чтобы познакомить читателя с основными способами графического представления сетей в R и рассказать о различных па-

раметрах для настройки *укладки сети* (*network layout*)¹ на экране или странице. Пример, приведенный ниже, показывает, как интерпретацию графика сети можно усложнить или упростить с помощью выбора той или иной укладки.

```
data(Moreno)
op <- par(mar = rep(0, 4), mfrow=c(1,2))
plot(Moreno, mode="circle", vertex.cex=1.5)
plot(Moreno, mode="fruchtermanreingold", vertex.cex=1.5)
par(op)
```

На первый взгляд, может показаться, что на рисунке представлены две совершенно различные сети. Фактически же перед нами – две различные визуализации одной и той же социальной сети, в данном случае сети дружеских контактов между учениками 4-го класса. Несмотря на то что на рисунке представлены одни и те же данные, легко заметить, что график справа интерпретировать проще. В частности, гораздо легче увидеть, что сеть составлена из двух отдельных компонент, а большая по размеру компонента состоит из двух довольно четких подгрупп. Таким образом, важные структурные характеристики сети легче определить на графике справа.

Несмотря на то что можно разместить сеть в трехмерном пространстве, подавляющее большинство визуализаций сети является двухмерным. Узлы представлены в виде геометрических фигур, обычно в виде кружков, а связи – в виде прямых или иногда изогнутых линий. Для человека, малознакомого с методами визуализации сети, интерпретация линий может быть сложной. В частности, длина линии не имеет никакого значения. Рассмотрим следующие два графика, которые выводят на экран одну и ту же простую сеть (рис. 4.2). На первый взгляд, может показаться, что на графике справа узел D удален от узлов B и C на большее расстояние, чем на графике слева. Но связи просто указывают на то, какие узлы *смежны* (*adjacent*) друг с другом, таким образом, длина линии не несет какой-либо существенной информации.

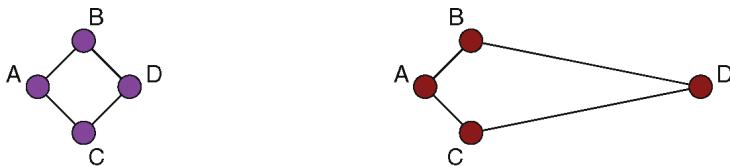


Рис. 4.2. Длина линии произвольна

Однако, как и в случае с сетью дружеских контактов Moreno (рис. 4.1), несмотря на произвольный характер некоторых элементов укладки, способ графического представления сети может прояснить или исказить важную информацию о ее структуре.

Это и есть фундаментальная проблема визуализации сети: раскрыть важные структурные характеристики сети без искажения, или, как говорил Эдвард Тафти,

¹ В качестве синонима также используется термин «компоновка сети».

минимум, на что мы должны надеяться, обладая той или иной технологией вывода изображения, – это то, что она не должна причинить вреда [Tufte, 1990].

4.2. Эстетический вид укладок сетей

Теоретически количество вариантов отображения сети на экране конечно, но практически неотличимо от бесконечности. (Например, возьмем небольшую сеть из 50 узлов и сеткой 10×10 . В действительности сетка может быть намного больше. Первый узел в сети может располагаться в любой из 100 позиций, 2-й узел – в 99 позициях и т. д. Для этого примера существует $3,1 \times 10^{93}$ различных укладок сети.) В большинстве случаев будут построены уродливые или сбивающие с толку укладки, поэтому возникает необходимость в такой укладке, которая с высокой долей вероятности будет адекватно представлять сеть.

К счастью, специалисты по визуализации сетей уже знают, что именно делает укладку сети понятной. Был сформулирован ряд эстетических принципов, которые могут использоваться для построения более эффективных графиков сетей. Графики сетей будет проще понять, если при их построении придерживаться следующих пяти принципов:

- минимизировать пересечения ребер;
- максимизировать симметричность укладки узлов;
- минимизировать изменчивость длины ребер;
- максимизировать угол между ребрами, когда они пересекают или соединяют узлы;
- минимизировать общее пространство, использованное для вывода сети.

Для автоматического построения укладок было разработано большое количество методов. Общий класс алгоритмов под названием *force-directed algorithms* (*силовые алгоритмы*) оказался гибким и мощным методом автоматической укладки сетей. Эти алгоритмы работают итеративно, чтобы уменьшить общую энергию сети, где энергия может быть определена различными способами. Общий подход заключается в том, что между узлами, соединенными ребром, действуют силы притяжения («пружины»), при этом одновременно между всеми парами узлов действуют силы отталкивания. *Пружины* (*springs*) в этом алгоритме стараются максимально сблизить смежные узлы, тогда как силы отталкивания максимально удаляют несмежные узлы друг от друга. Получающаяся в результате сеть будет некоторое время меняться, прежде чем обрести устойчивое состояние, при котором произойдет минимизация энергии сети¹. Мы описали работу алгоритма, но замечательный момент заключается в том, что с точки зрения принципов, описанных выше, на получившийся график сети приятно смотреть [Fruchterman, Reingold, 1991].

Чтобы оценить положительные результаты применения одного из этих алгоритмов, взгляните на сравнение, приведенное на рис. 4.3. Слева сеть Moreno пока-

¹ Под энергией подразумевается сумма сил, действующих на узел. – Прим. пер.

зана в случайной укладке. Справа для визуализации сети мы использовали алгоритм укладки Фрюхтермана и Рейнгольда. Фрюхтерман и Рейнгольд разработали один из первых силовых алгоритмов визуализации сети, и он все еще широко используется. Графические функции в комплекте пакетов `statnet` используют этот алгоритм по умолчанию. Справа узлы уложены более симметрично, мы видим меньшее количество пересечений ребер, и длина связей распределена более равномерно. Все это упрощает интерпретацию структуры сети.

```
op <- par(mar = c(0, 0, 4, 0), mfgow=c(1, 2))
gplot(Moreno, gmode="graph", mode="random",
      vertex.cex=1.5, main="Случайная укладка")
gplot(Moreno, gmode="graph", mode="fruchtermanreingold",
      vertex.cex=1.5, main="Фрюхтерман–Рейнгольд")
par(op)
```

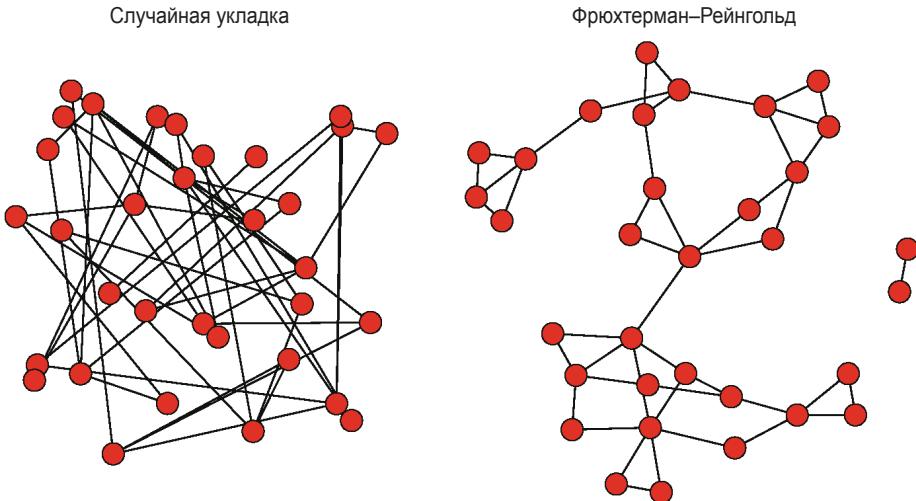


Рис. 4.3. Сеть *Moreno*, случайная укладка и укладка Фрюхтермана–Рейнгольда

Как говорилось выше, силовой алгоритм итеративно изменяет общую структуру сети до тех пор, пока не будет минимизирован определенный показатель общей энергии сети. Подробности этого процесса обычно не представляют интереса, посмотрим, как он работает на практике, взглянув на рис. 4.4, где показана сеть террористов, устроивших взрывы на Бали в 2002 году. На рисунке видно, как работает алгоритм укладки Фрюхтермана–Рейнгольда: алгоритм стартует с круговой укладки и выполняет последовательные итерации от 0 (круг в начале работы алгоритма) до 50.

Алгоритм Фрюхтермана–Рейнгольда наряду с другими силовыми методами является итеративным и недетерминированным. Это означает, что каждый раз, запуская алгоритм визуализации, вы не получите точно такой же укладки. Одна-

ко вы получите укладку, которая, как правило, симметрична, имеет минимальное количество пересечений ребер и т. д.

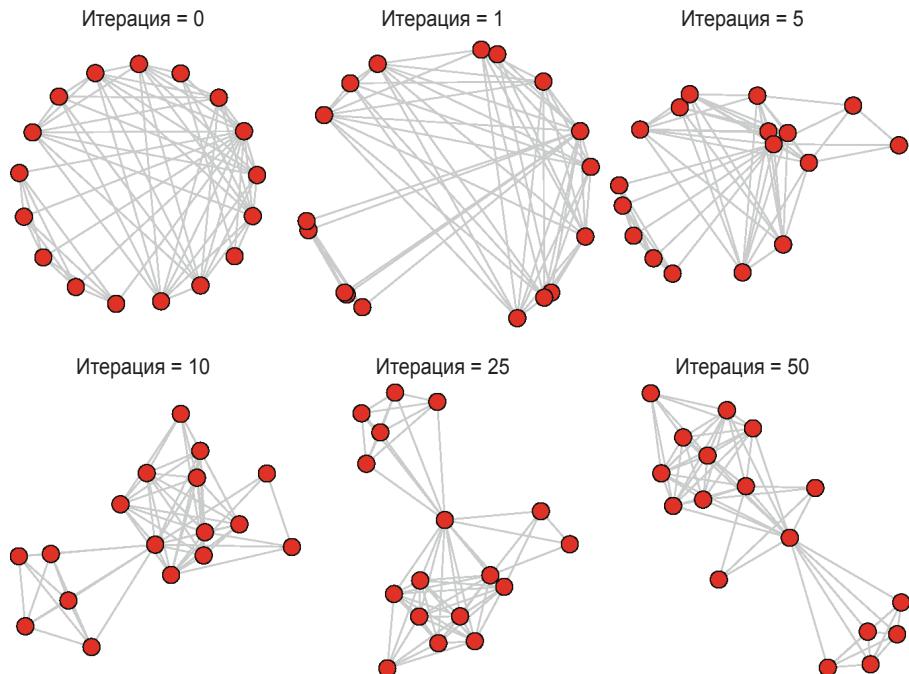


Рис. 4.4. Итеративный алгоритм Фрюхтермана–Рейнгольда

4.3. Основные алгоритмы и методы графического представления

Визуализация сети в statnet осуществляется с помощью двух тесно связанных между собой функций `plot` и `gplot`. Последняя предлагает большее количество алгоритмов укладки, таким образом, она, возможно, будет более полезной. Чтобы использовать тот или иной алгоритм укладки, просто задайте соответствующую укладку. Рисунок 4.5 показывает шесть алгоритмов укладки для функции `gplot`.

```
data(Bali)
op <- par(mar=c(0,0,4,0),mfrow=c(2,3))
gplot(Bali,gmode="graph",edge.col="grey75",
      vertex.cex=1.5,mode='circle',main="circle")
gplot(Bali,gmode="graph",edge.col="grey75",
      vertex.cex=1.5,mode='eigen',main="eigen")
gplot(Bali,gmode="graph",edge.col="grey75",
      vertex.cex=1.5,mode='random',main="random")
gplot(Bali,gmode="graph",edge.col="grey75",
      vertex.cex=1.5,mode='spring',main="spring")
```

```

vertex.cex=1.5,mode='spring',main="spring")
gplot(Bali,gmode="graph",edge.col="grey75",
      vertex.cex=1.5,mode='fruchtermanreingold',
      main='fruchtermanreingold')
gplot(Bali,gmode="graph",edge.col="grey75",
      vertex.cex=1.5,mode='kamadakawai',
      main='kamadakawai')
par(op)

```

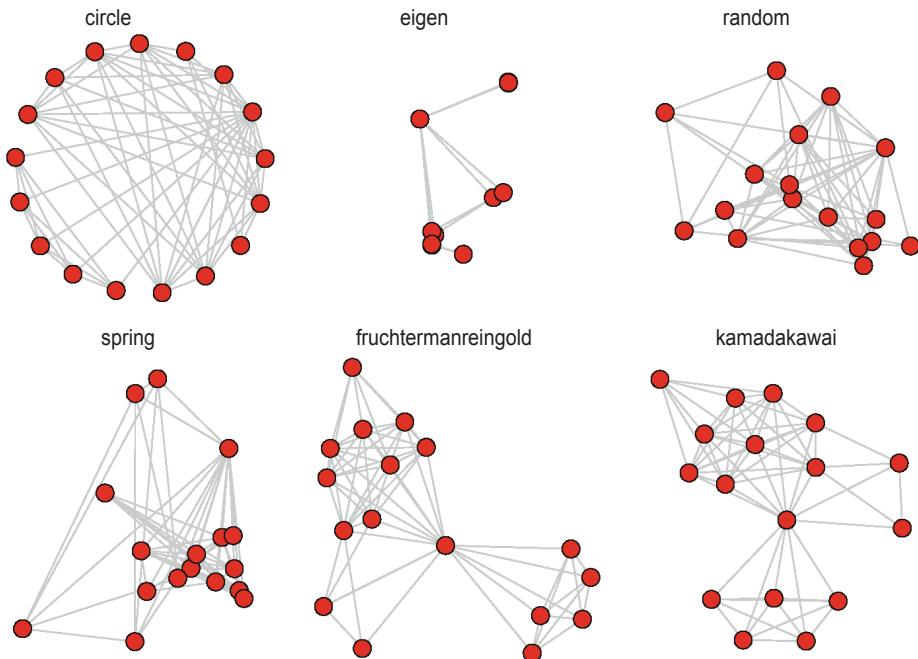


Рис. 4.5. Алгоритмы укладки сетей

4.3.1. Более точная настройка укладки сети

Алгоритмы укладки, представленные в `statnet` (и `igraph`, см. ниже), работают эвристически, обычно с некоторой долей случайности. Даже выбрав один и тот же алгоритм укладки, при каждом построении графика сети вы будете получать разную укладку. К счастью, в R можно точно настроить координаты укладки. Это позволяет добиться точного позиционирования или сохранить координаты укладки после того, как построен конкретный график сети.

Для этого используется параметр `coord` в функции `gplot`. Этому параметру нужна матрица с двумя столбцами. Каждая строка соответствует узлу, первый столбец задает координату X, а второй столбец – координату Y. Результаты, полученные с помощью функции `gplot`, можно сохранить в объекте. Объект хранит координаты построенного графика. Это показано в следующем примере. Здесь мы строим первоначальный график сети террористов, сохраняя координаты. Потом

мы растягиваем график путем умножения координат Y на константу. Оба графика показаны на рисунке, также приводятся оси, чтобы проще было увидеть, как изменились координаты (рис. 4.6). Существуют и другие способы задать определенные координаты, но основное применение заключается в том, чтобы сохранить конкретную укладку для построения и анализа графика в будущем.

```
mycoords1 <- gplot(Bali, gmode="graph",
                     vertex.cex=1.5)
mycoords2 <- mycoords1
mycoords2[,2] <- mycoords1[,2]*1.5
mycoords1

##           x     y
## [1,] -6.299 11.84
## [2,] -3.887 13.80
## [3,] -8.355  9.89
## [4,] -4.672 10.28
## [5,] -8.537 11.65
## [6,] -5.932 12.63
## [7,] -2.420 12.96
## [8,] -7.694 10.09
## [9,] -8.334 10.86
## [10,] -0.935  8.08
## [11,] -3.015  6.98
## [12,] -1.863  7.10
## [13,] -1.094  9.30
## [14,] -2.061  8.51
## [15,] -7.715 12.83
## [16,] -10.453 11.25
## [17,] -8.357 12.43

mycoords2

##           x     y
## [1,] -6.299 17.8
## [2,] -3.887 20.7
## [3,] -8.355 14.8
## [4,] -4.672 15.4
## [5,] -8.537 17.5
## [6,] -5.932 18.9
## [7,] -2.420 19.4
## [8,] -7.694 15.1
## [9,] -8.334 16.3
## [10,] -0.935 12.1
## [11,] -3.015 10.5
## [12,] -1.863 10.7
## [13,] -1.094 14.0
## [14,] -2.061 12.8
## [15,] -7.715 19.2
## [16,] -10.453 16.9
## [17,] -8.357 18.6
```

```
op <- par(mar=c(4, 3, 4, 3), mflow=c(1, 2))
gplot(Bali, gmode="graph", coord=mycoords1,
      vertex.cex=1.5, suppress.axes = FALSE,
      ylim=c(min(mycoords2[, 2])-1, max(mycoords2[, 2])+1),
      main="Исходные координаты")
gplot(Bali, gmode="graph", coord=mycoords2,
      vertex.cex=1.5, suppress.axes = FALSE,
      ylim=c(min(mycoords2[, 2])-1, max(mycoords2[, 2])+1),
      main="Измененные координаты")
par(op)
```

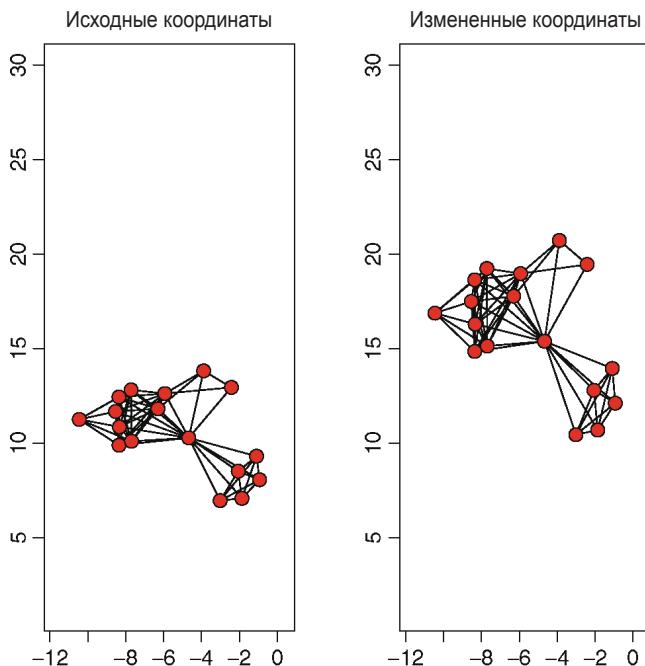


Рис. 4.6. Укладки сетей с измененными координатами

4.3.2. Укладки сетей, построенные с помощью *igraph*

Пакет *igraph* предлагает пользователю аналогичный набор параметров для настройки укладки сети. Параметр *layout* используется, чтобы задать алгоритм укладки или указать набор координат вершин. См. *?igraph.plotting* для получения дополнительной информации об алгоритмах укладки в пакете *igraph* (рис. 4.7).

```
detach(package:statnet)
library(igraph)
library(intergraph)
iBali <- asIgraph(Bali)
```

```
op <- par(mar=c(0,0,3,0),mfrow=c(1,3))
plot(iBali,layout=layout_in_circle,
     main="Круговая")
plot(iBali,layout=layout_randomly,
     main="Случайная")
plot(iBali,layout=layout_with_kk,
     main="Камада-Каваи")
par(op)
```

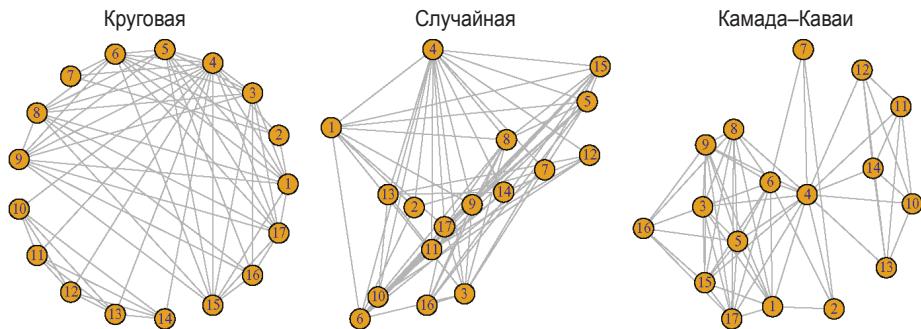


Рис. 4.7. Алгоритмы укладки сетей в igraph

Глава 5

Эффективный графический дизайн сетей

5.1. Основные принципы	65
5.2. Элементы дизайна.....	65

Как и любой график, сети используются для того, чтобы обнаружить соответствующие группы или проинформировать об обнаруженных группах и структурах. Они являются хорошим средством графического представления структур. Однако они перестают быть таковым средством, когда элементы сети становятся многочисленными. Рисунок быстро становится сложным, неразборчивым и не поддающимся преобразованию.

Жак Бертин.

5.1. Основные принципы

Создание эффективного графического дизайна сети мало чем отличается от какого-либо другого типа графической информации. Как отметил Эдвард Тафти (Edward Tufte) в своей фундаментальной работе *«Наглядное представление количественной информации»* (*The Visual Display of Quantitative Information*): «Графическое превосходство состоит в том, чтобы дать зрителю максимальное количество информации в кратчайший срок, используя наименьшее количество чернил на минимальном пространстве». У графиков сетей изначально есть важное преимущество в том плане, что они обычно характеризуются высоким соотношением объема информации к объему чернил.

Цель графического дизайна сети должна состоять в том, чтобы построить рисунок, который показывает важную или интересную информацию, содержащуюся в сетевых данных. Для этого аналитик должен определиться с каждым графическим элементом, который может появиться на рисунке. R и графические функции в *statnet* и *igraph* предлагают аналитику практически полное программное управление графиками сетей. Цель этой главы состоит в том, чтобы кратко рассказать о наиболее важных элементах графического дизайна сетей и обсудить, как их использовать и почему их нужно применять определенным образом.

5.2. Элементы дизайна

Как и любой другой тип графической информации, визуализация сети состоит из большого количества отдельных графических элементов. Эти отдельные элементы являются отличительными для того или иного графика сети, например узлы и связи, а также другие элементы, характерные для большинства графиков, например заголовки, легенды и т. д. Графические функции в *statnet* и *igraph* предлагают пользователю полноценное программное управление графиками.

Несмотря на то что для построения обычного графика сети достаточно простого вызова функции графического изображения, практически всегда имеет место ситуация, когда нужно потратить время на настройку соответствующих параметров функций и написать дополнительный программный код R для построения эффективного графика. В ряде случаев дизайн будет продиктован эстетическими

соображениями, тогда как в ряде других случаев дизайн будет зависеть от наиболее важной закономерности, которую вы хотите отразить на графике, подготовив соответствующие сетевые данные.

Следующие разделы представляют собой краткое знакомство с графическими элементами, наиболее часто используемыми для визуализации сети. О каждом элементе будет рассказано по порядку.

5.2.1. Цвет узла

По умолчанию `statnet` строит график сети, в котором узлы представлены в виде красных кружков. Чтобы задать цвет, используйте параметр `vertex.col` в функции `gplot` (также используется параметр `gmode`, который задает тип графа¹). Например, достаточно просто построить график с узлами привлекательного светло-синего цвета (рис. 5.1). Если вы работаете в режиме продолжения, перед запуском программного кода рекомендуем отключить пакет `igraph` и загрузить пакет `statnet`.

```
library(statnet)
library(UserNetR)
data(Bali)
gplot(Bali, vertex.col="slateblue2", gmode="graph")
```

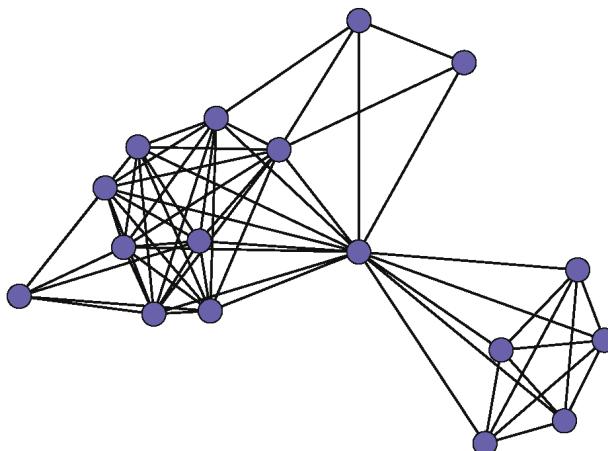


Рис. 5.1. Сеть Bali со светло-синими узлами

В целом с точки зрения графического представления сетей в R есть все основные параметры для работы с цветом. Все это открывает гибкие и мощные возможности для графического дизайна, однако эффективное использование цвета потребует не-

¹ Параметр `gmode` может принимать значение `digraph` (ребра графа интерпретируются как направленные) или значение `graph` (ребра графа интерпретируются как ненаправленные). По умолчанию используется значение `digraph`. В описанном примере сеть террористов, устроивших взрывы на Бали, интерпретируется как ненаправленная. – Прим. пер.

которой подготовительной работы. В частности, будет полезно ознакомиться со все-сторонним анализом вопросов использования цвета в R (например, [Murrell, 2005]).

Как явствует из предыдущего примера, цвет может определяться его названием. Чтобы взглянуть на все 657 названий цветов, распознаваемых R, воспользуйтесь командой `colors()`. Кроме того, цвета можно назначить с помощью RGB-триплетов¹. Помимо этого, цветовую схему RGB можно задать с помощью шестнадцатеричной строки в формате #RRGGBB, где RR, GG и BB – это шестнадцатеричные числа, которые задают интенсивности красной, зеленой и синей составляющих цвета в диапазоне от 00 до FF.

Программный код, приведенный ниже, построит тот же самый график сети с теми же самыми светло-синими узлами (рисунок не показан), иллюстрируя, как можно получить цвет, задав значения интенсивности для трех составляющих цвета или использовав шестнадцатеричную строку. Для получения подходящих RGB-значений для определенного названия цвета можно использовать функцию `col2rgb()`. Шестнадцатеричные коды были получены по адресу: <http://www.javascripter.net/faq/rgbtohex.htm>.

```
col2rgb('slateblue2')
gplot(Bali, vertex.col=rgb(122,103,238,
                           maxValue=255), gmode="graph")
gplot(Bali, vertex.col="#7A67EE", gmode="graph")
```

Одна из самых редко используемых настроек для работы с цветом может пригодиться для построения диаграмм больших сетей, где узлы накладываются друг на друга. Обычно цвета полностью непрозрачны, поэтому перекрывающиеся узлы в диаграмме выглядят как огромные цветовые «сгустки» («blobs»), где трудно выделить какие-либо узлы. Однако есть возможность применить частично прозрачные цвета, использовав встроенный альфа-канал прозрачности. Функцию `rgb()` можно использовать для определения значения прозрачности от 0 (полностью прозрачный) до 1 (полностью непрозрачный). См. `?rgb` для получения более подробной информации.

Рисунок 5.2 показывает разницу, которая получается при использовании альфа-канала прозрачности. Оба графика представляют собой одну и ту же случайную сеть, состоящую из 300 узлов. (Укладки отличаются, потому что использовался силовой алгоритм Фрюхтермана–Рейнгольда.) На рисунке слева используется полностью непрозрачный темно-синий цвет. Рисунок справа тоже использует темно-синий цвет, но со значением альфа-канала, равным примерно 30%. Перекрывающиеся узлы становятся намного проще увидеть, когда используются прозрачные цвета. Обратите внимание на то, что некоторые графические устройства R могут не поддерживать прозрачных цветов.

```
ndum <- rgraph(300, tprob=0.025, mode="graph")
op <- par(mar = c(0,0,2,0), mfrow=c(1,2))
```

¹ RGB-триплет – три значения интенсивности красной (red), зеленой (green) и синей (blue) составляющих цвета. – Прим. пер.

```
gplot(ndum, gmode="graph", vertex.cex=2,
       vertex.col=rgb(0,0,139,maxColorValue=255),
       edge.col="grey80", edge.lwd=0.5,
       main="Полностью непрозрачный")
gplot(ndum, gmode="graph", vertex.cex=2,
       vertex.col=rgb(0,0,139,alpha=80,maxColorValue=255),
       edge.col="grey80", edge.lwd=0.5,
       main="Частично прозрачный")
par(op)
```

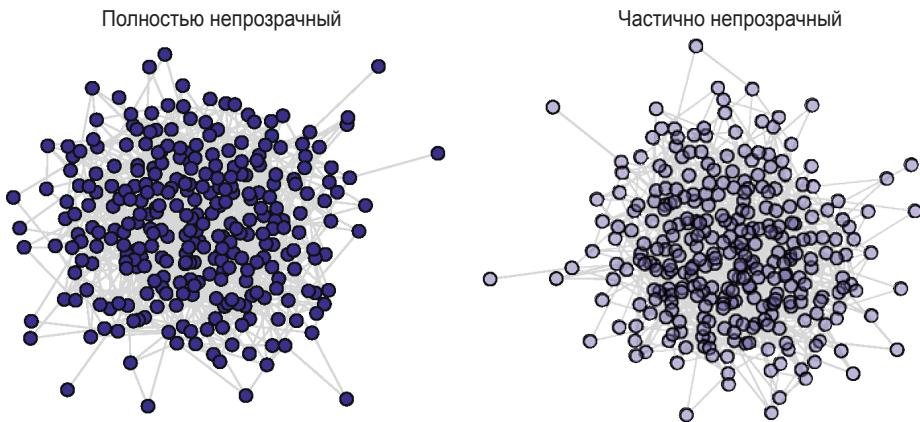


Рис. 5.2. Пример использования альфа-канала прозрачности

Во всех предыдущих примерах каждый узел имел одинаковый цвет. Более важная задача, решаемая с помощью цвета, заключается в том, чтобы показать определенную характеристику узла или сети, присвоив различным узлам разные цвета. В частности, информацию, хранящуюся в категориальном атрибуте узла, можно передавать с помощью цвета узла.

Например, сеть террористов Bali¹ имеет атрибут вершин `role`, в котором хранится категориальная информация о роли каждого участника сети. СТ означает член командной группы, BM – изготовитель бомб и т. д. (См. ?Bali для получения дополнительной информации.) Цвет узла можно использовать для эффективного различия ролей участников сети. Поскольку эта информация уже хранится в атрибуте вершин, `statnet` может использовать ее для автоматического выбора цвета узла. (Это верно лишь для `plot()`, но не для `gplot()`.)

```
rolelab <- get.vertex.attribute(Bali, "role")
op <- par(mar=c(0,0,0,0))
plot(Bali, usearrows=FALSE, vertex.cex=1.5, label=rolelab,
      displaylabels=T, vertex.col="role")
par(op)
```

¹ Речь идет о террористах, устроивших взрывы на Бали в 2002 году. – Прим. пер.

На рис. 5.3 показана сеть Bali, где узлы окрашены в соответствии с ролью каждого участника сети. (Метки узлов выведены для упрощения интерпретации. О присвоении меток узлам будет рассказано в разделе 5.2.4.) С помощью цветовой кодировки сеть стала гораздо более понятной. Например, мы можем легко определить подгруппы, заметив, что наибольшая плотность наблюдается между членами группы Lima (TL, голубой), а также между теми, кто изготавливал бомбы (BM, черный).

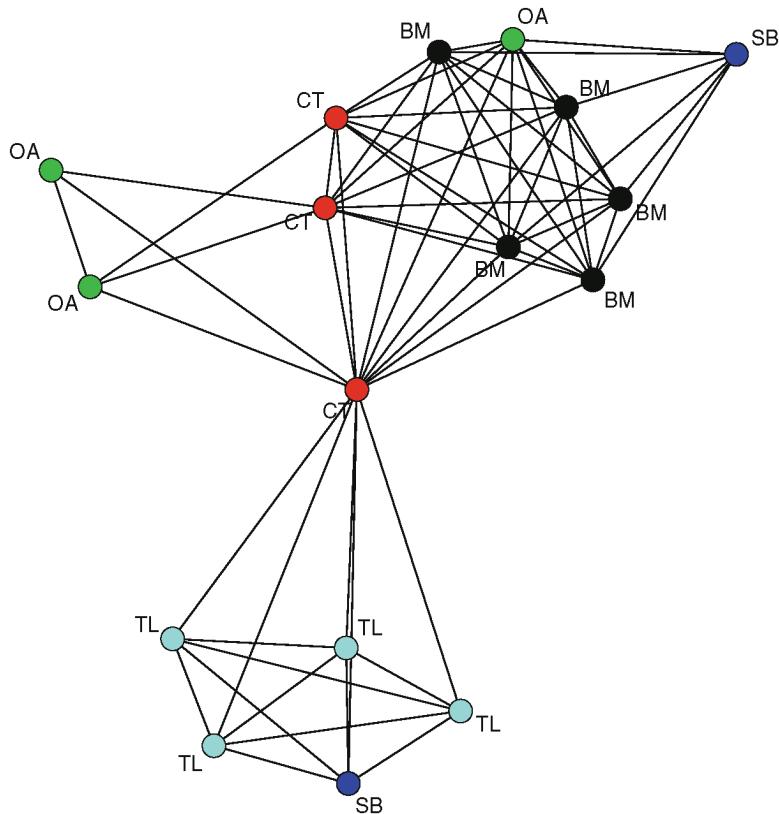


Рис. 5.3. Сеть Bali, роли участников выделены разными цветами

При этом, используя имя заданного атрибута вершин, statnet назначает цвета узлов, согласно текущей палитре цветов, принятой по умолчанию в R. Просматривая эту палитру, мы видим, что «BM» назначается черный цвет, потому что «BM» стоит первым по алфавиту в атрибуте role, a black – первая запись в палитре цветов. «CT» стоит вторым, поэтому назначается красный цвет, который является второй записью в палитре, и т. д.

`palette()`

```
## [1] "black"   "red"     "green3"   "blue"
## [5] "cyan"    "magenta" "yellow"   "gray"
```

Использование палитры, принятой по умолчанию, имеет много недостатков. Во-первых, выбор ограничен восемью цветами. (R циклически повторит набор из восьми цветов, если типов узлов, для которых нужно задать цвет, будет больше восьми.) Во-вторых, палитра, принятая по умолчанию, начинается с черного цвета, который, как правило, является не самым лучшим цветом для графика сети. Вообще, цвета, используемые по умолчанию, не являются эстетически приятным или удобным набором цветов для графического представления категориальных данных.

Более гибкий и оптимальный, с эстетической точки зрения, подход заключается в том, чтобы задать собственную цветовую палитру и индекс для выбора цвета. Пакет RColor Brewer предлагает ряд заранее разработанных цветовых палитр, которые очень удобны, если цвет используется для идентификации относительно небольшого количества категорий. Для получения дополнительной информации см. ?RColorBrewer. Больше подробную информацию о ColorBrewer можно получить по адресу <http://www.colorbrewer.org>. (Приводится информация о различных параметрах выбора цветов и палитр, например посмотрите интерактивный генератор палитр по адресу <http://paletton.com>.)

```
library(RColorBrewer)  
display.brewer.pal(5, "Dark2")
```

В программном коде, приведенном ниже, пользовательская палитра создается путем выбора пяти цветов из палитры большего размера под названием Dark2, входящей в RColorBrewer. Как только палитра задана, ее можно использовать для построения графика сети. Этот подход позволяет получить более приятные цвета и является гораздо более гибким, в отличие от ситуации, когда зависишь от палитры цветов, принятой по умолчанию (рис. 5.4).

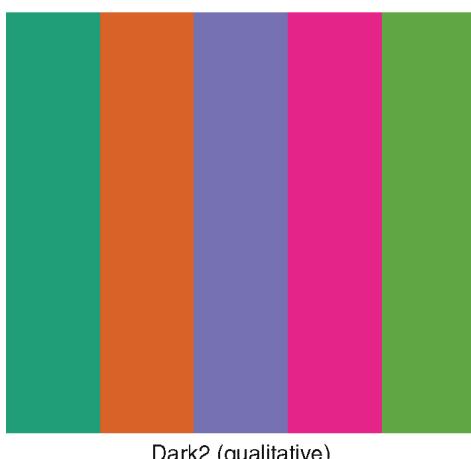


Рис. 5.4. Набор из пяти цветов, взятых из палитры RColorBrewer

Обратите внимание на то, что мы преобразуем символьный вектор атрибута вершин `role` в фактор, чтобы воспользоваться индексацией.

```
my_pal <- brewer.pal(5, "Dark2")
rolecat <- as.factor(get.vertex.attribute(Bali, "role"))
plot(Bali, vertex.cex=1.5, label=rolelab,
     displaylabels=T, vertex.col=my_pal[rolecat])
```

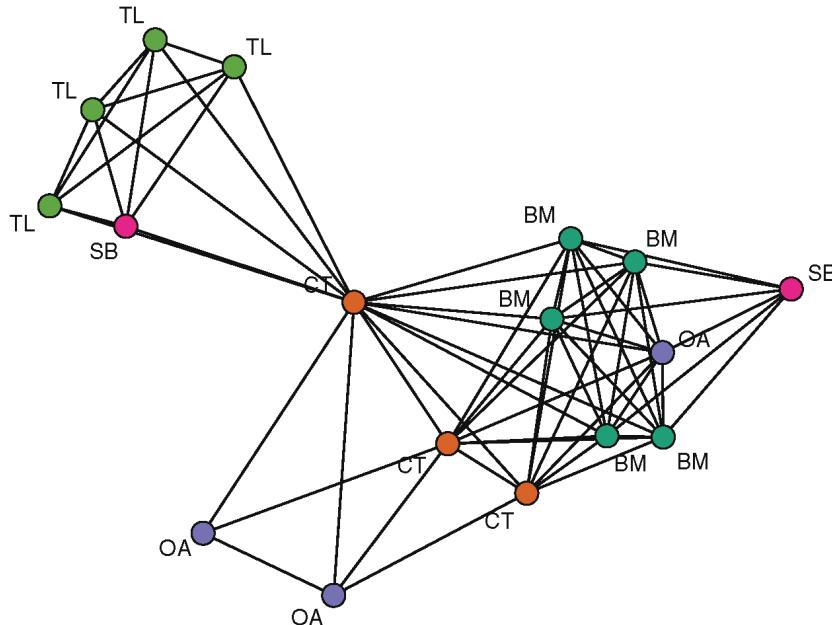


Рис. 5.5. Сеть Bali с более оптимальными цветами узлов

5.2.2. Форма узла

Помимо использования цвета для идентификации различных типов узлов, в `statnet` можно задавать разные формы узлов. В основном это удобно тогда, когда используется небольшое количество типов узлов. Кроме того, это особенно удобно, когда у вас нет возможности использовать цвет для идентификации узлов (или помочь дальтоникам).

К сожалению, `statnet` предлагает скромные возможности по идентификации узлов с помощью формы, автоматически определяя количество сторон, необходимых для построения многоугольника узла (обычно количество сторон равно 50 и строится круг). Если количество сторон равняется 3, вы получаете треугольник, 4 – квадрат и т. д. Это удобно лишь при работе с несколькими типами узлов (рис. 5.6).

Если у вас есть конкретная потребность использовать различные формы узлов для графика сети, пакет `igraph` в этом плане является гораздо более гибким. См.

раздел 9.2.3, где приводится пример графика сети с различными формами узлов, который построен в пакете *igraph*.

```
op <- par(mar=c(0,0,0,0))
sidenum <- 3:7
plot(Bali,usearrows=FALSE,vertex.cex=4,
      displaylabels=F,vertex.sides=sidenum[rolecat])
par(op)
```

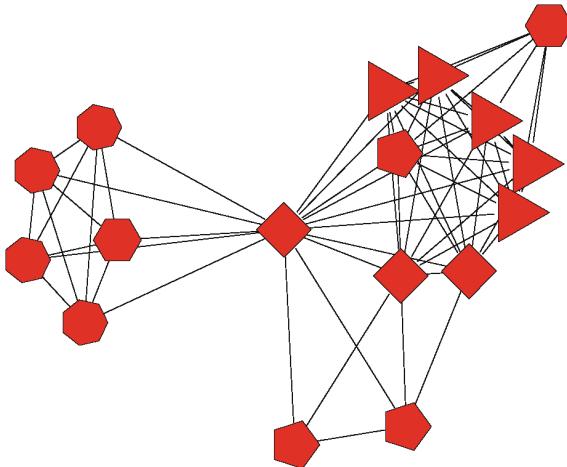


Рис. 5.6. Сеть *Bali* с различными формами узлов

5.2.3. Размер узла

В функциях *plot* и *gplot* комплекта пакетов *statnet* размеры узлов сети задаются параметром *vertex.cex* (аналогичным образом настраиваются размеры графических элементов в базовой графической системе R). Определяя абсолютные размеры узлов¹, нужно придерживаться правила: узлы должны быть достаточно большими, чтобы их можно было отличить друг от друга, и при этом достаточно маленькими, чтобы они не перекрывали сильно друг друга. В следующем примере, иллюстрирующем поиск «зоны Златовласки»², мы увидим, как можно скорректировать параметр *vertex.cex*, чтобы подобрать эффективный размер узла (рис. 5.7).

¹ Абсолютный размер – единый размер, который присваивается всем узлам независимо от их характеристик, относительный размер – размер, который зависит от характеристик узлов. – Прим. пер.

² «Зона Златовласки» – область в космосе, где условия могут быть подходящими для жизни. Это название представляет собой отсылку к английской сказке «*Goldilocks and the Three Bears*», на русском языке известной под названием «Три медведя». В сказке Златовласка пытается воспользоваться несколькими наборами из трех однородных предметов, в каждом из которых один из предметов оказывается чересчур большим (твёрдым, горячим и т. п.), другой – чересчур маленьким (мягким, холодным...), а третий, промежуточный между ними, предмет оказывается «в самый раз». В данном контексте речь идет об оптимальном абсолютном размере узлов. – Прим. пер.

```
op <- par(mar = c(0,0,2,0),mfrow=c(1,3))
plot(Bali,vertex.cex=0.5,main="Слишком маленький")
plot(Bali,vertex.cex=2,main="В самый раз")
plot(Bali,vertex.cex=6,main="Слишком большой")
par(op)
```

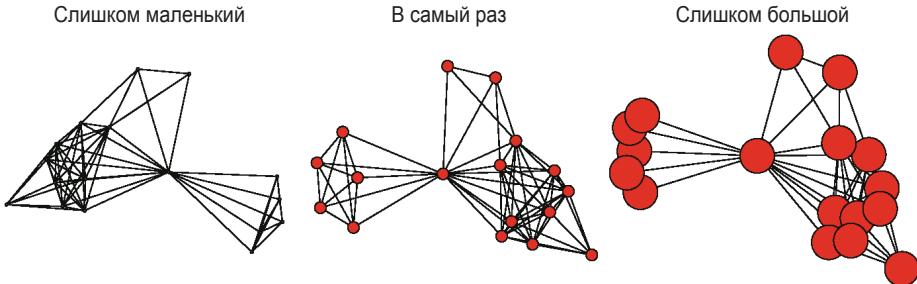


Рис. 5.7. Корректировка абсолютного размера узла

Вместо того чтобы задавать одинаковый абсолютный размер для каждого узла, часто возникает необходимость использовать размер узла, чтобы отразить какую-то важную количественную характеристику. Например, узлы отличаются по своему расположению в сети. Некоторые узлы являются более центральными, тогда как другие являются более периферийными. В главе 7 подробнее рассказывается о важности и центральности узлов, но сейчас мы просто вычислим некоторые характеристики узла так, что более высокие числовые значения будут указывать на более центральные узлы.

Для этого мы вычислим три различные меры центральности узла. Каждая из нижеперечисленных строк программного кода создает вектор мер центральности для каждого узла, и более высокие числовые значения указывают на большую центральность.

```
deg <- degree(Bali,gmode="graph")
deg
## [1] 9 4 9 15 9 10 3 9 9 5 5 5 5 5 5 9
## [16] 6 9

cls <- closeness(Bali,gmode="graph")
cls
## [1] 0.696 0.552 0.696 0.941 0.696 0.727 0.533
## [8] 0.696 0.696 0.571 0.571 0.571 0.571 0.571
## [15] 0.696 0.485 0.696

bet <- betweenness(Bali,gmode="graph")
bet
## [1] 2.333 0.333 1.667 61.167 1.667 6.167
## [7] 0.000 1.667 1.667 0.000 0.000 0.000
## [13] 0.000 0.000 1.667 0.000 1.667
```

Получив вектор, его можно использовать для определения относительных размеров узлов. Как и ранее, это делается с помощью того же самого параметра `vertex.cex`, но вместо конкретного числового значения мы задаем полученный вектор `deg`.

```
op <- par(mar = c(0, 0, 2, 1), mfrow=c(1, 2))
plot(Bali, usearrows=T, vertex.cex=deg, main="Исходный")
plot(Bali, usearrows=FALSE, vertex.cex=log(deg),
     main="Скорректированный")
par(op)
```

Однако, взглянув на график слева на рис. 5.8, мы видим, что исходные числовые значения вектора `deg` (*degree*, или *степень*) строят слишком большие узлы. Их нужно скорректировать, и в данном случае мы получим подходящие размеры узлов, прологарифмировав значения вектора `deg`. В результате получаем оптимальный вариант, когда можно легко увидеть узлы с высокой степенью и узлы с низкой степенью.

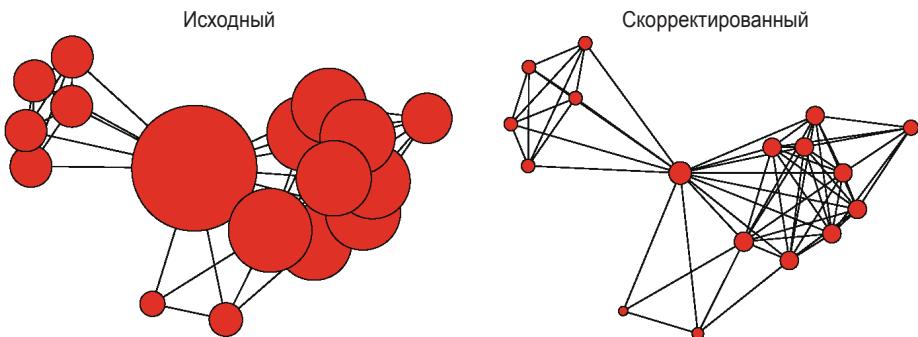


Рис. 5.8. Корректировка относительного размера узла – пример 1

В следующих двух примерах показаны другие типы корректировок, которые могут понадобиться при определении относительных размеров узлов. Воспользовавшись вектором `cls` (*closeness*, или *близость*), мы сталкиваемся с проблемой, обратной той, что была в предыдущем примере, – размеры узлов стали слишком маленькими. Поэтому соответствующая корректировка заключается в том, чтобы умножить исходные значения на константу (рис. 5.9). Использование вектора `bet` (*betweenness*, или *посредничество*) приводит к более сложной проблеме. Во-первых, исходные значения, указанные в векторе, могут отличаться друг от друга на несколько порядков (в результате один узел имеет размер 122,3). Кроме того, некоторые узлы имеют нулевые значения посредничества. Эти нули приведут к построению узлов нулевого размера, поэтому мы должны скорректировать их. Для этого добавим 1 к каждому значению вектора `bet` и извлечем квадратный корень (рис. 5.10).

```

op <- par(mar = c(0,0,2,1),mfrow=c(1,2))
plot(Bali,usearrows=T,vertex.cex=cls,main="Исходный")
plot(Bali,usearrows=FALSE,vertex.cex=4*cls,
     main="Скорректированный")
par(op)

op <- par(mar = c(0,0,2,1),mfrow=c(1,2))
plot(Bali,usearrows=T,vertex.cex=bet,main="Исходный")
plot(Bali,usearrows=FALSE,vertex.cex=sqrt(bet+1),
     main="Скорректированный")
par(op)

```

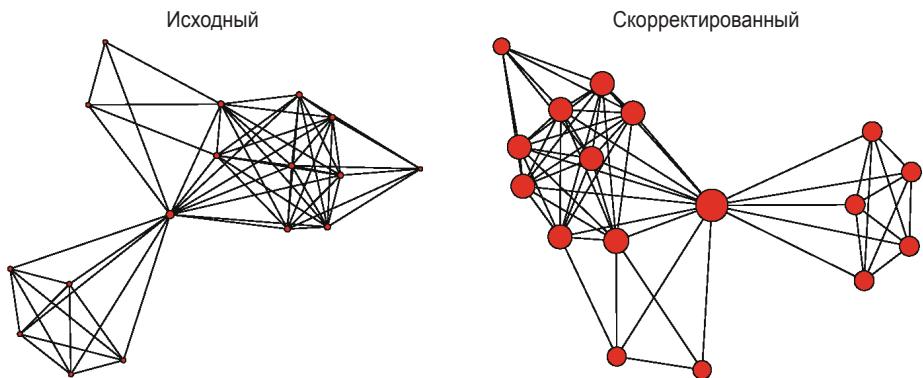


Рис. 5.9. Корректировка относительного размера узла – пример 2

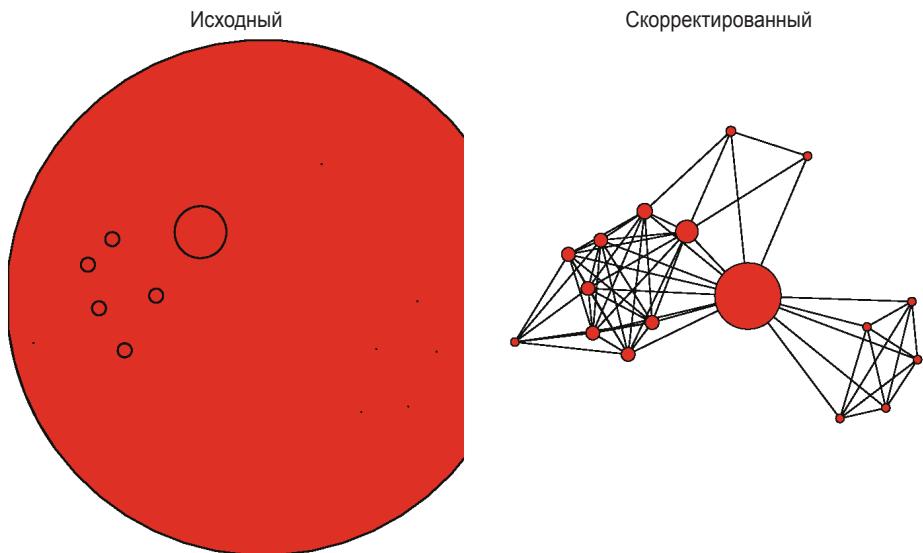


Рис. 5.10. Корректировка относительного размера узла – пример 3

Несмотря на то что R действительно позволяет вам полностью настраивать размеры узлов, корректировка относительных размеров узлов может быть утомительна. Функцию, приведенную ниже, можно использовать, чтобы сэкономить определенное время, которое уходит на определение оптимальных размеров узлов. Функция `rescale()` берет вектор характеристик узла (им может быть любой числовой вектор) и масштабирует значения так, чтобы они лежали в интервале между значениями `low` и `high`.

```
rescale <- function(nchar,low,high) {
  min_d <- min(nchar)
  max_d <- max(nchar)
  rscl <- ((high-low)*(nchar-min_d)) / (max_d-min_d)+low
  rscl
}
```

Следующий рисунок показывает результат работы функции `rescale`: исходные значения степени для сети Bali отмасштабированы так, что размеры узлов варьируют от 1 до 6 (рис. 5.11).

```
plot(Bali,vertex.cex=rescale(deg,1,6),
      main="Размеры узлов, скорректированные с помощью функции rescale.")
```

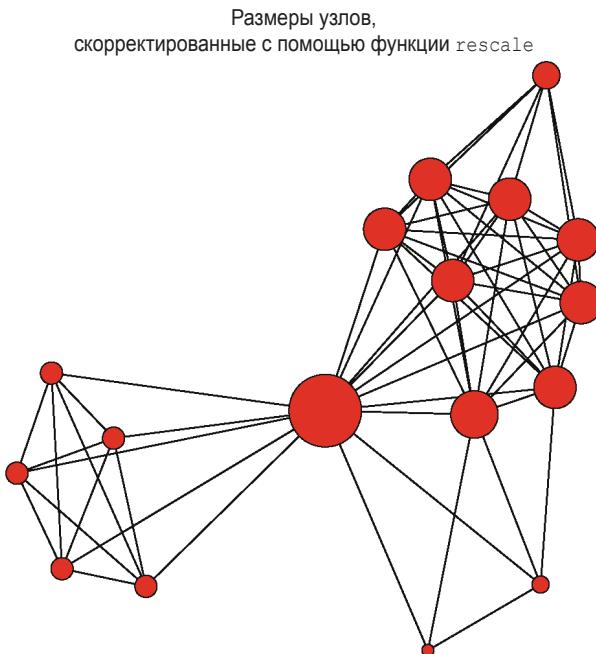


Рис. 5.11. Масштабирование размера узла на основе степени

5.2.4. Метка узла

Как правило, график сети интереснее и проще интерпретировать, если узлы имеют метки и можно составить представление об участниках сети. Это особенно удобно при работе с небольшими сетями, если же сети становятся слишком большими, метки уже сами по себе могут затруднить интерпретацию сети.

Если объект-сеть в statnet имеет специальный атрибут вершин vertex.names, то его можно использовать для автоматического вывода меток узлов при построении графика. Можно настроить различные характеристики меток узлов, например размер шрифта, цвет и расстояние от узла (рис. 5.12).

```
get.vertex.attribute(Bali, "vertex.names")

## [1] "Muklas"    "Amrozi"     "Imron"      "Samudra"
## [5] "Dulmatin"   "Idris"      "Mubarok"    "Husin"
## [9] "Ghoni"      "Arناسان"   "Rauf"       "Octavia"
## [13] "Hidayat"    "Junaedi"    "Patek"      "Feri"
## [17] "Sarijo"

op <- par(mar = c(0,0,0,0))
plot(Bali, displaylabels=TRUE, label.cex=0.8,
     pad=0.4, label.col="darkblue")
par(op)
```

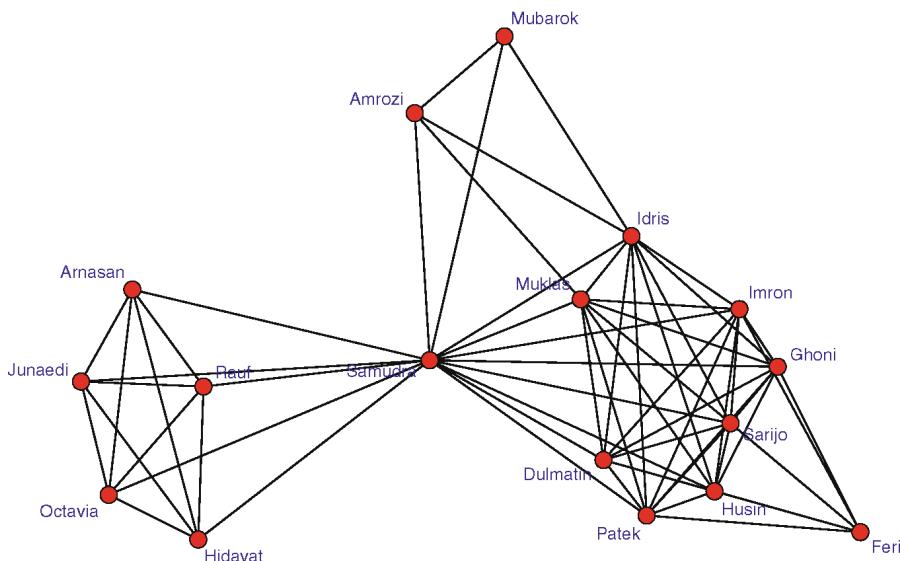


Рис. 5.12. Сеть Bali с метками узлов

Автоматические метки, основанные на информации, хранящейся в атрибуте vertex.names, не всегда отражают самую важную или полезную информацию. На-

пример, при анализе сети Bali подлинные имена террористов не очень интересны аудитории. К счастью, в качестве меток узлов можно использовать другую текстовую информацию. Ранее на рис. 5.3 мы уже видели пример такой информации. В данном случае в качестве меток узлов мы используем текстовые значения, хранящиеся в атрибуте вершин `role`. Ключевой момент здесь заключается в использовании параметра `label`, который задает текстовый вектор для меток (рис. 5.13).

```
rolelab <- get.vertex.attribute(Bali, "role")
plot(Bali, usearrows=FALSE, label=rolelab,
     displaylabels=T, label.col="darkblue")
```

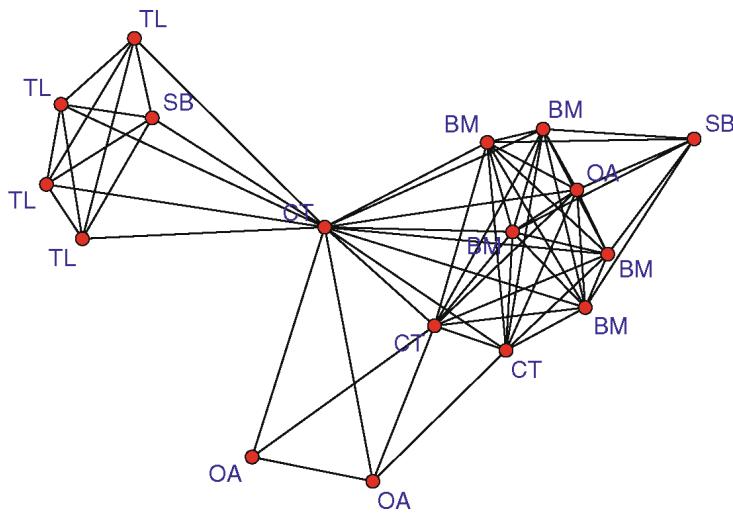


Рис. 5.13. Сеть Bali с метками-ролями

5.2.5. Ширина ребра

Если ваши сетевые данные предполагают связи с определенными значениями или вообще какую-либо количественную информацию, которая характеризует связи между узлами, можно отразить эту информацию визуально, изменив ширину связей в графике сети. Например, возможно, есть информация о силе дружеских связей или можно измерить денежную сумму, которая передается от организации к организации в направленной сети. В этих случаях более толстые связи могут означать более тесный контакт или более крупную денежную сумму (рис. 5.14).

Сеть Bali включает атрибут связей под названием IC, который представляет собой обычную пятиуровневую порядковую шкалу, использующуюся для изменения тесноты взаимодействия между участниками сети. Этот атрибут можно использовать для определения ширины связей. В примере, приведенном ниже, значения IC извлекаются из сохраненного атрибута ребер, это позволяет нам преобразовать вектор для более четкого разграничения пяти уровней IC (умножив значения вектора на 1,5).

```
op <- par(mar = c(0,0,0,0))
IClevel <- Bali %e% "IC"
plot(Bali,vertex.cex=1.5,
      edge.lwd=1.5*IClevel)
par(op)
```

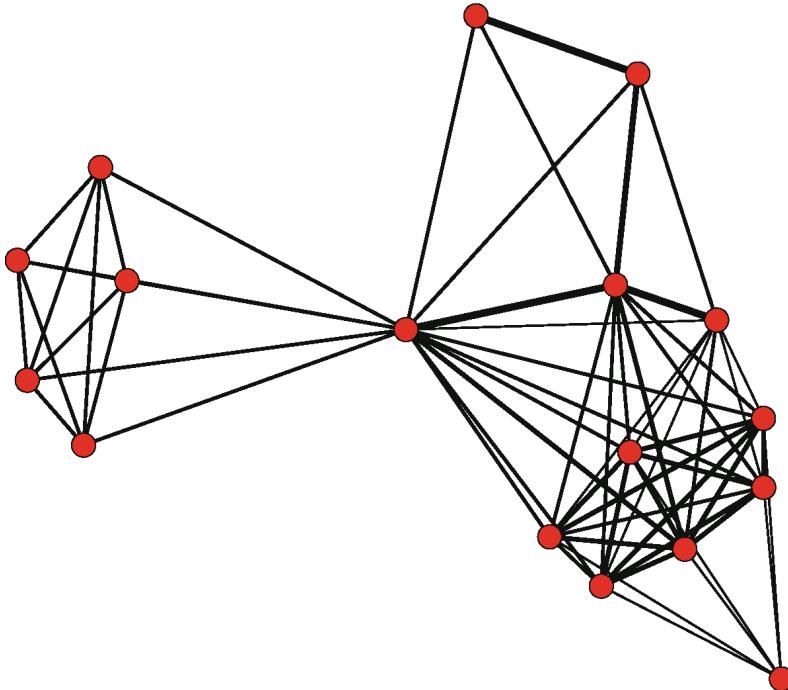


Рис. 5.14. Сеть *Bali*, ширина ребра обозначает тесноту контактов

5.2.6. Цвет ребра

Если ширину ребра можно использовать для представления количественной информации о связях сети, то цвет ребра можно применить для вывода качественной информации о связях, подобным же образом используется цвет узла. Например, вы можете использовать различные цвета линий, чтобы выделить положительные и отрицательные связи в социальной сети (рис. 5.15).

В атрибуте ребер сети *Bali* не содержится категориальной или качественной информации, поэтому здесь мы создаем случайный категориальный вектор, чтобы показать, как можно использовать различные цвета ребер в графике сети. Для этого примера мы задаем палитру цветов, которую можно использовать для индексации нужных цветов, на основе категориального вектора ребер. В данном случае синий цвет будет использоваться для типа ребра #1, красный цвет – для типа ребра #2 и зеленый цвет – для типа ребра #3. Это позволит показать нейтральные связи (синий цвет), отрицательные связи (красный цвет) и положительные связи

(зеленый цвет). (Также посмотрите рис. 7.8 в главе 7, на котором приводится более реалистичный пример использования различных цветов ребер.)

```
n_edge <- network.edgecount(Bali)
edge_cat <- sample(1:3,n_edge,replace=T)
linecol_pal <- c("blue","red","green")
plot(Bali,vertex.cex=1.5,vertex.col="grey25",
      edge.col=linecol_pal[edge_cat],edge.lwd=2)
```

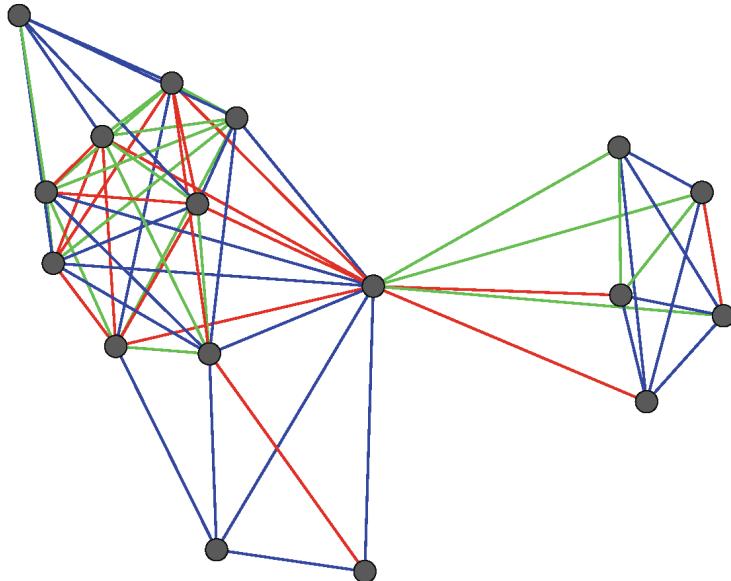


Рис. 5.15. Сеть Bali с разными цветами ребер

5.2.7. Тип ребра

Если ширину ребра можно использовать для представления количественной информации о связях сети, то цвет ребра можно применить для вывода качественной информации о связях. Например, вы можете использовать различные типы линий, чтобы выделить положительные и отрицательные связи в социальной сети.

В атрибуте ребер сети Bali не содержится категориальной или качественной информации, поэтому здесь мы создаем случайный категориальный вектор, чтобы показать, как можно использовать различные типы ребер в графике сети. В данном случае используются три различных типа линии (2 = тире; 3 = точка; 4 = точка-тире). Кроме того, поскольку при использовании функции plot() различные типы линий не отображаются четко, здесь используется функция gplot() (рис. 5.16).

```
n_edge <- network.edgecount(Bali)
edge_cat <- sample(1:3,n_edge,replace=T)
line Pal <- c(2,3,4)
```

```
gplot(Bali,vertex.cex=0.8,gmode="graph",
      vertex.col="gray50",edge.lwd=1.5,
      edge.lty=line_pal[edge_cat])
```

Несмотря на то что программный код работает как надо, получившийся график не очень привлекателен и (по моему мнению) сложен в плане интерпретации. Различные типы линий должны использоваться осторожно и, вероятно, подходят только для очень небольших сетей с двумя различными типами линий. В большинстве графиков сетей используется цвет и, возможно, ширина линий для изображения различных типов связей.

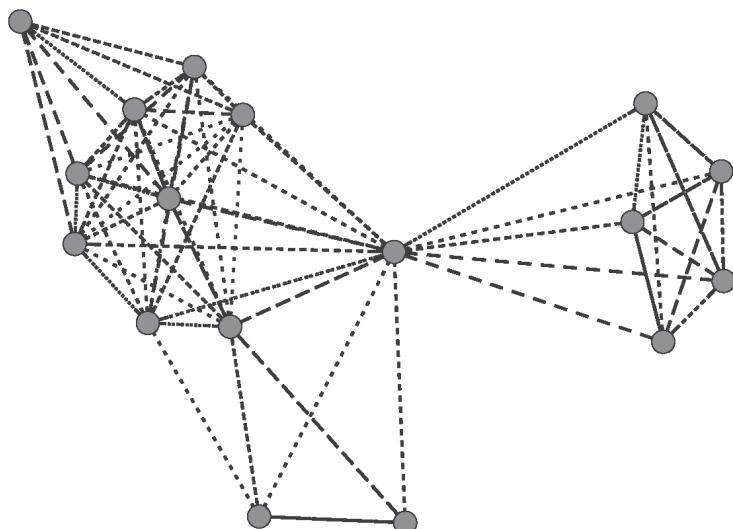


Рис. 5.16. Сеть Bali с различными типами связей

5.2.8. Легенды

Вышеприведенные примеры показывают, как графические элементы (цвет узла, форма узла, размер узла, тип ребра, ширина ребра) могут использоваться для отражения важных характеристик сети. Как и в случае с другими видами информационной графики, часто бывает полезно создать легенду, чтобы представленная информация стала понятна пользователю.

Базовые графические функции, имеющиеся в `statnet`, не могут автоматически создать легенду к графику. К счастью, чтобы добавить легенду к графику сети, можно просто воспользоваться функцией `legend()`, которая имеется в базовом пакете R. В примере, приведенном ниже, мы создаем копию графика, приведенного на рис. 5.5, но добавляем легенду, в которой в качестве ключа используется цвет узла. Кроме того, мы масштабируем размеры узлов, чтобы показать важность узла по степени центральности. См. `?legend` для получения более подробной информации о том, как использовать легенды. Фактически рис. 5.17 служит хорошим

примером тщательно спроектированного графика сети, который может использоваться в качестве итоговой диаграммы. Здесь используются размер узла, цвет узла и легенда, чтобы эффективно и четко отразить наиболее важную информацию, содержащуюся в сети Bali.

```
my_pal <- brewer.pal(5, "Dark2")
rolecat <- as.factor(get.vertex.attribute(Bali, "role"))
plot(Bali, vertex.cex=rescale(deg,1,5),
     vertex.col=my_pal[rolecat])
legend("bottomleft", legend=c("BM", "CT", "OA", "SB", "TL"),
       col=my_pal, pch=19, pt.cex=1.5, bty="n",
       title="Роль террориста")
```

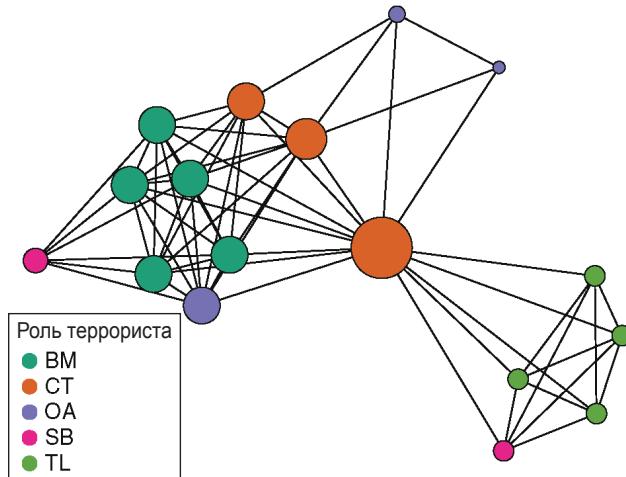


Рис. 5.17. Сеть Bali с легендой

Глава 6

Сложные графики сетей

6.1. Интерактивные графики сетей	84
6.2. Специализированные диаграммы сетей.....	88
6.3. Создание диаграмм сетей с помощью других пакетов R.....	95

Один глаз видит, другой чувствует.

Пауль Клее

Как было показано в двух предыдущих главах, `statnet` и `igraph` располагают широкими возможностями построения графиков, которые позволяют строить самые различные диаграммы сетей. Однако их графические функции не могут удовлетворить всех потребностей, связанных с анализом или визуализацией данных. В частности, специалистам по анализу сетей могут потребоваться более специализированные графики. Кроме того, хотя `statnet` и `igraph` как нельзя лучше подходят для построения высококачественных графиков, эти графики статичны. К счастью, появилась возможность строить графики сетей и отправлять их в веб-приложения, где пользователи могут уже самостоятельно настроить внешний вид диаграмм. В этой главе рассказывается о нескольких специализированных графиках сетей, а также в ней показано, как построить простые интерактивные веб-диаграммы сетей.

6.1. Интерактивные графики сетей

Одна из полезных настроек различных пакетов для анализа сетей, таких как UCINet и Pajek, – это возможность построить графики сетей, которые являются в некотором смысле интерактивными. Например, в Pajek визуализацию сети можно построить в отдельном окне **Draw**, а затем пользователь может воспользоваться этим окном, для того чтобы различными способами отредактировать или изменить график сети. Эти возможности позволяют исследовать сети, а также точно настроить диаграмму сети для последующей публикации.

Несмотря на то что программная платформа R предлагает детальную настройку всех элементов диаграммы, эта настройка, как правило, не осуществляется интерактивным способом. Существует несколько исключений, а также есть несколько новых пакетов, которые позволяют строить интерактивные графики сети с последующей публикацией в Интернете. В этом разделе мы расскажем о некоторых таких пакетах и функциях.

6.1.1. Простые интерактивные сети в `igraph`

Пакет `igraph` включает функцию `tkplot()`, которая поддерживает построение простых интерактивных графиков с помощью графического окна **Tk**. При этом можно изменить лишь некоторые настройки графиков сетей. Обычное использование этой функции заключается в построении интерактивного графика, корректировке позиций узлов для улучшения укладки сети, сохранении координат позиций узлов и построении итоговой (неинтерактивной) диаграммы сети на основе сохраненных координат. Этот рабочий поток показан ниже на примере сети Bali, см. главу 8 для знакомства с более детальным примером на основе этих данных.

```

library(intergraph)
library(igraph)
data(Bali)
iBali <- asIgraph(Bali)
Coord <- tkplot(iBali, vertex.size=3,
                 vertex.label=v(iBali)$role,
                 vertex.color="darkgreen")
# Редактируем график в графическом окне Tk, прежде чем
# запустить последующие две команды.
MCoords <- tkplot.getcoords(Coord)
plot(iBali, layout=MCoords, vertex.size=5,
      vertex.label=NA, vertex.color="lightblue")

```

6.1.2. Публикация интерактивных веб-диаграмм сетей

Вместо того чтобы строить интерактивные графики сетей в самом R, все больше людей начинают интересоваться построением интерактивных графиков, публикуемых в Интернете, с помощью фреймворков типа JavaScript-библиотеки D3 JavaScript (<http://d3js.org/>) и Shiny (<http://shiny.rstudio.com/>).

Ни одна из этих программ не приблизилась к тем возможностям, которые предоставляет такое полнофункциональное приложение для работы с графиками сетей, как Gephi. Однако я ожидаю, что в последующие несколько лет мы станем свидетелями бурного роста решений для визуализации сетей в Интернете, созданных на базе R.

Пакет networkD3 представляет собой небольшой набор функций, который можно использовать для создания простых интерактивных графиков сетей с последующей публикацией в shiny-совместимых документах (т. е. RStudio) или веб-страницах (html-документах). Программный код, приведенный ниже, показывает, как можно довольно просто построить интерактивный график. При выполнении команд в RStudio первые несколько строк отправляют график в окно **Viewer**. Функция `simpleNetwork()` работает с сетевыми данными в виде списка ребер, сохраненного в таблице данных. (Графические выводы для примеров в этом разделе не показаны, потому что для их просмотра требуется RStudio или веб-браузер.)

```

library(networkD3)
src <- c("A", "A", "B", "B", "C", "E")
target <- c("B", "C", "C", "D", "B", "C")
net_edge <- data.frame(src, target)
simpleNetwork(net_edge)

```

Чтобы сохранить интерактивный график сети в отдельный HTML-файл, используйте следующий программный код.

```

net_D3 <- simpleNetwork(net_edge)
saveNetwork(net_D3, file = 'Net_test1.html',
            selfcontained=TRUE)

```

Вывод функции `simpleNetwork` настолько прост, что в основном используется в качестве проверки или технической демонстрации. Чуть более сложный график сети можно получить с помощью функции `forceNetwork()`. Для этого примера мы снова воспользуемся сетью Bali. Данные должны быть переданы в функцию в двух таблицах данных. В таблице данных `Links` сетевые данные записаны в виде списка ребер. В таблице данных `Nodes` записаны идентификационные номера и свойства узлов. `Group` – категориальная группирующая переменная. Если узлы имеют числовые идентификаторы, они должны начинаться с 0. Таким образом, основная задача при работе с функцией `forceNetwork()` заключается в том, чтобы передать данные в правильном формате.

```
iBali_edge <- get.edgelist(iBali)
iBali_edge <- iBali_edge - 1
iBali_edge <- data.frame(iBali_edge)
iBali_nodes <- data.frame(NodeID=as.numeric(V(iBali))-1,
                           Group=V(iBali)$role,
                           Nodesize=(degree(iBali)))
forceNetwork(Links = iBali_edge, Nodes = iBali_nodes,
             Source = "X1", Target = "X2",
             NodeID = "NodeID", Nodesize = "Nodesize",
             radiusCalculation="Math.sqrt(d.nodesize)*3",
             Group = "Group", opacity = 0.8,
             legend=TRUE)
```

И снова результат можно сохранить во внешнем файле. Будьте внимательны, вы получите ошибку при попытке перезаписать уже существующий файл, даже если он не открыт в вашем браузере.

```
net_D3 <- forceNetwork(Links = iBali_edge,
                        Nodes = iBali_nodes,
                        Source = "X1", Target = "X2",
                        NodeID = "NodeID", Nodesize = "Nodesize",
                        radiusCalculation="Math.sqrt(d.nodesize)*3",
                        Group = "Group", opacity = 0.8,
                        legend=TRUE)
saveNetwork(net_D3,file = 'Net_test2.html',
            selfcontained=TRUE)
```

Пакет `visNetwork` является аналогичным набором инструментов, который для создания интерактивных веб-графиков сетей использует JavaScript-библиотеку `vis.js` (<http://visjs.org/>).

Этот пакет также требует, чтобы сетевые данные были записаны в таблице данных узлов и таблице данных ребер. Таблица данных узлов должна включать в себя столбец `id`, а таблица данных ребер – столбцы `from` и `columns`. Используя сеть Bali, программный код, приведенный ниже, создает данные и строит интерактивный график сети. Как и в предыдущем примере, этот программный код строит интерактивную сеть в окне **Viewer** программы RStudio.

```
library(visNetwork)
iBali_edge <- get.edgelist(iBali)
iBali_edge <- data.frame(from = iBali_edge[,1],
                         to = iBali_edge[,2])
iBali_nodes <- data.frame(id = as.numeric(V(iBali)))
visNetwork(iBali_nodes, iBali_edge, width = "100%")
```

Пакет visNetwork предлагает большое количество параметров, которые можно использовать, чтобы настроить внешний вид диаграммы сети, а также встроить график в веб-приложения Shiny. Посмотрите файл справки пакета для получения дополнительной информации, а также более развернутую информацию о его возможностях по адресу <http://dataknowledge.github.io/visNetwork/>. В программном коде, приведенном ниже, проиллюстрировано применение некоторых параметров.

```
iBali_nodes$group <- V(iBali)$role
iBali_nodes$value <- degree(iBali)
net <- visNetwork(iBali_nodes, iBali_edge,
                  width = "100%", legend=TRUE)
visOptions(net, highlightNearest = TRUE)
```

Во-первых, в таблицах данных nodes или edges хранится информация об узлах или ребрах. В переменной group хранится атрибут role, а переменная value используется для хранения информации о размерах узла (в данном случае степени). Функции visNetwork() и visOptions() используются для вывода сети, добавляют легенду на основе группирующей переменной, задают цвета по умолчанию для каждой группы и позволяют пользователю выделить отдельные узлы и их ближайших соседей с помощью щелчка по узлу.

Как и прежде, эти интерактивные диаграммы появляются в графическом окне, если используется RStudio. Как только график построен, его можно экспортirовать в отдельный html-файл или встроить в другие веб-приложения (например, Shiny). В заключительном примере показано, как сохранить график в отдельном веб-файле с помощью функции saveWidget() пакета htmlwidgets, который становится во время установки пакета visNetwork. Программный код, приведенный ниже, добавляет несколько кнопок навигации к итоговому графику сети, что позволяет перемещать сеть и менять ее масштаб.

```
net <- visNetwork(iBali_nodes, iBali_edge,
                  width = "100%", legend=TRUE)
net <- visOptions(net, highlightNearest = TRUE)
net <- visInteraction(net, navigationButtons = TRUE)
library(htmlwidgets)
saveWidget(net, "Net_test3.html")
```

6.1.3. Statnet Web: интерактивный statnet с помощью shiny

В качестве свидетельства бурного роста пакетов, предназначенных для построения интерактивных графиков сетей, можно привести тот факт, что команда раз-

работчиков Statnet недавно представила веб-версию своего пакета, созданного с помощью фреймворка для разработки веб-приложений shiny.

Statnet Web можно использовать, напрямую подключившись к серверу `shinyapps.io` по адресу `https://statnet.shinyapps.io/statnetWeb`. Кроме того, пакет можно запускать локально, установив пакет `statnetWeb`. Помимо создания базовых графиков с помощью параметров, выбираемых из выпадающих списков, `statnetWeb` может вывести различные статистические показатели сети, а также подогнать и протестировать экспоненциальные модели случайных графов (см. главу 11). Несмотря на то что, в отличие от программного подхода, `statnetWeb` не дает столь же убедительного контроля над результатами анализа сетей, этот пакет является отличной платформой для быстрого изучения характеристик сети и будет полезен для обучения, а также публикации результатов анализа сети.

```
library(statnetWeb)
run_sw()
```

6.2. Специализированные диаграммы сетей

Традиционно диаграммы сетей строятся для иллюстрации фундаментальных характеристик узлов и сети, например важности (см. главу 4). Однако существует ряд специализированных графиков, которые используются для выделения других значимых или интересных характеристик сетей. В этом разделе будут показаны три таких графика: дуговые диаграммы, хордовые диаграммы и теплокарты.

6.2.1. Дуговые диаграммы

Дуговые диаграммы (*arc diagrams*) могут использоваться, когда структура связей представляет больший интерес, чем расположение узлов в сети. Вот простой пример дуговой диаграммы, построенной с помощью пакета `arcdiagram`. Обратите внимание на то, что его нужно установить, воспользовавшись GitHub.

```
library(devtools)
install_github("gastonstat/arcdiagram")
```

Для этого примера нам нужно загрузить все необходимые библиотеки, затем создать объект (список ребер) для функции `arcplot()`. В этом примере мы воспользуемся набором данных `Simpsons`. Он представляет собой выдуманные сетьевые данные, которые отражают первичные взаимодействия между 15 героями телешоу «Симпсоны».

```
library(arcdiagram)
library(igraph)
library(intergraph)
data(Simpsons)
iSimp <- asIgraph(Simpsons)
simp_edge <- get.edgelist(iSimp)
```

Базовую дуговую диаграмму можно построить с помощью простого вызова функции (рис. 6.1).

```
arcplot(simp_edge)
```

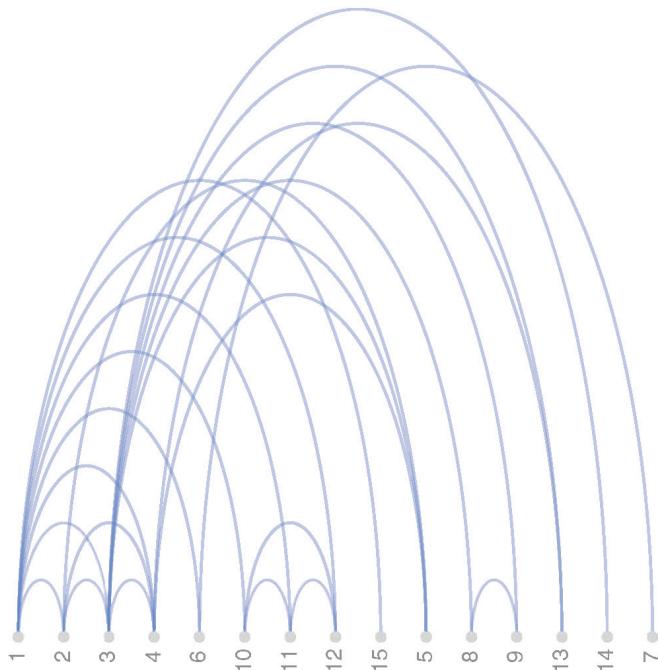


Рис. 6.1. Сеть контактов *Simpsons*

Дуговую диаграмму можно улучшить различными способами, чтобы выделить узлы и другие характеристики сети. Здесь мы задаем несколько подгрупп в сети (1 = семья, 2 = работа, 3 = школа, 4 = соседи) и используем цвета для идентификации групп (цвета взяты из палитры, размещенной на colorbrewer2.org). Кроме того, степень каждого узла используется для корректировки его размера (рис. 6.2).

```
s_grp <- V(iSimp)$group
s_col = c("#a6611a", "#dfc27d", "#80cdc1", "#018571")
cols = s_col[s_grp]
node_deg <- degree(iSimp)

arcplot(simp_edge, lwd.arcse=2, cex.nodes=node_deg/2,
        labels=V(iSimp)$vertex.names,
        col.labels="darkgreen", font=1,
        pch.nodes=21, line=1, col.nodes = cols,
        bg.nodes = cols, show.nodes = TRUE)
```

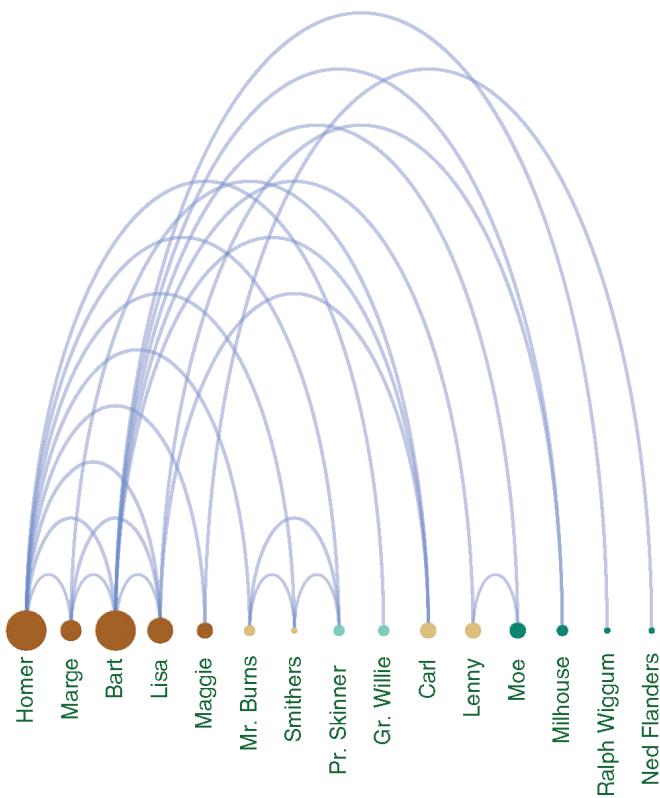


Рис. 6.2. Сеть контактов *Simpsons* – версия 2

6.2.2. Хордовые диаграммы

Хордовые диаграммы (*chord diagrams*) – это особый тип графика, в котором для отображения взаимосвязей между узлами используется круговая укладка. Они стали особенно популярными в генетических исследованиях. Поскольку информацию о сети можно хранить в матрице, хордовые диаграммы представляют интерес при построении графиков сетей. Особенно это верно для взвешенных (т. е. имеющих числовые значения) и направленных сетей, где сумма и направление «потоков» представляют интерес для исследователя.

В пакете *circlize*, разработанном Цзугуанем Гу (Zuguang Gu), реализованы различные круговые графики, включая хордовые диаграммы. Пакет имеет множество функций, предоставляя пользователю максимальные возможности по настройке внешнего вида графика. Рекомендуется ознакомиться с виньеткой *circular_visualization_of_matrix*, включенной в пакет.

В этом примере мы вернемся к сети игроков сборной Нидерландов, участвовавшей в Чемпионате мира по футболу FIFA 2010 года. Хотя на рис. 1.2 показана основная манера передачи мяча между одиннадцатью игроками команды, инфор-

мация о количестве передач мяча (хранится в атрибуте вершин `passes`) отсутствует. Мы построим хордовую диаграмму для более подробного исследования стиля игры.

Сперва нужно загрузить необходимые пакеты и подготовить данные. Главное требование заключается в том, что сетевые данные должны быть представлены в виде социоматрицы, в которой элементы соответствуют силе или размеру связи в том случае, если сеть содержит числовые значения. Кроме того, матрица должна содержать имена, присвоенные строкам и столбцам. (В этом примере мы работаем с матрицей $N \times N$, таким образом, для строк и столбцов имена будут одинаковыми. Кроме того, пакет `circlize` можно использовать для матриц $N \times k$, поэтому хордовые диаграммы еще применяются для анализа бимодальных сетей аффилированности, которые рассматриваются в главе 9.)

```
library(statnet)
library(circlize)
data(FIFA_Nether)
FIFAm <- as.sociomatrix(FIFA_Nether, attrname='passes')
names <- c("GK1", "DF3", "DF4", "DF5", "MF6",
          "FW7", "FW9", "MF10", "FW11", "DF2", "MF8")
rownames(FIFAm) = names
colnames(FIFAm) = names
FIFAm

##      GK1 DF3 DF4 DF5 MF6 FW7 FW9 MF10 FW11 DF2 MF8
## GK1    0  42  67  21   2  27   7   5    2  17   3
## DF3   30   0  44  14  42  15   8   7   10  36  29
## DF4   38  43   0  57  18  11   7  21   1   7  28
## DF5    6  14  47   0  11  50  20  40   1   4  42
## MF6    9  28  25  10   0  41  28  37  14  34  21
## FW7    4  12   1  21  21   0  15  33   9  25  18
## FW9    0   0   1   8   7  12   0  31  16   7   2
## MF10   1  11  11  22  43  29  20   0  28  13  21
## FW11   3   2   2   3   7   6  11  15   0  21  12
## DF2   29  38   8   3  45  38  10  18  26   0  15
## MF8   12  25  26  38  23  13  12  32  11  24   0
```

Взглянув на социоматрицу, мы видим довольно много связей с низким количеством передач мяча. Чтобы построить удобный в плане интерпретации график, мы исключим все связи с количеством передач меньше 10.

```
FIFAm[FIFAm < 10] <- 0
FIFAm

##      GK1 DF3 DF4 DF5 MF6 FW7 FW9 MF10 FW11 DF2 MF8
## GK1    0  42  67  21   0  27   0   0    0  17   0
## DF3   30   0  44  14  42  15   0   0   10  36  29
## DF4   38  43   0  57  18  11   0  21   0   0  28
## DF5    0  14  47   0  11  50  20  40   0   0  42
```

## MF6	0	28	25	10	0	41	28	37	14	34	21
## FW7	0	12	0	21	21	0	15	33	0	25	18
## FW9	0	0	0	0	0	12	0	31	16	0	0
## MF10	0	11	11	22	43	29	20	0	28	13	21
## FW11	0	0	0	0	0	0	11	15	0	21	12
## DF2	29	38	0	0	45	38	10	18	26	0	15
## MF8	12	25	26	38	23	13	12	32	11	24	0

Получив социоматрицу с присвоенными именами, хордовую диаграмму можно построить с помощью простого вызова функции `chordDiagram()` (рис. 6.3).

`chordDiagram(FIFAm)`

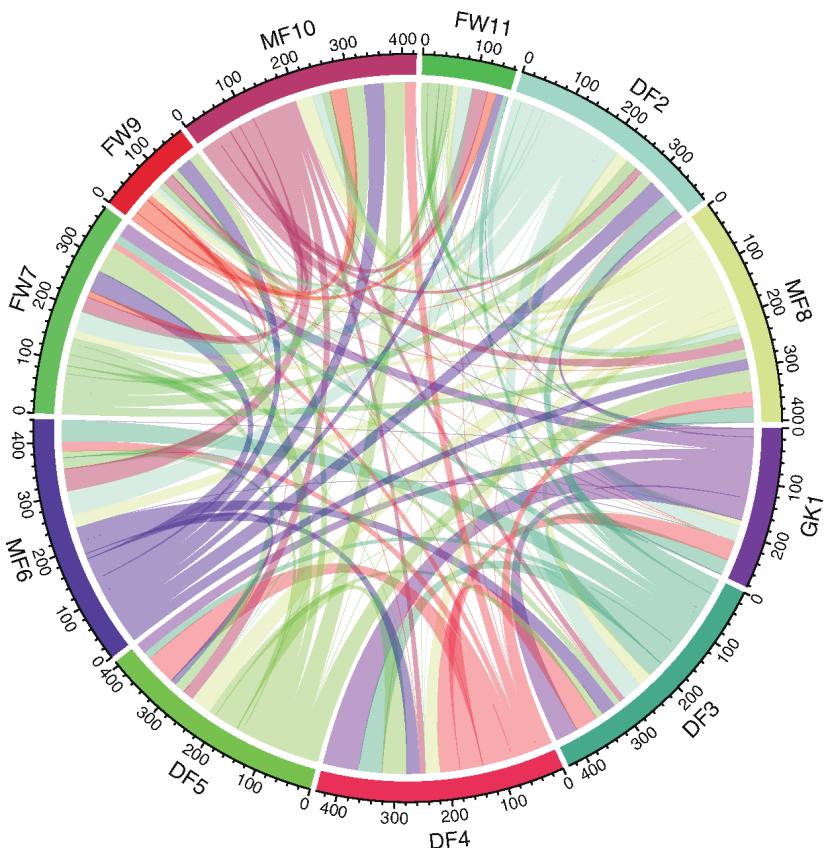


Рис. 6.3. Хордовая диаграмма для сети игроков сборной Нидерландов по футболу 2010 года, используются параметры по умолчанию

Хордовые диаграммы могут содержать большой объем информации, особенно когда речь идет о построении крупных сетей, поэтому важно настроить график так, чтобы выделить самую важную информацию. График, приведенный ниже, по-

строен с помощью нескольких параметров, немного упрощающих интерпретацию диаграммы. Во-первых, цвета выбраны так, что игрокам, занимающим определенную позицию (нападающим, полузащитникам и т. д.), присваивается одинаковый цвет. Сеть является направленной: если игрок А передает мяч игроку В, это вовсе не означает, что игрок В должен передать мяч игроку А. Параметр `directional` используется так, чтобы исходящие пасы располагались подальше от внешнего круга, тем самым подчеркнув разницу между отправленными и полученными пасами. Наконец, параметр `order` используется для упорядочения игроков по их позициям.

```
grid.col <- c("#AA3939", rep("#AA6C39", 4),
rep("#2D882D", 3), rep("#226666", 3))
chordDiagram(FIFAm,directional = TRUE,
            grid.col = grid.col,
            order=c("GK1","DF2","DF3","DF4","DF5",
                   "MF6","MF8","MF10","FW7",
                   "FW9","FW11"))
```

На получившейся хордовой диаграмме (рис. 6.4) намного легче увидеть различные манеры передач мяча, используемые игроками. Мы видим, что FW7 получает более чем в 2 раза больше передач, чем два остальных нападающих. Аналогично мы видим, что вратарь чаще всего передает мяч DF4, а DF4 предпочитает передавать мяч DF5.

6.2.3. Теплокарты для сетевых данных

Теплокарты – еще один пример специализированного графика, который можно использовать для визуализации сети, особенно когда речь идет о сети с числовыми значениями (т. е. взвешенной сети). В данном случае теплокарта строится, чтобы выделить игроков, которые передают или получают наибольшее количество пасов в команде.

Сначала создаем социоматрицу, где в ячейках записывается вес связи, в данном случае «передачи». Имена строк и столбцов задаются в качестве меток.

```
data(FIFA_Nether)
FIFAm <- as.sociomatrix(FIFA_Nether,attrname='passes')
colnames(FIFAm) <- c("GK1","DF3","DF4","DF5",
                      "MF6","FW7","FW9","MF10",
                      "FW11","DF2","MF8")
rownames(FIFAm) <- c("GK1","DF3","DF4","DF5",
                      "MF6","FW7","FW9","MF10",
                      "FW11","DF2","MF8")
```

Как только данные созданы, построить теплокарту не составляет труда (рис. 6.5). Функция `colorRampPalette()` задает цветовой диапазон, который будет

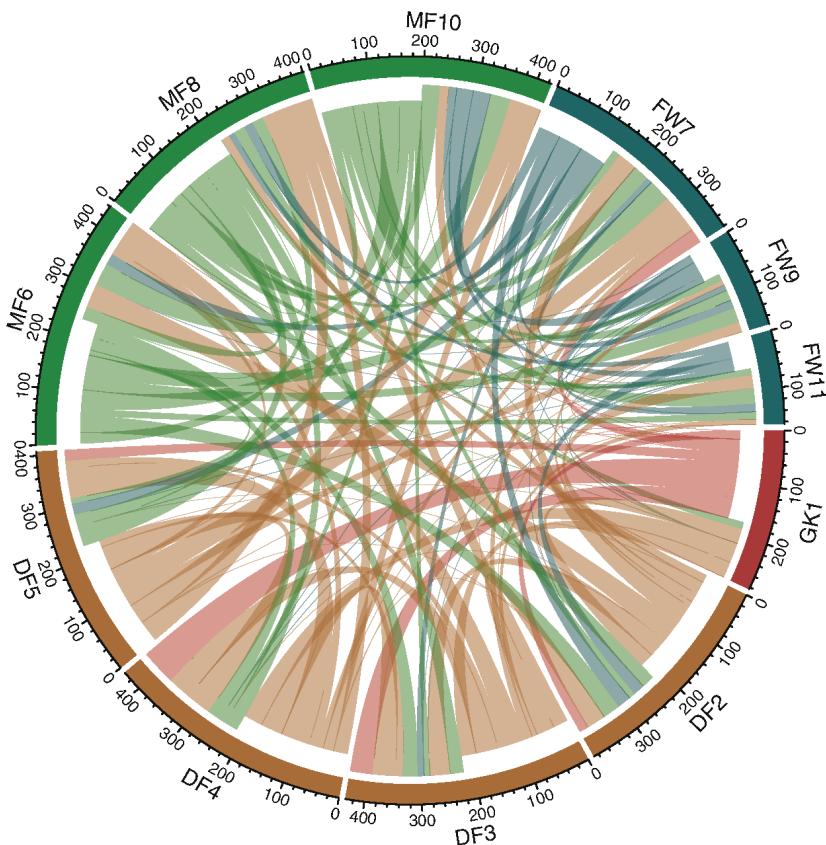


Рис. 6.4. Хордовая диаграмма для сети игроков сборной Нидерландов по футболу 2010 года, используются специальные параметры

использоваться для нижних и верхних уровней значений социоматрицы. (Цветовые диапазоны, использованные здесь, были получены с помощью генератора палитр, расположенного по адресу paletton.com.) Сеть является направленной, поэтому важно помнить, что здесь строки – это «игроки, отправляющие пасы», а столбцы – «игроки, получающие пасы».

```
palf <- colorRampPalette(c("#669999", "#003333"))
heatmap(FIFAm[,11:1],Rowv = NA,Colv = NA,col = palf(60),
       scale="none", margins=c(11,11) )
```

Кроме того, теплоКарта показывает те же самые манеры передачи мяча, что и рис. 6.4. Наиболее темный квадрат – это пасы от вратаря к DF4.

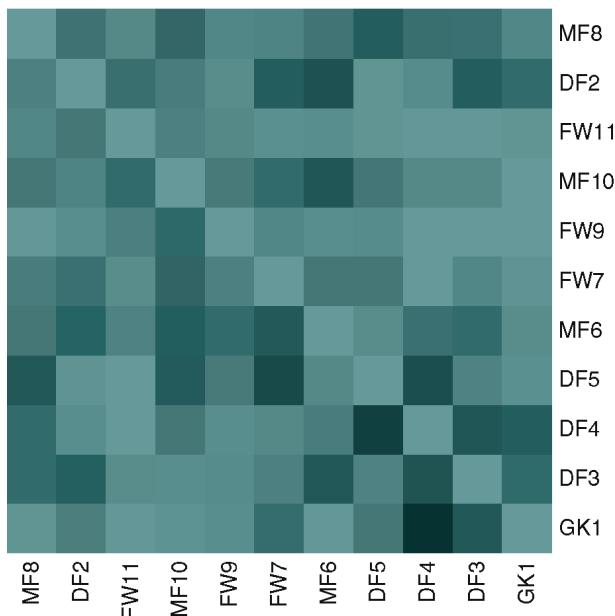


Рис. 6.5. Терлокарта для сети игроков сборной Нидерландов по футболу 2010 года, интенсивность цвета соответствует количеству пасов

6.3. Создание диаграмм сетей с помощью других пакетов R

6.3.1. Построение диаграмм сетей с помощью `ggplot2`

Несмотря на то что `ggplot2` не отвечает всем требованиям, которые предъявляются к полноценному пакету для визуализации сетей, некоторые его возможности можно использовать для создания специальных процедур построения графиков сетей. Пример, приведенный ниже, опирается на программный код, написанный Дэвидом Спарксом, и размещен в блоге *is.R()* (<http://is-r.tumblr.com>), который Дэвид ведет вместе с Кристофером Десанте¹.

Функция `edgeMaker()` и вспомогательный программный код позволяют создать привлекательные и функциональные графики направленных сетей, используя изогнутые ребра. Основной объем работы выполняет функция `edgeMaker()`, которая создает изогнутые связи между каждой парой узлов.

```
edgeMaker <- function(whichRow, len=100, curved = TRUE) {
  fromC <- layoutCoordinates[adjacencyList[whichRow, 1], ]
```

¹ Приведенный ниже программный код дан автором для общего ознакомления, указанная последовательность команд не приведет к построению графика, поэтому рекомендуем подробно ознакомиться с программным кодом в указанном блоге. – *Прим. пер.*

```

toC <- layoutCoordinates[adjacencyList[whichRow, 2], ]
graphCenter <- colMeans(layoutCoordinates)
bezierMid <- c(fromC[1], toC[2])
distance1 <- sum((graphCenter - bezierMid)^2)
if(distance1 < sum((graphCenter - c(toC[1],
                                    fromC[2]))^2)){
  bezierMid <- c(toC[1], fromC[2])
}
bezierMid <- (fromC + toC + bezierMid) / 3
if(curved == FALSE){bezierMid <- (fromC + toC) / 2}

edge <- data.frame(bezier(c(fromC[1], bezierMid[1],
                            toC[1]),
                            c(fromC[2], bezierMid[2],
                            toC[2]),
                            evaluation = len))
edge$Sequence <- 1:len
edge$Group <- paste(adjacencyList[whichRow, 1:2],
                     collapse = ">")
return(edge)
}

```

Помимо основных пакетов sna и ggplot2, используется пакет Hmisc. Он содержит функцию `bezier()`, используемую `edgeMaker`.

```

library(sna)
library(ggplot2)
library(Hmisc)

```

Как мы уже знаем из предыдущих примеров в этой главе, типичный подход заключается в том, чтобы перед использованием графических функций преобразовать сетевые данные в список ребер. В данном примере мы снова исключим связи, которые имеют вес пасов менее 10. Функция `edgeMaker` ожидает объект-список ребер `adjacencyList`.

```

data(FIFA_Nether)
fifa <- FIFA_Nether
fifa.edge <- as.edgelist.sna(fifa, attrname='passes')
fifa.edge <- data.frame(fifa.edge)
names(fifa.edge)[3] <- "value"
fifa.edge <- fifa.edge[fifa.edge$value > 9,]
adjacencyList <- fifa.edge

```

Теперь мы воспользуемся `edgeMaker` для создания изогнутых ребер. Кроме того, вызываем один раз функцию `gplot` (из пакета `sna`), чтобы сохранить координаты укладки для функции `ggplot2`. (Это означает, что в `ggplot2` можно передать любой набор координат.)

```
layoutCoordinates <- gplot(network(fifa.edge))
allEdges <- lapply(1:nrow(fifa.edge),
                    edgeMaker, len = 500, curved = TRUE)
allEdges <- do.call(rbind, allEdges)
```

Перед тем как построить график, мы создаем пустую тему `ggplot2`. Он используется, чтобы сбросить настройки после построения графика.

```
new_theme_empty <- theme_bw()
new_theme_empty$line <- element_blank()
new_theme_empty$rect <- element_blank()
new_theme_empty$strip.text <- element_blank()
new_theme_empty$axis.text <- element_blank()
new_theme_empty$plot.title <- element_blank()
new_theme_empty$axis.title <- element_blank()
new_theme_empty$plot.margin <- structure(c(0,0,-1,-1),
                                         unit = "lines",
                                         valid.unit = 3L,
                                         class = "unit")
```

И теперь последний шаг состоит в том, чтобы создать график с помощью `ggplot()`. Знакомство с `ggplot2` поможет понять этот программный код. Параметр `scale_colour_gradient` задает интенсивность градиента, а параметр `scale_size` задает величину уклона (рис. 6.6).

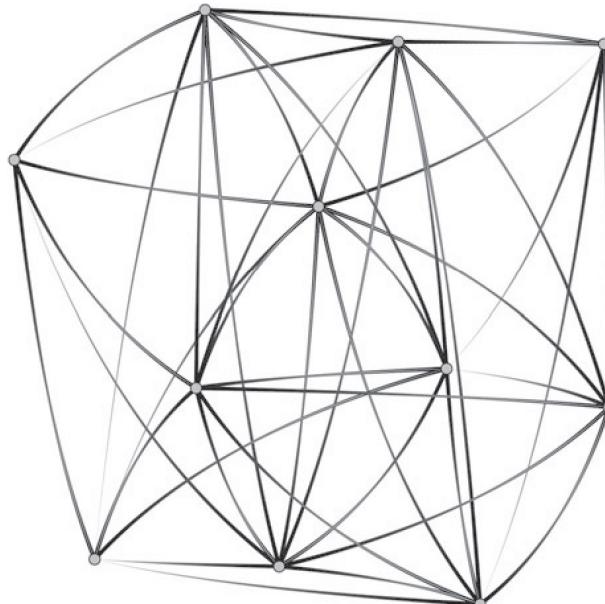


Рис. 6.6. Сеть игроков сборной Нидерландов по футболу 2010 года с изогнутыми связями

```
zp1 <- ggplot(allEdges)
zp1 <- zp1 + geom_path(aes(x = x, y = y, group = Group,
                           colour=Sequence, size=-Sequence))
zp1 <- zp1 + geom_point(data =
                         data.frame(layoutCoordinates),
                        aes(x = x, y = y),
                        size = 4, pch = 21,
                        colour = "black", fill = "gray")
zp1 <- zp1 + scale_colour_gradient(low = gray(0),
                                    high = gray(9/10),
                                    guide = "none")
zp1 <- zp1 + scale_size(range = c(1/10, 1.5),
                        guide = "none")
zp1 <- zp1 + new_theme_empty
print(zp1)
```

ЧАСТЬ III

ОПИСАНИЕ И АНАЛИЗ

Глава 7. Важность актора	100
Глава 8. Подгруппы	114
Глава 9. Сети аффилированности ...	133

Глава 7

Важность актора

7.1. Введение	101
7.2. Центральность – показатель важности для ненаправленных сетей.....	101
7.3. Точки сочленения и мосты.....	111

...Мы теперь связаны с людьми, связанными с тобой, и вынуждены продолжать участие в этой авантюре согласно правилам приличия.

Жан Жене

7.1. Введение

Сети интересны своими паттернами взаимосвязей и тем, как эти паттерны влияют на участников сети. Попросту говоря, влияние участника зависит от его расположения в сети. Человек, который связан с большим количеством других участников сети, вероятно, будет воспринимать остальных участников сети совершенно по-другому, нежели человек, который относительно изолирован от других участников.

Анализ сетей предлагает множество инструментов для просмотра, анализа и оценки позиций отдельных узлов и связей. Как правило, эти процедуры представляют собой первый этап анализа, который выполняется сразу после получения сетевых данных, если не рассматривать простое описание сети.

Изучив расположение участников отдельной сети, мы можем оценить *prominence* (*важность*)¹ этих участников. Актор является важным, если связи актора делают его видимым для других участников сети [Knoke, Burt, 1983]. В оставшейся части этой главы мы расскажем о наиболее распространенных методах оценки важности участника сети. Применительно к ненаправленным сетям мы разберем понятие *центральность* (*centrality*), где в качестве центрального актора мы рассматриваем актора, который вовлечен в большое количество связей (прямых или косвенных). Применительно к направленным сетям важность, как правило, называют *престижем* (*prestige*). Престижный актор – это актор, характеризующийся большим количеством входящих связей. Кроме того, в этой главе будет рассказано, как меры центральности и престижа, вычисленные для конкретных узлов, можно агрегировать в меры *централизации* (*centralization*) для сети в целом. Мы приведем пример того, как подготавливать результаты анализа важности. Наконец, мы кратко поговорим об определении точек сочленения и мостов в сетях. С технической точки зрения, они не являются мерами важности, но являются простыми характеристиками местоположения отдельных узлов или связей и поэтому вполне органично вписываются в тему этой главы.

7.2. Центральность – показатель важности для ненаправленных сетей

Интуитивно понятно, что участник сети, который связан с большим количеством участников сети, является важным (занимает выдающееся положение). Применительно к ненаправленным сетям мы будем говорить, что данный актор имеет высокую центральность или занимает центральное положение. При этом существу-

¹ В качестве синонима также употребляется термин «выдающееся положение». – *Прим. пер.*

ет ряд способов измерить данный тип важности. На самом деле в распоряжении специалиста по анализу сетей имеются десятки показателей центральности.

Чтобы увидеть, как можно получить различные меры центральности, обратимся к сети, показанной на рис. 7.1 и построенной на основе простой социоматрицы `net_mat`.

```
##  a b c d e f g h i j
## a 0 1 1 0 0 0 0 0 0 0
## b 1 0 1 0 0 0 0 0 0 0
## c 1 1 0 1 1 0 1 0 0 0
## d 0 0 1 0 1 0 0 0 0 0
## e 0 0 1 1 0 1 0 0 0 0
## f 0 0 0 0 1 0 1 0 0 0
## g 0 0 1 0 0 1 0 1 0 0
## h 0 0 0 0 0 0 1 0 1 1
## i 0 0 0 0 0 0 0 1 0 0
## j 0 0 0 0 0 0 0 1 0 0
```

Какой узел является самым центральным? Узлы *c* и *g* расположены в центре графика, но, как мы уже узнали из главы 4, расположение узлов может иметь, а может и не иметь никакого конкретного смысла. Однако узел *c* напрямую соединен с гораздо большим количеством участников сети, чем какой-либо другой узел, поэтому в этом смысле мы можем рассматривать *c* в качестве центрального узла. С другой стороны, узел *g* хоть и не имеет столь же большого количества прямых связей, но зато расположен таким образом, что соединяет две различные части сети. В частности, единственный путь, по которому информация от узлов *h*, *i* и *j* может быть передана остальной части сети, лежит через узел *g*. Наконец, даже несмотря на то, что узел *g* напрямую соединен лишь с тремя узлами, он расположен так, что находится достаточно близко к любому узлу сети. В частности, из узла *g* можно перейти в любой узел, сделав только один или два шага. То есть узел *g* соединен с остальной частью сети путями длиной 1 или 2. Поэтому, учитывая два вышеупомянутых аспекта, узел *g* также может считаться центральным узлом.

В следующих трех разделах мы расскажем о трех наиболее часто используемых мерах центральности.

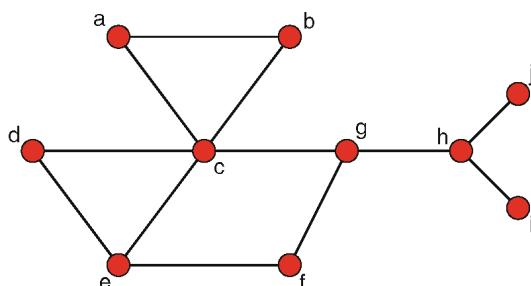


Рис. 7.1. Пример графика сети для иллюстрации различной трактовки важности узла

7.2.1. Три популярные меры центральности

7.2.1.1. Центральность по степени

Безусловно, самая простая мера центральности основывается на представлении о том, что узел, имеющий большее количество прямых связей, является более важным, чем узлы с меньшим количеством связей или узлы без связей. Таким образом, *центральность по степени* (*degree centrality*)¹ – это просто степень каждого узла. В первый раз мы рассказывали о степени узла в главе 2. Степень узла – это количество связей, которые соединяют данный узел с другими узлами сети.

Согласно [Wasserman, Faust, 1994], степень центральности определяется формулой:

$$C_D(n_i) = d(n_i).$$

Сеть, показанная на рис. 7.1, настолько проста, что мы можем подсчитать степени узлов вручную. Однако сейчас мы покажем, как можно вычислить степень центральности в statnet, предположив, что работаем с данными, сохраненными в объекте-сети под названием `net`. Если вы работаете в режиме продолжения, перед запуском программного кода не забудьте отсоединить пакеты `arcdiagram` и `igraph`.

```
library(statnet)
net_mat <- rbind(c(0,1,1,0,0,0,0,0,0),
                  c(1,0,1,0,0,0,0,0,0),
                  c(1,1,0,1,1,0,1,0,0),
                  c(0,0,1,0,1,0,0,0,0),
                  c(0,0,1,1,0,1,0,0,0),
                  c(0,0,0,1,0,1,0,0,0),
                  c(0,0,1,0,0,1,0,1,0),
                  c(0,0,0,0,0,0,1,0,1),
                  c(0,0,0,0,0,0,0,1,0),
                  c(0,0,0,0,0,0,0,1,0))
rownames(net_mat) <- c("a", "b", "c", "d", "e", "f", "g", "h", "i", "j")
colnames(net_mat) <- c("a", "b", "c", "d", "e", "f", "g", "h", "i", "j")
net <- network(net_mat, matrix.type="adjacency")
net %v% 'vertex.names'
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j"
degree(net, gmode="graph")
## [1] 2 2 5 2 3 2 3 3 1 1
```

Вначале создаем на основе социоматрицы `net_mat` объект-сеть `net`. Функция `degree()` вычисляет и возвращает значения степени центральности для каждого узла. Параметр `gmode` сообщает функции, что объект-сеть нужно обрабатывать как ненаправленную сеть (`graph`). (Этот параметр должен использоваться, даже если сеть создана и сохранена как ненаправленная.)

¹ В качестве синонима также употребляется термин «степень центральности». – Прим. пер.

Результаты подтверждают все сказанное нами выше. Узел c имеет самую высокую степень центральности. Он соединен с пятью узлами, и этот показатель самый высокий среди узлов сети.

7.2.1.2. Центральность по близости

Вместо того чтобы исследовать только прямые соединения узлов, мы можем сфокусироваться на том, насколько близко узел расположен к остальным узлам сети. Это приводит нас к понятию *центральность по близости (closeness centrality)*, где более важными узлами считаются узлы, наиболее близкие к остальным узлам сети. Ниже приводится уравнение для центральности по близости, которое выглядит сложнее, чем предыдущее:

$$C_c(n_i) = \left[\sum_{j=1}^g d(n_i, n_j) \right]^{-1},$$

где d является расстоянием пути между двумя узлами. Центральность по близости – это величина, обратная сумме расстояний от узла i до всех остальных узлов сети.

```
closeness(net, gmode="graph")
## [1] 0.409 0.409 0.600 0.429 0.450 0.450 0.600
## [8] 0.474 0.333 0.333
```

Эта сводка сообщает нам, что узлы c и g имеют наибольшие значения центральности по близости.

7.2.1.3. Центральность по посредничеству

Центральность по посредничеству (betweenness centrality) характеризует, насколько важную роль данный узел играет на путях «между» парами других узлов сети, в том смысле, что пути между другими узлами должны проходить через данный узел. Узел с наибольшим значением центральности по посредничеству является важным, потому что данный узел позволяет отслеживать или контролировать поток информации в сети. Уравнение для центральности по посредничеству выглядит так:

$$C_B(n_i) = \sum_{j < k} g_{jk}(n_i) / g_{jk},$$

где g_{jk} – это геодезическое расстояние между узлами j и k . (Геодезическое расстояние – это кратчайший путь между двумя узлами.) $g_{jk}(n_i)$ – это количество геодезических расстояний между узлами j и k , которые включают узел i .

```
betweenness(net, gmode="graph")
## [1] 0.0 0.0 20.0 0.0 2.5 2.0 19.5 15.0 0.0
## [10] 0.0
```

Эта сводка показывает, что узел c имеет наибольшее значение центральности по посредничеству, за ним с небольшим отрывом следуют узлы g и h . Эти прос-

тые примеры показывают, что различные меры центральности отражают разные аспекты важности узлов в сети.

7.2.2. Меры центральности в R

R может вычислить множество различных мер центральности и престижа. Посмотрите соответствующую таблицу, в которой приводится список метрик, включенных на данный момент в *statnet* и *igraph* (табл. 7.1).

Как мы видим, R предлагает самые разнообразные способы исследования центральности и престижа отдельных узлов сети. Выбор конкретной меры центральности или престижа отчасти зависит от типа сетевых данных (в частности, от того, является сеть направленной или нет). Однако, как уже было сказано в разделе 7.2.1, выбор прежде всего должен зависеть от того, какой тип информации мы хотим получить, задав меру важности.

При этом также полезно помнить, что во многих реальных социальных сетях значения различных мер центральности и престижа могут дублироваться. Узлы, которые идентифицированы как узлы с высокими значениями *центральности по собственному вектору* (*eigenvector centrality*), вероятно, другими метриками также будут идентифицированы как центральные, особенно если эти метрики тесно связаны с центральностью по собственному вектору (например, индекс силы Боначича). Мы можем проиллюстрировать это, показав корреляции значений мер центральности, использующихся в *statnet* и вычисленных для сети DHHS.

Таблица 7.1. Меры центральности, использующиеся в statnet и igraph

Меры центральности	statnet	igraph
Degree (По степени)	degree()	degree()
Closeness (По близости)	closeness()	closeness()
Betweenness (По посредничеству)	betweenness()	betweenness()
Eigenvector (По собственному вектору)	evcent()	evcent()
Bonacich power (По индексу силы Боначича)	bonpow()	bonpow()
Flow betweenness (По потоковому посредничеству)	flowbet()	
Load (По нагрузке)	loadcent()	
Information (По информации)	infocent()	
Stress (По стрессу)	stresscent()	
Harary graph (По графу Харари)	graphcent()	
Bonacich alpha (По альфе Боначича)		alpha.centrality()
Kleinberg authority (По авторитетности Кляйнберга)		auth.score()
Kleinberg hub (По концентрации Кляйнберга)		hub.score()
PageRank		page.rank()

```
library(UserNetR)
data(DHHS)
df.prom <- data.frame(
  deg = degree(DHHS),
  cls = closeness(DHHS),
  btw = betweenness(DHHS),
```

```

evc = evcent(DHHS),
inf = infocent(DHHS),
flb = flowbet(DHHS)
)

cor(df.prom)

##      deg    cls   btw   evc   inf   flb
## deg 1.000 0.973 0.750 0.972 0.902 0.944
## cls 0.973 1.000 0.787 0.934 0.890 0.941
## btw 0.750 0.787 1.000 0.600 0.485 0.884
## evc 0.972 0.934 0.600 1.000 0.940 0.843
## inf 0.902 0.890 0.485 0.940 1.000 0.773
## flb 0.944 0.941 0.884 0.843 0.773 1.000

```

7.2.3. Централизация: вычисление индексов центральности для сети в целом

Центральность и престиж – это характеристики узлов, основанные на расположении узла в сети. Изменчивость значений центральности, вычисленных для отдельных узлов, может быть очень информативной. Например, рассмотрим два крайних примера, приведенных ниже: звездчатый граф и круговой граф (рис. 7.2).

```

library(RColorBrewer)
dum1 <- rbind(c(1,2),c(1,3),c(1,4),c(1,5))
star_net <- network(dum1,directed=FALSE)
dum2 <- rbind(c(1,2),c(2,3),c(3,4),c(4,5),c(5,1))
circle_net <- network(dum2,directed=FALSE)
par(mar=c(4,4,.1,.1))
my_pal <- brewer.pal(5,"Set2")
gplot(star_net,usearrows=FALSE,displaylabels=FALSE,
      vertex.cex=2,
      vertex.col=my_pal[1],
      edge.lwd=0,edge.col="grey50",xlab="Звездчатый граф")
gplot(circle_net,usearrows=FALSE,displaylabels=FALSE,
      vertex.cex=2,
      vertex.col=my_pal[3],
      edge.lwd=0,edge.col="grey50",xlab="Круговой граф")

```

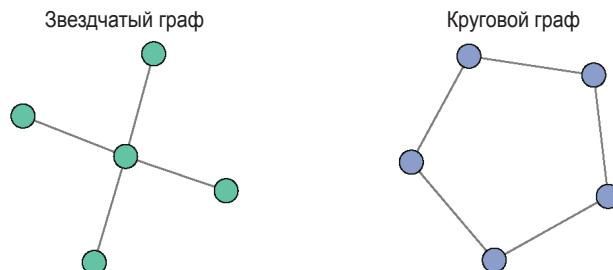


Рис. 7.2. Крайние примеры централизации

В statnet централизация вычисляется с помощью функции `centralization()`. Функция `centralization()` принимает в качестве аргументов объект-сеть, функцию центральности или престижа и возвращает соответствующее значение централизации для сети в целом. Обратите внимание на то, что вопреки своему названию и информации, представленной в файле справки для этой функции, `centralization()` может использоваться для направленных графов.

В примере с круговым графом мы видим, что каждый узел имеет одинаковое значение центральности, что ведет к получению минимального значения централизации. Звездчатый граф иллюстрирует противоположную ситуацию, когда высокий разброс значений центральности, вычисленных для конкретных узлов, приводит к получению более высокого значения централизации.

```
closeness(circle_net)
## [1] 0.667 0.667 0.667 0.667 0.667
centralization(circle_net,closeness)
## [1] 0
closeness(star_net)
## [1] 1.000 0.571 0.571 0.571 0.571
centralization(star_net,closeness)
## [1] 0.536
```

7.2.4. Создание отчетов по центральности

Все функции центральности и престижа в statnet (а также в `igraph`) создают вектор значений, по одному значению для каждого узла. На примере сети Bali мы видим, что центральность довольно сильно варьирует для различных участников сети.

```
data(Bali)
str(degree(Bali))
## num [1:17] 18 8 18 30 18 20 6 18 18 10 ...
summary(degree(Bali))
##      Min.   1st Qu.   Median   Mean   3rd Qu.   Max.
##      6.0     10.0    18.0   14.8    18.0   30.0
```

Эти значения можно исследовать по отдельности, однако для анализа и создания отчетов, как правило, более информативным способом является исследование тех или иных аспектов важности узлов с помощью различных мер важности и даже различных укладок сетей. В этом разделе мы более детально проанализируем центральность акторов на примере сети Bali (рис. 7.3).

```
data(Bali)
my_pal <- brewer.pal(5,"Set2")
rolecat <- Bali %v% "role"
```

```
gplot(Bali,usearrows=FALSE,displaylabels=TRUE,
      vertex.col=my_pal[as.factor(rolecat)],
      edge.lwd=0,edge.col="grey25")
legend("topright",legend=c("BM","CT","OA","SB",
      "TL"),col=my_pal,pch=19,pt.cex=2)
```

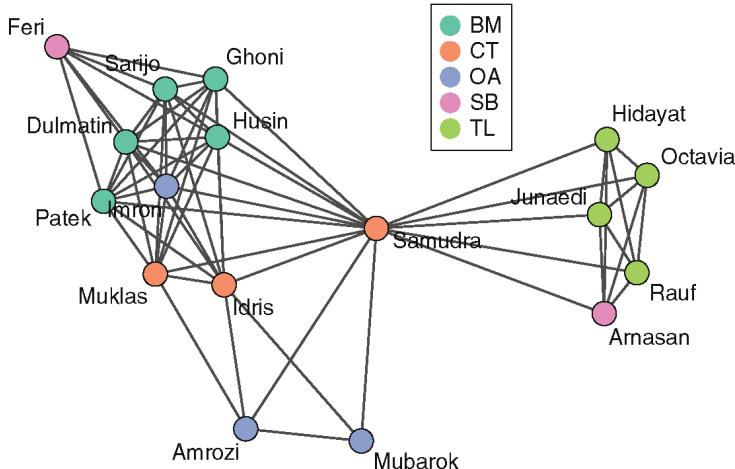


Рис. 7.3. Взаимодействие между участниками сети Bali

Если сеть небольшая, полезно исследовать значения важности, вычисленные для конкретных узлов. В табл. 7.2 для каждого узла приводятся значения трех популярных мер центральности: по степени, по близости и по промежуточности.

```
data(Bali)
df.prom2 <- data.frame(
  degree = degree(Bali),
  closeness = closeness(Bali),
  betweenness = betweenness(Bali)
  )
row.names(df.prom2) <- Bali %v% "vertex.names"
df.promsort <- df.prom2[order(-df.prom2$degree),]
cd <- centralization(Bali,degree)
cc <- centralization(Bali,closeness)
cb <- centralization(Bali,betweenness)
df.promsort <- rbind(df.promsort,c(cd,cc,cb))
row.names(df.promsort)[18] <- "\u2022\emph{Centralization}"
```

Таблица 7.2. Центральность 17 участников сети Bali

	Центральность по степени	Центральность по близости	Центральность по посредничеству
Samudra	30,00	0,94	122,33
Idris	20,00	0,73	12,33
Muklas	18,00	0,70	4,67

Таблица 7.2 (окончание)

	Центральность по степени	Центральность по близости	Центральность по посредничеству
Imron	18,00	0,70	3,33
Dulmatin	18,00	0,70	3,33
Husin	18,00	0,70	3,33
Ghoni	18,00	0,70	3,33
Patek	18,00	0,70	3,33
Sarijo	18,00	0,70	3,33
Feri	12,00	0,48	0,00
Arnasan	10,00	0,57	0,00
Rauf	10,00	0,57	0,00
Octavia	10,00	0,57	0,00
Hidayat	10,00	0,57	0,00
Junaedi	10,00	0,57	0,00
Amrozi	8,00	0,55	0,67
Mubarok	6,00	0,53	0,00
Централизация	0,54	0,33	0,50

Как уже рассказывалось в главе 5, размеры узлов можно настроить в соответствии с любой количественной характеристикой актора. Это может быть внешняя информация, например возраст или вес. Применительно к сети Bali более целесообразно использовать информацию самой сети, в данном случае значения центральности, вычисленные для каждого узла.

Это легко можно сделать с помощью параметров, отвечающих за построение графиков. Фактически в функцию `gplot()` нужно передать всего лишь один дополнительный параметр (`vertex.sex`). Этот параметр может быть константой, в данном случае он просто настраивает общий размер каждой вершины в графике. Однако вы можете также передать вектор числовых значений. Все меры важности, вычисляемые для конкретных узлов, возвращают числовой вектор, поэтому его можно использовать для масштабирования размера узла в зависимости от центральности или престижа.

Единственная сложность состоит в том, что когда R считывает исходные числовые значения, переданные в `vertex.sex`, эти числа нередко бывают слишком маленькими или слишком большими. Как правило, необходимо подобрать определенный коэффициент масштабирования, чтобы построить легко интерпретируемый график. (См. главу 5, где более подробно рассказывается о настройке и масштабировании размеров узлов.) Два графика, изображенных ниже, иллюстрируют это. Во-первых, для сети Bali вычисляется нормализованная центральность по степени (опция `rescale=TRUE`). Исходные значения степени масштабируются так, чтобы все они находились в диапазоне от 0 до 1. Первый график показывает, что нормализованные значения степени являются слишком маленькими. На втором графике изображены те же самые данные, но параметр `vertex.sex` умножен на 20, чтобы можно было увидеть относительные различия между размерами узлов (рис. 7.4).

```

deg <- degree(Bali, rescale=TRUE)
op <- par(mfrow=c(1,2))
gplot(Bali, usearrows=FALSE, displaylabels=FALSE,
vertex.cex=deg,
vertex.col=my_pal[as.factor(rolecat)],
edge.lwd=0, edge.col="grey25",
main="Слишком маленькие")
gplot(Bali, usearrows=FALSE, displaylabels=FALSE,
vertex.cex=deg*20,
vertex.col=my_pal[as.factor(rolecat)],
edge.lwd=0, edge.col="grey25",
main="Немного лучше")
par(op)

```

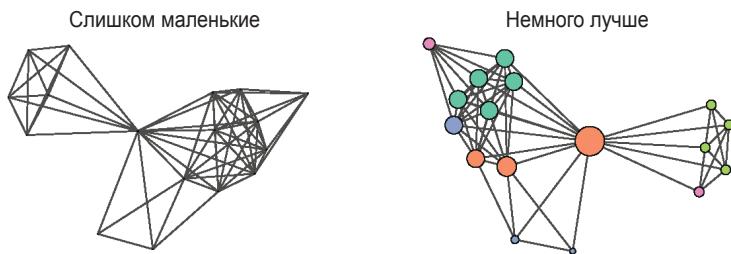


Рис. 7.4. Сравнение двух подходов к настройке размеров узлов с помощью центральности по степени

График сети, который включает в себя информацию о важности конкретных узлов, может быть эффективным инструментом анализа и визуализации. Можно составить более четкое представление об общей структуре сети, а также важности конкретных позиций. Рисунок 7.5 представляет собой итоговый график сети Bali, в котором категориальная информация, полученная для отдельных узлов (используется цвет вершин), сочетается с количественной информацией по ним (используется размер вершин).

```

deg <- degree(Bali, rescale=TRUE)
gplot(Bali, usearrows=FALSE, displaylabels=TRUE,
      vertex.cex=deg*12,
      vertex.col=my_pal[as.factor(rolecat)],
      edge.lwd=0.5, edge.col="grey75")
legend("topright", legend=c("BM", "CT", "OA", "SB", "TL"),
      col=my_pal, pch=19, pt.cex=2)

```

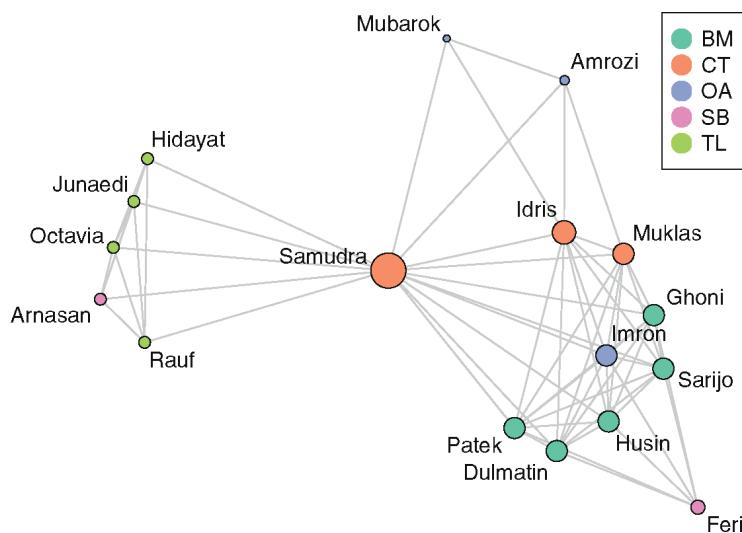


Рис. 7.5. Сеть Bali,
размеры узлов соответствуют степени центральности

7.3. Точки сочленения и мосты

В теории графов существуют еще два понятия, которые могут быть полезными при оценке локальных свойств отдельных узлов или связей. Первое понятие – *точка сочленения (cutpoint)¹*. Точка сочленения – это узел, при удалении которого увеличивается число компонент связности. Таким образом, точки сочленения занимают важные позиции, соединяющие различные части сети. Их удаление приведет к тому, что два подмножества акторов не смогут взаимодействовать друг с другом (рис. 7.6).

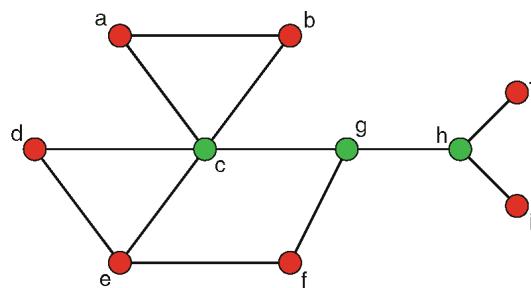


Рис. 7.6. Пример графа
с обнаруженными точками сочленения

¹ В качестве синонима также употребляется термин «точка артикуляции» (articulation point). – Прим. нерп.

Для быстрого определения любых точек сочленения в сети вы можете воспользоваться функцией `cutpoint()` из комплекта пакетов `statnet`. (Чтобы определить точки сочленения для направленной сети, вы должны задать тип компоненты связности. См. `?cutpoints` для получения дополнительной информации.)

```
cpnet <- cutpoints(net, mode="graph",
                     return.indicator=TRUE)
mycoord <- gplot(net, gmode="graph",
                  vertex.cex=1.5)
gplot(net, gmode="graph", vertex.col=cpnet+2,
      coord=mycoord,
      jitter=FALSE, displaylabels=TRUE)
```

Таким образом, помимо двух центральных узлов (*c* и *g*), определенных нами ранее, мы видим, что *h* также является точкой сочленения. Несмотря на то что ее легко найти в приведенном примере, мы можем идентифицировать эти узлы в качестве точек сочленения несколькими разными способами (рис. 7.7).

```
net2 <- net
components(net2)

## [1] 1

delete.vertices(net2, 7)
components(net2)

## [1] 2

gplot(net2, gmode="graph", vertex.col=2,
      coord=mycoord [-7,],
      jitter=FALSE, displaylabels=TRUE)
```

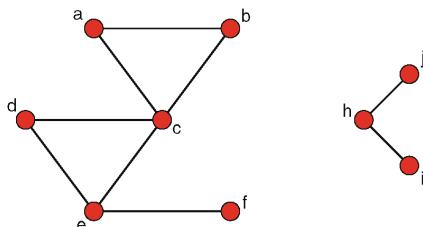


Рис. 7.7. Пример графа с одной удаленной точкой сочленения

Мосты (bridges) – это ребра, эквивалентные точкам сочленения. Мост – это ребро, при удалении которого одна компонента разделяется на две. В `statnet` нет функций для определения мостов, но довольно просто создать функцию, которая позволит найти мосты. Эта функция берет направленную или ненаправленную сеть в `statnet` и исследует каждую связь (она проверяет, происходит ли при удалении связи увеличение числа компонент). Функция возвращает логический вектор длиной, равной количеству связей, указывая, какие связи являются мостами.

```

bridges <- function(dat, mode="graph",
                     connected=c("strong", "weak")) {
  e_cnt <- network.edgecount(dat)
  if (mode == "graph") {
    cmp_cnt <- components(dat)
    b_vec <- rep(FALSE, e_cnt)
    for(i in 1:e_cnt) {
      dat2 <- dat
      delete.edges(dat2, i)
      b_vec[i] <- (components(dat2) != cmp_cnt)
    }
  } else {
    cmp_cnt <- components(dat, connected=connected)
    b_vec <- rep(FALSE, e_cnt)
    for(i in 1:e_cnt) {
      dat2 <- dat
      delete.edges(dat2, i)
      b_vec[i] <- (components(dat2, connected=connected)
                    != cmp_cnt)
    }
  }
  return(b_vec)
}

```

Как только функция определена, мы можем использовать ее напрямую:

```

bridges(net)

## [1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [8] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [15] FALSE FALSE FALSE FALSE TRUE TRUE TRUE TRUE
## [22] TRUE TRUE TRUE

```

Эта сводка показывает нам, что существуют три связи, которые являются мостами. Кроме того, мы можем использовать функцию `bridges` так же, как и функцию `cutpoints`, чтобы показать на графике, какие ребра являются мостами (рис. 7.8).

```

brnet <- bridges(net)
gplot(net, gmode="graph", vertex.col="red",
      edge.col=brnet+2, coord=mycoord,
      jitter=FALSE, displaylabels=TRUE)

```

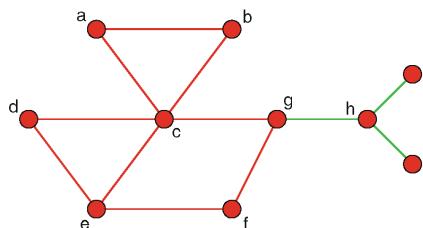


Рис. 7.8. Пример графа с обнаруженными мостами

Глава 8

Подгруппы

8.1. Введение	115
8.2. Социальная сплоченность	116
8.3. Обнаружение сообществ	123

Наши молодые люди видят перед собой целый ряд различных групп, верящих в разные вещи и пропагандирующих различные способы поведения. К каждой из этих групп могут принадлежать их близкие друзья или родственники.

Маргарет Мид

8.1. Введение

Социальные системы, представленные в сетях, как правило, характеризуются сложной структурой. Например, в своей классической работе «*Сила слабых связей*» (*The strength of weak ties*) 1973 года Марк Грановеттер (Mark Granovetter) предположил, что многие социальные сети состоят из относительно плотных подгрупп (например, подсетей дружеских отношений), которые, в свою очередь, соединены друг с другом менее крепкими связями (например, связями между знакомыми)¹. Из этого следует, что очень важно уметь определить и найти такие подгруппы. В различных отраслях науки применяются теории, согласно которым большие социальные системы состоят из различных подгрупп, например социологи выделяют социальные классы, психологи исследуют поведение малых групп, врачи изучают различия в показателях состояния здоровья между разными социальными группами.

В этой главе рассматривается ряд методов, использующихся в R для поиска и исследования подгрупп в рамках больших социальных сетей. В этой главе активно используется пакет *igraph* в силу его больших возможностей по обнаружению подгрупп и сообществ.

В ряде случаев нет никакой необходимости в том, чтобы использовать специальные методы обнаружения подгрупп. Например, посмотрите на социограмму Морено, которую мы исследовали в главе 2 (рис. 8.1). Здесь очевидно, что сеть состоит из двух основных групп, даже если бы мы не знали заранее, что здесь изображены ученики 4-го класса.

Однако обычно в реальных социальных сетях подгрупповая структура не так отчетливо видна, если она вообще существует. Рисунок 8.2 показывает более реалистичную сеть, где есть намек на определенную подгрупповую структуру, однако, чтобы определить ее, требуется более развернутый анализ. Цветовая кодировка и метки предполагают, что между сотрудниками одного и того же агентства DHHS, возможно, есть некоторая сплоченность, но это совершенно очевидно.

¹ По мнению Грановеттера, «сила слабых связей» заключается в том, что слабые связи позволяют информационным потокам вырваться из замкнутых подгрупп (кластеров). Информация быстро распространяется внутри одного кластера, где все друг друга знают. Но если речь заходит о поиске новых возможностей, слабые связи помогают расширить круг и получить новую информацию из других кластеров. В частности, Грановеттер выяснил, что люди чаще получали работу, о которой они узнали от малознакомых людей, чем от близких знакомых. – Прим. пер.

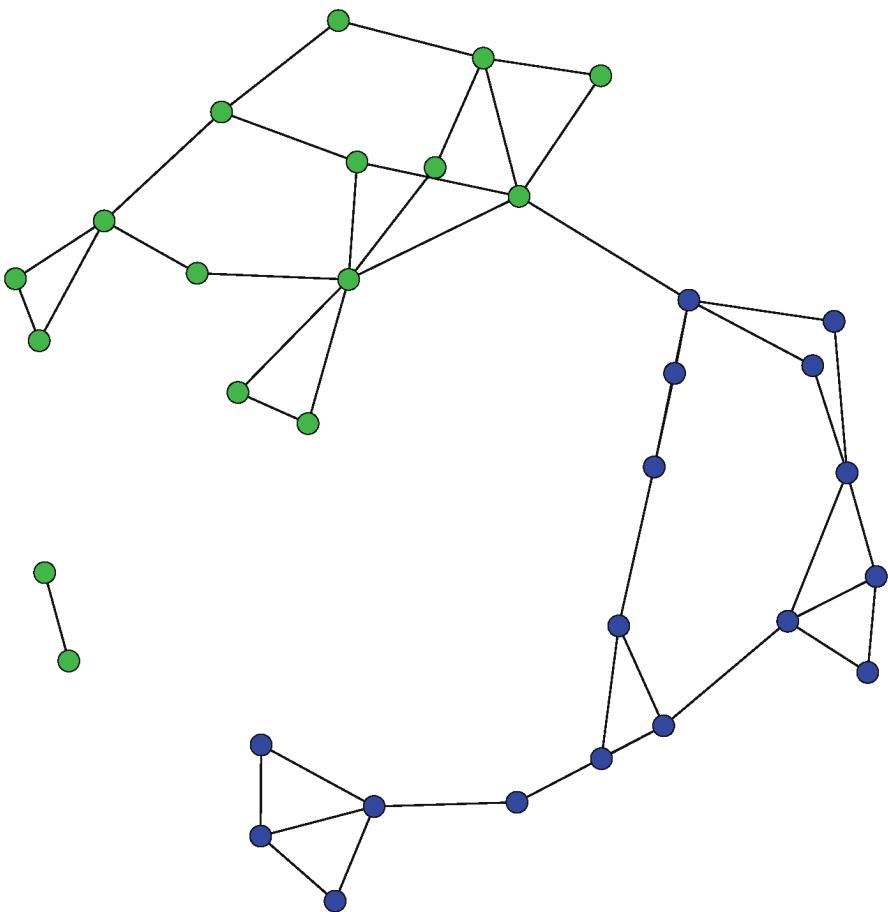


Рис. 8.1. Социограмма Морено, показывающая две подгруппы

8.2. Социальная сплоченность

Один из способов взглянуть на подгруппы сети заключается в исследовании *социальной сплоченности* (*social cohesion*). Сплоченные подгруппы – это множества акторов, которые соединены между собой посредством многочисленных, сильных и прямых связей [Wasserman, Faust, 1994]. Этот подход настолько очевиден, что привел к появлению целого ряда методов обнаружения подгрупп.

8.2.1. Клики

Клика (*clique*) – один из самых простых типов сплоченных подгрупп и в силу своего простого определения один из самых понятных типов. Клика – это максимальный полный подграф, т. е. клика – это подмножество узлов со всеми возможными связями между ними.

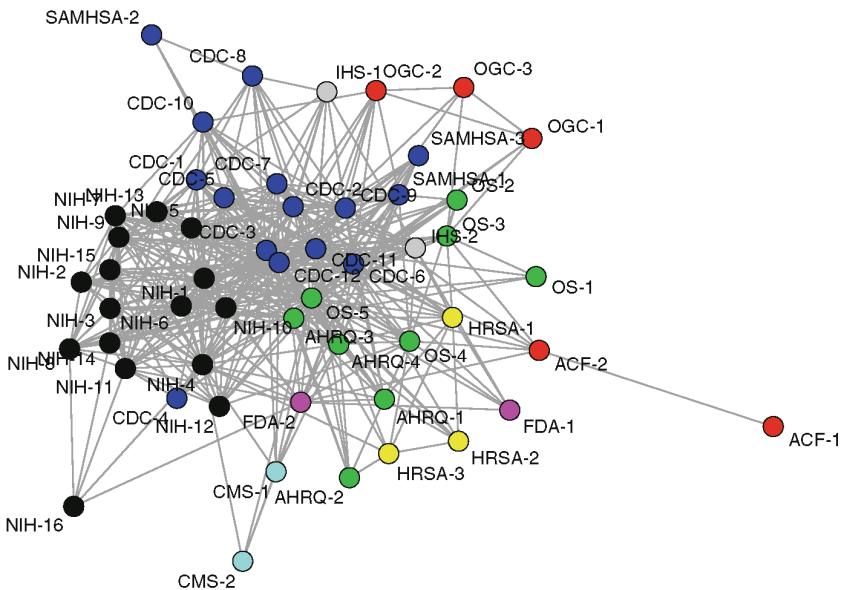


Рис. 8.2. Сотрудничество между агентствами DHHS

Рассмотрим пример графика, приведенный на рис. 8.3. На этом графике показаны две клики: A, B, C, D и E, F, G. (С технической точки зрения, диады также являются кликами, но обычно лишь клики размера 3 и более представляют интерес. Кроме того, по определению любая клика размера k также будет включать все клики размером $k-1, k-2$ и т. д.¹)

```
library(igraph)
clqexmp <- graph.formula(A:B:C:D--A:B:C:D, D-E, E-F-G-E)
```

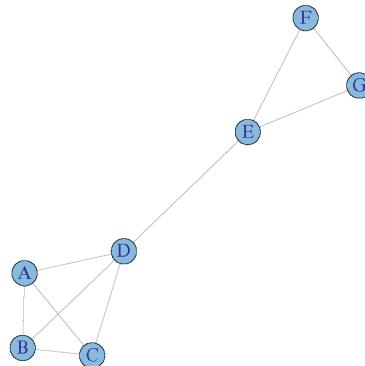


Рис. 8.3. Пример графа с двумя кликами

¹ Размер клики определяется как число вершин в ней. – Прим. пер.

Команды, приведенные ниже, показывают, как получить информацию о кликах в сети. Вопреки своему названию функция `clique.number()` вместо числа клик возвращает размер наибольшей клики. Чтобы получить список всех клик, регулируя при этом минимально или максимально допустимый размер клик, используйте `cliques()`. Когда сеть содержит большое количество клик, функция `maximal.cliques()` будет более полезной. Наконец, как следует из названия, функция `largest.cliques()` находит все наиболее крупные клики в сети.

```
clique.number(clqexmp)
## [1] 4

cliques(clqexmp, min=3)
## [[1]]
## + 3/7 vertices, named:
## [1] A B C
##
## [[2]]
## + 3/7 vertices, named:
## [1] A B D
##
## [[3]]
## + 3/7 vertices, named:
## [1] A C D
##
## [[4]]
## + 3/7 vertices, named:
## [1] B C D
##
## [[5]]
## + 3/7 vertices, named:
## [1] E F G
##
## [[6]]
## + 4/7 vertices, named:
## [1] A B C D

maximal.cliques(clqexmp, min=3)
## [[1]]
## + 3/7 vertices, named:
## [1] E F G
##
## [[2]]
## + 4/7 vertices, named:
## [1] A B D C

largest.cliques(clqexmp)
## [[1]]
## + 4/7 vertices, named:
## [1] D A B C
```

Обратите внимание на то, что последние три функции возвращают списки идентификационных номеров вершин. Синтаксис, приведенный ниже, показывает, как можно вывести имена вершин вместо идентификаторов, если у объекта `igraph` вершины имеют имена.

```
V(clqexmp) [unlist(largest.cliques(clqexmp))]

## + 4/7 vertices, named:
## [1] D A B C
```

Однако у клик есть два главных недостатка, которые уменьшают их полезную роль в анализе реальных социальных сетей. Во-первых, клика – это очень строгое определение сплоченной подгруппы. Рассмотрим подграф, состоящий из семи вершин. Чтобы быть кликой, между 7 участниками должно быть проведено 21 ребро (максимально возможное количество ребер). Если хотя бы одно ребро будет удалено, эти семь вершин уже не будут принадлежать одной клике, даже при том, что плотность этих семи вершин ($20/21 = 0,95$) предполагает, что они являются сплоченной подгруппой.

Следствием этого несовершенного определения является вторая главная проблема клик: они просто не очень распространены в больших социальных сетях. В табл. 8.1 приведены некоторые результаты простого имитационного моделирования сетей, демонстрирующие редкую встречаемость клик. Были созданы четыре случайные сети с 25, 50, 100 и 500 узлами. Средняя степень каждой сети устанавливалась примерно равной 6. Таблица показывает, что количество клик остается примерно одинаковым, даже когда размер сети существенно увеличивается. Кроме того, размер клик так и остается небольшим. (См. главу 10 для получения дополнительной информации о моделях случайных графов, например `erdos.renyi.game`.)

```
g25 <- erdos.renyi.game(25, 75, type="gnm")
g50 <- erdos.renyi.game(50, 150, type="gnm")
g100 <- erdos.renyi.game(100, 300, type="gnm")
g500 <- erdos.renyi.game(500, 1500, type="gnm")
nodes <- c(25,50,100,500)
lrgclq <- c(cliique.number(g25), cliique.number(g50),
              cliique.number(g100), cliique.number(g500))
numclq <- c(length(cliques(g25,min=3)),
             length(cliques(g50,min=3)),
             length(cliques(g100,min=3)),
             length(cliques(g500,min=3)))
clqinfo <- data.frame(Nodes=nodes, Largest=lrgclq, Number=numclq)
clqinfo
```

Таблица 8.1. Характеристики клик для сетей различного размера

Количество узлов	Наибольший размер	Количество клик
25	3	27
50	4	47
100	3	35
500	3	38

8.2.2. *k*-ядра

Частично из-за редкости клик были предложены альтернативные определения социальной сплоченности. Популярным определением является *k*-ядро (*k*-core). *k*-ядро – это максимальный подграф, в котором каждая вершина связана минимум с *k* другими вершинами этого же подграфа. *k*-ядра имеют массу преимуществ: они вложены (каждый участник 4-ядра является также участником 3-ядра и т. д.), они не перекрываются, и их легко определить.

Как правило, анализ *k*-ядер начинается с определения всего множества *k*-ядер, включает визуальное исследование *k*-ядерной структуры, после которого, возможно, проводится более подробный анализ ядер конкретной степени (например, проводится анализ 6-ядра).

Чтобы показать, как можно исследовать *k*-ядра в социальной сети, мы воспользуемся набором данных DHHS. Этот набор данных иллюстрирует взаимосвязи между экспертами, работавшими в различных учреждениях и агентствах Министерства здравоохранения и социальных служб в 2005 году ([Leischow, Luke, et al., 2010]). Он является объектом-сетью statnet, поэтому мы преобразуем его в объект *igraph*, воспользовавшись пакетом *intergraph*. Кроме того, связи сети DHHS имеют числовые значения в диапазоне от 1 (только делятся информацией) до 4 (официальное сотрудничество по нескольким проектам). Если учитывать все значения, сеть получается сильно взаимосвязанной. Для этого примера мы будем учитывать лишь официальное сотрудничество (т. е. когда атрибут ребер *collab* равен 3 или 4). В данном примере для отбора лишь этих ребер мы воспользуемся функцией *subgraph.edges* пакета *igraph*. Она построит нам новую сеть, которая будет в два раза менее плотной, чем исходная.

```
data(DHHS)
library(intergraph)
iDHHS <- asIgraph(DHHS)
graph.density(iDHHS)

## [1] 0.312

iDHHS <- subgraph.edges(iDHHS, E(iDHHS)[collab > 2])
graph.density(iDHHS)

## [1] 0.153
```

Для определения *k*-ядерной структуры используется функция *graph.coreness*. Для каждой вершины вычисляется ядро с максимальным *k*, которому она принадлежит. 1-ядро содержит 7 вершин, 2-ядро – 6 вершин, 3-ядро – 2 вершины и т. д. Результаты показывают нам, что *k* варьирует от 1 до 6.

```
coreness <- graph.coreness(iDHHS)
table(coreness)

## coreness
## 1 2 3 4 5 6
## 7 6 2 5 2 26
```

```
maxCoreness <- max(coreness)
maxCoreness
## [1] 6
```

Для лучшей интерпретации k -ядерной структуры мы можем графически изобразить сеть, используя информацию о множестве k -ядер. Этот пример иллюстрирует, как в пакете `igraph` можно использовать специальные атрибуты вершин `name` и `color`. Атрибут имен используется по умолчанию для присвоения меток узлам на графике. Здесь мы копируем имена вершин, которые были сохранены в атрибуте вершин `vertex.names` в `statnet`. Атрибут цветов вершин используется, чтобы задать цвета узлов по умолчанию. Здесь мы добавляем 1 к значениям k -ядер, сохраненным в векторе `coreness`, чтобы быстро и эффективно подобрать различные цвета для каждого k -ядра, а также избежать черного цвета (рис. 8.4).

```
Vname <- get.vertex.attribute(iDHHS, name='vertex.names',
                               index=V(iDHHS))
V(iDHHS)$name <- Vname
V(iDHHS)$color <- coreness + 1
op <- par(mar = rep(0, 4))
plot(iDHHS, vertex.label.cex=0.8)
par(op)
```

Чтобы упростить интерпретацию, мы можем присвоить узлам метки, где будут указаны k -ядра, которым они принадлежат. Кроме того, в этом примере мы покажем, как можно еще автоматически подобрать различные цвета для узлов (рис. 8.5).

```
colors <- rainbow(maxCoreness)
op <- par(mar = rep(0, 4))
plot(iDHHS, vertex.label=coreness,
      vertex.color=colors[coreness])
par(op)
```

Этот рисунок показывает, что центр сети в основном сформирован ядром наивысшей степени. В данном случае речь идет о 6-ядре, которому принадлежат 26 узлов¹. Поскольку k -ядра имеют вложенную структуру, мы можем глубже исследовать подгруппы, последовательно удаляя k -ядра более низкой степени. Чтобы сделать это, мы воспользуемся функцией `induced.subgraph` (рис. 8.6).

```
V(iDHHS)$name <- coreness
V(iDHHS)$color <- colors[coreness]
IDHHS1_6 <- iDHHS
IDHHS2_6 <- induced.subgraph(iDHHS,
                               vids=which(coreness > 1))
IDHHS3_6 <- induced.subgraph(iDHHS,
                               vids=which(coreness > 2))
```

¹ Интерпретировать такое ядро можно как группу экспертов, каждый из которых общается не менее чем с шестью другими участниками этой группы. – Прим. пер.

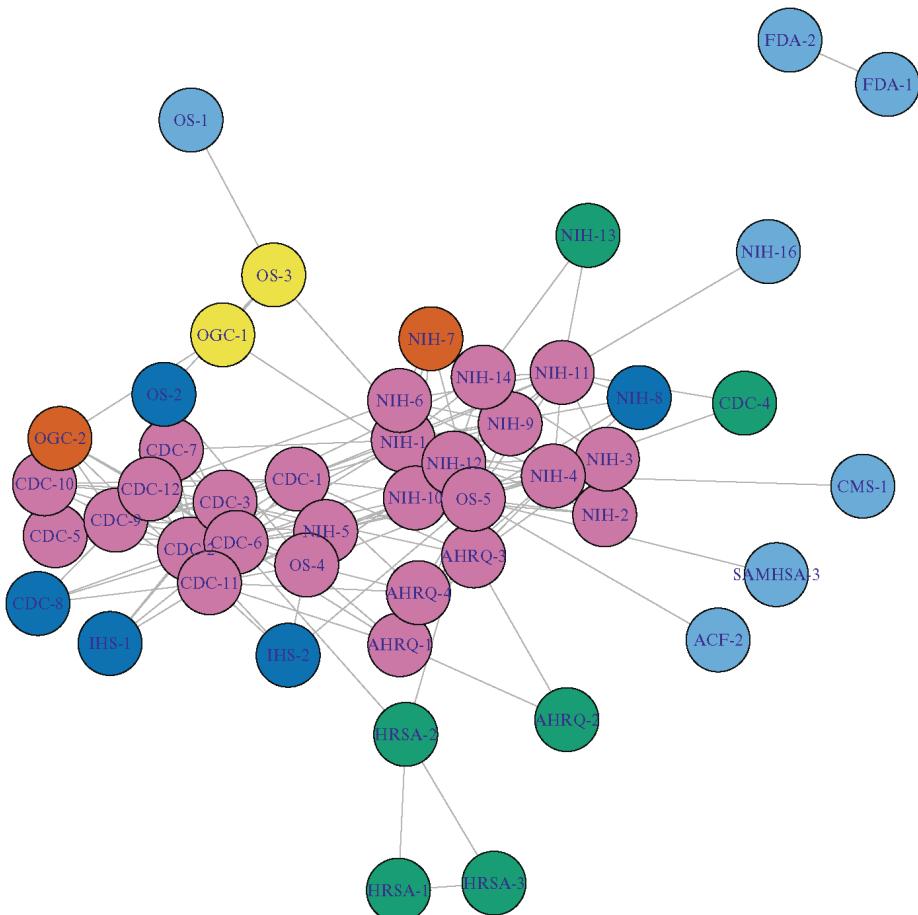


Рис. 8.4. k-ядерная структура сети DHHS

```

iDHHS4_6 <- induced.subgraph(iDHHS,
                               vids=which(coreness > 3))
iDHHS5_6 <- induced.subgraph(iDHHS,
                               vids=which(coreness > 4))
iDHHS6_6 <- induced.subgraph(iDHHS,
                               vids=which(coreness > 5))

lay <- layout.fruchterman.reingold(iDHHS)
op <- par(mfrow=c(3,2), mar = c(3,0,2,0))
plot(iDHHS1_6, layout=lay, main="Все k-ядра")
plot(iDHHS2_6, layout=lay[which(coreness > 1),],
     main="k-ядра 2-6")
plot(iDHHS3_6, layout=lay[which(coreness > 2),],
     main="k-ядра 3-6")

```

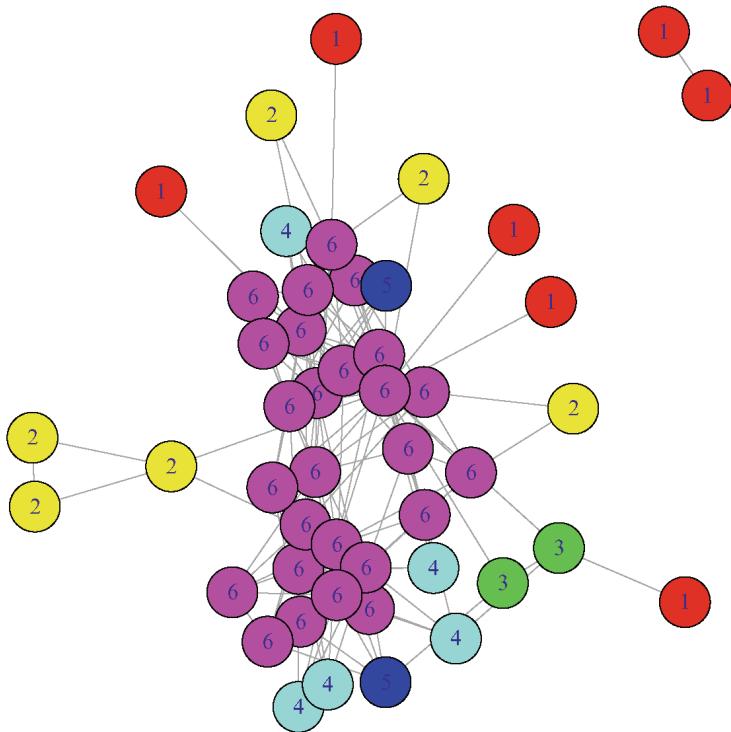


Рис. 8.5. k -ядерная структура сети DHHS,
указана принадлежность к k -ядрам

```
plot(iDHHS4_6,layout=lay[which(coreness > 3),],
     main="k-ядра 4-6")
plot(iDHHS5_6,layout=lay[which(coreness > 4),],
     main="k-ядра 5-6")
plot(iDHHS6_6,layout=lay[which(coreness > 5),],
     main="k-ядра 6-6")
par(op)
```

8.3. Обнаружение сообществ

Клики и k -ядра используются для поиска подгрупп, которые полностью зависят от структуры внутренних связей. Специалисты по анализу сетей разработали целый ряд алгоритмов и эвристик выявления подгрупп, которые находят группы, не только основываясь на внутренних связях, но также на структуре связей между различными группами. Таким образом, подгруппа в сети – это множество узлов, которое имеет относительно большое количество внутренних связей и при этом относительно небольшое количество связей между данной группой и остальной сетью. Эти методы отличаются по своим деталям, но все они пред-

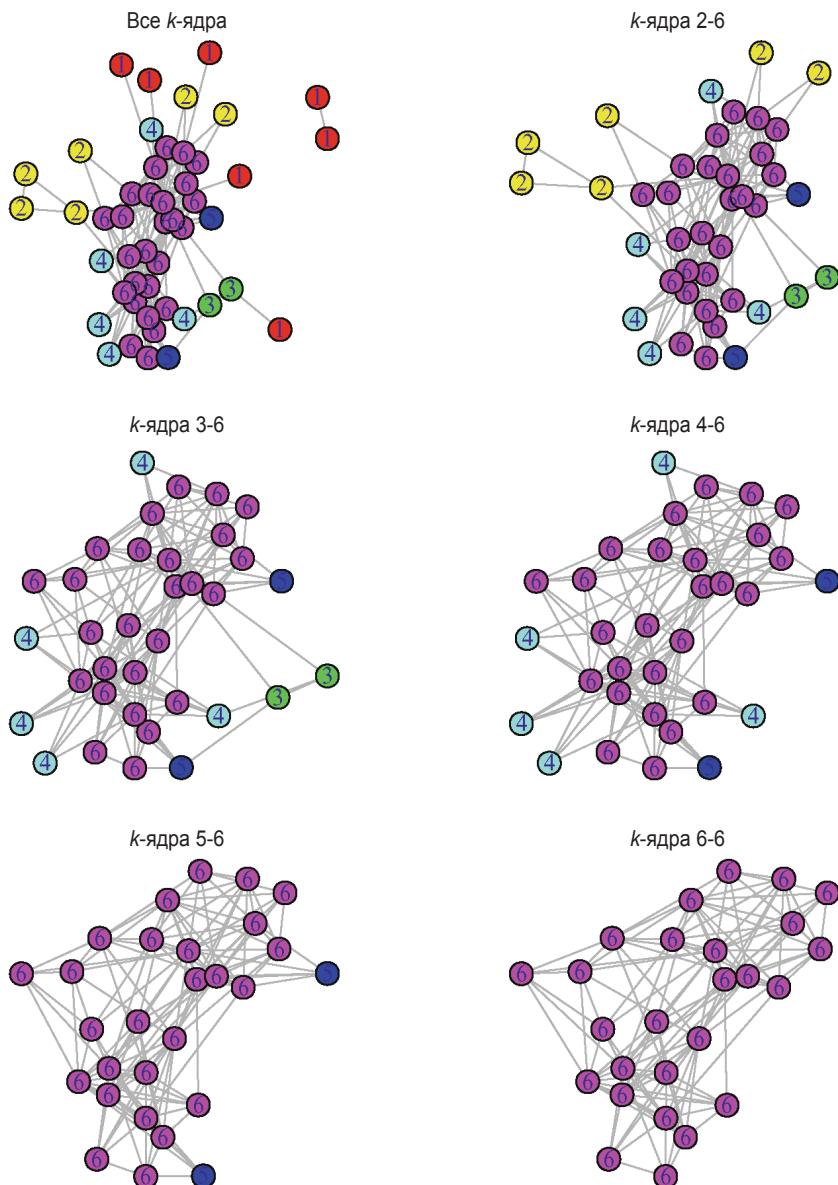


Рис. 8.6. Последовательное удаление k -ядер сети DHHS

назначены для выявления внутренне сплоченных подгрупп, которые в какой-то степени отделены или изолированы от других групп или узлов. Иногда эти методы называют *алгоритмами обнаружения сообществ* (*community detection algorithms*).

8.3.1. Модулярность

Важная характеристика сети, используемая во многих алгоритмах обнаружения сообществ, – это *модулярность* (*modularity*). Модулярность характеризует структуру сети, в частности степень кластеризации узлов, когда внутри кластера наблюдается много узлов (высокая плотность), а между кластерами мало узлов (низкая плотность) (Newman 2006). Модулярность можно использовать в исследовательских целях, когда мы с помощью того или иного алгоритма пытаемся максимизировать модулярность и выполнить классификацию узлов, которая наилучшим образом объясняет существующую кластеризацию. С другой стороны, модулярность можно использовать для описания сети, когда показатель модулярности вычисляется для любой переменной группировки узлов. Например, для сети дружеских контактов аналитик может вычислить модулярность по полу участников сети. Таким образом, модулярность показывает, в какой степени пол участников сети объясняет наблюдаемую кластеризацию среди друзей. Показатель модулярности определяется как разница между долей связей внутри группы и ожидаемой долей связей, если бы связи были размещены случайно. Показатель модулярности может принимать значения в диапазоне от $-1/2$ до $+1$. Чем выше показатель, тем больше уровень кластеризации сети в соответствии с данной группировкой узлов.

Рассмотрим простой пример сети с девятью узлами, приведенный ниже. У нас есть два категориальных атрибута вершин, которые классифицируют узлы на три группы (рис. 8.7).

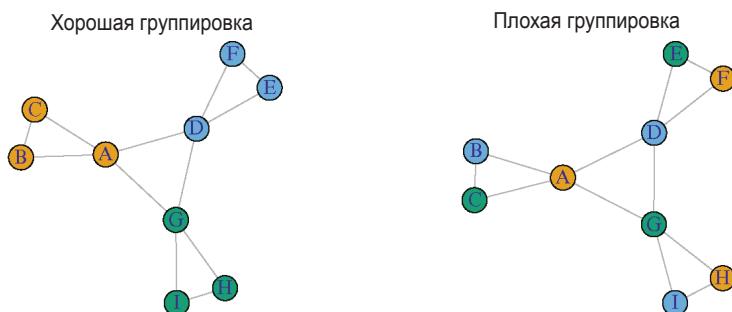


Рис. 8.7. Пример модулярности

```
g1 <- graph.formula(A-B-C-A, D-E-F-D, G-H-I-G, A-D-G-A)
V(g1)$grp_good <- c(1,1,1,2,2,2,3,3,3)
V(g1)$grp_bad <- c(1,2,3,2,3,1,3,1,2)

op <- par(mfrow=c(1,2))
plot(g1,vertex.color=(V(g1)$grp_good),
      vertex.size=20,
      main="Хорошая группировка")
plot(g1,vertex.color=(V(g1)$grp_bad),
      vertex.size=20,
```

```
main="Плохая группировка")
par(op)
```

Как видно на рисунке, кластеризация, очевидная для данной сети, лучше объясняется атрибутом узлов grp_good, в отличие от атрибута grp_bad. Это можно подтвердить, вычислив значение модулярности с помощью функции modularity в пакете igraph.

```
modularity(g1, V(g1)$grp_good)
## [1] 0.417
modularity(g1, V(g1)$grp_bad)
## [1] -0.333
```

Реальные социальные сети часто характеризуются кластеризацией, однако оценить уровень кластеризации на глаз, разумеется, довольно сложно. Ранее в этой главе мы уже видели, что сеть DHSS имеет интересную подгрупповую структуру, и эту структуру можно рассмотреть с точки зрения агентств, взаимодействующих друг с другом.

```
library(intergraph)
data(DHHS)
iDHHS <- asIgraph(DHHS)
table(V(iDHHS)$agency)

##
## 0 1 2 3 4 5 6 7 8 9 10
## 2 4 12 2 2 3 2 16 3 5 3

V(iDHHS)[1:10]$agency
## [1] 0 0 1 1 1 2 2 2 2
modularity(iDHHS, (V(iDHHS)$agency+1))
## [1] 0.14
```

Функция modularity требует, чтобы переменная группировки узлов была пронумерована начиная с 1 (и фактически текущая версия функции выдаст ошибку, если принадлежность к сообществу будет нулевой.) В данном случае agency пронумерована начиная с 0, поэтому мы добавляем 1 к ней, прежде чем передать ее в функцию modularity. Значение модулярности 0,14 подразумевает, что агентства действительно частично объясняют наблюдаемую кластеризацию сети. Однако, как и большинство описательных статистик сети, модулярность сама по себе несет мало смысла. Интерпретация характеристики сети становится более содержательной, когда ее сравнивают с другой соответствующей метрикой. Например, как модулярность меняется с течением времени? Или как соотносится значение модулярности со значением модулярности, вычисленным по другому атрибуту вершин этой же сети?

В качестве сравнения мы можем проанализировать значения модулярности для двух других наборов данных, включенных в пакет UserNetR. На примере данных Moreno мы видим, как пол объясняет подгрупповую структуру сети. Для сети Facebook мы можем воспользоваться атрибутом узлов group, который определяет тип социальной группы, к которой принадлежат друзья по Facebook (семья, рабочта, музыка, школа и т. д.). Результаты показывают, что социальные сети Moreno и Facebook имеют более высокую модулярность, чем сеть DHHS.

```
data (Moreno)
iMoreno <- asIgraph (Moreno)
table (V(iMoreno) $gender)

##
## 1 2
## 16 17

modularity (iMoreno, V(iMoreno) $gender)
## [1] 0.476

data (Facebook)
levels (factor (V(Facebook) $group))

## [1] "B" "C" "F" "G" "H" "M" "S" "W"
grp_num <- as.numeric (factor (V(Facebook) $group))
modularity (Facebook, grp_num)
## [1] 0.615
```

8.3.2. Алгоритмы обнаружения сообществ

Главная причина, по которой в этой главе используется igraph, заключается в том, что данный пакет поддерживает если не все, то, по крайней мере, большую часть существующих алгоритмов обнаружения сообществ. В табл. 8.2 перечислены алгоритмы, имеющиеся на данный момент в пакете igraph, а также информация о том, поддерживает ли конкретная функция направленные сети, взвешенные сети (сети, в которых связям присвоены числовые значения) и возможность работы с сетями, состоящими из нескольких компонентов.

В пакете igraph основные операции, связанные с обнаружением сообществ, сводятся к тому, что нужно запустить одну из функций обнаружения сообществ и сохранить результаты в объекте класса communities. Затем обнаруженные подгруппы можно исследовать с помощью различных функций igraph, которые умеют работать с объектами communities. Кроме того, можно легко построить графики сетей для иллюстрации результатов обнаружения сообществ.

Например, рассмотрим простую сеть дружеских отношений Moreno, в которой четко выделяются две подгруппы по полу. Поиск сообществ в этой сети осуществляется следующим образом.

```
cw <- cluster_walktrap(iMoreno)
membership(cw)

## [1] 1 1 1 1 1 1 1 1 1 3 3 3 5 5 5 5 1 3 2 2 2 4 4 4
## [24] 2 2 2 2 2 2 2 2 6 6

modularity(cw)
## [1] 0.618
```

Таблица 8.2. Функции обнаружения сообществ в пакете *igraph*

Название алгоритма	Функция	Поддержка		
		Направленных сетей	Взвешенных сетей	Сетей из нескольких компонент
Edge-betweenness (Посредничество ребер ¹)	cluster_edge_betweenness	Да	Да	Да
Leading eigenvector (Главный собственный вектор)	cluster_leading_eigen	Нет	Нет	Да
Fast-greedy (Быстро работающий жадный)	cluster_fast_greedy	Нет	Да	Да
Louvain (Лувайн)	cluster_louvain	Нет	Да	Да
Walktrap (Случайное блуждание)	cluster_walktrap	Нет	Да	Нет
Label propagation (Распространение меток)	cluster_label_prop	Нет	Да	Нет
InfoMAP	cluster_infomap	Да	Да	Да
Spinglass (Спиновое стекло)	cluster_spinglass	Нет	Да	Нет
Optimal (Оптимальный)	cluster_optimal	Нет	Да	Да

Значение модулярности является довольно высоким. Это предполагает, что алгоритм `cluster_walktrap` прекрасно справился с задачей поиска подгрупп. Функция `membership` показывает, что было обнаружено шесть различных подгрупп. Для лучшей интерпретации визуализируем их. Если в графическую функцию передать объект `communities` вместе с сетью, к которой он принадлежит, можно построить красивый график, на котором каждая подгруппа будет обрамлена затененной областью определенного цвета (рис. 8.8).

```
plot(cw, iMoreno)
```

Выявив сообщества, их можно исследовать, как и любой тип подгрупп. Например, вы можете сравнить полученное решение с уже существующим, основанным на характеристике узлов. В данном случае на примере сети DHHS выясним, как решение на основе алгоритма `walktrap` выглядит в сравнении с решением, в котором узлы группируются по конкретным агентствам.

¹ В качестве синонима также используется термин «промежуточность ребер». – Прим. пер.

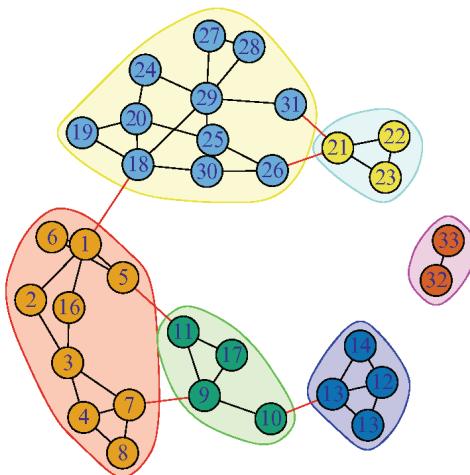


Рис. 8.8. Выявление сообществ в сети Bali

```

cw <- cluster_walktrap(iDHHS)
modularity(cw)

## [1] 0.165

membership(cw)

## [1] 4 5 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
## [24] 1 1 1 1 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 2 2 2
## [47] 2 1 2 1 1 1 1 1 1

table(V(iDHHS)$agency, membership(cw))

##
##      1   2   3   4   5
## 0   0   0   0   1   1
## 1   4   0   0   0   0
## 2  12   0   0   0   0
## 3   2   0   0   0   0
## 4   2   0   0   0   0
## 5   3   0   0   0   0
## 6   2   0   0   0   0
## 7   0   0 16   0   0
## 8   0   3   0   0   0
## 9   3   2   0   0   0
## 10  3   0   0   0   0

```

Применение нескольких алгоритмов обнаружения сообществ и сравнение полученных результатов являются общераспространенной практикой. (При этом помните, что лишь несколько алгоритмов могут работать с определенными типами сетей, например с направленными сетями.) Примеры, приведенные ниже,

показывают, как различные алгоритмы немного по-разному находят подгруппы в террористической сети Bali.

```
data(Bali)
iBali <- asIgraph(Bali)
data(Bali)
iBali <- asIgraph(Bali)
cw <- cluster_walktrap(iBali)
modularity(cw)

## [1] 0.283

membership(cw)

## [1] 2 1 2 1 2 2 1 2 2 3 3 3 3 3 2 2 2

ceb <- cluster_edge_betweenness(iBali)
modularity(ceb)

## [1] 0.239

membership(ceb)

## [1] 1 1 1 1 1 1 1 1 1 2 2 2 2 2 1 1 1

cs <- cluster_springlass(iBali)
modularity(cs)

## [1] 0.297

membership(cs)

## [1] 1 2 1 3 1 1 2 1 1 3 3 3 3 3 1 1 1

cfg <- cluster_fast_greedy(iBali)
modularity(cfg)

## [1] 0.263

membership(cfg)

## [1] 2 2 1 2 1 2 2 1 1 3 3 3 3 3 1 1 1

clp <- cluster_label_prop(iBali)
modularity(clp)

## [1] 0.239

membership(clp)

## [1] 1 1 1 1 1 1 1 1 1 2 2 2 2 2 1 1 1

cle <- cluster_leading_eigen(iBali)
modularity(cle)

## [1] 0.275

membership(cle)

## [1] 1 1 1 2 1 1 2 1 1 2 2 2 2 2 1 1 1
```

```
cl <- cluster_louvain(iBali)
modularity(cl)
## [1] 0.297
membership(cl)
## [1] 3 1 3 2 3 3 1 3 3 2 2 2 2 3 3 3
co <- cluster_optimal(iBali)
modularity(co)
## [1] 0.297
membership(co)
## [1] 1 2 1 3 1 1 2 1 1 3 3 3 3 3 1 1 1
```

Эти результаты показывают, что все алгоритмы выделяют две или три подгруппы. Модулярность варьирует приблизительно от 0,24 до 0,30.

Полученные результаты можно сопоставить с другими результатами, которые основаны на метриках сравнения классификаций, включая скорректированный индекс Рэнда.

```
table(V(iBali)$role, membership(cw))
##
##      1 2 3
## BM 0 5 0
## CT 1 2 0
## OA 2 1 0
## SB 0 1 1
## TL 0 0 4

compare(as.numeric(factor(V(iBali)$role)), cw,
       method="adjusted.rand")
## [1] 0.35

compare(cw, ceb, method="adjusted.rand")
## [1] 0.616

compare(cw, cs, method="adjusted.rand")
## [1] 0.89

compare(cw, cfg, method="adjusted.rand")
## [1] 0.669
```

Наконец, мы можем графически изобразить полученные решения, чтобы лучше понять сходства и различия между разными алгоритмами обнаружения сообществ (рис. 8.9).

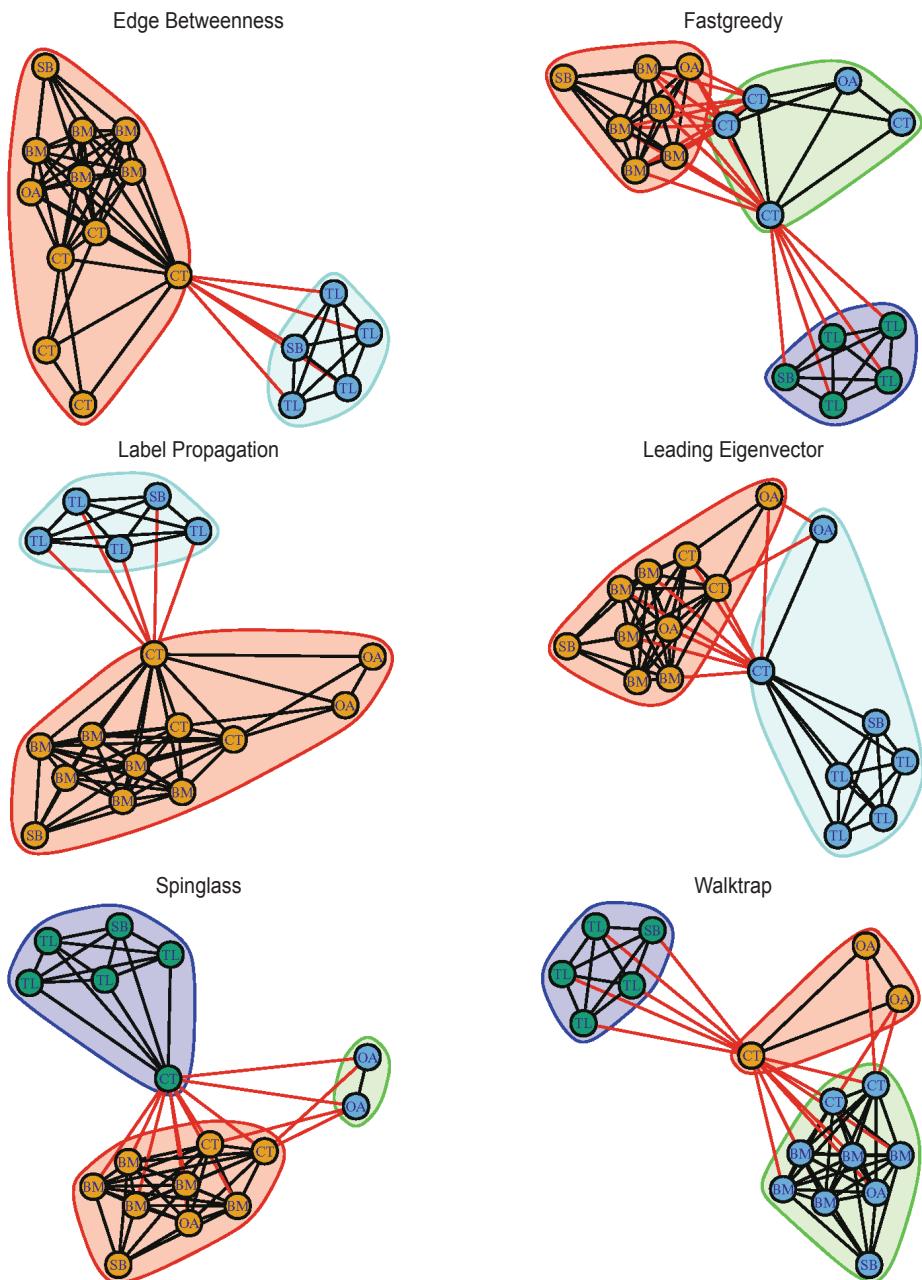


Рис. 8.9. Сравнение алгоритмов обнаружения сообществ на примере сети *Bali*

```
op <- par(mfrow=c(3,2),mar=c(3,0,2,0))
plot(ceb, iBali,vertex.label=V(iBali)$role,
     main="Edge Betweenness")
plot(cfg, iBali,vertex.label=V(iBali)$role,
      main="Fastgreedy")
plot(clp, iBali,vertex.label=V(iBali)$role,
      main="Label Propagation")
plot(cle, iBali,vertex.label=V(iBali)$role,
      main="Leading Eigenvector")
plot(cs, iBali,vertex.label=V(iBali)$role,
      main="Spinglass")
plot(cw, iBali,vertex.label=V(iBali)$role,
      main="Walktrap")
par(op)
```

Глава 9

Сети аффилированности

-
- | | |
|---|-----|
| 9.1. Определение сетей
аффилированности..... | 134 |
| 9.2. Основы
сетей аффилированности | 136 |
| 9.3. Пример: актеры Голливуда
как пример сети
аффилированности..... | 142 |

Племя – это группа людей, связанных между собой, связанных с лидером, связанных идеей. На протяжении миллионов лет люди были частью некоего племени. Чтобы быть племенем, группе нужны две вещи: общий интерес и способ коммуникации.

Сет Годин. «Племена: ты нужен нам – веди нас»

9.1. Определение сетей аффилированности

До сих пор все сети, которые мы анализировали, основывались на прямых связях. Таким образом, социальные связи, соединяющие участников социальной сети, можно определить с помощью самоанализа, прямого наблюдения или некоторых других видов сбора данных, которые сообщают нам о том, что участники связаны друг с другом напрямую.

Однако социологов часто интересуют ситуации, когда существует возможность возникновения социальных взаимосвязей, но наблюдать напрямую эти взаимосвязи нельзя. Тем не менее если участники относятся к одной и той же социальной группе, мы можем сделать вывод, что существует возможность или потенциал развития социальных связей между ними.

Мы назовем этот новый тип социальной сети *сетью аффилированности (affiliation network)*. Сеть аффилированности – это сеть, в которой участники аффилированы друг с другом на основе сотрудничества в рамках какой-то группы или совместного участия в определенном событии. Например, студентов одного и того же класса можно воспринимать как связанных между собою участников, несмотря на то что на самом деле между ними, возможно, нет прямых социальных связей¹.

Классический пример – переплетения директоратов. Директора компаний могут взаимодействовать друг с другом, заседая в совете директоров одной фирмы. Кроме того, сами компании можно рассматривать как взаимосвязанные по причине общего директората. То есть когда один и тот же директор заседает в советах директоров двух различных компаний, эти компании связаны друг с другом через этого директора. Социологи и политологи изучают этот тип сетей аффилированности, чтобы объяснить сходства во взаимодействии компаний друг с другом [Galaskiewicz, 1985].

9.1.1. Аффилированность в виде бимодальных сетей

В качестве простого примера сети аффилированности рассмотрим таблицу, в которой студенты сгруппированы по классам (табл. 9.1).

¹ В отличие от нашей системы образования, американские студенты сами составляют себе расписание, и поэтому нет определенного состава студентов в группах, т. е. слова «группа» нет, есть «класс» (class). Студент может вместе с другими студентами посещать класс английского языка, не будучи знаком с ними. – Прим. пер.

```
C1 <- c(1,1,1,0,0,0)
C2 <- c(0,1,1,1,0,0)
C3 <- c(0,0,1,1,1,0)
C4 <- c(0,0,0,0,1,1)
aff.df <- data.frame(C1,C2,C3,C4)
row.names(aff.df) <- c("S1", "S2", "S3", "S4", "S5", "S6")
```

Таблица 9.1. Студенты, сгруппированные по классам

	C1	C2	C3	C4
S1	1	0	0	0
S2	1	1	0	0
S3	1	1	1	0
S4	0	1	1	0
S5	0	0	1	1
S6	0	0	0	1

Этот тип матрицы данных называется *матрицей инцидентности* (*incidence matrix*), и он показывает, каким образом n акторов принадлежат g группам. В данном случае у нас есть шесть студентов, сгруппированных по четырем классам. Матрица инцидентности аналогична матрице смежности, но матрица смежности является квадратной матрицей $n \times n$, в которой одно измерение – акторы сети. Матрица инцидентности, наоборот, является прямоугольной матрицей $n \times g$ с двумя различными измерениями: акторами и группами. Поэтому сети аффилированности также известны как *бимодальные сети* (*two-mode networks*).

9.1.2. Двудольные графы (биграфы)

В сетях аффилированности всегда есть два типа узлов: один тип для акторов и другой тип для групп или событий, которым принадлежат акторы. Связи соединяют акторов с этими группами. Результатами этого являются отсутствие прямых связей между акторами и отсутствие прямых связей между группами. Рисунок 9.1, на котором в качестве примера показана сеть аффилированности студентов, иллюстрирует эту определяющую характеристику двудольного графа.

Комплект пакетов *statnet* и пакет *igraph* обладают встроенным функционалом для работы с сетями аффилированности. Работать с сетями аффилированности в пакете *igraph* чуть более проще, поэтому в данной главе будет использоваться именно этот пакет.

```
library(igraph)
bn <- graph.incidence(aff.df)

plt.x <- c(rep(2,6),rep(4,4))
plt.y <- c(7:2,6:3)
lay <- as.matrix(cbind=plt.x,plt.y))
```

```

shapes <- c("circle", "square")
colors <- c("blue", "red")
plot(bn, vertex.color=colors[V(bn)$type+1],
      vertex.shape=shapes[V(bn)$type+1],
      vertex.size=10, vertex.label.degree=-pi/2,
      vertex.label.dist=1.2, vertex.label.cex=0.9,
      layout=lay)

```

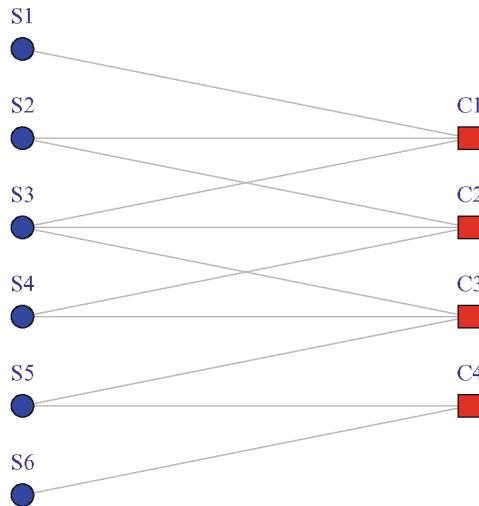


Рис. 9.1. Сеть аффилированности, представленная в виде двудольного графа

9.2. Основы сетей аффилированности

9.2.1. Создание сетей аффилированности из матриц инцидентности

Сеть аффилированности можно сохранить в качестве объекта `igraph` несколькими различными способами. Если исходные данные уже записаны в виде матрицы инцидентности (например, как в табл. 9.1), то это можно сделать с помощью одной строки программного кода.

```

bn <- graph.incidence(aff.df)
bn

## IGRAPH UN-B 10 11 --
## + attr: type (v/l), name (v/c)
## + edges (vertex names):
## [1] S1--C1 S2--C1 S2--C2 S3--C1 S3--C2 S3--C3
## [7] S4--C2 S4--C3 S5--C3 S5--C4 S6--C4

```

Функция `graph.incidence` берет матрицу или таблицу данных и преобразовывает ее в сеть аффилированности, считывая строки в качестве акторов и столбцы в качестве групп или событий. Обратите внимание, имена строк и столбцов должны быть заданы так, чтобы их можно было правильно присвоить конкретным акторам и группам.

Введя имя объекта `igraph` (назовем его `bn`), мы получаем две загадочные строки сводки. В в строке `UN-B` сообщает нам, что мы работаем с двудольной сетью. Кроме того, вторая строка показывает, что эта сеть имеет два атрибута вершин: в `name` хранятся имена вершин, а `type` представляет собой логический вектор, который используется пакетом `igraph` для дифференцировки двух различных типов узлов (в данном случае студентов и классов).

Более подробную информацию о сети аффилированности можно получить с помощью привычных функций `igraph`.

```
get.incidence(bn)
##      C1 C2 C3 C4
## S1   1  0  0  0
## S2   1  1  0  0
## S3   1  1  1  0
## S4   0  1  1  0
## S5   0  0  1  1
## S6   0  0  0  1

V(bn)$type
## [1] FALSE FALSE FALSE FALSE FALSE FALSE TRUE
## [8] TRUE  TRUE  TRUE

V(bn)$name
## [1] "S1" "S2" "S3" "S4" "S5" "S6" "C1" "C2" "C3"
## [10] "C4"
```

Здесь мы видим исходную матрицу инцидентности, имена и типы вершин. Составить имена и типы вершин не составляет труда, всем узлам-студентам присваивается тип `FALSE`, а узлам-классам – тип `TRUE`.

9.2.2. Создание сетей аффилированности из списков ребер

Для работы с большими сетями исходные данные чаще всего записывают в виде списка ребер. Список ребер также можно преобразовать в сеть аффилированности, поскольку узлы одного типа (например, студенты) строго соединены с узлами другого типа (например, классами). Программный код, приведенный ниже, создает из списка ребер ту же самую сеть аффилированности.

```
el.df <- data.frame(rbind(c("S1", "C1"),
                           c("S2", "C1"),
                           c("S2", "C2"),
```

```

c("S3", "C1"),
c("S3", "C2"),
c("S3", "C3"),
c("S4", "C2"),
c("S4", "C3"),
c("S5", "C3"),
c("S5", "C4"),
c("S6", "C4")))
el.df

##      X1 X2
## 1   S1 C1
## 2   S2 C1
## 3   S2 C2
## 4   S3 C1
## 5   S3 C2
## 6   S3 C3
## 7   S4 C2
## 8   S4 C3
## 9   S5 C3
## 10  S5 C4
## 11  S6 C4

bn2 <- graph.data.frame(el.df, directed=FALSE)
bn2

## IGRAPH UN-- 10 11 --
## + attr: name (v/c)
## + edges (vertex names):
## [1] S1--C1 S2--C1 S2--C2 S3--C1 S3--C2 S3--C3
## [7] S4--C2 S4--C3 S5--C3 S5--C4 S6--C4

```

Вышеприведенный программный код создает объект-сеть, но *igraph* не знает, что объект является двудольным графом. (Обратите внимание на то, что в описании сети отсутствует буква В, которая указывает на двудольный граф.) Чтобы исправить это, мы можем просто задать атрибут вершин *type*. Как только это сделано, мы получаем объект (сеть аффилированности), который создается из двудольного графа.

```

V(bn2)$type <- V(bn2)$name %in% el.df[,1]
bn2

## IGRAPH UN-B 10 11 --
## + attr: name (v/c), type (v/l)
## + edges (vertex names):
## [1] S1--C1 S2--C1 S2--C2 S3--C1 S3--C2 S3--C3
## [7] S4--C2 S4--C3 S5--C3 S5--C4 S6--C4

graph.density(bn)==graph.density(bn2)

## [1] TRUE

```

9.2.3. Графическое представление сетей аффилированности

Как и любой тип сети, сеть аффилированности можно представить графически для визуального анализа. Однако важно определить различные формы и цвета узлов, чтобы структуру аффилированности было проще интерпретировать. Здесь мы обозначим студентов синими кружками, а классы – красными квадратиками. Программный код, приведенный ниже, показывает, как можно использовать атрибут `type` в качестве индекса, помещенного в вектор форм и вектор цветов, чтобы выбрать соответствующую форму и цвет для каждого узла. Обратите внимание на то, что к значениям индекса `type` добавлена 1, поскольку он как логический вектор начинается с 0, тогда как мы хотим выбрать либо первый, либо второй элемент векторов форм/цветов.

```
shapes <- c("circle", "square")
colors <- c("blue", "red")
plot(bn, vertex.color=colors[V(bn)$type+1],
      vertex.shape=shapes[V(bn)$type+1],
      vertex.size=10, vertex.label.degree=-pi/2,
      vertex.label.dist=1.2, vertex.label.cex=0.9)
```

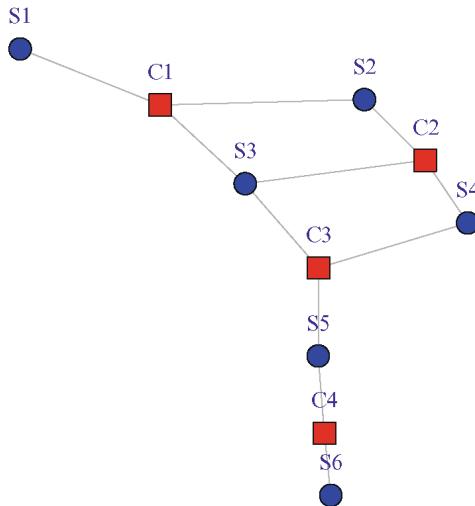


Рис. 9.2. Простой график сети аффилированности

9.2.4. Проекции

Изучив рис. 9.2, мы видим, как классы косвенно связаны друг с другом через общих студентов. Например, классы 2 и 3 косвенно связаны друг с другом через двух общих студентов (S3 и S4). Для сравнения, классы 3 и 4 также косвенно связаны между собой, но только через одного общего студента (S5). Кроме того, мы

можем сосредоточить внимание на узлах, обозначающих конкретных студентов. В данном случае рисунок показывает, что студенты 2 и 4 косвенно взаимосвязаны между собой тем, что оба посещают класс 2.

Исследование обоих типов узлов с помощью графика бимодальной сети часто является первым шагом в изучении сети аффилированности. Однако также полезно исследовать прямые связи между узлами одного и того же типа (в данном случае речь идет о классах и студентах). Это можно сделать путем выделения и визуализации одномодальных проекций. То есть разные типы узлов рассматриваются отдельно и анализируются как обычные одномодальные сети. Например, бимодальную сеть аффилированности студентов можно проецировать таким образом: 1-я сеть – сеть студентов, где связь – это участие в одном событии; 2-я сеть – сеть событий, где связь – это наличие общих студентов, участвовавших в событии. В данном случае событием является посещение класса.

В пакете `igraph` проекции можно получить с помощью всего одной строки программного кода. Функция `bipartite.projection` возвращает список из двух объектов-сетей `igraph`. Первая сеть включает прямые связи между узлами первого типа (между студентами), а вторая сеть – прямые связи между узлами второго типа (между классами).

```
bn.pr <- bipartite.projection(bn)
bn.pr

## $proj1
## IGRAPH UNW- 6 8 --
## + attr: name (v/c), weight (e/n)
## + edges (vertex names):
## [1] S1--S2 S1--S3 S2--S3 S2--S4 S3--S4 S3--S5
## [7] S4--S5 S5--S6
##
## $proj2
## IGRAPH UNW- 4 4 --
## + attr: name (v/c), weight (e/n)
## + edges (vertex names):
## [1] C1--C2 C1--C3 C2--C3 C3--C4
```

Каждый объект из этого списка можно прочитать и обработать как обычный объект-сеть `igraph` либо внутри списка, либо создав новый объект.

```
graph.density(bn.pr$proj1)
## [1] 0.533

bn.student <- bn.pr$proj1
bn.class <- bn.pr$proj2
graph.density(bn.student)
## [1] 0.533
```

Матрицу смежности для каждой одномодальной проекции можно получить с помощью функции `get.adjacency`. В коде, приведенном ниже, обратите внимание на то, как задан атрибут ребер `weight`. Он строит матрицу смежности с числовыми значениями, где значения указывают, какое количество связей соединяет любой из узлов. Значение матрицы смежности для объекта `bn.class` показывает количество общих студентов, которыми связаны узлы-классы. Например, в матрице смежности для объекта `bn.class` видим, что классы 2 и 3 имеют вес 2. Это подтверждает наблюдение, сделанное нами ранее, о том, что классы 2 и 3 связаны друг с другом через двух общих студентов (S3 и S4). Значение матрицы смежности для объекта `bn.student` показывает количество общих классов, которыми связаны узлы-студенты. Например, в матрице смежности для объекта `bn.student` видим, что студенты 3 и 4 имеют вес 2. Это также подтверждает наблюдение о том, что студенты 3 и 4 посещают два общих класса (C2 и C3).

```
get.adjacency(bn.student, sparse=FALSE, attr="weight")
##      S1 S2 S3 S4 S5 S6
## S1  0  1  1  0  0  0
## S2  1  0  2  1  0  0
## S3  1  2  0  2  1  0
## S4  0  1  2  0  1  0
## S5  0  0  1  1  0  1
## S6  0  0  0  0  1  0

get.adjacency(bn.class, sparse=FALSE, attr="weight")
##      C1 C2 C3 C4
## C1  0  2  1  0
## C2  2  0  2  0
## C3  1  2  0  1
## C4  0  0  1  0
```

Разумеется, можно построить график каждой одномодальной проекции для визуального анализа. Кроме того, мы можем (по крайней мере, при работе с небольшими сетями) воспользоваться атрибутом ребер `weight`, чтобы исследовать относительную силу связей (рис. 9.3).

```
shapes <- c("circle", "square")
colors <- c("blue", "red")
op <- par(mfrow=c(1,2))
plot(bn.student, vertex.color="blue",
      vertex.shape="circle", main="Студенты",
      edge.width=E(bn.student)$weight*2,
      vertex.size=15, vertex.label.degree=-pi/2,
      vertex.label.dist=1.2, vertex.label.cex=1)
plot(bn.class, vertex.color="red",
      vertex.shape="square", main="Классы",
      edge.width=E(bn.student)$weight*2,
```

```
vertex.size=15,vertex.label.degree=-pi/2,
vertex.label.dist=1.2,vertex.label.cex=1)
par(op)
```

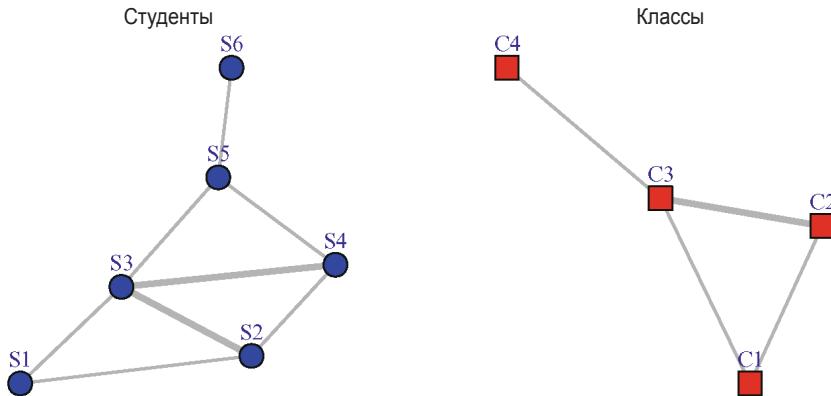


Рис. 9.3. Графики одномодальных проекций

9.3. Пример: актеры Голливуда как пример сети аффилированности

Файл данных `hwd` в пакете `UserNetR` содержит большую и более интересную сеть аффилированности, которую можно исследовать с помощью вышеупомянутых методов. Актеры Голливуда – хороший пример сети аффилированности, актеры связаны друг с другом фильмами, в которых они снялись вместе. Набор данных `hwd` представляет собой объект-биграф `igraph`. Данные получены изначально от IMDB (www.imdb.com). Набор данных содержит десять самых популярных фильмов (оценивались пользователями IMDB) в период с 1999 по 2014 год и первые 10 актеров по каждому фильму. Кроме названий фильмов и фамилий актеров, по каждому фильму представлена информация о году выхода, пользовательском рейтинге IMDB и рейтинге МПАА (т. е. G, PG, PG-13 и R), сохраненная в виде характеристик узлов.

9.3.1. Анализ полной сети аффилированности актеров Голливуда

Первые шаги в изучении этих данных заключаются в том, чтобы загрузить файл и исследовать базовую структуру сети аффилированности.

```
data(hwd)
h1 <- hwd
h1
## IGRAPH UN-B 1365 1600 --
```

```
## + attr: name (v/c), type (v/l), year (v/n),
## | IMDBrating (v/n), MPAArating (v/c)
## + edges (vertex names):
## [1] Inception--Leonardo DiCaprio
## [2] Inception--Joseph Gordon-Levitt
## [3] Inception--Ellen Page
## [4] Inception--Tom Hardy
## [5] Inception--Ken Watanabe
## [6] Inception--Dileep Rao
## [7] Inception--Cillian Murphy
## + ... omitted several edges
```

V(h1)\$name[1:10]

```
## [1] "Inception"
## [2] "Alice in Wonderland"
## [3] "Kick-Ass"
## [4] "Toy Story 3"
## [5] "How to Train Your Dragon"
## [6] "Despicable Me"
## [7] "Scott Pilgrim vs. the World"
## [8] "Hot Tub Time Machine"
## [9] "Harry Potter and the Deathly Hallows: Part 1"
## [10] "Tangled"
```

V(h1)\$type[1:10]

```
## [1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
## [10] TRUE
```

V(h1)\$IMDBrating[1:10]

```
## [1] 8.8 6.5 7.8 8.4 8.2 7.7 7.5 6.5 7.7 7.9
```

V(h1)\$name[155:165]

```
## [1] "Notting Hill"
## [2] "Eyes Wide Shut"
## [3] "The Green Mile"
## [4] "10 Things I Hate About You"
## [5] "American Pie"
## [6] "Girl, Interrupted"
## [7] "Leonardo DiCaprio"
## [8] "Joseph Gordon-Levitt"
## [9] "Ellen Page"
## [10] "Tom Hardy"
## [11] "Ken Watanabe"
```

Сводка по объекту h1 указывает на то, что hwd действительно является двудольным графом. Мы можем предположить, что связи соединяют каждого актера с фильмом, в котором он снялся. Кроме того, сводка показывает, что сеть имеет 1365 узлов и 1600 связей. Такую сеть аффилированности будет труднее расшиф-

ровать, но, учитывая уже имеющуюся информацию, можно выяснить, что у нас 160 узлов-фильмов, 1205 узлов-актеров, а 1600 связей – это результат того, что каждый фильм связан лишь с 10 актерами. (Всего у нас 1205 актеров, поскольку некоторые актеры снялись в нескольких фильмах.)

Полная сеть является слишком большой, чтобы выводить ее график, но мы можем исследовать небольшое подмножество фильмов, прежде чем проводить более детальный анализ. В качестве первого шага мы воспользуемся возможностью пакета `igraph` хранить графическую информацию внутри самого объекта-сети. В данном случае цвет и форму узлов можно задать, назначив их в качестве атрибутов вершин. (Сравните с тем, как это было сделано в предыдущем примере построения графика, где цвета и формы узлов задавались в вызове графической функции.)

```
V(h1)$shape <- ifelse(V(h1)$type==TRUE,
                      "square", "circle")
V(h1)$shape[1:10]
## [1] "square" "square" "square" "square" "square"
## [6] "square" "square" "square" "square" "square"
V(h1)$color <- ifelse(V(h1)$type==TRUE,
                      "red", "lightblue")
```

На первом графике мы посмотрим на подмножество фильмов Матрина Скорсезе, которые были выпущены за последние 15 лет. Кроме того, этот пример иллюстрирует, как создать подграф, извлекая лишь ребра, инцидентные вершинам с определенными свойствами (в данном случае имя соответствует одному из трех указанных фильмов Скорсезе). Ключевой здесь является специальная функция `inc` для итератора ребер `E()`. Функция `inc` берет последовательность вершин в качестве аргумента и возвращает инцидентные ребра. В данном случае мы извлекаем все ребра, которые инцидентны трем фильмам Скорсезе. Для получения более подробной информации см. раздел справки по `igraph`, посвященный итераторам, его легко найти с помощью `help(E)`. Получившийся график подчеркивает особую роль Леонардо Ди Каприо в фильмах Скорсезе, он является единственным актером, снявшимся во всех трех фильмах этого режиссера (рис. 9.4).

Что можно узнать из полной сети актеров Голливуда? Большую часть описательных статистик можно использовать и для анализа сетей аффилированности, но, как правило, их нужно скорректировать с точки зрения вычисления или интерпретации. Например, можно легко вычислить общую плотность сети аффилированности, но она не будет содержательной, учитывая особенности сбора сетевых данных (каждый актер по определению связан с фильмом) и отсутствие связей между узлами-фильмами или между узлами-актерами.

```
graph.density(h1)
## [1] 0.00172
```

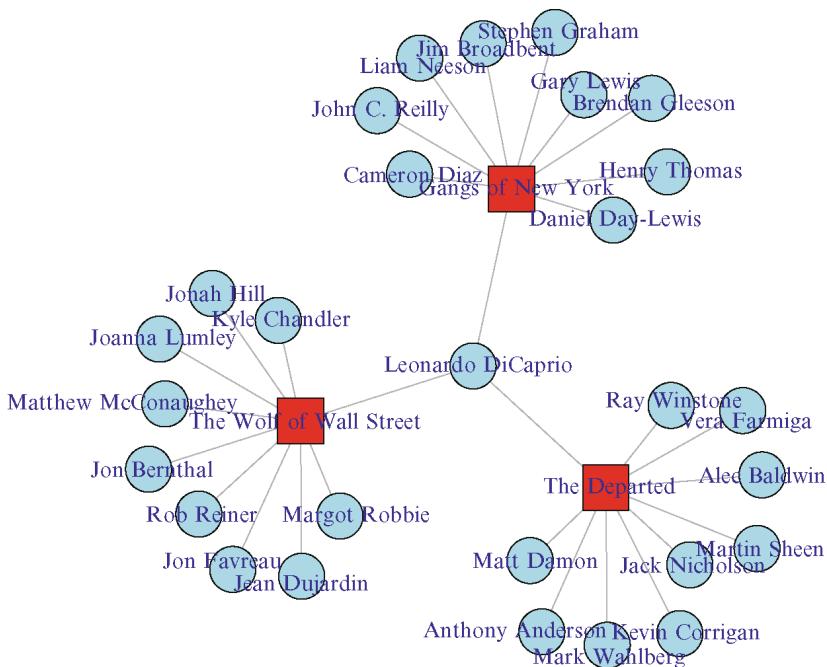


Рис. 9.4. Сеть аффилированности на примере фильмов Скорсезе

Степень узла, напротив, может дать больше информации, по крайней мере об актерах. (В этом наборе данных каждый фильм имеет одинаковую степень, равную 10.) Функция `degree` позволяет задать вершины для включения в анализ и используется, чтобы выбрать актеров (для которых характеристика узла `type` имеет значение `FALSE`).

```
table(degree(h1, v=V(h1)[type==FALSE]))  
##  
##   1   2   3   4   5   6   7   8  
## 955 165 47  23  11   2   1   1  
  
mean(degree(h1, v=V(h1)[type==FALSE]))  
## [1] 1.33
```

Эта сводка показывает, что подавляющее большинство актеров снялось только в одном фильме, но есть 15 актеров, каждый из которых снялся в пяти или более фильмах, начиная с 1999 года. Среднее количество фильмов, в котором снялся каждый актер, равно 1,33. Эту информацию можно использовать для определения самых занятых актеров за последние 15 лет. Они в большом долгу перед Гарри Потером и Бэтменом!

```
V(h1)$deg <- degree(h1)
V(h1)[type==FALSE & deg > 4]$name

## [1] "Leonardo DiCaprio" "Emma Watson"
## [3] "Richard Griffiths"  "Harry Melling"
## [5] "Daniel Radcliffe"  "Rupert Grint"
## [7] "James Franco"      "Ian McKellen"
## [9] "Martin Freeman"    "Bradley Cooper"
## [11] "Christian Bale"   "Samuel L. Jackson"
## [13] "Natalie Portman"  "Brad Pitt"
## [15] "Liam Neeson"

busy_actor <- data.frame(cbind(
  Actor = V(h1)[type==FALSE & deg > 4]$name,
  Movies = V(h1)[type==FALSE & deg > 4]$deg
))
busy_actor[order(busy_actor$Movies,decreasing=TRUE),]

##          Actor Movies
## 5  Daniel Radcliffe     8
## 11 Christian Bale      7
## 1 Leonardo DiCaprio    6
## 2  Emma Watson         6
## 3 Richard Griffiths    5
## 4  Harry Melling        5
## 6  Rupert Grint         5
## 7  James Franco         5
## 8  Ian McKellen         5
## 9 Martin Freeman        5
## 10 Bradley Cooper       5
## 12 Samuel L. Jackson    5
## 13 Natalie Portman      5
## 14 Brad Pitt             5
## 15 Liam Neeson           5
```

В этой сводке представлена информация о самых занятых актерах. Если бы мы хотели оценить популярность актеров, основываясь на популярности фильмов, в которых они снялись, мы сделали бы это, использовав характеристики каждого фильма, в котором появился этот актер. В отличие от предыдущего примера, это будет сделать чуть сложнее, однако вполне выполнимо, если воспользоваться возможностями пакета *igraph* по поиску смежных соседей для любого узла графа.

Программный код, приведенный ниже, проходит по узлам-актерам сети и суммирует рейтинг IMDB по всем соседям каждого узла. Обратите внимание на то, что цикл лишь присваивает просуммированные значения рейтинга IMDB узлам-актерам (первые 160 узлов-фильмов в вычислениях не участвуют).

```
for (i in 161:1365) {
  V(h1)[i]$totrating <- sum(V(h1)[nei(i)]$IMDBrating)
}
```

Получив просуммированные значения, мы можем снова исследовать самых популярных актеров, теперь основываясь как на количестве, так и на общей популярности этих фильмов.

```
max(V(h1)$totrating,na.rm=TRUE)
## [1] 60.9
pop_actor <- data.frame(cbind(
  Actor = V(h1)[type==FALSE & totrating > 40]$name,
  Popularity = V(h1)[type==FALSE &
    totrating > 40]$totrating))
pop_actor[order(pop_actor$Popularity,decreasing=TRUE),]
##          Actor Popularity
## 3 Daniel Radcliffe      60.9
## 4 Christian Bale        55.5
## 1 Leonardo DiCaprio     49.6
## 2 Emma Watson            45
## 5 Brad Pitt                40.5
```

Наконец, характеристики сети всегда можно исследовать с помощью более традиционных графических и статистических подходов. Например, мы можем узнать, снимаются ли самые занятые актеры в наиболее популярных фильмах. Сначала вычислим характеристику `avgrating`, которая основывается на среднем, а не суммарном значении рейтинга IMDB. Затем с помощью простой диаграммы рассеяния и линейной регрессии исследуем взаимосвязь между количеством фильмов, в которых снялся актер, и средним рейтингом фильма. Результаты свидетельствуют об отсутствии прочной взаимосвязи между занятостью актера и популярностью фильмов. Однако диаграмма рассеяния показывает, что актер, который снимается в менее популярных фильмах, с большей вероятностью появится лишь в одном или двух фильмах (рис. 9.5).

```
for (i in 161:1365) {
  V(h1)[i]$avgrating <- mean(V(h1)[nei(i)]$IMDBrating)
}
num <- V(h1)[type==FALSE]$deg
avgpop <- V(h1)[type==FALSE]$avgrating
summary(lm(avgpop ~ num))

##
## Call:
## lm(formula = avgpop ~ num)
##
## Residuals:
##   Min    1Q Median    3Q   Max
## -3.986 -0.433  0.198  0.617 1.614
##
## Coefficients:
```

```

##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 7.3387    0.0544 134.91 <2e-16
## num         0.0471    0.0353   1.34    0.18
##
## Residual standard error: 0.96 on 1203 df
## Multiple R-sq:  0.00148, Adjusted R-sq:  0.000653
## F-statistic: 1.79 on 1 and 1203 DF,  p-value: 0.182

scatter.smooth(num,avgpop,col="lightblue",
               ylim=c(2,10),span=.8,
               xlab="Занятость актера",
               ylab="Средн. популярность фильма")

```

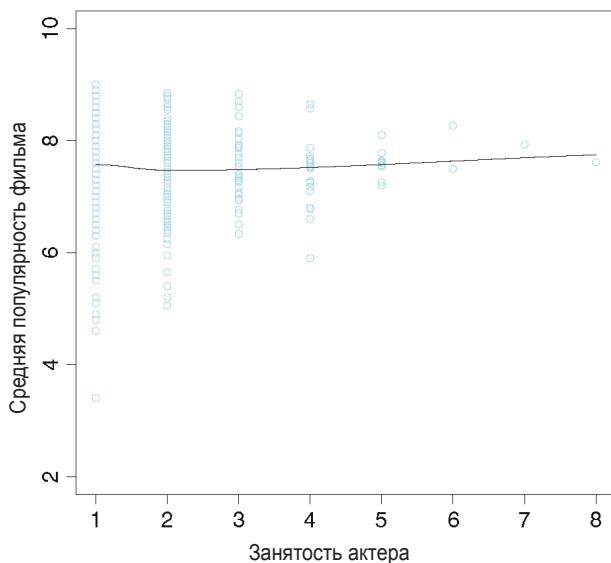


Рис. 9.5. Зависимость между занятостью актера и популярностью фильма

9.3.2. Анализ проекций актеров и фильмов

Выполнив те же процедуры, что и в разделе 9.2.4, можно создать и проанализировать две проекции сети аффилированности актеров Голливуда. В результате получим сеть актеров, в которой актеры связаны между собой, если снялись вместе в одном и том же фильме, и сеть фильмов, в которой фильмы связаны между собой, если в них снимались одни и те же актеры. Таким образом, проекция актеров будет состоять из 1205 узлов, а проекция фильмов – из 160 узлов.

```

h1.pr <- bipartite.projection(h1)
h1.act <- h1.pr$proj1
h1.mov <- h1.pr$proj2

```

```

h1.act
## IGRAPH UNW- 1205 6903 --
## + attr: name (v/c), year (v/n), IMDBrating
## | (v/n), MPAArating (v/c), shape (v/c),
## | color (v/c), deg (v/n), totrating (v/n),
## | avgrating (v/n), weight (e/n)
## + edges (vertex names):
## [1] Leonardo DiCaprio--Joseph Gordon-Levitt
## [2] Leonardo DiCaprio--Ellen Page
## [3] Leonardo DiCaprio--Tom Hardy
## [4] Leonardo DiCaprio--Ken Watanabe
## [5] Leonardo DiCaprio--Dileep Rao
## + ... omitted several edges

h1.mov
## IGRAPH UNW- 160 472 --
## + attr: name (v/c), year (v/n), IMDBrating
## | (v/n), MPAArating (v/c), shape (v/c),
## | color (v/c), deg (v/n), totrating (v/n),
## | avgrating (v/n), weight (e/n)
## + edges (vertex names):
## [1] Inception--The Wolf of Wall Street
## [2] Inception--Django Unchained
## [3] Inception--The Departed
## [4] Inception--Gangs of New York
## [5] Inception--Catch Me If You Can
## + ... omitted several edges

```

На этом рисунке показана сеть аффилированности «фильмы», в которой размеры узлов зависят от рейтинга IMDB, поэтому самые популярные фильмы имеют максимальные размеры узлов (рис. 9.6).

```

op <- par(mar = rep(0, 4))
plot(h1.mov, vertex.color="red",
      vertex.shape="circle",
      vertex.size=(V(h1.mov)$IMDBrating)-3,
      vertex.label=NA)
par(op)

```

Некоторые описательные статистики дают более полную информацию о сети голливудских фильмов. Несмотря на наличие нескольких обособленных фильмов (т. е. фильмов, в которых нет актеров, которые могли бы связать их с другими фильмами), большая часть фильмов (148) формирует гигантскую связную компоненту¹.

¹ В теории графов гигантской компонентой называют компоненту наибольшего размера. Здесь и далее термины «гигантская компонента» и «наибольшая компонента» используются как синонимы. – *Прим. пер.*

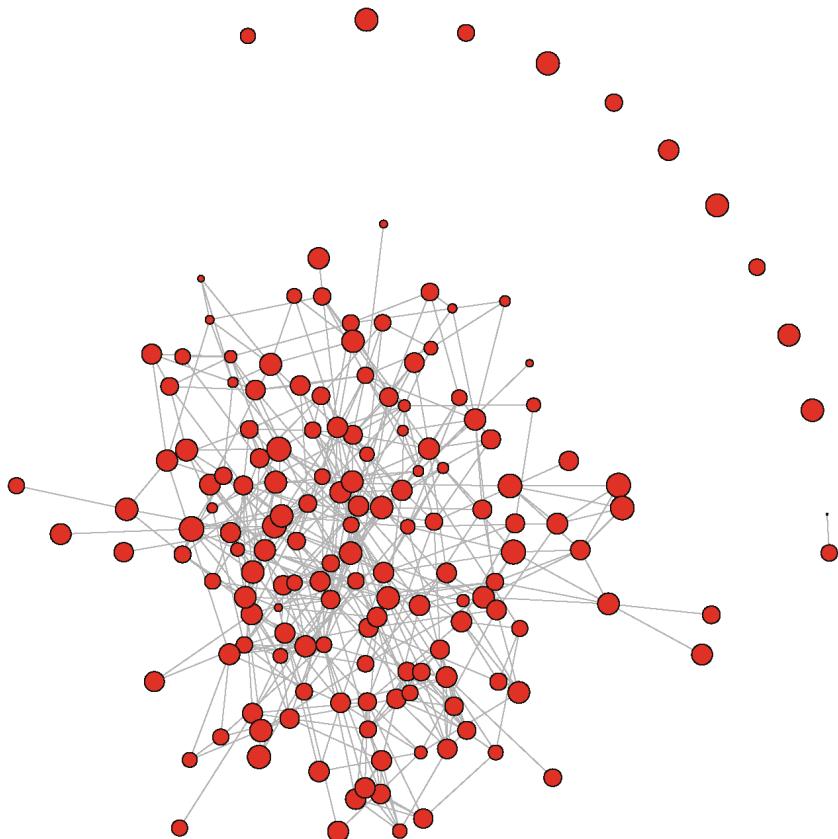


Рис. 9.6. Сеть аффилированности «фильмы»

```
graph.density(h1.mov)
## [1] 0.0371
no.clusters(h1.mov)
## [1] 12
clusters(h1.mov)$csize
## [1] 148   1    1    1    1    1    1    2    1    1    1
## [12]    1
table(E(h1.mov)$weight)

##
##    1    2    3    4    5    6    7    10
## 411  21  12  16    6   1    2    3
```

Полную сеть фильмов можно отфильтровать, чтобы отдельно проанализировать эту компоненту. На рисунке, приведенном ниже, ширина ребра равна квад-

ратному корню из значения атрибута ребер `weight`. В итоге получаем связи различной толщины, чем толще связь между фильмами, тем большее количество общих актеров у них (рис. 9.7).

```
h2.mov <- induced.subgraph(h1.mov,
  vids=clusters(h1.mov)$membership==1)
```

```
plot(h2.mov, vertex.color="red",
  edge.width=sqrt(E(h1.mov)$weight),
  vertex.shape="circle",
  vertex.size=(V(h2.mov)$IMDBrating)-3,
  vertex.label=NA)
```

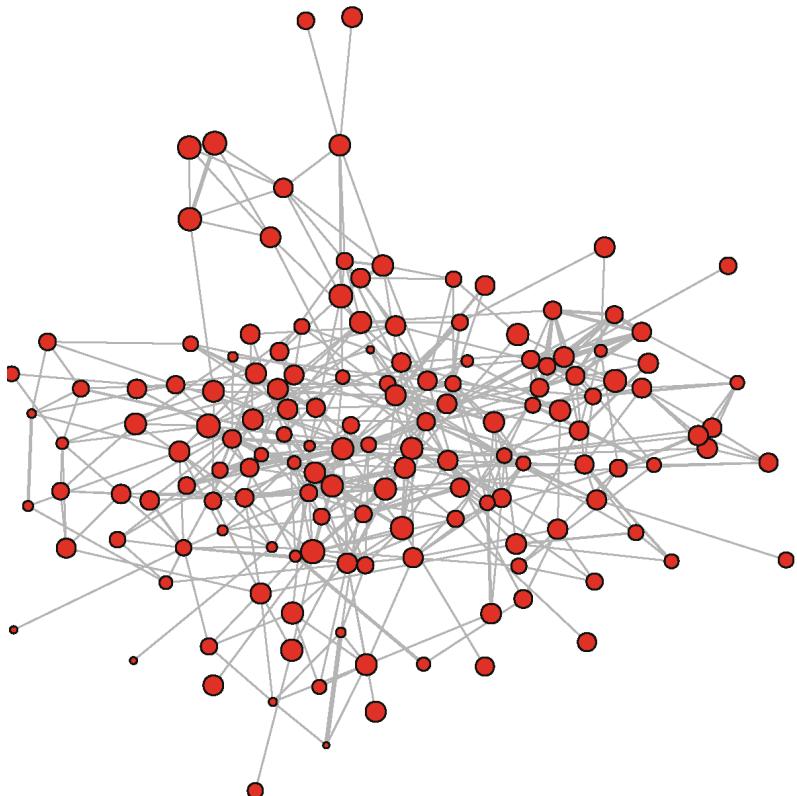


Рис. 9.7. Гигантская компонента сети аффилированности «фильмы»

Построенный график по-прежнему громоздок, и относительно высокая плотность в определенной степени затрудняет интерпретацию любых характеристик сети. Чтобы исправить это, мы можем вывести ядра более высокой степени и тем

самым детальнее рассмотреть наиболее взаимосвязанные между собою узлы (см. главу 8 для получения дополнительной информации.) Такая сеть будет уже достаточно компактной, поэтому мы можем добавить метки узла, чтобы упростить интерпретацию. Мы увидим, что наиболее плотно взаимосвязанные участки сети соответствуют популярным сериям фильмов («Гарри Поттер», «Бэтмен», «Звездные войны» и «Хоббит»). В этом есть смысл, потому что в фильмах одного цикла, как правило, многие роли или большинство ролей играют одни и те же актеры (рис. 9.8).

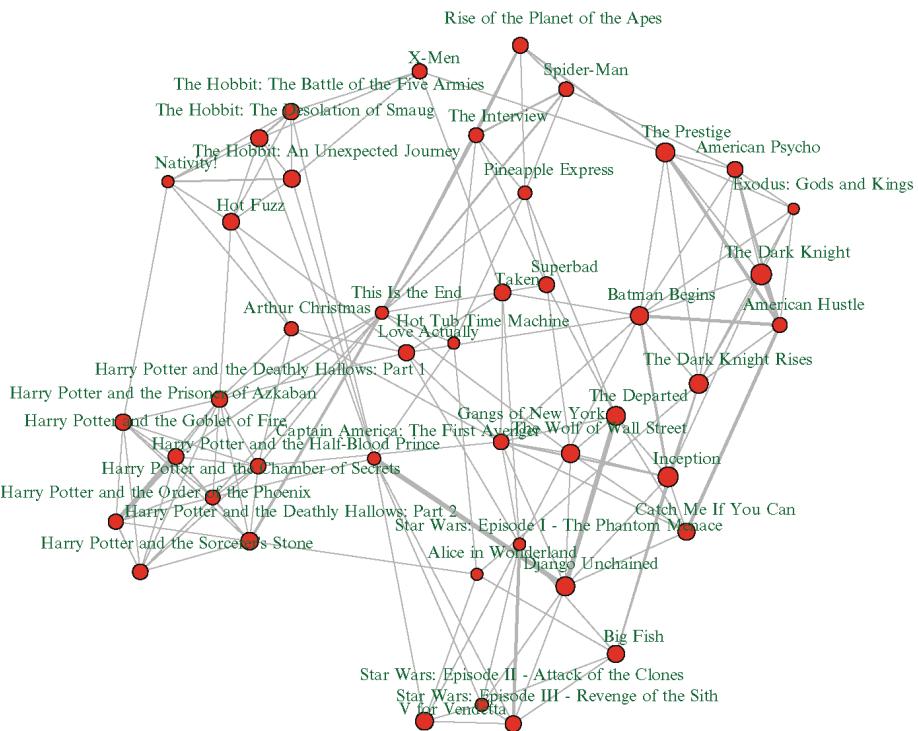


Рис. 9.8. Ядро сети аффилированности «фильмы»

```
table(graph.coreness(h2.mov))
```

```

##   1   2   3   4   5   6   7
## 11  5 23 65 29  7  8

```

```
h3.mov <- induced.subgraph(h2.mov,  
vids=graph.coreness(h2.mov)>4)  
h3.mov
```

IGRAPH UNW- 44 158 --

```
## + attr: name (v/c), year (v/n), IMDBrating
## | (v/n), MPAArating (v/c), shape (v/c),
## | color (v/c), deg (v/n), totrating (v/n),
## | avgrating (v/n), weight (e/n)
## + edges (vertex names):
## [1] Inception--The Wolf of Wall Street
## [2] Inception--Django Unchained
## [3] Inception--The Dark Knight Rises
## [4] Inception--The Dark Knight
## [5] Inception--The Departed
## + ... omitted several edges

plot(h3.mov, vertex.color="red",
      vertex.shape="circle",
      edge.width=sqrt(E(h1.mov)$weight),
      vertex.label.cex=0.7, vertex.label.color="darkgreen",
      vertex.label.dist=0.3,
      vertex.size=(V(h3.mov)$IMDBrating)-3)
```

ЧАСТЬ IV

МОДЕЛИРОВАНИЕ

Глава 10. Модели случайных сетей	155
Глава 11. Статистические модели сетей	172
Глава 12. Модели динамических сетей	198
Глава 13. Имитационные модели....	227

Глава 10

Модели случайных сетей

10.1. Предназначение моделей сетей	156
10.2. Модели формирования и структуры сети	157
10.3. Сравнение моделей случайных графов с наблюдаемыми сетями.....	169

Что это? Школа для муравьев? Как мы можем научить детей читать... если они даже не влезут в это здание?

Дерек Золландер в фильме «Образцовый самец»
после осмотра миниатюрной модели
школьного здания

10.1. Предназначение моделей сетей

Согласно [Linton Freeman, 2004], современному анализу социальных сетей присущи четыре основные характеристики:

- 1) он обусловлен интуитивным пониманием структуры, основанным на связях между акторами социальной сети;
- 2) он опирается на систематизированные эмпирические данные;
- 3) он активно использует графику;
- 4) он использует математические и/или вычислительные модели.

Предыдущие разделы этой книги были посвящены первым трем характеристикам. Теперь последующие четыре главы будут сосредоточены на рассмотрении последнего пункта, моделировании сетей. Научные модели являются упрощенными описаниями реального мира, которые используются для прогнозирования (объяснения) характеристик или поведения интересующих объектов. В науке о сетях модели используются аналогичным образом. С помощью моделей сетей мы можем выйти за рамки простого описания, чтобы создать и протестировать гипотезы о сетевых структурах, процессах их формирования и динамике сетей.

В этой главе освещается ряд базовых математических моделей, описывающих структуру и формирование сетей. Эти модели сыграли важную роль в науке о сетях, однако и сейчас они полезны тем, что дают понимание фундаментальных свойств социальных сетей, служат в качестве базовых или эталонных моделей для наблюдаемых социальных сетей и являются основой для имитационного моделирования более сложных сетей.

Более десятка функций предлагает пакет `igraph` для генерации случайных сетей на основе различных математических алгоритмов и эвристик. Названия всех этих функций заканчиваются на «game», например `barabasi.game()` строит свободно масштабируемые случайные графы, основанные на модели Барабаши–Альберта (предложена в 1999 году). В оставшейся части этой главы будет представлен ряд важных математических моделей сетей, имеющихся в пакете `igraph`, а также некоторые примеры того, как использовать эти модели для исследования свойств сетей и сравнения с имеющимися социальными сетями.

10.2. Модели формирования и структуры сети

10.2.1. Модель случайного графа Эрдеша–Ренъи

Исторически наиболее ранней и по-прежнему самой важной математической моделью структуры сети является модель случайного графа, впервые предложенная Полом Эрдешем и Альфредом Ренъи в конце 1950 – начале 1960-х годов [Newman 2010]. Ее иногда называют *моделью пуассоновского случайного графа* (*Poisson random graph model*) из-за пуассоновского распределения степеней, или иногда просто *моделью случайного графа* (*random graph model*). Модель выглядит довольно просто – $G(n, m)$, где G – случайный граф с n вершинами, соединенными m ребрами, которые выбираются случайным образом из числа всех возможных ребер. Эквивалентная модель, с которой проще работать, – $G(n, p)$, где вместо определения количества ребер m каждое ребро появляется в графе с вероятностью p . Эта модель случайного графа реализована в пакете `igraph` с помощью функции `erdos.renyi.game()`. Для построения случайного графа задаем количество вершин в графе, а также либо количество ребер, либо вероятность появления ребра. С помощью аргумента `type` определяем способ интерпретации второго аргумента (как вероятность появления ребра p или как количество ребер m)¹.

```
library(igraph)
g <- erdos.renyi.game(n=12,10,type='gnm')
g

## IGRAPH U--- 12 10 -- Erdos renyi (gnm) graph
## + attr: name (g/c), type (g/c), loops (g/l),
## | m (g/n)
## + edges:
## [1] 4-- 5 3-- 6 2-- 8 1-- 9 8-- 9 8--10 1--11
## [8] 6--11 8--12 9--12

graph.density(g)
## [1] 0.152
```

О случайной природе графов можно судить, построив и исследовав несколько графов. В каждом случае количество вершин остается одинаковым, а вот связи за-даются случайным образом (рис. 10.1).

```
op <- par(mar=c(0,1,3,1),mfrow=c(1,2))
plot(erdos.renyi.game(n=12,10,type='gnm'),
      vertex.color=2,
      main="Первый случайный граф")
```

¹ То есть с помощью аргумента `type` задаем тип модели случайного графа. Значение `gnp` задает модель $G(n, p)$. Значение `gnm` задает модель $G(n, m)$. – Прим. пер.

```
plot(erdos.renyi.game(n=12, 10, type='gnm'),
      vertex.color=4,
      main="Второй случайный граф")
par(op)
```

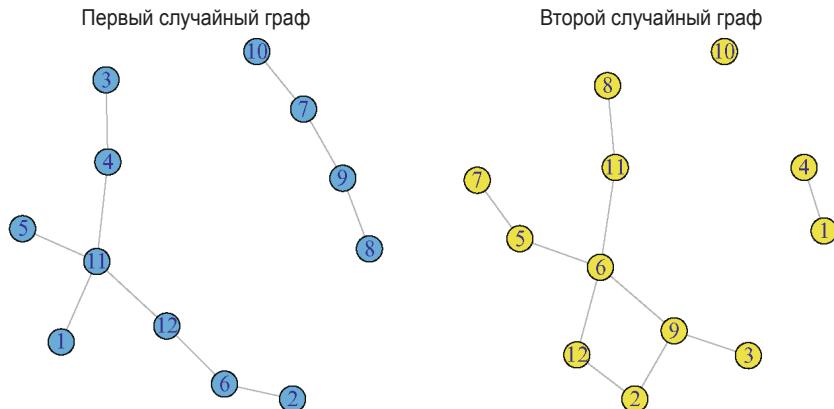


Рис. 10.1. Два случайных графа

Несмотря на простоту модели случайного графа, она позволяет сделать ряд важных наблюдений касательно структуры сети. Во-первых, как уже говорилось выше, для большого значения n сеть будет иметь пуассоновское распределение степеней (рис. 10.2).

```
g <- erdos.renyi.game(n=1000, .005, type='gnp')
plot(degree.distribution(g),
      type="b", xlab="Степень", ylab="Процент случаев")
```

Более неожиданным оказалось то, что случайные графы становятся полностью связными при довольно низких значениях средней степени. Это означает, что даже когда ребра определяются случным образом, для получения связной сети (т. е. сети, состоящей только из одной компоненты) каждый ее конкретный участник не должен быть соединен со слишком большим количеством других участников. Более точно, при $p > \frac{\ln n}{n}$ случайный граф с большой вероятностью превращается в одну гигантскую компоненту [Newman, 2010]. Средняя степень случайного графа с зависит от размера графа и вероятности появления ребра:

$$c = (n - 1)p.$$

Таким образом, это означает, что если поставить серию экспериментов с различным количеством вершин (скажем, от 100 до 10 000), то средняя степень, необходимая для построения полностью связной сети, будет меньше 12. Полученный случайный граф и соответствующий график демонстрируют эту взаимосвязь (рис. 10.3).

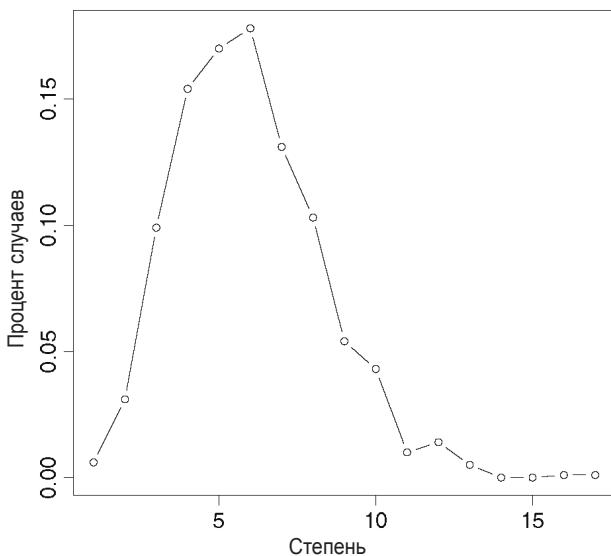


Рис. 10.2. Распределение степеней
для графа G с $n = 1000$ и $p = 0,005$

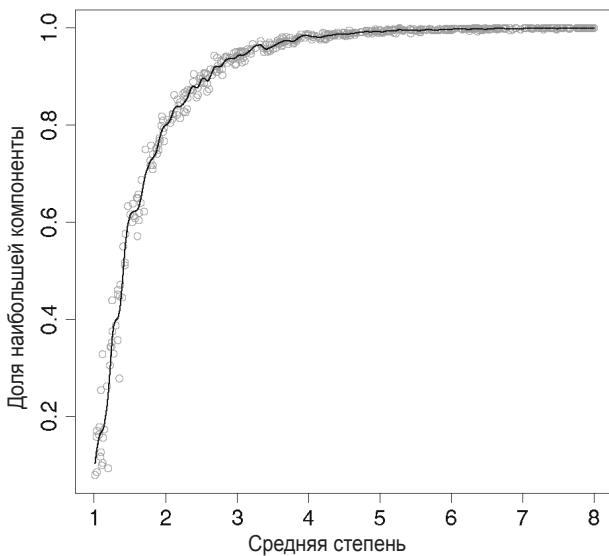


Рис. 10.3. Зависимость связности от средней степени
в случайных графах

```

crnd <- runif(500,1,8)
cmp_prp <- sapply(crnd,function(x)
    max(clusters(erdos.renyi.game(n=1000,
        p=x/999))$csize)/1000)
smoothingSpline <- smooth.spline(crnd,cmp_prp,
    spar=0.25)
plot(crnd,cmp_prp,col='grey60',
    xlab="Средн. степень",
    ylab="Доля наибольшей компоненты")
lines(smoothingSpline,lwd=1.5)

```

Этот программный код требует небольшой расшифровки для понимания. Сначала создается вектор из 500 случайных значений в диапазоне от 1 до 8. Он будет использоваться в качестве вводной информации для функции, которая построит 500 случайных графов со средней степенью от 1 до 8. Затем используется функция `sapply()`, чтобы неоднократно вызвать функцию случайного графа и записать результаты в объект `cmp_prp`. Сама функция каждый раз строит случайный граф, состоящий из 1000 узлов, p равно среднему значению степени, поделенному на 999 (взято из формулы выше, $p = \frac{c}{n-1}$). Как только случайный граф построен, вычисляется размер наибольшей компоненты с помощью функции `clusters()`. Затем это число делится на размер сети (1000), чтобы вычислить долю сети, объясненную наибольшей компонентой. Результаты показывают, что для случайных сетей размером 1000 узлов сеть становится почти или полностью связной, когда средняя степень принимает значение больше 4 или 5.

Другое удивительное свойство случайных графов заключается в том, что связные случайные графы довольно компактны. То есть диаметр наибольшей компоненты в случайном графе остается относительно небольшим, даже если сеть имеет огромный размер.

```

n_vect <- rep(c(50,100,500,1000,5000),each=50)
g_diam <- sapply(n_vect,function(x)
    diameter(erdos.renyi.game(n=x,p=6/(x-1))))
library(lattice)
bwplot(g_diam ~ factor(n_vect), panel = panel.violin,
    xlab = "Размер сети", ylab = "Диаметр")

```

Вышеупомянутый программный код выполняет в общей сложности 250 имитаций, строя случайные графы с количеством узлов от 50 до 5000. Как показывает график, несмотря на то что размер графов возрастает на два порядка, диаметр наибольшей компоненты в каждом графе растет гораздо медленнее, увеличившись примерно с 5 до 10 (рис. 10.4). Таким образом, случайные графы характеризуются двумя свойствами: они становятся полностью связными при низком значении

средней степени, а диаметр графа увеличивается гораздо медленнее размера графа, возможно, это обусловлено некоторыми характеристиками «малого мира», которыми обладают реальные социальные сети (Newman 2010).

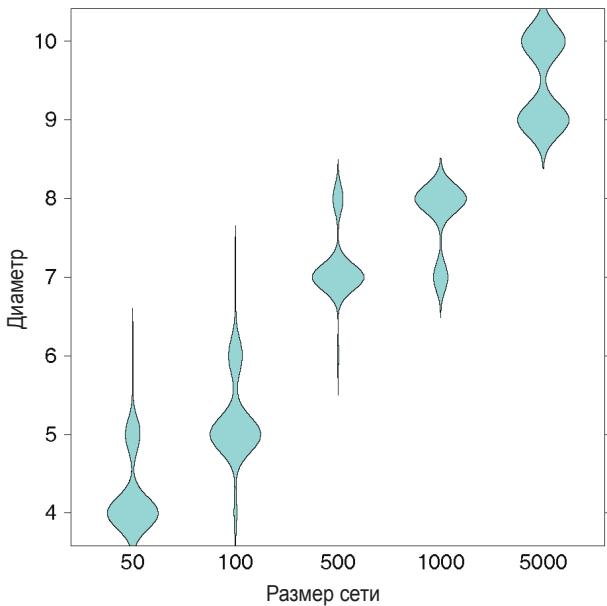


Рис. 10.4. Взаимосвязь между размером и диаметром случайного графа, средняя степень = 6

10.2.2. Модель малого мира

Модель случайного графа Эрдеша–Ренни имеет одно главное ограничение, в силу которого она не может описывать свойства многих реальных социальных сетей. В частности, полностью случайные графы имеют распределения степеней, которые не соответствуют реальным сетям, и, кроме того, они имеют довольно низкий уровень кластеризации (транзитивности).

Тип модели, названный *моделью малого мира* (*small-world model*)¹ Уоттса–Стротгатца (1998), строит случайные графы, которые более реалистичны, чем графы Эрдеша–Ренни. В частности, сети на основе модели малого мира имеют более реалистичный уровень транзитивности при небольшом диаметре.

Исходный вид модели малого мира – круг узлов, где каждый узел соединен со своими с ближайшими соседями (образуя обычную структуру решетки). Затем осуществляется *переключение* (*rewiring*) небольшого количества ребер, в ходе которого они удаляются и заменяются другими ребрами, соединяющими два случайно выбранных узла. Если вероятность переключения p равна 0, получаем сеть с ис-

¹ В качестве синонима также используется термин «модель тесного мира». – Прим. пер.

ходной решеткой. Если p равняется 1, получаем случайный граф Эрдеша–Рены. Главным интересным открытием Уоттса и Строгатца (а также других ученых) было то, что для значительного уменьшения диаметра сети требуется переключить лишь небольшое количество ребер.

На рис. 10.5 показаны сети малого мира с использованием различных вероятностей переключения ребер. Для построения сети малого мира из 30 узлов вызывается функция `watts.strogatz.game()`. Опция `nei=2` (задает число соседей) запускает сеть, в которой каждый узел с обеих сторон связан с двумя ближайшими соседями. В итоге степень каждого узла равна 4.

```
g1 <- watts.strogatz.game(dim=1, size=30, nei=2, p=0)
g2 <- watts.strogatz.game(dim=1, size=30, nei=2, p=.05)
g3 <- watts.strogatz.game(dim=1, size=30, nei=2, p=.20)
g4 <- watts.strogatz.game(dim=1, size=30, nei=2, p=1)
op <- par(mar=c(2,1,3,1),mfrow=c(2,2))
plot(g1,vertex.label=NA,layout=layout with kk,
     main=expression(paste(italic(p)," = 0")))
plot(g2,vertex.label=NA,
     main=expression(paste(italic(p)," = .05")))
plot(g3,vertex.label=NA,
     main=expression(paste(italic(p)," = .20")))
plot(g4,vertex.label=NA,
     main=expression(paste(italic(p)," = 1")))
par(op)
```

Результаты имитационного моделирования, приведенные в графике ниже, показывают, насколько быстро переключение уменьшает диаметр сети в модели малого мира. В сети, состоящей из 100 узлов, каждый узел начинает соединяться с двумя соседями с каждой стороны. Таким образом, график состоит из 200 ребер. Исходный диаметр сети равен 25 (то есть максимально возможное количество шагов, требующееся для того, чтобы достичь одного узла из другого, равно 25).

```
g100 <- watts.strogatz.game(dim=1,size=100,nei=2,p=0)
g100
## IGRAPH U--- 100 200 -- Watts-Strogatz random graph
## + attr: name (g/c), dim (g/n), size (g/n),
## | nei (g/n), p (g/n), loops (g/l), multiple
## | (g/l)
## + edges:
## [1] 1-- 2 2-- 3 3-- 4 4-- 5 5-- 6 6-- 7
## [7] 7-- 8 8-- 9 9--10 10--11 11--12 12--13
## [13] 13--14 14--15 15--16 16--17 17--18 18--19
## [19] 19--20 20--21 21--22 22--23 23--24 24--25
## [25] 25--26 26--27 27--28 28--29 29--30 30--31
## [31] 31--32 32--33 33--34 34--35 35--36 36--37
## + ... omitted several edges
diameter(g100)
## [1] 25
```

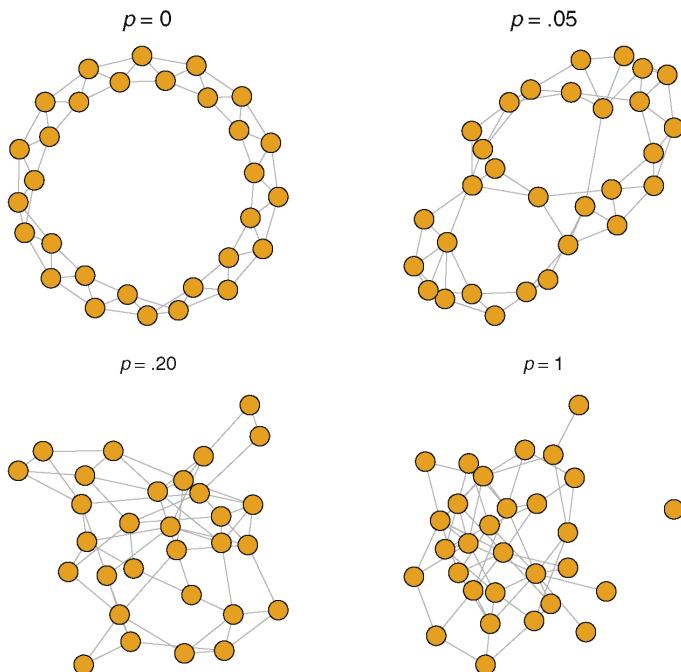


Рис. 10.5. Модели малого мира
с возрастающей вероятностью переключения ребер

В ходе имитационного моделирования строится 300 сетей, после каждого построения 10 моделей количество переключаемых ребер возрастает на 1 в диапазоне от 1 до 30. То есть сначала строятся 10 сетей с 1 переключаемым ребром, затем 10 сетей с 2 переключаемыми ребрами и т. д., пока не будут построены итоговые 10 сетей с 30 переключаемыми ребрами. Поскольку мы знаем, сколько ребер содержит каждый граф (200), вероятность переключения можно вычислить как количество переключенных ребер, поделенное на общее количество ребер. Если переключено 30 ребер, вероятность равна 0,15.

```
p_vect <- rep(1:30,each=10)
g_diam <- sapply(p_vect,function(x)
diameter(watts.strogatz.game(dim=1, size=100,
nei=2, p=x/200)))
smoothingSpline = smooth.spline(p_vect, g_diam,
spar=0.35)
plot(jitter(p_vect,1),g_diam,col='grey60',
xlab="Количество переключенных ребер",
ylab="Диаметр")
lines(smoothingSpline,lwd=1.5)
```

График показывает, что после переключения всего 10 ребер ($p = 0,05$) диаметр сети сжимается, по меньшей мере, на 60%, с 25 до 10 (рис. 10.6).

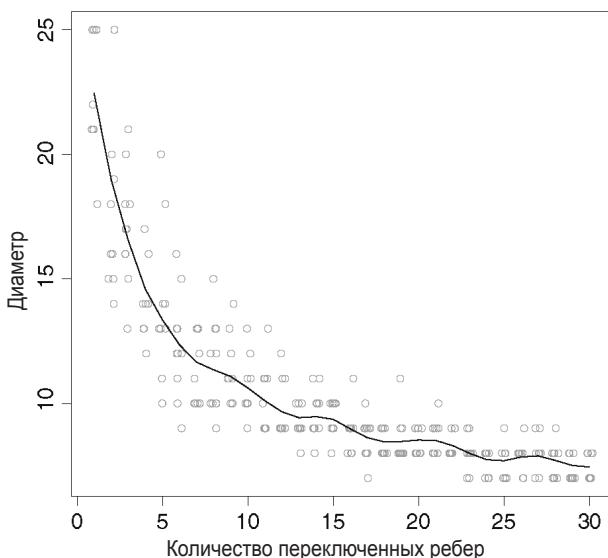


Рис. 10.6. Взаимосвязь между вероятностью переключения ребер и диаметром сети для модели малого мира

10.2.3. Свободно масштабируемые модели

Важным ограничением двух предыдущих математических моделей является то, что они строят графы со степенными распределениями, не характерными для многих реальных социальных сетей. Многочисленные исследования показали, что большое количество существующих сетей имеет степенное распределение с «тяжелым хвостом», которое приблизительно соответствует степенному закону. Их обычно называют *свободно масштабируемыми сетями (scale-free network)*¹. Например, и сеть сексуальных партнеров, и Всемирная паутина являются свободно масштабируемыми ([Broder at el., 2000], [Liljeros at al., 2001]). То есть некоторые участники характеризуются большим количеством сексуальных партнеров (высокая степень), однако у большинства людей число партнеров остается невысоким. Аналогично некоторые веб-сайты связаны с очень большим количеством других веб-сайтов, однако большинство веб-сайтов связано лишь с несколькими сайтами.

Как возникает этот степенной закон в свободно масштабируемых сетях? Ряд ученых исследовал этот вопрос и пришел к выводу, что ответ на него может дать процесс формирования сети под названием *кумулятивное преимущество (cumulative advantage)*, или *предпочтительное присоединение (preferential attachment)*. То есть в процессе роста сети новые узлы с большей вероятностью образуют связи с теми узлами, которые уже характеризуются большим количеством связей в силу их выдающегося положения в сети. Было доказано, что именно феномен «богатый

¹ В качестве синонимов также используются термины «безмасштабные сети», «масштабно-инвариантные сети». – Прим. пер.

богатеет» ведет к возникновению степенных законов в сетях ([de Solla Price, 1976], [Barabási, Albert 1999]).

Модель предпочтительного присоединения Барабаши–Альберта реализована в пакете `igraph` с помощью функции `barabasi.game()`. Здесь используется более сложный алгоритм, чем в предыдущих моделях, отчасти в силу того, что речь идет о модели роста сети, а не просто о модели статичной структуры.

На рис. 10.7 показана сеть из 500 узлов, которая построена с помощью модели предпочтительного присоединения. По умолчанию алгоритм работает следующим образом: когда в сеть добавляется новый узел, он соединяется с уже существующим узлом сети с вероятностью, пропорциональной степени этого узла. Таким образом, некоторые узлы в сети будут иметь гораздо больше связей, чем подавляющая часть остальных. Программный код позволяет выделить эти *хабы* (*hubs*), помечая цветом узлы со степенью > 9 .

```
g <- barabasi.game(500, directed = FALSE)
V(g)$color <- "lightblue"
V(g)[degree(g) > 9]$color <- "red"
rescale <- function(nchar,low,high) {
min_d <- min(nchar)
max_d <- max(nchar)
rscl <- ((high-low)*(nchar-min_d))/(max_d-min_d)+low
rscl
}
node_size <- rescale(degree(g), 2, 8)
plot(g, vertex.label = NA, vertex.size = node_size)
```

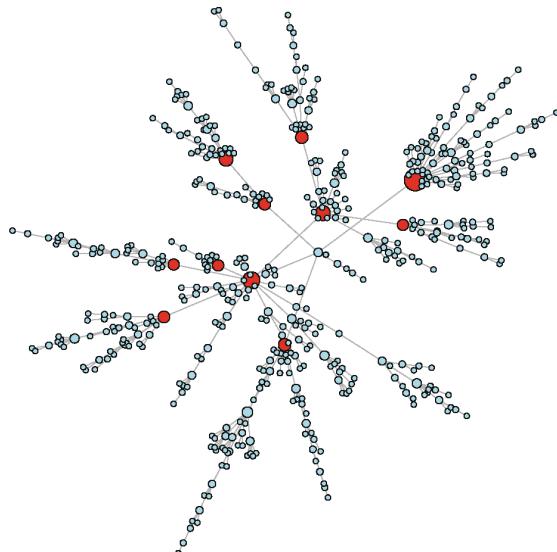


Рис. 10.7. Пример свободно масштабируемой сети с настройками по умолчанию

Распределение с «тяжелым хвостом» можно проанализировать несколькими способами. В данном примере медиана степени равна 1, а среднее равно 2. Наивысшая степень равна 27. Это легко увидеть на рис. 10.8. На графике слева показано исходное степенное распределение, в то время как на графике справа показано то же самое степенное распределение, но в логлинейной шкале. Если распределение подчиняется степенному закону, точки данных должны выстроиться вдоль прямой линии (по крайней мере, в районе хвоста). (Обратите внимание на то, что для небольших сетей довольно трудно оценить степенные зависимости.)

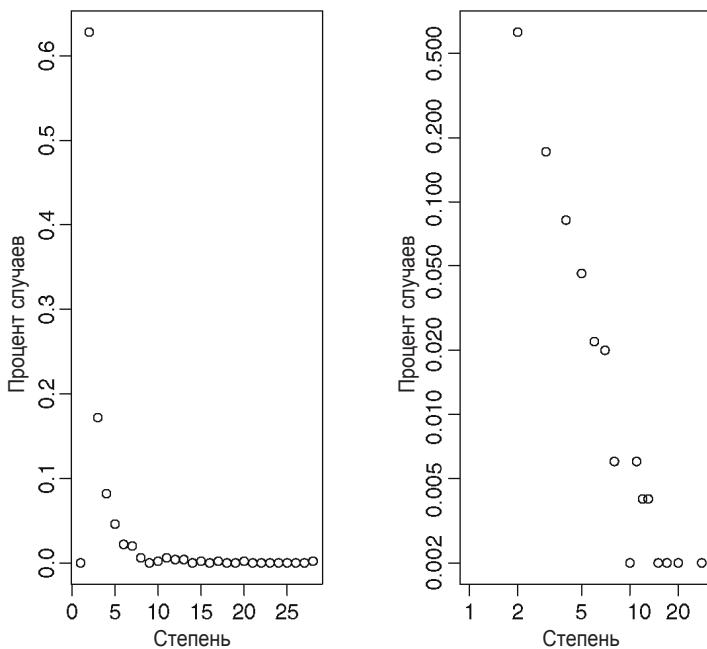


Рис. 10.8. Степенное распределение для свободно масштабируемой модели (линейная и логлинейная шкалы)

```
median(degree(g))
## [1] 1
mean(degree(g))
## [1] 2
table(degree(g))

##
##    1    2    3    4    5    6    7    9   10   11   12   14
## 314   86   41   23   11   10    3    1    3    2    2    1
##   16   19   27
##    1    1    1
```

```
op <- par(mfrow=c(1,2))
plot(degree.distribution(g),xlab="Степень",
     ylab="Процент случаев")
plot(degree.distribution(g),log='xy',
     xlab="Степень",ylab="Процент случаев")
par(op)
```

Пользователь может задать ряд параметров для функции `barabasi.game()`, чтобы построить разные сети предпочтительного присоединения. Например, программный код, приведенный ниже, строит сеть, которая, возможно, будет выглядеть более реалистично, чем та, что показана на предыдущем рисунке. Здесь, вместо того чтобы соединять каждый новый узел с еще одним узлом, используется параметр `out.dist`, задающий распределение вероятностей. Теперь в 25% случаев новый узел вообще не будет соединен ни с одним узлом (т. е. будет изолированным), в 50% случаев он будет соединен с одним узлом, в 25% случаев – с двумя узлами. Кроме того, используется параметр `zero.appeal`, чтобы немного повысить вероятность установления связей между новыми узлами и уже существующими изолированными узлами. Рисунок 10.9 показывает, что получившийся график содержит изолированные узлы и несколько меньшее количество узлов с высокой степенью.

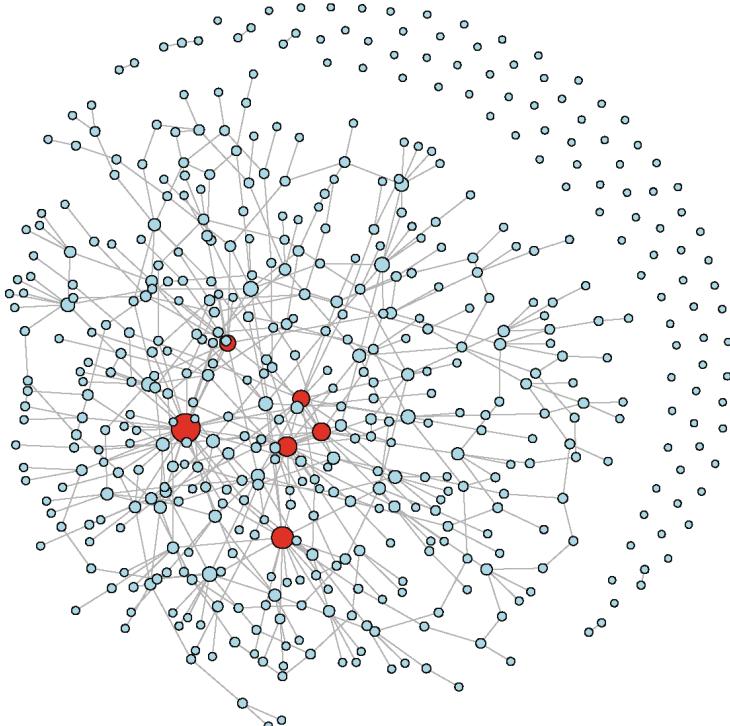


Рис. 10.9. Пример свободно масштабируемой сети с измененными настройками

```

g <- barabasi.game(500, out.dist = c(0.25, 0.5, 0.25),
  directed = FALSE, zero.appeal = 1)
V(g)$color <- "lightblue"
V(g)[degree(g) > 9]$color <- "red"
node_size <- rescale(degree(g), 2, 8)
plot(g, vertex.label = NA, vertex.size = node_size)

```

Наконец, чтобы проиллюстрировать рост сети предпочтительного присоединения, приведем рисунок, на котором показано, как выглядит сеть на четырех различных этапах, т. е. строим сеть размером 10, 25, 50 и 100 узлов (рис. 10.10).

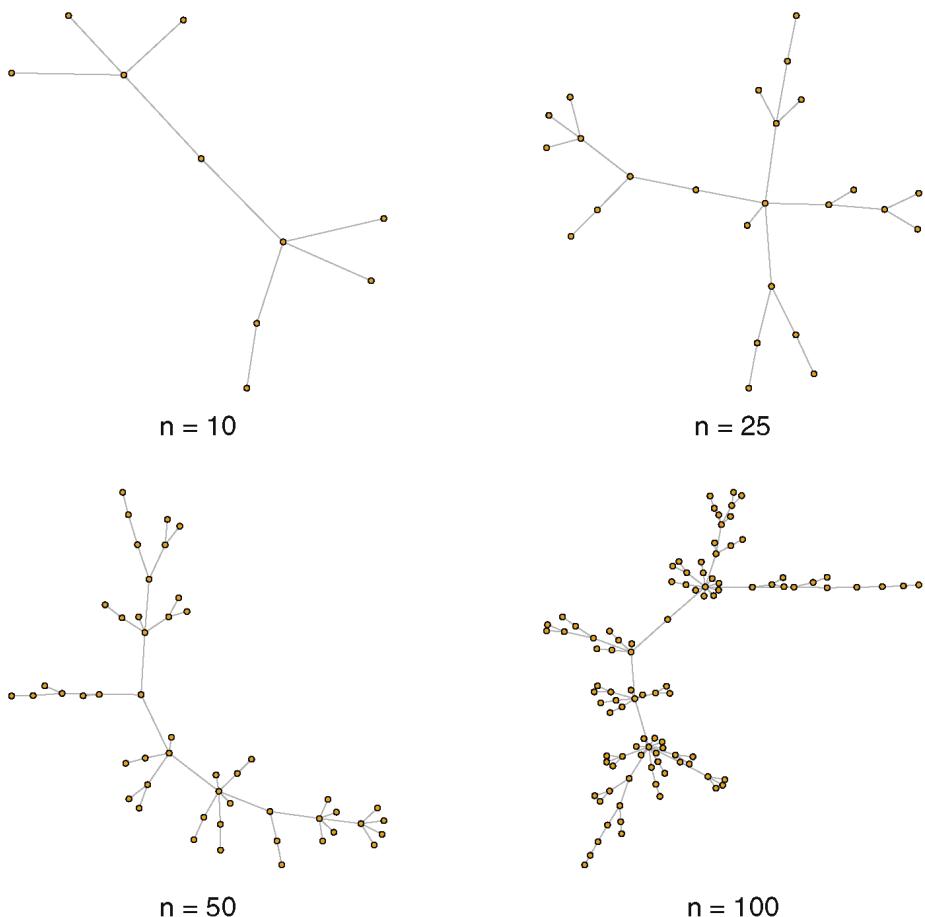


Рис. 10.10. Рост сети, построенной с помощью модели предпочтительного присоединения

```

g1 <- barabasi.game(10,m=1,directed=FALSE)
g2 <- barabasi.game(25,m=1,directed=FALSE)
g3 <- barabasi.game(50,m=1,directed=FALSE)

```

```

g4 <- barabasi.game(100,m=1,directed=FALSE)

op <- par(mfrow=c(2,2),mar=c(4,0,1,0))
plot(g1, vertex.label= NA, vertex.size = 3,
      xlab = "n = 10")
plot(g2, vertex.label= NA, vertex.size = 3,
      xlab = "n = 25")
plot(g3, vertex.label= NA, vertex.size = 3,
      xlab = "n = 50")
plot(g4, vertex.label= NA, vertex.size = 3,
      xlab = "n = 100")
par(op)

```

10.3. Сравнение моделей случайных графов с наблюдаемыми сетями

Математические модели, описанные здесь, а также многие другие используются для изучения теоретических свойств сетей. Кроме того, эти модели можно сравнить с наблюдаемыми социальными сетями. В качестве простого примера мы можем исследовать некоторые характеристики сети lhd5, взятой из книги [Harris, 2013], по экспоненциальному моделям случайных графов (см. главу 11). Сеть lhd5 образована взаимосвязями между 1283 главами местных департаментов здравоохранения. Сеть имеет довольно низкую плотность, несмотря на то что средняя степень составляет больше 4 (рис. 10.11).

```

library(UserNetR)
library(intergraph)
data(lhd5)
ilhd5 <- asIgraph(lhd5)
ilhd5

## IGRAPH U--- 1283 2708 --
## + attr: title (g/c), hivscreen (v/c), na
## | (v/l), nutrition (v/c), popmil (v/n),
## | state (v/c), vertex.names (v/c), years
## | (v/n), na (e/l)
## + edges:
## [1] 2-- 10 2-- 11 2-- 19 2-- 20 5--1003
## [6] 5-- 6 6-- 11 6-- 17 10-- 11 11-- 19
## [11] 11-- 26 2-- 12 6-- 12 10-- 12 11-- 12
## [16] 12-- 19 12-- 26 9-- 14 14-- 15 14-- 18
## [21] 14-- 25 14-- 27 14-- 226 14-- 414 14-- 697
## + ... omitted several edges

graph.density(ilhd5)
## [1] 0.00329

mean(degree(ilhd5))
## [1] 4.22

```

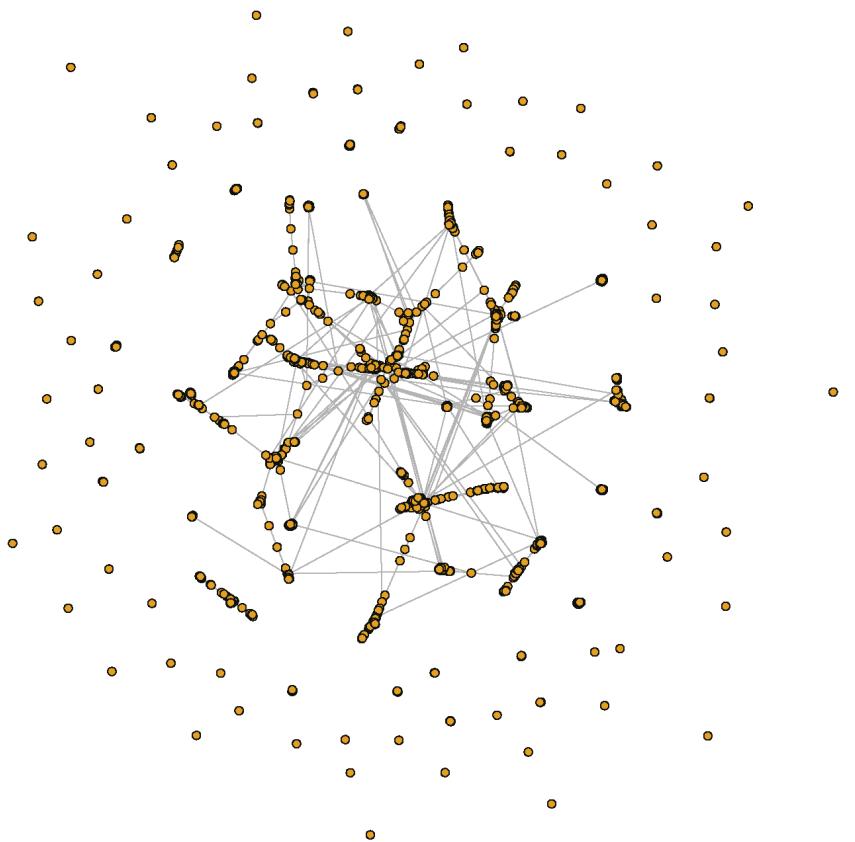


Рис. 10.11. Сеть lhd

Программный код, приведенный ниже, строит три модели сети, которые имеют такой же размер и такую же плотность, как и сеть lhd. Сравнив характеристики моделей сети с характеристиками наблюдаемой сети, мы можем выделить интересные или важные свойства реальной сети, которые могут пригодиться для дальнейшего анализа (с использованием различных методов статистического моделирования и имитационного моделирования, представленных в следующих нескольких главах).

```
g_rnd <- erdos.renyi.game(1283,.0033,type='gnp')
g_smwrld <- watts.strogatz.game(dim=1,size=1283,
                                 nei=2,p=.25)
g_prfatt <- barabasi.game(1283,out.dist=c(.15,.6,.25),
                           directed=FALSE,zero.appeal=2)
```

В табл. 10.1 представлены некоторые описательные статистики для трех построенных моделей и сети lhd. Несмотря на то что каждая модель перенимает некоторые характеристики наблюдаемой сети, ни одна из них не соответствует

в полной мере сети lhdс. В частности, сеть lhdс имеет гораздо более высокую транзитивность, чем любая из моделей (рис. 10.12).

Таблица 10.1. Сравнение характеристик моделей и наблюдаемой сети

Название	Размер	Плотность	Средн. степень	Транзи- тивность	Изолированные узлы
Эрдеш–Ренни	1283	0,003	4,404	0,002	21
Малый мир	1283	0,003	4,000	0,088	1
Предпочтительное присоединение	1283	0,002	2,195	0,003	109
lhdс	1283	0,003	4,221	0,306	58

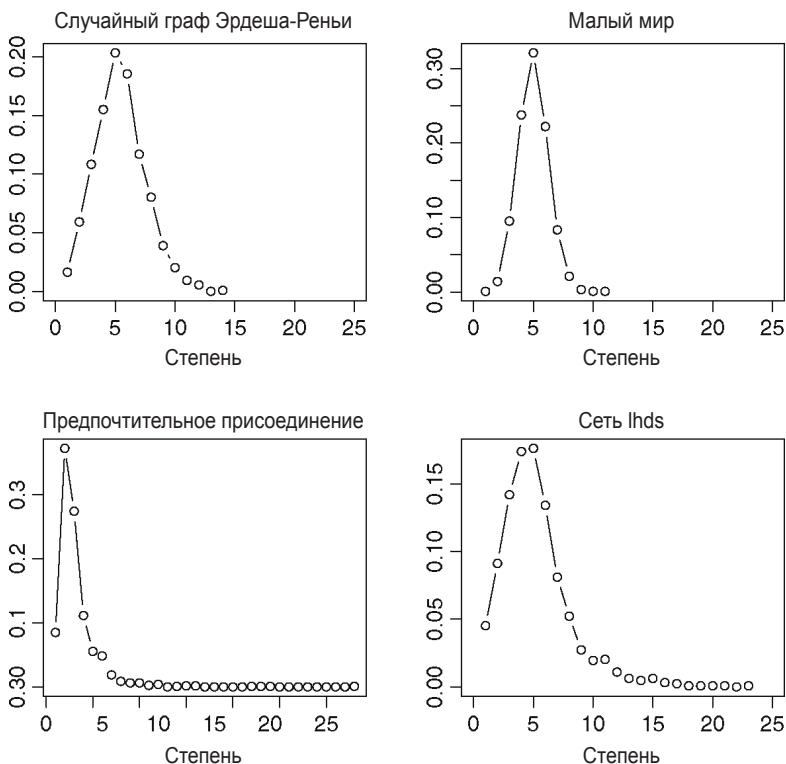


Рис. 10.12. Сравнение степенных распределений для моделей случайных графов и наблюдаемой сети

Глава 11

Статистические модели сетей

11.1. Введение	173
11.2. Построение экспоненциальных моделей случайных графов	176
11.3. Анализ экспоненциальных моделей случайных графов ...	190

Прогнозы и разъяснения в точности симметричны. По сути, разъяснения – это прогнозы по поводу того, что уже произошло, тогда как прогнозы – это разъяснения по поводу того, что еще только произойдет.

Джон Роджерс Сёрл

11.1. Введение

Как уже говорилось в предыдущей главе, долгий период своей истории наука о сетях ограничивалась лишь вопросами визуализации и описания сети. Лишь в течение последних нескольких десятилетий статистическая теория сетей и вычислительные мощности компьютеров достигли того уровня, когда статистическое моделирование сетей стало практически осуществимым. Главным препятствием на пути к статистическому моделированию сетей было фундаментальное предположение о независимости наблюдений, которое лежит в основе большинства традиционных статистических методов. Сети по определению зависимы. Если вы знаете, что один актор связан с другим актором, у вас появляется информация о том, что второй актор зависит от первого.

На протяжении целого ряда лет специалисты по статистическим методам последовательно разрабатывали все более и более сложные модели, которые можно было применить к эмпирическим сетевым данным, включая модели зависимых диадных связей и модели независимых диадных связей (например, p^* -модели, см. [Harris, 2013]). Эта глава сфокусируется на *экспоненциальных моделях случайных графов* (*exponential random graph models* или *ERGM*), которые, как показывает опыт, являются самым мощным, гибким и широко используемым методом для построения и тестирования статистических моделей сетей.

Экспоненциальная модель случайного графа является истинно порождающей статистической моделью структуры и характеристик сети (Hunter et al., 2008). Это означает, что мы можем выдвинуть и протестировать статистические гипотезы. Она является порождающей в том смысле, что характеристики отдельных элементов сети (т. е. акторов) и свойства локальных структур могут использоваться для прогнозирования свойств сети в целом (например, для прогнозирования диаметра, степенного распределения и т. д.). Экспоненциальные модели случайных графов популярны, по крайней мере, по четырем причинам. Во-первых, они могут обработать сложные зависимости, имеющиеся в сетевых данных, минуя проблему вырожденности, которая часто встречалась в более ранних моделях сетей. Во-вторых, экспоненциальные модели случайных графов являются гибкими и могут работать с различными типами предикторов и ковариат. В-третьих, порождающий подход, где характеристики сети в целом предсказываются по конкретным акторам и свойствам локальных структур, повышает надежность моделей. Наконец, экспоненциальные модели случайных графов реализованы в различных программах и статистических пакетах типа R, что позволяет аналитикам упростить

процесс построения и тестирования моделей с последующим применением их результатов.

В экспоненциальных моделях случайных графов оценки коэффициентов – это оценки максимального правдоподобия, вычисленные с помощью *метода Монте-Карло по схеме марковских цепей* (*Monte Carlo Markov Chain, MCMC*). То есть оценки коэффициентов основываются на имитационном моделировании, когда строится множество (как правило, тысячи) сетей, чтобы воспроизвести конкретную тестируемую модель. Базовую экспоненциальную модель случайного графа можно записать так:

$$P(y_{ij} = 1 | Y_{ij}^C) = \left(\frac{1}{c} \right) \exp \left\{ \sum_{k=1}^K \theta_k z_k(y) \right\}.$$

Эта формула показывает, что модель предсказывает вероятность появления связи между акторами i и j в зависимости от всех остальных связей. Тета-коэффициенты θ_k – это коэффициенты интересующих статистик сети, по одному на каждую из K включенных статистик $z_k(y)$. $\left(\frac{1}{c} \right)$ – это нормирующая константа, которая гарантирует, что вычисленные вероятности будут лежать в диапазоне от 0 до 1 (см. [Harris, 2013] для получения дополнительной информации).

Экспоненциальные модели случайных графов реализованы в пакете *ergm*, который входит в комплект пакетов для анализа сетей *statnet*. Наряду с остальными он активно поддерживается и разрабатывается специалистами по анализу сетей из Вашингтонского университета. Более подробная техническая информация о пакете *ergm* представлена в превосходных статьях [Hunter et al., 2008], а также [Goodreau, 2007].

Как уже говорилось выше, одним из преимуществ экспоненциальных моделей случайных графов является их способность работать с различными типами предикторов. Фактически в документации по пакету *ergm* перечисляется более сотни членов, которые можно включить в уравнение экспоненциальной модели случайного графа. Чтобы легче ориентироваться в них, важно знать, что все предикторы, которые можно использовать в экспоненциальной модели случайного графа, можно разбить на четыре большие категории: предикторы узлов, предикторы диад, предикторы ребер и предикторы локальных структур.

В табл. 11.1 эти категории перечислены наряду с некоторыми наиболее часто используемыми членами уравнения. Первый тип предиктора – характеристики узлов или акторов, когда наличие конкретного параметра гипотетически влияет на вероятность возникновения связи. Например, если вы выдвигаете гипотезу, согласно которой девочки в средней школе с большей вероятностью заводят дружеские контакты, чем мальчики, вы можете использовать пол в качестве предиктора узлов. Предикторы диад используются, когда вы выдвигаете гипотезу, согласно которой характеристики обоих акторов в диаде могут влиять на вероятность возникновения связи между этими двумя акторами. Данный тип предикторов позволяет вам тестировать гипотезы об ассортативном или диссортативном смешива-

нии¹, формирующем паттерны гомофилии или гетерофилии. Например, если вы выдвигаете гипотезу, согласно которой дружеские контакты с большей вероятностью завязываются внутри одного и того же класса² средней школы (ассортативное смешивание по признаку «класс»), вы можете использовать класс в качестве предиктора диад. Третий тип предикторов в экспоненциальных моделях случайных графов – это мощный параметр, позволяющий использовать дополнительную информацию о связях или взаимосвязях между узлами для прогнозирования появления ребер в сети. То есть связи одного типа используются для прогнозирования связей другого типа (при условии, что они собраны по одному и тому же набору акторов). Например, зная расстояния между участниками сети, мы можем спрогнозировать вероятность возникновения дружеских связей между ними. Наконец, информация о свойствах локальных структур сети может использоваться в качестве ковариат модели. Это позволяет учитывать наблюдаемое степенное распределение в модели сети или наблюдаемый уровень транзитивности (закрытые треугольники).

Таблица 11.1. Наиболее часто используемые члены уравнения

Тип предиктора	Член
Предиктор узлов	nodefactor nodecov
Предиктор диад	nodemix nodematch absdiff
Предиктор ребер	edgecov
Предиктор локальных структур	gwdegree gwdsp gwesp

В следующих примерах мы построим ряд экспоненциальных моделей случайных графов с использованием всех четырех типов членов. Для получения более подробной информации о членах, включенных в пакет `ergm`, см. справку `help('ergm-terms')`. Более общий обзор представлен Morris, Handcock и Hunter (2008). Наконец, пакет `ergm` включает полезную виньетку, в которой рассказывается о том, как различные члены связаны друг с другом (`vignette('ergm-term-crossRef')`).

¹ Пример ассортативного смешивания в социальных сетях – люди из одного и того же города с большей вероятностью общаются друг с другом (ассортативность по признаку «город»). Диссортативное смешивание часто наблюдается в социальной сети службы знакомств, когда представители противоположного пола с большей вероятностью завязывают контакты друг с другом (диссортативность по признаку «пол»). – Прим. пер.

² Здесь под словом «класс» (grade) подразумевается год обучения в школе, а не группа учеников или предмет. – Прим. пер.

11.2. Построение экспоненциальных моделей случайных графов

Чтобы продемонстрировать возможности пакета `ergm` по стохастическому моделированию, мы воспользуемся сетевыми данными, которые описывают взаимосвязи между 25 агентствами, участвовавшими в программе по борьбе с распространением табака в штате Индиана в 2010 году. Эти данные включают три различных типа взаимосвязей: частоту контакта, уровень сотрудничества, а также факт взаимодействия между любыми двумя агентствами по подготовке сборника руководящих принципов «Лучшие практики контроля за табакокурением», который был издан Центром по профилактике и предупреждению заболеваний США (для краткости назовем этот тип взаимосвязи информационно-просветительским сотрудничеством). Модели, приведенные ниже в качестве примера, будут прогнозировать вероятность информационно-просветительского сотрудничества между организациями, входящими в программу по борьбе с распространением табака в штате Индиана.

Данные включены в пакет `UserNetR` в виде списка `TCnetworks`. Сетевые данные включают несколько характеристик узлов (например, `tob_yrs`, в котором записана информация о давности участия агентства в программе), характеристики ребер и социоматрицу (`TCdist`), которая содержит географическое расстояние между каждой парой агентств. Для получения дополнительной информации см. справочный файл по `TCnetworks`.

Перед моделированием сетевые данные нужно извлечь из списка, и тогда можно будет выполнить любую задачу по предварительному описанию и визуализации сети. Нижеприведенный программный код рекомендуем запускать в отдельной сессии.

```
library(UserNetR)
library(statnet)
data(TCnetworks)

TCcnt <- TCnetworks$TCcnt
TCcoll <- TCnetworks$TCcoll
TCdiss <- TCnetworks$TCdiss
TCdist <- TCnetworks$TCdist

summary(TCdiss,print.adj=FALSE)

## Network attributes:
##   vertices = 25
##   directed = FALSE
##   hyper = FALSE
##   loops = FALSE
##   multiple = FALSE
##   bipartite = FALSE
##   title = IN_Diffusion
##   total edges = 103
##   missing edges = 0
##   non-missing edges = 103
```

```

## density = 0.343
##
## Vertex attributes:
##
## agency_cat:
##   numeric valued attribute
##   attribute summary:
##     Min. 1st Qu. Median Mean 3rd Qu. Max.
##     1.00    2.00    2.00  3.24    5.00    6.00
##
## agency_lvl:
##   numeric valued attribute
##   attribute summary:
##     Min. 1st Qu. Median Mean 3rd Qu. Max.
##     1.00    1.00    2.00  2.04    3.00    3.00
##
## lead_agency:
##   numeric valued attribute
##   attribute summary:
##     Min. 1st Qu. Median Mean 3rd Qu. Max.
##     0.00    0.00    0.00  0.04    0.00    1.00
##
## tob_yrs:
##   numeric valued attribute
##   attribute summary:
##     Min. 1st Qu. Median Mean 3rd Qu. Max.
##     1.00    3.00    4.50  6.76    9.00   21.00
##
## vertex.names:
##   character valued attribute
##   25 valid vertex names
##
## No edge attributes

```

Беглый анализ сети показывает, что сеть образована тремя типами организаций (на местном уровне, на уровне штата и на федеральном уровне), имеет одну связную компоненту, которая является довольно плотной, и характеризуется определенным разбросом значений центральности, вычисленных для участников сети (это показывает значение централизации по посредничеству и разброс размеров узлов, здесь размер узла зависит от его степени) (рис. 11.1).

```

components(TCdiss)
## [1] 1
gden(TCdiss)
## [1] 0.343
centralization(TCdiss,betweenness,mode='graph')
## [1] 0.381

```

```

deg <- degree(TCdiss,gmode='graph')
lvl <- TCdiss %v% 'agency_lvl'
plot(TCdiss,usearrows=FALSE,displaylabels=TRUE,
      vertex.cex=log(deg),
      vertex.col=lvl+1,
      label.pos=3,label.cex=.7,
      edge.lwd=0.5,edge.col="grey75")
legend("bottomleft",legend=c("Местные","На уровне штата",
                           "Федеральные"),
      col=2:4,pch=19,pt.cex=1.5)

```

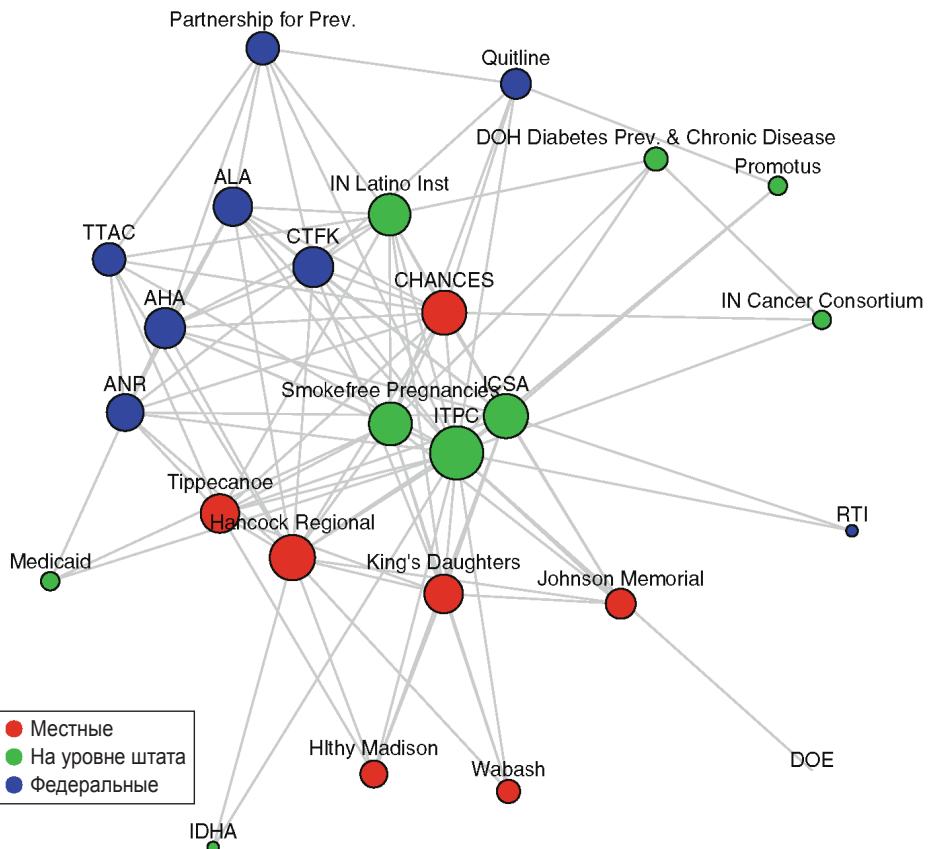


Рис. 11.1. Сеть агентств, участвующих в программе по борьбе с распространением табака

11.2.1. Построение нулевой модели

В ряде случаев полезно начать процесс моделирования, построив нулевую модель, т. е. модель без предикторов. Ее можно использовать в качестве базовой модели для сравнения с последующими моделями. Нулевая модель обычно имеет лишь

один член edges, создается модель случайного графа, которая состоит из такого же количества ребер, что и реальная сеть.

При построении модели используется синтаксис, аналогичный синтаксису функций статистического моделирования в R. Функция `ergm` вызывается с помощью формулы модели. Эта формула задает название реальной сети в качестве зависимой переменной (слева от знака тильды), а затем перечисляет все члены модели (справа от знака тильды). Кроме того, пользователь может задать дополнительные параметры. Параметр `control` используется для передачи параметров настройки в функцию `ergm`. Здесь мы задаем стартовое значение для генератора случайных чисел, чтобы гарантировать получение одинаковых результатов по итогам многократных запусков. Результаты подгонки модели сохраняются в объекте-модели для дальнейшего исследования и анализа.

```
library(ergm)
DSmod0 <- ergm(TCdiss ~ edges,
                  control=control.ergm(seed=40))
class(DSmod0)
## [1] "ergm"

summary(DSmod0)

##
## =====
## Summary of model fit
## =====
##
## Formula: TCdiss ~ edges
##
## Iterations: 4 out of 20
##
## Monte Carlo MLE Results:
##      Estimate Std. Error MCMC % p-value
## edges   -0.648     0.122      0  <1e-04
##
##      Null Deviance: 416  on 300  degrees of freedom
##  Residual Deviance: 386  on 299  degrees of freedom
##
## AIC: 388 BIC: 392 (Smaller is better.)
```

Нулевая модель включает только член `edges`. Он выступает в качестве нулевого члена (константы) модели и гарантирует, что моделируемые сети имеют точно такое же количество ребер, что и реальная сеть. В этом можно убедиться, выполнив логистическое преобразование параметра `edges`, которое вычислит общую плотность сети. Сводка, приведенная ниже, показывает, что нулевая модель включает лишь количество ребер в наблюдаемой сети.

```
plogis(coef(DSmod0))
## edges
## 0.343
```

11.2.2. Включение предикторов узлов

Как только нулевая модель получена, можно построить более интересные модели, используя самые различные предикторы. Следуя порядку, указанному в табл. 11.1, мы начнем с членов главных эффектов, основанных на характеристиках отдельных узлов. Касательно сети Indiana мы знаем, какое агентство является ведущим (получает финансирование от Центра по профилактике и предупреждению заболеваний США), кроме того, мы знаем, сколько времени агентство участвует в программе по борьбе с распространением табака. Разумно предположить, что агентства с большей вероятностью будут устанавливать связи с ведущим агентством. Помимо этого, будет логичным предположить, что агентства с более давней историей участия в антитабачной программе с большей вероятностью будут связаны с другими агентствами. Диаграмма рассеяния, приведенная ниже, свидетельствует о том, что, возможно, существует зависимость между опытом участия в антитабачной программе и количеством связей, которыми это агентство соединено с другими агентствами (рис. 11.2).

```
scatter.smooth(TCdiss %v% 'tob_yrs',
degree(TCdiss, gmode='graph'),
xlab='Опыт участия в годах',
ylab='Степень')
```

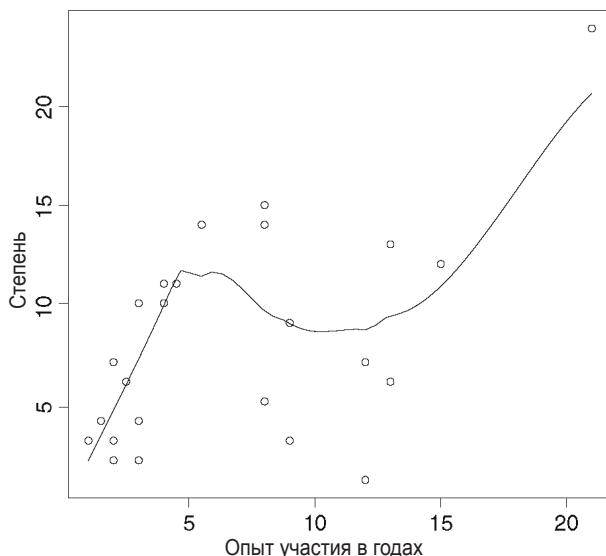


Рис. 11.2. Связь между опытом участия и степенью узла

Обе вышеупомянутые гипотезы можно формально протестировать. Существуют два основных члена для тестирования характеристик узлов, `nodelfactor` и `nodecov`. Член `nodelfactor` используется для категориальных характеристик (например, `lead_agency`), в то время как `nodecov` используется для количественных характеристиках (например, `tob_yrs`).

```
DSmod1 <- ergm(TCdiss ~ edges +
                  nodelfactor('lead_agency') +
                  nodecov('tob_yrs'),
                  control=control.ergm(seed=40))
summary(DSmod1)

## 
## =====
## Summary of model fit
## =====
##
## Formula: TCdiss ~ edges +
##           nodelfactor("lead_agency") +
##           nodecov("tob_yrs")
##
## Iterations: 16 out of 20
##
## Monte Carlo MLE Results:
##                               Estimate Std. Error
## edges                   -1.6783    0.3293
## nodelfactor.lead_agency.1 17.9366   933.5551
## nodecov.tob_yrs          0.0599    0.0228
##                               MCMC % p-value
## edges                      0 <1e-04
## nodelfactor.lead_agency.1  0  0.9847
## nodecov.tob_yrs           0  0.0091
##
##      Null Deviance: 416 on 300 degrees of freedom
##  Residual Deviance: 323 on 297 degrees of freedom
##
## AIC: 329     BIC: 341    (Smaller is better.)
```

Результаты показывают много интересных моментов. Во-первых, опыт участия в антитабачной программе имеет положительный коэффициент и статистически значимо связан с вероятностью существования связи между двумя агентствами (вспомним, что здесь связь отражает информационно-просветительское сотрудничество между организациями). Во-вторых, несмотря на то что коэффициент для предиктора `lead_agency` является довольно большим, он не значим. Пожалуй, это обусловлено низкой точностью оценки. Вероятно, для небольшой сети из 25 участников и одного ведущего агентства мощности для обнаружения этого эффекта недостаточно. Наконец, AIC (информационный критерий Акаике) для

этой модели с двумя предикторами ниже AIC для нулевой модели. Это говорит о том, что данная модель лучше объясняет данные, чем базовая модель.

Как и при проведении анализа на основе логистической регрессии, в данном случае мы можем оценить вероятность существования определенных типов связей с помощью полученных оценок параметров. Для этого потребуется логистическое преобразование, чтобы получить числовые значения, которые можно будет интерпретировать как вероятности. Например, для модели 1 программный код, приведенный ниже, вычисляет вероятность информационно-просветительского сотрудничества между двумя агентствами, если одно агентство имеет 5-летний опыт участия в антитабачной программе, а другое – 10-летний опыт участия, при этом ни одно из них не является ведущим агентством.

```
p_edg <- coef(DSmod1) [1]
p_yrs <- coef(DSmod1) [3]
plogis(p_edg + 5*p_yrs + 10*p_yrs)

## edges
## 0.314
```

Результат равен 0,31, что чуть меньше общей плотности сети (т. е. общей вероятности информационно-просветительского сотрудничества).

11.2.3. Включение предикторов диад

Богатым источником гипотез о структуре сети является исследование гомофилии и гетерофилии сети. То есть необходимо исследовать склонность участников сети устанавливать связи с людьми, схожими (гомофилия) или непохожими на них по какой-либо характеристике (гетерофилия). Для этого нужно задать предиктор диадного взаимодействия.

Исходные частоты связей между различными типами акторов сети можно вывести с помощью функции `mixingmatrix()`. Здесь, например, мы видим, что чаще всего (в 24 случаях) информационно-просветительское сотрудничество возникает между местными агентствами и агентствами на уровне штата (см. `?Tcnetworks`, чтобы получить информацию о кодировках). Возможно, интерпретация исходных частот несколько сложна, однако их можно использовать для выдвижения гипотез о диадных взаимосвязях, которые формально можно протестировать с помощью экспоненциальной модели случайного графа.

```
mixingmatrix(TCdiss, 'agency_lvl')

## Note: Marginal totals can be misleading
## for undirected mixing matrices.
##   1  2  3
## 1 13 24 14
## 2 24 16 23
## 3 14 23 13
```

```
mixingmatrix(TCdiss, 'agency_cat')

## Note: Marginal totals can be misleading
## for undirected mixing matrices.
##   1 2 3 4 5 6
## 1 0 12 3 2 3 4
## 2 12 19 18 6 1 14
## 3 3 18 0 4 3 2
## 4 2 6 4 1 1 6
## 5 3 1 3 1 0 0
## 6 4 14 2 6 0 4
```

В моделях, приведенных ниже, удален статистически незначимый предиктор lead_agency. Теперь построим три варианта модели 2, применив различные настройки для включения agency_lvl в качестве предиктора диад.

```
DSmod2a <- ergm(TCdiss ~ edges +
                  nodecov('tob_yrs') +
                  nodematch('agency_lvl'),
                  control=control.ergm(seed=40))

summary(DSmod2a)

##
## =====
## Summary of model fit
## =====
##
## Formula: TCdiss ~ edges +
##           nodecov("tob_yrs") +
##           nodematch("agency_lvl")
##
## Iterations: 4 out of 20
##
## Monte Carlo MLE Results:
##                               Estimate Std. Error MCMC %
## edges                   -2.4808    0.3413    0
## nodecov.tob_yrs        0.1133    0.0201    0
## nodematch.agency_lvl   0.6875    0.2770    0
##
##                               p-value
## edges                   <1e-04
## nodecov.tob_yrs        <1e-04
## nodematch.agency_lvl   0.014
##
## Null Deviance: 416 on 300 degrees of freedom
## Residual Deviance: 342 on 297 degrees of freedom
##
## AIC: 348     BIC: 359     (Smaller is better.)
```

В модели 2а используется член nodematch. Мы оцениваем вероятность информационно-просветительского сотрудничества между агентствами при условии,

что оба агентства занимают один и тот же уровень (например, оба агентства являются местными). То есть выдвигаем гипотезу об общей гомофилии, согласно которой организации одного и того же типа с большей вероятностью взаимодействуют друг с другом. Положительная и статистически значимая оценка параметра указывает на то, что в данном случае мы наблюдаем эффект гомофилии.

```
DSmod2b <- ergm(TCdiss ~ edges +
  nodecov('tob_yrs') +
  nodematch('agency_lvl', diff=TRUE),
  control=control.ergm(seed=40))
summary(DSmod2b)

##
## =====
## Summary of model fit
## =====
##
## Formula: TCdiss ~ edges +
##           nodecov("tob_yrs") +
##           nodematch("agency_lvl",
##                      diff = TRUE)
##
## Iterations: 4 out of 20
##
## Monte Carlo MLE Results:
##                               Estimate Std. Error MCMC %
## edges                  -2.7792    0.3685    0
## nodecov.tob_yrs        0.1331    0.0217    0
## nodematch.agency_lvl.1 1.6145    0.4983    0
## nodematch.agency_lvl.2 -0.2148    0.3974    0
## nodematch.agency_lvl.3 1.3016    0.4422    0
##                               p-value
## edges                  <1e-04
## nodecov.tob_yrs        <1e-04
## nodematch.agency_lvl.1 0.0013
## nodematch.agency_lvl.2 0.5891
## nodematch.agency_lvl.3 0.0035
##
##      Null Deviance: 416 on 300 degrees of freedom
##  Residual Deviance: 330 on 295 degrees of freedom
##
## AIC: 340     BIC: 358     (Smaller is better.)
```

Модель 2b показывает, как тестировать гипотезу о дифференциальной гомофилии¹. Здесь вместо одного диадного члена мы задаем три, по одному для каждого типа агентства (для местных агентств, для агентств на уровне штата, для

¹ То есть предполагаем разную степень гомофилии для каждого типа агентства. – *Прим. пер.*

федеральных агентств). Результаты свидетельствуют, что эффект гомофилии наблюдается лишь на местном и федеральном уровнях.

```
DSmod2c <- ergm(TCdiss ~ edges +
  nodecov('tob_yrs') +
  nodemix('agency_lvl', base=1),
  control=control.ergm(seed=40))
summary(DSmod2c)

##
## =====
## Summary of model fit
## =====
##
## Formula: TCdiss ~ edges +
##           nodecov("tob_yrs") +
##           nodemix("agency_lvl", base = 1)
##
## Iterations: 4 out of 20
##
## Monte Carlo MLE Results:
##             Estimate Std. Error MCMC %
## edges          -1.1757    0.5372   0
## nodecov.tob_yrs     0.1340    0.0222   0
## mix.agency_lvl.1.2 -1.5805    0.5501   0
## mix.agency_lvl.2.2 -1.8354    0.6028   0
## mix.agency_lvl.1.3 -1.5363    0.5659   0
## mix.agency_lvl.2.3 -1.7073    0.5445   0
## mix.agency_lvl.3.3 -0.3110    0.6119   0
##             p-value
## edges          0.0294
## nodecov.tob_yrs <1e-04
## mix.agency_lvl.1.2 0.0044
## mix.agency_lvl.2.2 0.0025
## mix.agency_lvl.1.3 0.0070
## mix.agency_lvl.2.3 0.0019
## mix.agency_lvl.3.3 0.6116
##
## Null Deviance: 416 on 300 degrees of freedom
## Residual Deviance: 330 on 293 degrees of freedom
##
## AIC: 344      BIC: 370      (Smaller is better.)
```

Наконец, модель 2с показывает, как включать самые подробные тесты на гомофилию и гетерофилию. Член `nodemix` включает все возможные комбинации уровней для категориального атрибута узла. Параметр `base` задает опорную категорию, в противном случае включаются все возможные эффекты (что может привести к проблемам стабильности модели). Здесь опорная категория – это (1,1), связи

между местными агентствами. Обратите внимание на то, что для небольших сетей и категориальных атрибутов с большим количеством значений матрица смешивания может содержать пустые ячейки (а также требует большого количества степеней свободы). Все это может вызвать проблемы при оценке и интерпретации модели.

11.2.4. Включение предикторов ребер

Третий тип предиктора, который можно включить в экспоненциальную модель случайного графа, – это предиктор ребер. Предиктор ребер – это количественная характеристика связей между участниками сети, которую можно использовать для прогнозирования зависимой переменной-связи.

В этом примере, помимо традиционных предикторов, мы используем два предиктора ребер. Во-первых, у нас есть переменная `contact`, которая измеряет частоту контакта между агентствами, участвующими в антитабачной программе штата Индианы (1 = ежегодно; 2 = ежеквартально; 3 = ежемесечно; 4 = еженедельно и 5 = ежедневно). Во-вторых, используем физическое расстояние (в милях) между каждой парой агентств, которое было вычислено и сохранено в объекте-сети `statnet`. Гипотезы, выдвинутые по каждому предиктору ребер, довольно очевидны. Мы ожидаем, что агентства, которые чаще всего контактируют друг с другом, с большей вероятностью будут участвовать в составлении сборника руководящих принципов «Лучшие практики контроля за табакокурением». Во-вторых, мы ожидаем, что чем дальше агентства находятся друг от друга, тем меньше вероятность совместного участия в подготовке этого сборника.

Для включения предикторов ребер используется член `edgecov`. Кроме того, поскольку эти предикторы записаны в виде сетей с числовыми значениями, для параметра `attr` указываем атрибут ребер, в котором записаны соответствующие количественные данные. Сначала мы выведем информацию по каждому предиктору ребер, затем построим экспоненциальную модель случайного графа.

```
as.sociomatrix(TCdist,attrname = 'distance')[1:5,1:5]

##      1     2     3     4     5
## 1 0.00 1.94 492 1870 1.27
## 2 1.94 0.00 492 1869 1.91
## 3 491.87 491.97 0 2325 493.08
## 4 1869.88 1868.98 2325 0 1868.61
## 5 1.27 1.91 493 1869 0.00

as.sociomatrix(TCcnt,attrname = 'contact')[1:5,1:5]

##      ITPC Promotus RTI Quitline IDHA
## ITPC 0      5     4      4     3
## Promotus 5      0     3      4     0
## RTI    4      3     0      2     0
## Quitline 4      4     2      0     0
## IDHA   3      0     0      0     0
```

```

DSmod3 <- ergm(TCdiss ~ edges +
                 nodecov('tob_yrs') +
                 nodematch('agency_lvl', diff=TRUE) +
                 edgecov(TCdist, attr='distance') +
                 edgecov(TCcnt, attr='contact'),
                 control=control.ergm(seed=40))

summary(DSmod3)

##
## =====
## Summary of model fit
## =====
##
## Formula: TCdiss ~ edges +
##           nodecov("tob_yrs") +
##           nodematch("agency_lvl", diff = TRUE) +
##           edgecov(TCdist, attr = "distance") +
##           edgecov(TCcnt, attr = "contact")
##
## Iterations: 5 out of 20
##
## Monte Carlo MLE Results:
##                               Estimate Std. Error
## edges                  -4.850619  0.629666
## nodecov.tob_yrs        0.128750  0.028270
## nodematch.agency_lvl.1 1.795102  0.625698
## nodematch.agency_lvl.2 -0.646015  0.508164
## nodematch.agency_lvl.3 1.721850  0.546870
## edgecov.distance       -0.000184  0.000253
## edgecov.contact         1.124253  0.146957
##                               MCMC % p-value
## edges                      0 <1e-04
## nodecov.tob_yrs           0 <1e-04
## nodematch.agency_lvl.1    0 0.0044
## nodematch.agency_lvl.2    0 0.2046
## nodematch.agency_lvl.3    0 0.0018
## edgecov.distance          0 0.4683
## edgecov.contact            0 <1e-04
##
##      Null Deviance: 416 on 300 degrees of freedom
##  Residual Deviance: 237 on 293 degrees of freedom
##
## AIC: 251     BIC: 277     (Smaller is better.)

```

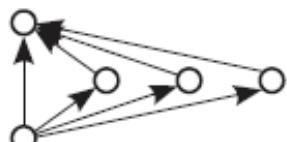
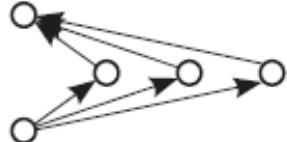
Результаты показывают, что чем чаще агентства контактируют друг с другом, тем выше вероятность информационно-просветительского сотрудничества между ними, как мы и предполагали. С другой стороны, похоже, что физическое расстояние между агентствами не влияет на информационно-просветительское сотрудничество.

11.2.5. Включение предикторов локальных структур (зависимых диадных связей)

Последний тип предиктора, который можно включить в экспоненциальную модель случайного графа, – это информация о свойствах локальных структур. Вспомним, что нам необходимо смоделировать внешний вид и работу сети в целом. Включив некоторую информацию о тенденциях, характеризующих локальные структуры (например, информацию о реципрокности – тенденции формировать взаимные связи), мы, как правило, можем построить модели, которые будут намного лучше соответствовать реальной наблюдаемой сети. Эти типы предикторов приводят нас к моделям зависимых диадных связей, с которыми связано еще больше вычислительных и статистических проблем ([Harris, 2013]). Выбрав эти типы предикторов, аналитик должен быть готов к тому, что время выполнения задачи может значительно возрасти, и вы с гораздо большей степенью вероятности можете столкнуться с проблемами вырожденности модели и отсутствия сходимости.

В последние годы были найдены и разработаны новые типы предикторов локальных структур, которые хотя бы частично позволяют избежать наиболее серьезных проблем, связанных со стабильностью и сходимостью моделей ([Snijders, Pattison, 2006]). Тремя наиболее часто используемыми членами являются *gwdegree* (geometrically weighted degree distribution – геометрически взвешенное степенное распределение), *gwesp* (geometrically weighted edgewise shared partnerships – геометрически взвешенное распределение общих узлов по связям) и *gwdsp* (geometrically weighted dyadwise shared partnerships – геометрически взвешенное распределение общих узлов по диадам). GWESP и GWDSP измеряют кластеризацию (транзитивность) сети. Они показывают вероятность того, что два узла, связанных или не связанных между собой, будут иметь несколько общих узлов. См. монографию [Harris, 2013], чтобы получить дополнительную информацию о том, как выбрать и интерпретировать эти предикторы локальных структур.

Таблица 11.2. GWESP и GWDSP

GWESP (Закрытые триадные связи)	Тенденция связанных диад иметь несколько общих узлов	
GWDSP (Открытые триадные связи)	Тенденция несвязанных диад иметь несколько общих узлов	

В нашем примере мы включим GWESP. Результаты модели действительно показывают, что в сети наблюдается транзитивность (связанные диады имеют не-

сколько общих узлов) и она положительно связана с вероятностью информационно-просветительского сотрудничества.

```
DSmod4 <- ergm(TCdiss ~ edges +
  nodecov('tob_yrs') +
  nodematch('agency_lvl', diff=TRUE) +
  edgecov(TCdist, attr='distance') +
  edgecov(TCcnt, attr="contact") +
  gwesp(0.7, fixed=TRUE),
  control=control.ergm(seed=40))

## Starting maximum likelihood estimation via MCMLE:
## Iteration 1 of at most 20:
## The log-likelihood improved by 0.5168
## Step length converged once.
## Increasing MCMC sample size.
## Iteration 2 of at most 20:
## The log-likelihood improved by 0.03238
## Step length converged twice. Stopping.
##
## This model was fit using MCMC.
## To examine model diagnostics and check
## for degeneracy, use the mcmc.diagnostics()
## function.

summary(DSmod4)

## =====
## Summary of model fit
## =====
##
## Formula: TCdiss ~ edges + nodecov("tob_yrs") +
##           nodematch("agency_lvl", diff = TRUE) +
##           edgecov(TCdist, attr = "distance") +
##           edgecov(TCcnt, attr = "contact") +
##           gwesp(0.7, fixed = TRUE)
##
## Iterations: 2 out of 20
##
## Monte Carlo MLE Results:
##                               Estimate Std. Error
## edges                  -6.326172  0.960886
## nodecov.tob_yrs        0.097673  0.029612
## nodematch.agency_lvl.1 1.557478  0.595676
## nodematch.agency_lvl.2 -0.266426  0.471595
## nodematch.agency_lvl.3 1.506054  0.526105
## edgecov.distance       -0.000154  0.000243
## edgecov.contact         1.039252  0.145160
```

```

## gwesp.fixed.0.7      0.877169   0.377682
##                               MCMC % p-value
## edges                  0   <1e-04
## nodecov.tob_yrs       0   0.0011
## nodematch.agency_lvl.1 0   0.0094
## nodematch.agency_lvl.2 0   0.5725
## nodematch.agency_lvl.3 0   0.0045
## edgcov.distance        0   0.5279
## edgcov.contact         0   <1e-04
## gwesp.fixed.0.7      0   0.0209
##
## Null Deviance: 416  on 300  degrees of freedom
## Residual Deviance: 231  on 292  degrees of freedom
##
## AIC: 247    BIC: 276    (Smaller is better.)

```

11.3. Анализ экспоненциальных моделей случайных графов

11.3.1. Интерпретация модели

Оцененная экспоненциальная модель случайного графа, записанная в объект R, содержит большой объем информации об оценках параметров, структуре сети и качестве подгонки модели. Наиболее важная информация приводится в сводке модели. Обращайте особое внимание на любые сообщения о проблемах сходимости, поскольку они обычно указывают на проблемы оценивания, которые обязательно нужно решить.

Сами оценки параметров вместе с их стандартными ошибками можно интерпретировать аналогично параметрам логистической регрессии. *p*-значение – вероятность того, что случайная величина с данным распределением (в данном случае используется распределение хи-квадрат Вальда) превысит фактическое значение статистики. Кроме того, можно вычислить экспоненты оценок параметров (по умолчанию в сводке модели не показаны), чтобы получить отношения шансов.

Значения AIC и BIC измеряют общее качество подгонки модели. Более низкие значения указывают на более точное соответствие модели реальной сети. Заметьте, что значения AIC и BIC последовательно уменьшались по мере добавления предикторов в модель. Это говорит о том, что мы добавили полезные предикторы в нашу экспоненциальную модель случайного графа.

Наконец, как и в случае с любой статистической моделью, часто бывает сложно интерпретировать модель, анализируя лишь отдельные оценки параметров. Обычно построенную модель используют для получения прогнозов, которые можно представить графически или проверить ее работу на другом наборе данных.

```
prd_prob1 <- plogis(-6.31 + 2*1*.099 + 1.52 +
                      4*1.042 + .858*(.50^4))
```

```

prd_prob1
## [1] 0.408

prd_prob2 <- plogis(-6.31 + 2*5*.099 +
1*1.042 + .858*(.50^4))
prd_prob2
## [1] 0.0144

```

В качестве простого примера мы, используя нашу итоговую модель, спрогнозируем вероятность информационно-просветительского сотрудничества между двумя агентствами, при условии, что оба агентства участвуют в антитабачной программе 1 год, являются федеральными агентствами, еженедельно контактируют друг с другом, а сеть имеет средний уровень транзитивности. Мы игнорируем расстояние в силу маленького значения параметра и отсутствия статистической значимости. В данном случае вероятность информационно-просветительского сотрудничества равна 41%. Если агентства участвуют в антитабачной программе 5 лет и относятся к разным уровням (например, одно агентство является местным, а другое – федеральным), контактируют друг с другом 1 раз в год, вероятность будет равна всего лишь 1,4%. (См. [Harris, 2013], чтобы ознакомиться с более тщательно проработанными примерами, а также получить подробную информацию о том, как для прогнозирования использовать параметры локальных структур, например `gwesp`.)

11.3.2. Подгонка модели

Пакет `egm` включает ряд инструментов, который можно использовать для проверки соответствия модели реальным данным. Во-первых, убедитесь в отсутствии проблем со сходимостью и обоснованности полученных оценок параметров, стандартных ошибок и p -значений. Значения AIC тоже могут быть полезны, особенно анализ того, как уменьшались значения AIC (и BIC) по мере добавления предикторов в модель.

Имитационное моделирование, лежащее в основе алгоритмов марковских цепей Монте-Карло, также дает полезную информацию, позволяющую судить о качестве подгонки модели. Процедура сравнивает характеристики сетей, имитированных на основе нашей итоговой модели, с теми же самыми характеристиками реальной сети. Конкретно в данном случае мы исследуем геодезические расстояния, распределение общих узлов по связям, степенное распределение и сенсус триад (частоту встречаемости различных вариантов триад).

```

DSmod.fit <- gof(DSmod4,
                    GOF = ~distance + espartners +
                    degree + triadcensus,
                    burnin=1e+5, interval = 1e+5)
summary(DSmod.fit)

##
## Goodness-of-fit for minimum geodesic distance

```

```
##  
##      obs min   mean max MC p-value  
## 1  103  88 102.90 116      1.00  
## 2  197 123 169.44 200      0.04  
## 3    0   0   8.90  34      0.20  
## 4    0   0   0.02   1      1.00  
## Inf   0   0 18.74  69      0.80  
##  
## Goodness-of-fit for edgewise shared partner  
##  
##      obs min   mean max MC p-value  
## esp0    1   0   0.76   3      1.00  
## esp1    8   0   4.94  14      0.28  
## esp2   10   3 10.28  21      1.00  
## esp3    7   7 17.68  34      0.02  
## esp4   15   8 20.21  32      0.24  
## esp5   11   7 16.77  25      0.32  
## esp6    9   4 12.83  22      0.48  
## esp7   14   3   7.73  16      0.12  
## esp8   14   0   5.08  13      0.00  
## esp9    5   0   2.77   8      0.32  
## esp10   4   0   1.74   7      0.28  
## esp11   1   0   1.19   3      1.00  
## esp12   1   0   0.61   4      0.88  
## esp13   2   0   0.13   1      0.00  
## esp14   1   0   0.17   2      0.32  
## esp15   0   0   0.01   1      1.00  
##  
## Goodness-of-fit for degree  
##  
##      obs min mean max MC p-value  
## 0    0   0 0.79   3      0.80  
## 1    1   0 0.61   3      0.96  
## 2    2   0 1.07   4      0.56  
## 3    3   0 1.02   4      0.14  
## 4    2   0 1.22   4      0.66  
## 5    1   0 1.70   6      0.98  
## 6    2   0 1.87   5      1.00  
## 7    2   0 2.47   7      1.00  
## 8    0   0 2.76   7      0.14  
## 9    1   0 2.57   8      0.54  
## 10   3   0 2.25   6      0.84  
## 11   2   0 2.15   5      1.00  
## 12   1   0 1.45   5      1.00  
## 13   1   0 1.05   4      1.00  
## 14   2   0 0.62   3      0.20  
## 15   1   0 0.22   2      0.40  
## 16   0   0 0.13   1      1.00
```

```

## 17 0 0 0.05 1 1.00
## 18 0 0 0.08 1 1.00
## 19 0 0 0.11 1 1.00
## 20 0 0 0.24 1 1.00
## 21 0 0 0.22 1 1.00
## 22 0 0 0.24 1 1.00
## 23 0 0 0.09 1 1.00
## 24 1 0 0.02 1 0.04
##
## Goodness-of-fit for triad census
##
##   obs min mean max MC p-value
## 0 832 616 756 911 0.20
## 1 759 787 881 944 0.00
## 2 517 407 502 625 0.72
## 3 192 114 161 221 0.18

```

В объекте `DSmod.fit` сохраняются результаты вышеприведенных сравнений. Если модель адекватно описывает реальную сеть, то мы увидим, что имитированные сети похожи на реальную сеть. Для каждого возможного значения выбранной статистики сети приводятся частота, а также минимум, среднее и максимум, которые по умолчанию вычисляются по 100 имитированным сетям. Также приводятся эмпирические p -значения Монте-Карло. p -значение – это доля случаев, когда смоделированное значение статистики превысило наблюдаемое значение. Таким образом, маленькие p -значения (традиционно < 0.05) указывают на ситуации, где модель не в состоянии воспроизвести определенную характеристику сети (т. е. наблюдается плохое качество подгонки).

Исследование объекта `DSmod.fit` показывает, что наша относительно простая модель с семью предикторами довольно точно описывает структурные паттерны в `TCdiss`. Из 50 значений статистик сети лишь четыре указывают на плохое качество подгонки.

Помимо исследования объекта `DSmod.fit`, в пакете `ergm` можно легко построить информативные графики, иллюстрирующие качество подгонки. Для каждой из четырех статистик сети строится отдельный график. Каждый график включает в себя ящичковые диаграммы с 95%-ми доверительными интервалами (светло-серые линии), которые показывают разброс значений конкретной статистики (по данным 100 имитированных сетей). Толстая черная линия показывает значение той же самой статистики для наблюдаемой сети. У хорошо подогнанной модели толстая жирная линия находится внутри границ интервалов. На рис. 11.3 мы видим, что наша итоговая модель в целом хорошо соответствует реальной сети, однако мы также видим, что наша модель имеет тенденцию строить сети, которые недооценивают количество диад с геодезическим расстоянием 2 и переоценивают количество диад с геодезическим расстоянием 3.

```

op <- par(mfrow=c(2,2))
plot(DSmod.fit, cex.axis=1.6, cex.label=1.6)
par(op)

```

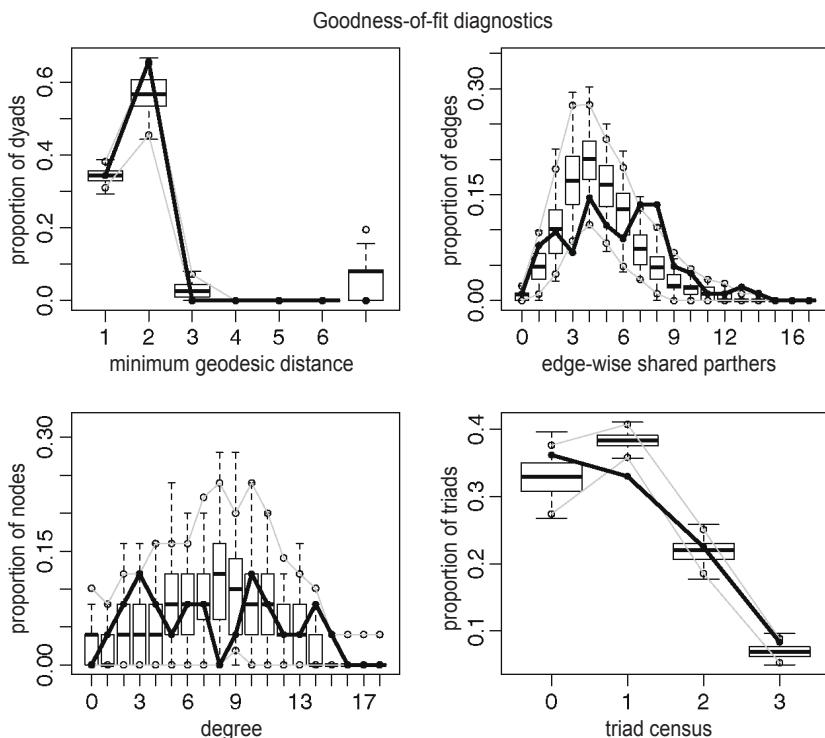


Рис. 11.3. Графики качества подгонки модели

11.3.3. Диагностика модели

Более подробную диагностическую информацию об оценивании модели можно получить, вызвав функцию `mcmc.diagnostics()`. Полезно посмотреть, как «закулисно» происходит процесс МCMC-оценивания, и особенно это важно, когда сталкиваешься с проблемами сходимости. Отчет по диагностике модели включает в себя подробную статистическую информацию по всем ковариатам модели, а также содержит информацию о том, как модель меняется с течением времени. Построенные графики показывают изменение марковской цепи Монте-Карло во времени и соответствующую гистограмму. Оба типа графиков должны показать оценки, которые центрированы около 0 (из-за больших размеров здесь показаны лишь графики диагностики) (рис. 11.4).

`mcmc.diagnostics(DSmod4)`

11.3.4. Имитационное моделирование сетей на основе оцененной модели

Оцененную экспоненциальную модель случайного графа можно использовать для имитационного моделирования одной или нескольких сетей, которые затем ис-

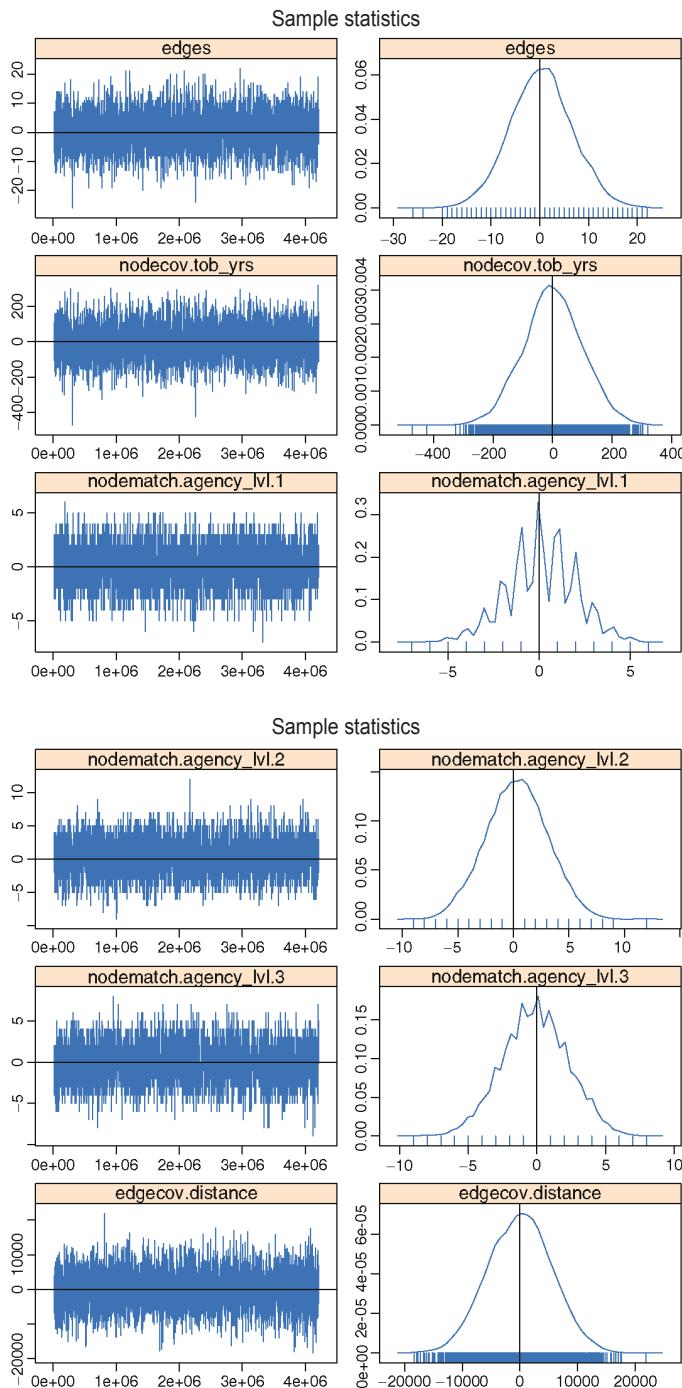


Рис. 11.4 MCMC-диагностика (фрагмент)

следуются или анализируются так, как если бы были реальной сетью. Например, вот как выглядит имитированная сеть на основе нашей итоговой модели в сравнении с реальной сетью. Обратите внимание на то, что имитированная сеть имеет точно такие же атрибуты узла, что и реальная сеть (рис. 11.5).

```
sim4 <- simulate(DSmod4, nsim=1, seed=569)
summary(sim4,print.adj=FALSE)

## Network attributes:
##   vertices = 25
##   directed = FALSE
##   hyper = FALSE
##   loops = FALSE
##   multiple = FALSE
##   bipartite = FALSE
##   title = IN_Diffusion
##   total edges = 115
##     missing edges = 0
##     non-missing edges = 115
##   density = 0.383
##
## Vertex attributes:
##
##   agency_cat:
##     numeric valued attribute
##     attribute summary:
##       Min. 1st Qu. Median     Mean 3rd Qu.    Max.
##       1.00    2.00    2.00    3.24    5.00    6.00
##
##   agency_lvl:
##     numeric valued attribute
##     attribute summary:
##       Min. 1st Qu. Median     Mean 3rd Qu.    Max.
##       1.00    1.00    2.00    2.04    3.00    3.00
##
##   lead_agency:
##     numeric valued attribute
##     attribute summary:
##       Min. 1st Qu. Median     Mean 3rd Qu.    Max.
##       0.00    0.00    0.00    0.04    0.00    1.00
##
##   tob_yrs:
##     numeric valued attribute
##     attribute summary:
##       Min. 1st Qu. Median     Mean 3rd Qu.    Max.
##       1.00    3.00    4.50    6.76    9.00   21.00
##
##   vertex.names:
##     character valued attribute
```

```

##      25 valid vertex names
##
## No edge attributes

op <- par(mfrow=c(1,2),mar=c(0,0,2,0))
lvlobz <- TCdiss %v% 'agency_lvl'
plot(TCdiss,usearrows=FALSE,
     vertex.col=lvl1+1,
     edge.lwd=0.5,edge.col="grey75",
     main="Реальная сеть")
lvl4 <- sim4 %v% 'agency_lvl'
plot(sim4,usearrows=FALSE,
     vertex.col=lvl4+1,
     edge.lwd=0.5,edge.col="grey75",
     main="Имитированная сеть – модель 4")
par(op)

```

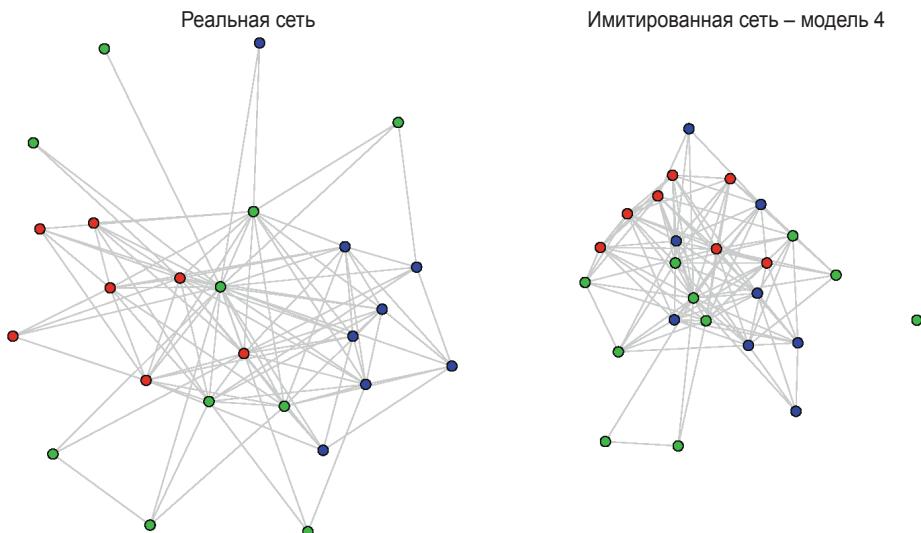


Рис. 11.5. Сравнение имитированной сети с реальной сетью

Глава 12

Модели динамических сетей

12.1. Введение	199
12.2. Подготовка данных	202
12.3. Спецификация и оценивание модели.....	209
12.4. Анализ модели.....	214

Что чему предшествовало: музыка страданию или наоборот? Слушал ли я музыку потому, что страдал? Или же страдал, оттого что слушал музыку? Может, все эти пластинки и сделали меня меланхоликом?

Ник Хорнби. «*Hi-Fi*»

12.1. Введение

Как было показано в главе 11, экспоненциальные модели случайных графов позволяют выполнять сложное и мощное моделирование сетевых структур и взаимосвязей. Порождающие модели сетей можно построить с помощью различных предикторов, включая характеристики узлов, характеристики диад, характеристики локальных структур и даже другие взаимосвязи. Основные гипотезы можно проверить с помощью экспоненциальных моделей случайных графов, а сами оцененные модели можно исследовать с помощью средств имитационного моделирования и диагностики качества подгонки, которыелагаются в пакете ergm.

Однако экспоненциальные модели случайных графов обычно ограничиваются кросс-секционными сетевыми данными¹. Социальные сети по своей природе являются динамическими. В частности, сетевые связи возникают, поддерживаются и иногда расторгаются с течением времени. Эти динамические процессы могут быть обусловлены некоторыми социальными процессами, затрагивающими характеристики акторов, диад и локальных структур. Например, студент может подружиться с другим студентом, частично в силу характеристики альтера² (например, по причине привлекательности), частично в силу схожести с определенным типом поведения (например, обоим нравится один и тот же стиль музыки), либо в силу локальной структуры (например, они оба уже дружат с одним и тем же студентом). В этой главе рассматриваются *стохастические акторно-ориентированные модели сетевой динамики* (*stochastic actor-based models for network dynamics*), которые включены в пакет RSiena и могут использоваться для построения моделей и проверки гипотез о динамических процессах сети.

12.1.1. Динамические сети

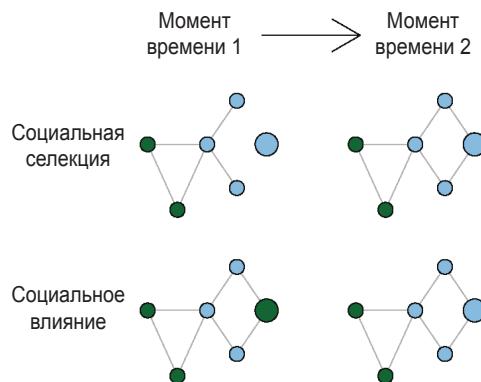
Сети могут меняться с течением времени двумя фундаментальными способами. Во-первых, со временем сеть может увеличиться или уменьшиться, что приведет к изменениям в структуре сети. Во-вторых, как уже говорилось выше, связи между участниками сети могут изменяться. Методы моделирования, рассмотренные в этой главе, прежде всего применяются для анализа изменений второго типа.

¹ Кросс-секционные сетевые данные – это характеристики участников сети, измеренные в один определенный момент времени, в противоположность лонгитюдным сетевым данным, когда характеристики участников сети фиксируются в разные моменты времени. – Прим. пер.

² Здесь и далее *эго* – актор, который направляет связь, *альтер* – актор, который принимает связь. – Прим. пер.

(Несмотря на то что RSiena может обработать сети, которые характеризуются некоторыми изменениями в структуре, сами эти изменения не моделируются.)

Одна из проблем моделирования сетевой динамики заключается в том, что общие характеристики сети могут быть обусловлены рядом базовых социальных механизмов. Например, гомофилия – это склонность людей (или других социальных объектов) устанавливать связи с теми, кто похож на них. Социальные сети характеризуются сильной гомофилией, и это явление уже наблюдается в течение многих десятилетий в разных областях общественных наук и медицины. Существует, по крайней мере, два социальных механизма, которые могут объяснить гомофилию, – социальная селекция и социальное влияние. Социальная селекция происходит, когда актор выбирает или образует новую социальную связь с другим актором, похожим на него по определенной релевантной характеристике. С другой стороны, социальное влияние осуществляется посредством установленных социальных связей. Социальное влияние возникает, когда поведение одного актора изменяется так, что становится похожим (или непохожим) на поведение другого актора или акторов.



двух совершенно различных механизмов. Определение этих механизмов в реальной сети имеет важные научные и практические последствия. Например, политика в области общественного здравоохранения может использовать стратегии «сарафанного радио» для распространения информации о мерах профилактики через социальные сети. И эта политика, вероятно, будет иметь больший эффект, если механизмы социального влияния будут преимущественно динамическими, когда уже задействованы социальные связи и сообщения с большей вероятностью передаются от человека к человеку. Напротив, если основным механизмом является социальная селекция, когда люди завязывают новые связи на основе схожего поведения, влияние «сарафанного радио» будет слабее.

Большая часть методов моделирования сетей типа экспоненциальных моделей случайных графов не позволяет выделить эффекты социального влияния и социальной селекции. В основном это обусловлено тем, что экспоненциальные модели случайных графов ограничиваются кросс-секционными сетевыми данными. Точная оценка динамических механизмов сетей, которые меняются со временем, требует применения методов динамического моделирования типа тех, что представлены в RSiena.

12.1.2. *RSiena*

SIENA расшифровывается как *Simulation Investigation for Empirical Network Analysis* (*Имитационное моделирование для анализа эмпирических сетей*) и является набором аналитических инструментов, который можно использовать для моделирования лонгитюдных сетевых данных. Для этого применяется *стохастическая акторно-ориентированная модель* (*stochastic actor-oriented model, SAOM*), разработанная Снайдерсом и его коллегами ([Snijders et al., 2010]). RSiena является пакетом R, в котором предлагаются функции оценивания модели, а также различные вспомогательные средства для графического изображения, диагностики и исследования построенных моделей и имитированных сетей. Ядром SAOM является акторно- или агентно-ориентированная имитационная модель – она использует методы оценивания на основе марковского процесса, согласно которому будущие изменения состояния сети (т. е. образование или распад связей) с определенной долей вероятности определяются текущим состоянием сети в целом ([Snijders et al., 2010]).

RSiena сочетает мощные возможности стохастического моделирования сетей с лонгитюдным анализом. Это открывает много перспектив для анализа. RSiena можно использовать для моделирования эволюции одномодальных сетей, бимодальных сетей (см. главу 9) и коэволюции¹ динамических одномодальных или бимодальных сетей. Последний тип модели позволяет исследовать процессы социального влияния и социальной селекции, например изучить коэволюцию дружбы и курительного статуса.

¹ Здесь под коэволюцией сети подразумевается совместное развитие нескольких взаимосвязанных процессов, происходящих в сети. – Прим. пер.

С появлением этих возможностей значительно возрастает и сложность. В частности, обработка пропущенных данных, анализ лонгитюдных сетевых данных, для которых характерны изменения в структуре сети (т. е. со временем появляются новые узлы или исчезают уже существующие), необходимость предварительного анализа сотен потенциальных параметров для включения в модель, устранение проблем сходимости – все эти трудности остаются за рамками данной короткой главы, которая не может подробно рассказать о способах их решения. Вместо этого глава знакомит с основами анализа сетей в пакете RSiena. В качестве примера используется набор лонгитюдных сетевых данных, созданный для иллюстрации базового подхода к моделированию динамических сетей. Он должен помочь читателям начать использовать RSiena, тем не менее важно обратиться к имеющимся статьям, учебникам и документации, посвященным этому пакету. Руководство по RSiena будет хорошей отправной точкой, его можно найти по адресу http://www.stats.ox.ac.uk/~snijders/siena/siena_r.htm.

12.2. Подготовка данных

RSiena работает с лонгитюдными или панельными данными, которые фиксируются для одной и той же сети в двух и более временных точках (желательно брать большее количество временных точек). Набор данных Coevolve, который включен в пакет UserNetR, был разработан для исследования простой модели коэволюции. Данные по коэволюции дружбы и курительного статуса записаны в виде списка из четырех сетей-объектов *igraph*. Речь идет о сети дружеских контактов между 37 учащимися, измеренной в четырех временных точках («волнах»). Эти данные основываются на реальной направленной сети дружеских контактов, которую использовал Валенте в своей работе 2010 года. Изначально данные для сети собирались в один определенный момент времени. Здесь мы добавили три дополнительные вымышленные волны сбора данных, которые показывают как изменение связей, так и изменение курительного статуса.

Для создания новых волн использовались следующие правила:

1. В каждой волне один курящий случайным образом становился некурящим, а три некурящих – курящими, что в чистом итоге давало двух курящих. Новые курильщики с большей вероятностью становились участниками сети, связанными с другими курильщиками.
2. В каждой волне случайным образом удалялось 10% существующих связей. Затем устанавливалось точно такое же количество новых связей. Это позволяло сохранить общую плотность сети на одном и том же уровне.
3. При добавлении новых направленных связей использовались следующие правила:
 - (1) выбрать кого-то, кто имеет тот же самый курительный статус;
 - (2) выбрать кого-то, кто популярен (т. е. имеет высокую исходящую степень);
 - (3) сделать существующую связь взаимной.

Эти правила использовались для имитации динамики, которая придала сети определенную реалистичность, но при этом была достаточно проста, чтобы ее смогла обнаружить базовая модель RSiena. Для исследования сети с помощью пакета `igraph` будут построены графики. Данные хранятся в виде списка, поэтому их надо сначала извлечь.

```
library(igraph)
library(UserNetR)
data(Coevolve)
fr_w1 <- Coevolve$fr_w1
fr_w2 <- Coevolve$fr_w2
fr_w3 <- Coevolve$fr_w3
fr_w4 <- Coevolve$fr_w4
```

На рис. 12.2 показаны четыре волны данных. Форма узла соответствует полу (кружок = женщина; квадратик = мужчина), а курительный статус передан цветом узла (зеленый = некурящий; синий = курящий). Увеличение числа курящих с течением времени вполне очевидно, и похоже, что со временем курительный статус позволяет все более четко выделить участников сети в отдельные кластеры, по крайней мере мужчин.

```
colors <- c("darkgreen", "SkyBlue2")
shapes <- c("circle", "square")
coord <- layout.kamada.kawai(fr_w1)
op <- par(mfrow=c(2,2), mar=c(1,1,2,1))
plot(fr_w1, vertex.color=colors[V(fr_w1)$smoke+1],
      vertex.shape=shapes[V(fr_w1)$gender],
      vertex.size=10, main="Волна 1", vertex.label=NA,
      edge.arrow.size=0.5, layout=coord)
plot(fr_w2, vertex.color=colors[V(fr_w2)$smoke+1],
      vertex.shape=shapes[V(fr_w2)$gender],
      vertex.size=10, main="Волна 2", vertex.label=NA,
      edge.arrow.size=0.5, layout=coord)
plot(fr_w3, vertex.color=colors[V(fr_w3)$smoke+1],
      vertex.shape=shapes[V(fr_w3)$gender],
      vertex.size=10, main="Волна 3", vertex.label=NA,
      edge.arrow.size=0.5, layout=coord)
plot(fr_w4, vertex.color=colors[V(fr_w4)$smoke+1],
      vertex.shape=shapes[V(fr_w4)$gender],
      vertex.size=10, main="Волна 4", vertex.label=NA,
      edge.arrow.size=0.5, layout=coord)
par(op)
```

В табл. 12.1 представлены некоторые описательные статистики для сетевых данных. Как видно, размер и плотность сети остаются неизменными, однако количество курильщиков увеличивается со временем, так же как и модульность, основанная на курительном статусе. Обычно перед тем, как перейти к динамическому моделированию, нужно подробно исследовать графики сети и описательные статистики.

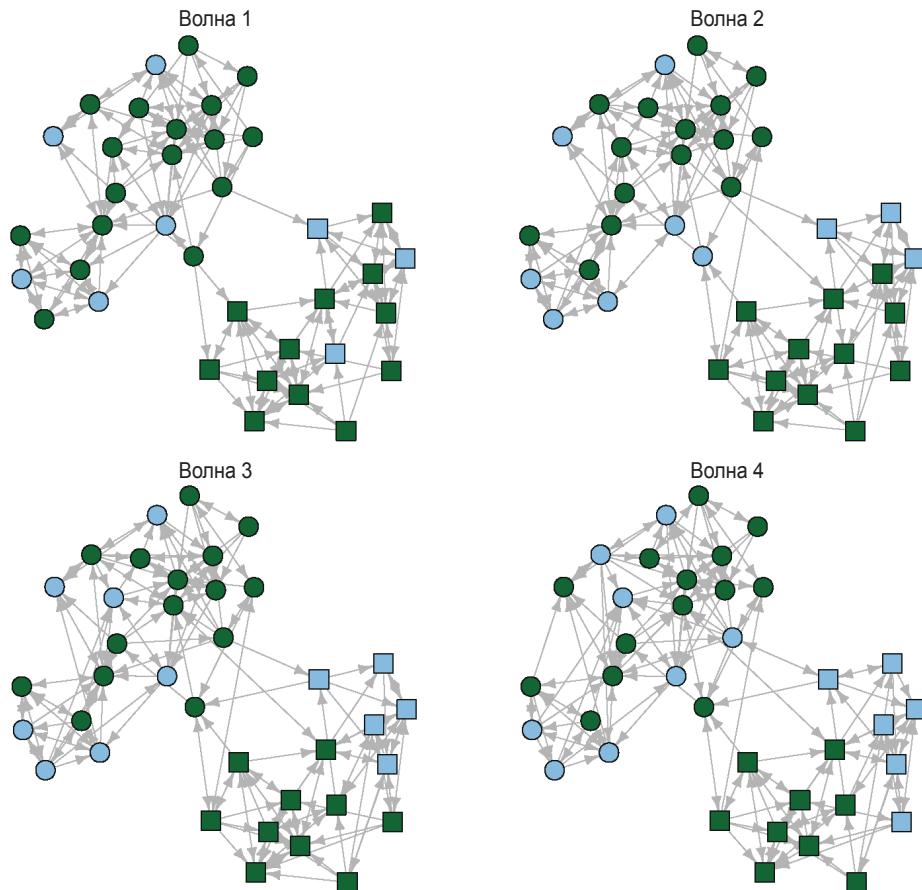


Рис. 12.2. Изменения, которые происходят в сети Coevolve со временем

Таблица 12.1. Характеристика сети Coevolve по четырем волнам

Волна	Размер	Плотность	Средняя входящая степень	Количество курящих	Модулярность
Волна 1	37	0,134	4,838	8	0,001
Волна 2	37	0,134	4,838	10	0,044
Волна 3	37	0,134	4,838	12	0,077
Волна 4	37	0,134	4,838	14	0,129

Графики и описательные статистики свидетельствуют о том, что наблюдается определенная динамика сети (увеличение модулярности) и поведения участников (увеличение числа курящих), которую можно смоделировать с помощью RSiena. В оставшейся части главы мы будем работать с простой моделью коэволюции дружбы и курительного статуса. Схема построения включает три основных шага: (1) подготовку данных; (2) оценку модели и (3) исследование и тестирование модели.

Перед тем как начать строить модель, убедитесь в том, что загрузили и установили пакет RSiena. Как и большинство пакетов R, его можно загрузить из CRAN-репозитория. Однако более свежие версии можно найти на веб-сайте разработчиков пакета RSiena http://www.stats.ox.ac.uk/~snijders/siena/siena_downloads.htm. Использованная здесь версия пакета под названием RSienaTest была на момент написания книги самой свежей. (Например, на момент написания книги из CRAN-репозитория можно было загрузить пакет Rsiena версии 1.1-232, тогда как с сайта разработчиков можно было загрузить RSienaTest версии 1.1-284.)

В RSiena не нужно задавать статистическую формулу для функции моделирования, как это делается в ergm, lm и большинстве остальных процедур статистического моделирования R. Вместо этого функция моделирования (под названием siena07) применяется к набору объектов RSiena, который как минимум должен включать объект *data* (содержащий все сетевые данные и ковариаты), объект *effects* (содержащий все эффекты, которые будут включены в модель) и объект *algorithm* (который предназначен для настройки большей части параметров моделирования).

Первый шаг заключается в том, чтобы «упаковать» сетевые данные так, чтобы RSiena мог прочитать их. RSiena может обработать шесть различных типов переменных. Переменная *network* – основная зависимая переменная в модели RSiena и может быть одномодальной или бимодальной сетью. Переменная *behavior* – зависимая переменная иного типа. Она представляет собой изменяющуюся во времени характеристику узла, эволюция которой может рассматриваться в рамках модели коэволюции. В нашем наборе данных, взятом для примера, курительный статус обрабатывается как зависимая переменная *behavior* (поведенческая зависимая переменная). Остальные четыре типа переменных обрабатываются как ковариаты. *coCovar* – это постоянный атрибут узла, который не изменяется со временем (например, пол). Напротив, *varCovar* – это атрибут, который изменяется со временем. (Обратите внимание на то, что переменная *behavior* – это особый тип изменяющейся во времени ковариаты, который обрабатывается как зависимая переменная.) Как и ergm, RSiena может также обработать диадные ковариаты. *coDyadCovar* – это постоянная диадная ковариата (например, родственные связи), в то время как *varDyadCovar* – это изменяющаяся во времени диадная ковариата.

В наших данных есть одна зависимая переменная *network* (дружеские связи), одна постоянная ковариата (пол) и одна изменяющаяся во времени ковариата, которая будет рассматриваться как зависимая переменная *behavior* (курительный статус). RSiena не может обработать данные igraph или statnet непосредственно, данные должны быть записаны в виде исходных массивов, матриц или векторов. Здесь будет полезно ознакомиться с некоторыми подходами при работе с данными, рассмотренными в главе 3. Первый шаг заключается в том, чтобы преобразовать данные в исходные социоматрицы.

```
library(RSienaTest)
matw1 <- as.matrix(get.adjacency(fr_w1))
matw2 <- as.matrix(get.adjacency(fr_w2))
```

```
matw3 <- as.matrix(get.adjacency(fr_w3))
matw4 <- as.matrix(get.adjacency(fr_w4))
matw1[1:8,1:8]

##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8]
## [1,]     0   0   0   0   0   0   1   1
## [2,]     0   0   0   0   0   0   1   0
## [3,]     0   1   0   0   0   0   0   0
## [4,]     0   0   0   0   0   0   1   0
## [5,]     0   0   0   0   0   0   0   0
## [6,]     0   0   0   0   0   0   1   0
## [7,]     1   0   0   0   0   1   0   1
## [8,]     1   0   0   0   0   0   1   0
```

Затем с помощью функции `sienaDependent` создается объект-зависимая переменная *network*. На вход подается многомерный массив, в котором каждый массив соответствует одной из четырех волн. По умолчанию `sienaDependent` ожидает данных, записанных в виде разреженной матрицы (ее можно получить с помощью пакета `Matrix`). В нашем примере данные являются простыми полными матрицами, поэтому для параметра `sparse` должно быть установлено значение `FALSE`.

```
fr4wav<-sienaDependent(array(c(matw1,matw2,matw3,matw4),
dim=c(37,37,4)),sparse=FALSE)
class(fr4wav)

## [1] "sienaDependent"

fr4wav

## Type          oneMode
## Observations 4
## Nodeset       Actors (37 elements)
```

Единственная проблема этого подхода состоит в том, что социоматрицы для больших сетей будут слишком громоздкими. Как уже говорилось в главе 3, для сетей больших размеров предпочтительнее использовать списки ребер. `RSiena` не может непосредственно обработать списки ребер, поэтому их нужно преобразовать в разреженные матрицы с помощью пакета `Matrix`. Программный код, приведенный ниже, создает ту же самую зависимую переменную дружеских связей, используя списки ребер, преобразованные в разреженные матрицы.

```
library(Matrix)
w1 <- cbind(get.edgelist(fr_w1), 1)
w2 <- cbind(get.edgelist(fr_w2), 1)
w3 <- cbind(get.edgelist(fr_w3), 1)
w4 <- cbind(get.edgelist(fr_w4), 1)
w1s <- spMatrix(37, 37, w1[,1], w1[,2], w1[,3])
w2s <- spMatrix(37, 37, w2[,1], w2[,2], w2[,3])
w3s <- spMatrix(37, 37, w3[,1], w3[,2], w3[,3])
```

```
w4s <- spMatrix(37, 37, w4[,1], w4[,2], w4[,3])
fr4wav2 <- sienaDependent(list(w1s,w2s,w3s,w4s))
fr4wav2

## Type          oneMode
## Observations 4
## Nodeset      Actors (37 elements)
```

Создав зависимую переменную *network*, можно создать и другие объекты данных, например ковариаты. Пол в сетях *igraph* сохраняется в виде характеристики вершин, поэтому создать объект *coCovar* довольно просто. Пол кодируется: 1 – женщина, 2 – мужчина.

```
gender_vect <- V(fr_w1)$gender
table(gender_vect)

## gender_vect
## 1 2
## 22 15

gender <- coCovar(gender_vect)
gender

## [1] 1 1 1 1 2 1 1 1 1 2 1 2 1 2 2 2 1 1 1 1 1 2 1
## [24] 2 2 2 1 2 2 1 2 1 1 1 1 2 2
## attr(),"class")
## [1] "coCovar"
## attr(),"centered")
## [1] FALSE
## attr(),"nodeSet")
## [1] "Actors"
```

Курительный статус – это наша поведенческая переменная для модели коэволюции. *RSiena* работает с матрицей $N \times W$, где N – строки (акторы) и W – столбцы (волны). И вновь мы извлекаем эту информацию из объектов *igraph*. Поскольку поведенческая переменная – это тип зависимой переменной, используется функция *sienaDependent*, но в данном случае мы задаем уже не зависимую *network*, а переменную *behavior*.

```
smoke <- array(c(V(fr_w1)$smoke,V(fr_w2)$smoke,
V(fr_w3)$smoke,V(fr_w4)$smoke),dim=c(37,4))
smokebeh <- sienaDependent(smoke,type = "behavior")
smokebeh

## Type          behavior
## Observations 4
## Nodeset      Actors (37 elements)
```

Наконец, все объекты-переменные помещаем в отдельный объект *data(friend)*.

```
friend <- sienaDataCreate(fr4wav, smokebeh, gender)
friend

## Dependent variables: fr4wav, smokebeh
## Number of observations: 4
##
## Nodeset          Actors
## Number of nodes      37
##
## Dependent variable fr4wav
## Type            oneMode
## Observations     4
## Nodeset          Actors
## Densities        0.13 0.13 0.13 0.13
##
## Dependent variable smokebeh
## Type            behavior
## Observations     4
## Nodeset          Actors
## Range           0 - 1
##
## Constant covariates: gender
```

Создав объект *data*, можно вывести базовый отчет, в нем приводится важная информация, которую нужно внимательно изучить, прежде чем приступать к моделированию.

```
print01Report(friend, modelName = 'Coevolve Example' )
```

Результаты этой команды не выводятся на консоль, не записываются в объект. Вместо этого в рабочем каталоге создается внешний текстовый файл, в данном случае он называется *Coevolve Example.out*. Его можно посмотреть с помощью любого текстового редактора, например Блокнота. Отчет содержит различную информацию о данных, включая информацию о пропущенных данных, степенных распределениях каждой волны и сводную информацию по каждой зависимой переменной и ковариате. Важнейшая информация располагается в нижней части отчета под заголовком **Change in Networks (Изменение в сетях)**. Мера Жаккара, которая является мерой сходства, вычисляется по переменным связей для каждой последовательной пары волн. Хотя для моделирования требуется, чтобы в рассматриваемой сети происходили изменения, они не должны быть очень существенными, иначе предположение о постепенном изменении будет несостоятельным. Авторы пакета RSiena полагают, что значения меры Жаккара должны быть выше 0,3 (Snijders и др. 2010). Применительно к нашим данных мы видим значения Жаккара выше 0,8, это позволяет нам предположить, что на протяжении рассматриваемого промежутка времени сеть сохраняет довольно высокий уровень устойчивости.

12.3. Спецификация и оценивание модели

12.3.1. Спецификация модели

Создав объект *data*, можно приступать к спецификации и оцениванию модели. В главе 11 мы видели, что стохастические сетевые модели могут включать различные параметры, которые проверяют гипотезы об атрибутах узлов, сходстве атрибутов узлов, входящих в диады, атрибутах связей и свойствах локальных структур. Лонгитюдные сетевые модели позволяют включать еще больший набор потенциальных параметров, поэтому выбор подходящего набора параметров может быть довольно сложен. В этой главе мы разберем модель с очень небольшим набором параметров. Для получения более подробной информации необходимо прочитать документацию по пакету RSiena (особенно главу 5, посвященную настройке модели).

Первый шаг спецификации модели состоит в том, чтобы создать объект *effects* с минимальным набором параметров.

```
frnдеff <- getEffects( friend )
frnдеff

##   name      effectName
## 1 fr4wav  constant fr4wav rate (period 1)
## 2 fr4wav  constant fr4wav rate (period 2)
## 3 fr4wav  constant fr4wav rate (period 3)
## 4 fr4wav  outdegree (density)
## 5 fr4wav  reciprocity
## 6 smokebeh rate smokebeh (period 1)
## 7 smokebeh rate smokebeh (period 2)
## 8 smokebeh rate smokebeh (period 3)
## 9 smokebeh behavior smokebeh linear shape
##   include fix  test  initialValue parm
## 1 TRUE    FALSE FALSE     2.004  0
## 2 TRUE    FALSE FALSE     2.004  0
## 3 TRUE    FALSE FALSE     2.004  0
## 4 TRUE    FALSE FALSE    -0.807  0
## 5 TRUE    FALSE FALSE     0.000  0
## 6 TRUE    FALSE FALSE     0.208  0
## 7 TRUE    FALSE FALSE     0.208  0
## 8 TRUE    FALSE FALSE     0.208  0
## 9 TRUE    FALSE FALSE     0.562  0
```

Перед нами базовая модель, которая включает лишь небольшое количество эффектов, используемых по умолчанию, в частности исходящую степень центральности (*outdegree*), отражающую склонность акторов образовывать новые связи с течением времени, и взаимность (*reciprocity*), т. е. склонность акторов образовывать со временем взаимные связи. Обычно мы добавляем дополнительные эффекты, которые нужно протестировать или изучить. Что это за эффекты и как их задать?

Все эффекты, которые можно использовать с учетом структуры набора данных friend, смотрим с помощью функции `effectsDocumentation`. Это как раз тот пример, когда пакет RSiena демонстрирует нехарактерную для R природу. Вместо того чтобы вывести результаты на консоль или создать новый объект, данная функция создает HTML-файл, который затем можно открыть в браузере.

`effectsDocumentation`(frndeef)

Документация по эффектам модели – это своего рода «словарь эффектов», в котором приводится вся необходимая информация по отбору нужных параметров модели. Однако она может обескуражить вас – для простого набора данных с четырьмя точками наблюдения, одной ковариатой (`gender`) и одной поведенческой зависимой переменной (`smokebeh`) существует более 400 возможных эффектов!

В табл. 12.2 приводятся эффекты, которые можно протестировать, а также информация, взятая из документации по эффектам, ее можно использовать, чтобы правильно задать эффекты в модели. Чтобы разобраться в этой информации, также обратитесь к файлу `frndeef.html`, который создается функцией `effectsDocumentation()`. Поскольку мы исследуем коэволюционную модель, здесь нас интересуют эффекты, влияющие на вероятность установления связей (зависимая переменная `fr4wav`), и эффекты, влияющие на изменение поведения (зависимая переменная `smokebeh`). Есть два типа эффектов, в документации по эффектам они приводятся в столбце «`name`» (в табл. 12.2 это столбец «имя»). Конкретный эффект, который можно включить в модель, задают с помощью члена, указанного в столбце «короткое имя». Многие из этих эффектов должны быть связаны с определенной ковариатой или зависимой переменной, поэтому их задают с помощью члена, указанного в столбце «`interaction1`» (в табл. 12.2 это столбец «взаимодействие1»). Для удобства навигации в табл. 12.2 дополнительно приводится конкретный номер строки из документации по эффектам, однако нумерация строк будет верной только в том случае, если данные были подготовлены точно так же, как в этой главе.

Таблица 12.2. Эффекты для данных Coevolve

Эффект	Тип эффекта	Информация из документации по эффектам (файл <code>frndeef.html</code>)			
		имя (<code>name</code>)	короткое имя (<code>shortName</code>)	взаимодействие1 (<code>interaction1</code>)	строка (<code>row</code>)
1 – Гомофилия по полу	Селекция	<code>fr4wav</code>	<code>sameX</code>	<code>gender</code>	139
2 – Курительный статус эго	Селекция	<code>fr4wav</code>	<code>egoX</code>	<code>smokebeh</code>	200
3 – Курительный статус альтера	Селекция	<code>fr4wav</code>	<code>altX</code>	<code>smokebeh</code>	197
4 – Гомофилия по курительному статусу	Селекция	<code>fr4wav</code>	<code>sameX</code>	<code>smokebeh</code>	212
5 – Усредненное влияние альтеров (средняя оценка)	Влияние	<code>smokebeh</code>	<code>avSim</code>	<code>fr4wav</code>	321
6 – Суммарное влияние альтеров (суммарная оценка)	Влияние	<code>smokebeh</code>	<code>totSim</code>	<code>fr4wav</code>	324
7 – Взаимность	Структурный	<code>fr4wav</code>	<code>recip</code>	NA	14
8 – Транзитивность	Структурный	<code>fr4wav</code>	<code>transTrip</code>	NA	17

Восемь различных гипотез будут протестираны с помощью восьми эффектов, перечисленных в таблице. Во-первых, исходя из паттерна, хорошо видного на рис. 12.2, похоже, существует сильный эффект гомофилии по полу, согласно которому дружеские контакты с большей вероятностью устанавливаются среди учащихся одного пола. Речь идет об эффекте социальной селекции, и мы выдвигаем гипотезу: вероятность того, что это установит новый дружеский контакт, увеличивается, если альтер будет того же пола. Член, который будет использоваться для тестирования этой гипотезы, – sameX . Затем мы сформулируем еще несколько гипотез, связанных с главными эффектами социальной селекции. В зависимости от своего курительного статуса это с большей или с меньшей вероятностью устанавливает дружеский контакт (egoX). И наоборот, вероятность установления дружеского контакта может зависеть от курительного статуса альтеров (altX). Например, это характерно в школах, в которых курение довольно распространено. Возможно, я хочу дружить с кем-то, потому что он курит и курение – это « круто », независимо от того, курю я или нет. Обратите внимание на то, что у нас нет причины считать эти гипотезы истинными, учитывая то, как эти данные были созданы. Наконец, последняя гипотеза, касающаяся социальной селекции, рассматривает другой эффект гомофилии, но на этот раз не по полу, а по курительному статусу. Гипотеза звучит так: новые дружеские связи с большей вероятностью устанавливаются среди учащихся с одним и тем же курительным статусом. Обратите внимание на то, что эта гипотеза использует тот же shortName (sameX). В данном случае использован член interaction1 , чтобы указать, что теперь эффект гомофилии связан с курительным статусом (а не с полом).

Следующие две гипотезы связаны с исследованием социального влияния. Они схожи друг с другом в том плане, что обе сфокусированы на вопросе, можно ли изменения в курительном статусе этого объяснить курительным статусом его друзей (т. е. участников, с которым связан это). Первая гипотеза состоит в том, что вероятность этих изменений связана с усредненным сходством курительного статуса этого и всех связанных с ним альтеров ($avSim$). Вторая гипотеза аналогична первой, но, согласно ей, влияние основывается на суммарном сходстве. (Суммарное сходство учитывает эффект более персонализированной социальной сети, который влияет на поведение.)

Последние две гипотезы касаются эффектов локальных структур. Здесь мы моделируем взаимность – склонность учащихся к образованию взаимных связей (*recip*), а также транзитивность – склонность учащихся устанавливать связи с теми, с кем устанавливают связи их друзья (*transTrip*).

Эти эффекты задаются в объекте *effects*. Как правило, эффекты добавляют по одному с помощью функции `includeEffects()`. Программный код, приведенный ниже, добавляет эффекты, которые соответствуют только что описанным восьми гипотезам.

```
##   effectName  include fix    test  initialValue
## 1 same gender TRUE      FALSE FALSE          0
##   parm
## 1 0

frnreff <- includeEffects(frnreff,egoX,
                           interaction1="smokebeh",name="fr4wav")

##   effectName  include fix    test  initialValue
## 1 smokebeh ego TRUE      FALSE FALSE          0
##   parm
## 1 0

frnreff <- includeEffects(frnreff,altX,
                           interaction1="smokebeh",name="fr4wav")

##   effectName      include fix    test  initialValue
## 1 1 smokebeh alter TRUE      FALSE FALSE          0
##   parm
## 1 0

frnreff <- includeEffects(frnreff,sameX,
                           interaction1="smokebeh",name="fr4wav")

##   effectName      include fix    test  initialValue
## 1 1 same smokebeh TRUE      FALSE FALSE          0
##   parm
## 1 0

frnreff <- includeEffects(frnreff,avSim,
                           interaction1="fr4wav",name="smokebeh")

##   effectName           include
## 1 behavior smokebeh average similarity TRUE
##   fix    test initialValue parm
## 1 FALSE FALSE          0    0

frnreff <- includeEffects(frnreff,totSim,
                           interaction1="fr4wav",name="smokebeh")

##   effectName           include
## 1 behavior smokebeh total similarity TRUE
##   fix    test initialValue parm
## 1 FALSE FALSE          0    0

frnreff <- includeEffects(frnreff,recip,transTrip,
                           name="fr4wav")

##   effectName      include fix    test
## 1 reciprocity     TRUE      FALSE FALSE
## 2 transitive triplets TRUE      FALSE FALSE
##   initialValue parm
## 1             0    0
## 2             0    0
```

```

frnдеff

##   name      effectName
## 1 fr4wav  constant fr4wav rate (period 1)
## 2 fr4wav  constant fr4wav rate (period 2)
## 3 fr4wav  constant fr4wav rate (period 3)
## 4 fr4wav  outdegree (density)
## 5 fr4wav  reciprocity
## 6 fr4wav  transitive triplets
## 7 fr4wav  same gender
## 8 fr4wav  smokebeh alter
## 9 fr4wav  smokebeh ego
## 10 fr4wav same smokebeh
## 11 smokebeh rate smokebeh (period 1)
## 12 smokebeh rate smokebeh (period 2)
## 13 smokebeh rate smokebeh (period 3)
## 14 smokebeh behavior smokebeh linear shape
## 15 smokebeh behavior smokebeh average similarity
## 16 smokebeh behavior smokebeh total similarity
##   include fix test initialValue parm
## 1 TRUE FALSE FALSE    2.004 0
## 2 TRUE FALSE FALSE    2.004 0
## 3 TRUE FALSE FALSE    2.004 0
## 4 TRUE FALSE FALSE   -0.807 0
## 5 TRUE FALSE FALSE    0.000 0
## 6 TRUE FALSE FALSE    0.000 0
## 7 TRUE FALSE FALSE    0.000 0
## 8 TRUE FALSE FALSE    0.000 0
## 9 TRUE FALSE FALSE    0.000 0
## 10 TRUE FALSE FALSE   0.000 0
## 11 TRUE FALSE FALSE   0.208 0
## 12 TRUE FALSE FALSE   0.208 0
## 13 TRUE FALSE FALSE   0.208 0
## 14 TRUE FALSE FALSE   0.562 0
## 15 TRUE FALSE FALSE   0.000 0
## 16 TRUE FALSE FALSE   0.000 0

```

12.3.2. Оценивание модели

Последний шаг перед оцениванием модели заключается в том, что нужно задать параметры алгоритма. В данном случае объект *algorithm* будет использовать параметры по умолчанию, кроме строки заголовка для модели.

```
myalgorithm <- sienaAlgorithmCreate(projname='coevolve')
```

Модель в пакете RSiena оценивается с помощью функции *siena07()*, в которую мы передаем уже созданные нами объекты *algorithm*, *data*, *effects*. Для настройки процесса оценивания можно задать дополнительные параметры. В данном примере параметры *batch* и *verbose* используются для упрощения вывода. Запуская этот

программный код в интерактивной среде, вы можете задать для этих параметров значение TRUE. Последние три параметра позволяют ускорить процесс оценивания за счет использования нескольких процессорных ядер (если такая возможность имеется). Здесь используются три ядра из четырех. Соблюдайте осторожность при использовании всех ядер процессора в том случае, если есть еще процессы, выполняемые операционной системой. Для получения более подробной технической информации обратитесь к файлу справки.

```
set.seed(999)
RSmod1 <- siena07( myalgorithm, data = friend,
                    effects = frnдеff, batch=TRUE,
                    verbose=FALSE, useCluster=TRUE,
                    initC=TRUE, nbrNodes=3)
```

12.4. Анализ модели

12.4.1. Интерпретация модели

И как принято для любого метода оценивания в R, результаты моделирования можно исследовать, просмотрев содержимое объекта-модели (RSmod1). Непосредственно укажите объект-модель или воспользуйтесь командой `summary()` для получения более подробного вывода. (Вывод, приведенный здесь, был отредактирован с целью экономии места и лучшей читаемости.)

```
summary(RSmod1)

## Estimates, standard errors and convergence t-ratios
##
## Network Dynamics
##   1. rate constant fr4wav rate (period 1)
##   2. rate constant fr4wav rate (period 2)
##   3. rate constant fr4wav rate (period 3)
##   4. eval outdegree (density)
##   5. eval reciprocity
##   6. eval transitive triplets
##   7. eval same gender
##   8. eval smokebeh alter
##   9. eval smokebeh ego
## 10. eval same smokebeh
##
##           Estimate   Standard   Convergence
##                   Error       t-ratio
##
##   1.      1.1572  ( 0.2073 )  -0.0491
##   2.      1.1410  ( 0.1990 )  -0.0114
##   3.      1.1366  ( 0.1948 )  -0.0273
##   4.     -2.9556  ( 0.3949 )   0.0141
##   5.      0.7990  ( 0.2539 )  -0.0805
```

```

##      6.      0.0860  (  0.0785  )   -0.0508
##      7.     1.1429  (  0.3174  )   -0.1147
##      8.      0.6885  (  0.3792  )   -0.0122
##      9.     -0.0847  (  0.2878  )    0.0165
##     10.     1.0975  (  0.4373  )   -0.1392
##
## Behavior Dynamics
## 11. rate rate smokebeh (period 1)
## 12. rate rate smokebeh (period 2)
## 13. rate rate smokebeh (period 3)
## 14. eval behavior smokebeh linear shape
## 15. eval behavior smokebeh average similarity
## 16. eval behavior smokebeh total similarity
##
##          Estimate   Standard Convergence
##                      Error       t-ratio
##
##      11.     0.3028  (  0.1684  )    0.0082
##      12.     0.3485  (  0.1963  )    0.0528
##      13.     0.3363  (  0.1949  )    0.0406
##      14.     4.0791  (  8.7065  )   -0.0218
##      15.    18.7278  ( 53.9223  )   -0.1372
##      16.    -1.4614  (  6.9254  )    0.0824
##
## Total of 2340 iteration steps.
##

```

Для модели коэволюции оценки параметров приводятся в двух разделах вывода. В разделе «Network Dynamics» («Сетевая динамика») приводятся оценки, относящиеся к формированию связей (т. е. к зависимой переменной `fr4wav`). С другой стороны, раздел «Behavior Dynamics» («Поведенческая динамика») содержит оценки, связанные с изменениями в поведении участников сети (т. е. связанные с зависимой переменной `smokebeh`).

t-коэффициенты сходимости не являются традиционными *t*-статистиками, использующимися для проверки значимости оценок параметров. Они проверяют сходимость каждой оценки, маленькие значения указывают на хорошую сходимость. Согласно руководству по пакету `RSiena`, абсолютные значения, не превышающие 0,10, указывают на превосходную сходимость, а значения, не превышающие 0,15, считаются приемлемыми значениями сходимости. Здесь мы видим, что все параметры сетевой динамики имеют превосходную сходимость, в то время как несколько параметров поведенческой динамики демонстрируют лишь приемлемую сходимость.

Оценка интенсивности (rate estimates) – скорость, с которой изменяется зависимая переменная за определенный период (где `period 1` соответствуют интервалу между волной 1 и волной 2). Более точно, это частота, с которой каждый актор сети может поменять свой статус-кво (значение зависимой переменной) в интер-

вале между двумя точками наблюдения. *Оценка веса (eval estimates)* – это вес, использующийся в функции оценивания сети. Точные вычисления для правильной интерпретации этих эффектов довольно сложны, поэтому для получения дополнительной информации см. [Snijders et al., 2010]. Однако в целом эти оценки представляют собой относительную «привлекательность» конкретного состояния сети для актора. Например, положительная оценка для `same gender (1,13)` указывает на то, что связи с большей вероятностью устанавливаются (или поддерживаются) между актерами одного и того же пола.

Значимость этих весов можно определить, разделив оценки на их стандартные ошибки. Полученные значения подчиняются t -распределению, поэтому любые абсолютные значения больше 2 являются значимыми на уровне значимости 0,05.

Применительно к нашему примеру мы видим, что `его` с большей вероятностью устанавливает дружеские контакты с альтерами своего пола и с таким же курительным статусом, как и у него. С другой стороны, похоже, что курительный статус `это` и курительный статус альтера не являются значимыми предикторами, влияющими на формирование связей. Исходящая степень центральности и взаимность являются значимыми структурными предикторами, чего нельзя сказать о транзитивности. Результаты поведенческой динамики свидетельствуют о том, что количество курящих с течением времени увеличивается (*linear shape*). Большой положительный коэффициент для `average similarity` предполагает, что изменение курительного статуса обусловлено усредненным сходством курительного статуса `это` и всех связанных с ним альтеров¹. Однако эта оценка имеет очень большую стандартную ошибку, таким образом, вес функции оценен неточно. И это неудивительно, потому что обнаружить изменения в поведении акторов труднее, чем обнаружить изменения в формировании связей. С одной стороны, существует огромное число возможных связей между актерами (равное квадрату количества вершин сети за каждый период). С другой стороны, количество изменений в поведении акторов – это обычное количество участников сети за каждый период. Особенно это верно для нашего примера, в котором используется сеть относительно небольшого размера и лишь небольшое количество участников сети в каждой волне меняют свой курительный статус. Поэтому, несмотря на то что мы знаем, что эти изменения «реальны», анализ не обладает необходимой мощностью, способной обнаружить данные эффекты.

Как правило, мы вносим изменения и строим новые модели, основываясь на информации, почерпнутой из предыдущих моделей. Для этого примера мы исключим несколько незначимых предикторов. Чтобы сделать это, мы просто обновим объект `effects`, включив в него новые предикторы, или просто укажем предикторы, которые мы хотели бы исключить. Исключенный предиктор указывается с помощью параметра `include=FALSE`. В данном случае мы исключаем предиктор общего сходства для поведенческой переменной, а также предиктор транзитивности.

¹ То есть подтверждается гипотеза о социальном влиянии, согласно которой это склонен менять свое отношение к курению в соответствии с отношением альтеров к курению. – Прим. пер.

```

frnдеff2 <- includeEffects(frnдеff,totSim,
                           interaction1="fr4wav",
                           name="smokebeh",
                           include=FALSE)

## [1] effectName   include      fix
## [4] test         initialValue parm
## <0 rows> (or 0-length row.names)

frnдеff2 <- includeEffects(frnдеff2,transTrip,
                           name="fr4wav",
                           include=FALSE)

## [1] effectName   include      fix
## [4] test         initialValue parm
## <0 rows> (or 0-length row.names)

frnдеff2

##    name    effectName
## 1 fr4wav constant fr4wav rate (period 1)
## 2 fr4wav constant fr4wav rate (period 2)
## 3 fr4wav constant fr4wav rate (period 3)
## 4 fr4wav outdegree (density)
## 5 fr4wav reciprocity
## 6 fr4wav same gender
## 7 fr4wav smokebeh alter
## 8 fr4wav smokebeh ego
## 9 fr4wav same smokebeh
## 10 smokebeh rate smokebeh (period 1)
## 11 smokebeh rate smokebeh (period 2)
## 12 smokebeh rate smokebeh (period 3)
## 13 smokebeh behavior smokebeh linear shape
## 14 smokebeh behavior smokebeh average similarity
##    include fix  test  initialValue  parm
## 1 TRUE  FALSE FALSE  2.004  0
## 2 TRUE  FALSE FALSE  2.004  0
## 3 TRUE  FALSE FALSE  2.004  0
## 4 TRUE  FALSE FALSE -0.807  0
## 5 TRUE  FALSE FALSE  0.000  0
## 6 TRUE  FALSE FALSE  0.000  0
## 7 TRUE  FALSE FALSE  0.000  0
## 8 TRUE  FALSE FALSE  0.000  0
## 9 TRUE  FALSE FALSE  0.000  0
## 10 TRUE FALSE FALSE  0.208  0
## 11 TRUE FALSE FALSE  0.208  0
## 12 TRUE FALSE FALSE  0.208  0
## 13 TRUE FALSE FALSE  0.562  0
## 14 TRUE FALSE FALSE  0.000  0

myalgorithm <- sienaAlgorithmCreate(projname='coevol2')

```

Теперь оцениваем новую модель. RSiena позволяет нам использовать оценки, полученные из предыдущей модели, в качестве стартовых значений для построения новой модели. В данном случае мы определяем, что стартовые значения должны основываться на оценках, записанных в RSmod1, используя параметр prevAns. Иногда это помогает улучшить сходимость конкретных оценок весов. Наконец, при построении второй модели мы воспользуемся опцией returnDeps. Она позволяет сохранить некоторые вспомогательные статистики по моделируемым зависимым переменным для последующего исследования качества подгонки.

```
set.seed(999)
RSmod2 <- siena07(myalgorithm, data = friend,
                    effects = frnreff2,
                    prevAns=RSmod1,batch=TRUE,
                    verbose=FALSE,useCluster=TRUE,
                    initC=TRUE,nbrNodes=3,
                    returnDeps=TRUE)

summary(RSmod2)

## Estimates, standard errors and convergence t-ratios
##
## Network Dynamics
##   1. rate constant fr4wav rate (period 1)
##   2. rate constant fr4wav rate (period 2)
##   3. rate constant fr4wav rate (period 3)
##   4. eval outdegree (density)
##   5. eval reciprocity
##   6. eval same gender
##   7. eval smokebeh alter
##   8. eval smokebeh ego
##   9. eval same smokebeh
##
##
##          Estimate   Standard Convergence
##                      Error      t-ratio
##
##   1.     1.1392  ( 0.223 ) -0.0454
##   2.     1.1321  ( 0.213 )  0.0056
##   3.     1.1260  ( 0.200 ) -0.0086
##   4.    -3.0585  ( 0.422 )  0.0695
##   5.     0.8387  ( 0.247 )  0.0807
##   6.     1.4113  ( 0.303 )  0.0423
##   7.     0.7123  ( 0.417 )  0.0127
##   8.    -0.0733  ( 0.307 )  0.0721
##   9.     1.2041  ( 0.486 )  0.0303
##
## Behavior Dynamics
## 10. rate rate smokebeh (period 1)
```

```

## 11. rate rate smokebeh (period 2)
## 12. rate rate smokebeh (period 3)
## 13. eval behavior smokebeh linear shape
## 14. eval behavior smokebeh average similarity
##
##
##           Estimate   Standard   Convergence
##                      Error      t-ratio
##
## 10.       0.3076  ( 0.170  )    0.0508
## 11.       0.3680  ( 0.249  )    0.0212
## 12.       0.3493  ( 0.181  )    0.0178
## 13.       6.6261  ( 37.771 )   -0.0061
## 14.      18.6088  ( 111.033 )    0.0270
##
## Total of 2140 iteration steps.
##

```

Исключив некоторые незначимые переменные и использовав в качестве старовых значений оценки весов предыдущей модели, мы улучшили сходимость, теперь все эффекты имеют превосходную сходимость. Эффект сходства по куритльному статусу все еще положителен, однако по-прежнему сохраняется большая стандартная ошибка. Возможно, требуется больший размер сети или большее количество волн данных, чтобы уменьшить стандартную ошибку.

12.4.2. Качество подгонки

Аналогично пакету `ergm`, `RSiena` включает в себя графические и диагностические средства, позволяющие исследовать качество соответствия оцененной модели реальной сети. Как и в пакете `ergm`, статистики качества подгонки можно вычислить по характеристикам имитированных сетей, которые по умолчанию не включаются в оцененные модели в качестве предикторов. Это позволяет нам оценить способность модели строить имитированные сети, «похожие» на наблюдаемую сеть.

В пакете `RSiena` качество подгонки оценивается с помощью функции `sienaGOF`. Описательная статистика задается и вычисляется по имитированным сетям в конце каждого периода. Затем эти значения сравниваются с наблюдаемыми значениями с помощью расстояния Махalanобиса.

В текущей версии пакета `RSienaTest` функция `sienaGOF` вычисляет небольшое количество статистик сети. Одна из таких статистик – это *распределение исходящих степеней (indegree distribution)*. В программном коде, приведенном ниже, мы ограничиваем возможные значения распределения диапазоном от 1 до 10 (используя параметр `levls`). Сводка показывает распределение исходящих степеней в реальной сети для волны 4.

```



```

```

## 1 2 3 4 5 6 7 8 9 10
## 2 3 7 6 5 4 6 2 1 1

gofi <- sienaGOF(RSmmod2, IndegreeDistribution,
                  levels=1:10, verbose=FALSE, join=TRUE,
                  varName="fr4wav")

```

Как только объект gofi создан, его можно использовать для вывода графической информации о качестве подгонки модели. На рис. 12.3 приведен скриптический график, который показывает разброс значений описательной статистики по имитированным сетям, в данном случае речь идет об исходящих степенях. Пунктирные серые линии представляют собой эмпирический 95%-ный доверительный интервал. Красные кружки – это значения описательной статистики для наблюдаемой сети. Если кружки находятся внутри доверительного интервала, это служит свидетельством хорошей подгонки. В данном случае наша вторая модель строит превосходные имитированные сети, которые имеют такое же или схожее распределение исходящих степеней.

```
plot(gofi)
```

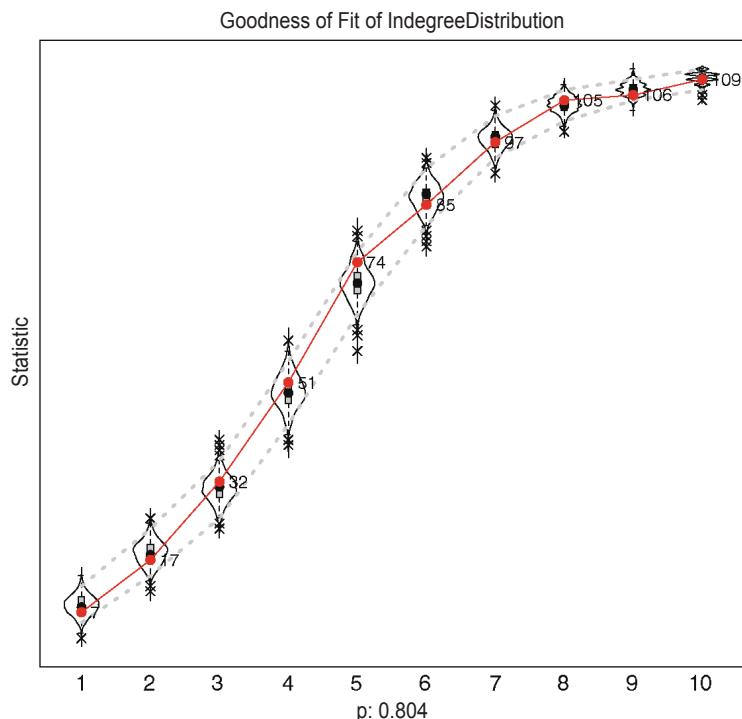


Рис. 12.3. Качество подгонки по распределению исходящих степеней

Хотя с помощью sienaGOF вычисляется лишь несколько статистик, RSiena позволяет задавать функции расчета пользовательских статистик. Благодаря этому можно легко оценить качество подгонки, используя практически любую интересующую характеристику сети. Пример, приведенный ниже (взят из файла справки sienaGOF-auxiliary), показывает, как задать сенсус триад, который был предложен Холландом и Лейнхардтом в 1978 году, а затем использовать его для анализа качества подгонки. Сенсус триад представляет собой частотное распределение всех возможных вариантов триад в направленной сети. Сенсус использует 3-разрядный цифровой код для обозначения возможной структуры триады, всего выделяют 16 структур (рис. 12.4). Первая цифра означает количество взаимных диад в триаде, вторая цифра – это количество асимметрических диад в триаде, а третья цифра – это количество нулевых, или пустых, диад в триаде. См. работу [Wasserman, Faust, 1994] для получения дополнительной информации.

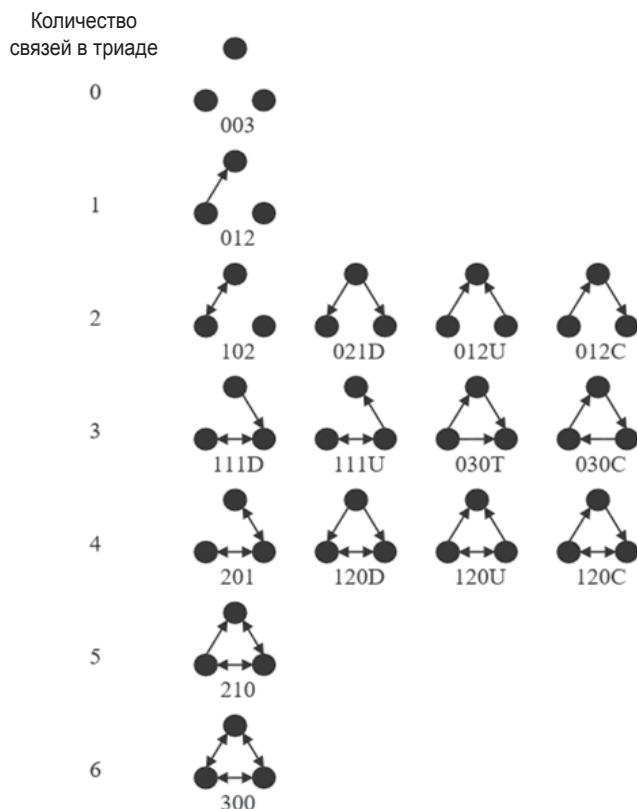


Рис. 12.4. Структуры триад

В программном коде, приведенном ниже, показано создание новой функции TriadCensus. Эта функция работает с уже существующей функцией triad.census

из комплекта пакетов statnet. (Обратите внимание, что для вычисления описательных статистик, используемых функцией sienaGOF, можно использовать пакет igraph.) Затем эта функция-обертка используется функцией sienaGOF.

```
TriadCensus <- function(i,data,sims,wave,
                         groupName,varName,levls=1:16) {
  unloadNamespace("igraph") # чтобы избежать конфликта пакетов
  require(sna)
  require(network)
  x <- networkExtraction(i,data,sims,wave,
                         groupName,varName)
  if (network.edgecount(x) <= 0){x <- symmetrize(x)}
  # иначе вызов triad.census(x) вернет ошибку
  tc <- sna::triad.census(x)[1,levls]
  # имена передаются автоматически
  tc
}
```

Информацию о качестве подгонки, сохраненную в объекте-модели, также можно непосредственно исследовать или обобщить. Информацию можно представить и в графическом виде. Для этой вспомогательной статистики желательно выполнить центрирование и масштабирование значений.

Здесь мы видим, что наша вторая модель довольно хорошо воспроизводит реальные структуры триад, за исключением 021C (модель переоценивает количество триад с двумя направленными связями) и 120U (модель недооценивает количество триад с одной взаимной связью и двумя направленными связями) (рис. 12.5).

```
goftc <- sienaGOF(RSmod2, TriadCensus,
                     varName="fr4wav",
                     verbose=FALSE, join=TRUE)
descriptives.sienaGOF(goftc)

##          003   012   102   021D   021U   021C   111D
## max      12416  6506  4301   203   273   425   454
## perc.upper 12199  6248  4055   183   247   360   431
## mean     11830  5895  3775   152   208   302   390
## median    11832  5900  3774   151   208   301   390
## perc.lower 11474  5538  3513   124   173   252   350
## min      11289  5235  3369   111   153   199   328
## obs       11771  6018  3816   137   213   232   353
##           111U   030T   030C   201   120D   120U   120C
## max       336 100.0 19.00  182 80.0 54.0 85.0
## perc.upper 301 88.0 15.00 157 70.0 46.0 69.0
## mean      262 68.3 8.11 127 57.5 35.9 53.7
## median    263 68.0 8.00 126 58.0 36.0 54.0
## perc.lower 227 51.0 3.00 101 45.0 25.0 41.0
## min       214 39.0 1.00  91 41.0 19.0 35.0
## obs       245 82.0 8.00 119 61.0 49.0 65.0
```

```

##          210   300
## max      128  67.0
## perc.upper 118 55.0
## mean     102 43.3
## median    102 43.0
## perc.lower 85 32.0
## min       74 25.0
## obs      105 36.0

plot(goftc, center=TRUE, scale=TRUE)

```

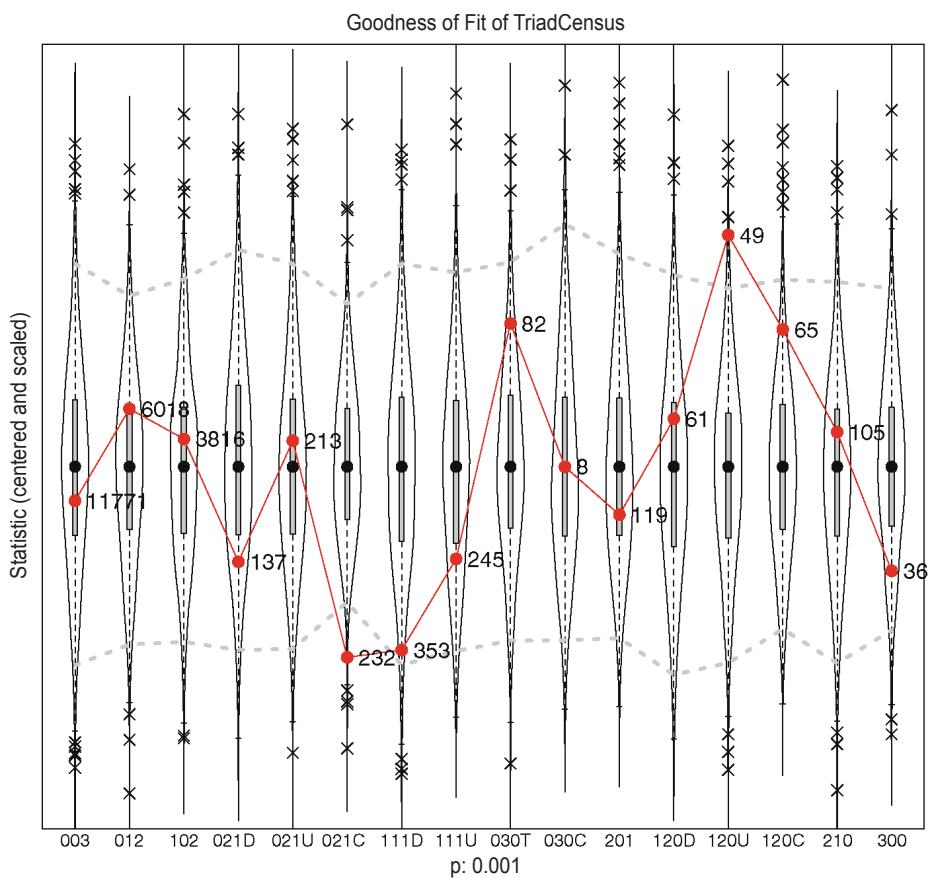


Рис. 12.5. Качество подгонки по сенсусу триад

12.4.3. Имитационное моделирование

Имитированные сети можно изучить подробнее, если при оценивании модели для параметра `returnDeps` задать значение `TRUE`. (При построении больших сетей это потребует значительного объема памяти, поэтому по умолчанию установлено

значение FALSE.) Информация об имитированных сетях хранится во вложенном списке (`sims`) внутри объекта-модели (`RSmod2`). Информация представлена в виде списка ребер по каждой имитированной сети за каждый период. По умолчанию количество имитируемых сетей равно 1000 (задается параметром `n3` в функции `sienaAlgorithmCreate`). В ходе конкретного прогона в конце каждого периода создается одна имитированная сеть. Так, в этом примере с четырьмя волнами данных будут построены три имитированные сети, по одной сети в конце периодов 1, 2 и 3.

Общую структуру информации, записанную в `sims`, можно посмотреть, воспользовавшись нижеприведенным программным кодом. Здесь мы считываем информацию по 500-му имитационному прогону.

```
str(RSmod2$sims[[500]])

## List of 1
## $ Data1:List of 2
## ..$ fr4wav :List of 3
## ...$ 1: int [1:188, 1:3] 1 1 2 2 2 2 3 3 3 ...
## ...$ 2: int [1:185, 1:3] 1 1 1 2 2 2 2 2 3 3 ...
## ...$ 3: int [1:176, 1:3] 1 1 1 2 2 2 2 2 2 2 ...
## ..$ smokebeh:List of 3
## ...$ 1: int [1:37] 1 0 0 0 0 1 0 0 0 0 ...
## ...$ 2: int [1:37] 1 1 0 0 0 1 0 0 0 0 ...
## ...$ 3: int [1:37] 1 0 0 1 0 1 0 0 0 0 ...
```

Теперь выведем список ребер для 500-го имитационного прогона. Первый индекс – номер имитационного прогона, второй индекс – номер группы (`RSiena` может выполнять мультигрупповое оценивание), третий индекс – номер зависимой переменной, и последний индекс – номер периода. В модели коэволюции используются две зависимые переменные. Первая переменная – зависимая переменная дружеских связей `fr4wav`, а вторая – зависимая переменная курительного статуса `smokebeh`. Таким образом, этот код строит список ребер, где ребра – это дружеские связи для 500-го имитационного прогона и третьего периода (ограничившись первыми 25 наблюдениями).

```
RSmod2$sims[[500]][[1]][[1]][[3]][1:25,]

##      [,1] [,2] [,3]
## [1,]     1    7    1
## [2,]     1    8    1
## [3,]     1   11    1
## [4,]     2    7    1
## [5,]     2   17    1
## [6,]     2   21    1
## [7,]     2   30    1
## [8,]     2   32    1
## [9,]     2   35    1
## [10,]    2   37    1
## [11,]    3   13    1
```

```

## [12,] 3 17 1
## [13,] 3 20 1
## [14,] 3 21 1
## [15,] 3 33 1
## [16,] 4 13 1
## [17,] 4 17 1
## [18,] 4 21 1
## [19,] 4 27 1
## [20,] 5 10 1
## [21,] 5 22 1
## [22,] 5 25 1
## [23,] 5 28 1
## [24,] 5 29 1
## [25,] 6 9 1

```

Информация о курительном статусе для того же самого имитационного про-
гона и периода выглядит так:

```

RSmod2$sims[[500]][[1]][[2]][[3]]
## [1] 1 0 0 1 0 1 0 0 0 0 1 0 0 1 1 1 0 0 0 0 1 0 0
## [24] 1 0 0 1 0 0 0 0 1 1 1 0 0 1

```

Используя вышеприведенную информацию, можно считать и преобразовать
данные в объект-сеть `statnet` или `igraph`. Например, нижеприведенный про-
граммный код использует пакет `igraph`, чтобы создать, исследовать и графически
представить одну из сетей, имитированных на основе второй модели в пакете `RSi-
ena` (рис. 12.5).

```

library(igraph)
el <- RSmod2$sims[[500]][[1]][[1]][[3]]
sb <- RSmod2$sims[[500]][[1]][[2]][[3]]
fr_w4_sim <- graph.data.frame(el,directed = TRUE)
V(fr_w4_sim)$smoke <- sb
V(fr_w4_sim)$gender <- V(fr_w4)$gender
fr_w4_sim
## IGRAPH DN-- 37 176 --
## + attr: name (v/c), smoke (v/n), gender
## | (v/n), V3 (e/n)
## + edges (vertex names):
## [1] 1 ->7 1 ->8 1 ->11 2 ->7 2 ->17 2 ->21
## [7] 2 ->30 2 ->32 2 ->35 2 ->37 3 ->13 3 ->17
## [13] 3 ->20 3 ->21 3 ->33 4 ->13 4 ->17 4 ->21
## [19] 4 ->27 5 ->10 5 ->22 5 ->25 5 ->28 5 ->29
## [25] 6 ->9 6 ->11 6 ->15 6 ->34 7 ->1 7 ->8
## [31] 7 ->13 7 ->18 8 ->1 8 ->4 8 ->7 8 ->17
## [37] 8 ->19 8 ->21 8 ->30 8 ->32 9 ->6 9 ->7
## + ... omitted several edges

```

```

modularity(fr_w4_sim, membership = V(fr_w4_sim)$smoke+1)
## [1] 0.112

modularity(fr_w4, membership = V(fr_w4)$smoke+1)
## [1] 0.129

colors <- c("darkgreen", "SkyBlue2")
coord <- layout.kamada.kawai(fr_w4)
op <- par(mfrow=c(1,2), mar=c(1,1,2,1))
plot(fr_w4, vertex.color=colors[V(fr_w4)$smoke+1],
      vertex.shape=shapes[V(fr_w4)$gender],
      vertex.size=10, main="Реальная сеть - Волна 4",
      vertex.label=NA,
      edge.arrow.size=0.5, layout=coord)
plot(fr_w4_sim,
      vertex.color=colors[V(fr_w4_sim)$smoke+1],
      vertex.shape=shapes[V(fr_w4_sim)$gender],
      vertex.size=10, main="Имитированная сеть - Волна 4",
      vertex.label=NA,
      edge.arrow.size=0.5, layout=coord)
par(op)

```

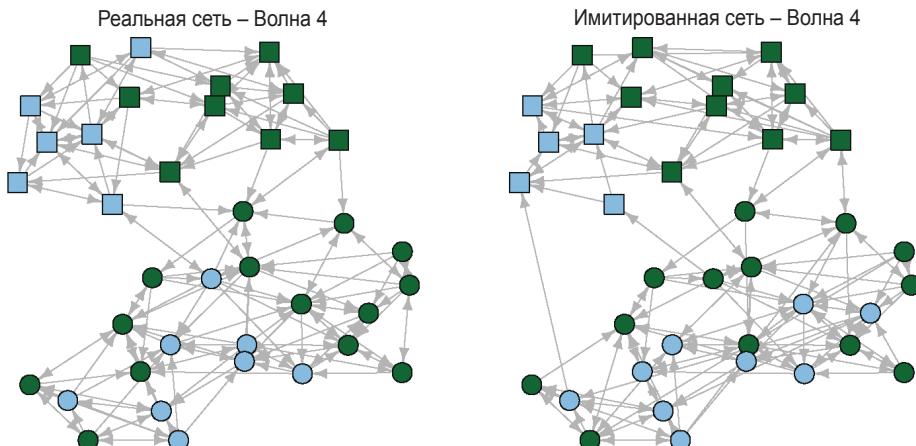


Рис. 12.6. Сравнение реальной сети с имитированной сетью

Глава 13

Имитационные модели

13.1. Имитационные модели
сетевой динамики..... 228

Иногда, чтобы изменить мнение человека, приходится менять сознание тех, кто находится с ним рядом.

Меган Уолен Тернер – царь Аттолии

13.1. Имитационные модели сетевой динамики

В главе 10 было показано, как инструменты R могут использоваться для имитации сетей с определенной структурой на основе конкретных построенных моделей. Эти имитированные сети полезны тем, что показывают социальные структуры, которые могут отражать реальность или интересны нам по чисто теоретическим причинам. В любом случае, они представляют собой статические сети.

Однако социальным сетям свойственна динамика. Социальные сети со временем могут увеличиться или уменьшиться в размерах, кроме того, может измениться их структура. Например, сети дружеских контактов растут по мере того, как участники расширяют свой круг друзей, или уменьшаются, если друзья переезжают или дружеские отношения охладевают. Структура сети дружеских контактов может существенно измениться, если учащиеся перешли из средней школы в старшую или, закончив колледж, стали работать. Данный тип сетевой динамики описывается изменениями узлов (которые соответствуют конкретным участникам сети) и изменениями связей, соединяющих узлы.

Второй тип сетевой динамики имеет место, когда на некоторую характеристику или поведение участников социальной сети влияют структурные свойства самой сети. Например, в сфере общественного здравоохранения уже давно известно, что подростки с большей вероятностью начнут курить, если их друзья или члены семьи курят.

В оставшейся части главы будут представлены два подробных примера, которые покажут, как можно использовать R для моделирования этих двух типов социальной динамики. Возможность строить имитационные модели сетевой динамики свидетельствует о преимуществе R. В частности, имитационное моделирование сетей стало возможным в силу того, что программная среда R объединила в себе такие направления, как управление данными, статистическое программирование и анализ сетей. Такие модели невозможно построить ни в одном традиционном пакете для анализа сетей типа Pajek, UCINet, Gephi или NodeXL.

13.1.1. Имитационное моделирование социальной селекции

Когда структура сети изменяется со временем, мы делаем предположение о том, что существует базовый процесс *социальной селекции* (*social selection*), который определяет способ установления и расторжения новых связей. (Несмотря на то что этот процесс может быть, по меньшей мере, отчасти случайным, мы обычно работаем с моделью, где формирование связей зависит от характеристик узлов,

локальных структур или исторических данных сети.) Социальная селекция была подробно изучена в рамках общественных наук, и, как показала практика, она частично объясняется *гомофилией* (*homophily*), склонностью людей устанавливать связи с теми, кто похож на них ([McPherson et al., 2001], также см. рис. 12.1).

В этом разделе мы построим динамическую модель социальной селекции. Мы сознательно упростили модель, чтобы облегчить ее интерпретацию и в то же время продемонстрировать пример построения хорошей модели. В частности, при выполнении имитационного моделирования лучше начинать с простой модели и усложнять ее только после того, как будет полностью интерпретирована простая модель. Кроме того, в нашем случае модель строится не для того, чтобы подчеркнуть эффективность в плане скорости выполнения. Оптимизацию с точки зрения эффективности можно выполнить позже, когда имитационная модель будет полностью протестирована и аналитик будет готов к ее масштабированию, чтобы задать большее число прогонов.

Применительно к нашей модели мы предположим, что у нас есть сеть дружеских контактов, где дружеские связи со временем могут изменяться, и эти изменения обусловлены сходством (или различием) участников сети по какой-то абстрактной характеристики узла. Эта характеристика может быть поведением, отношением или мнением. Кроме того, эта характеристика является количественной, поэтому у каждого участника сети она может проявляться в большей или меньшей степени. Например, такой характеристикой может быть физическая активность, когда некоторые участники сети обладают этой характеристикой в меньшей или большей степени (например, участники чаще тренируются). В этом примере мы будем использовать имитационную модель, чтобы понять, как со временем изменяется общая гомофилия сети в зависимости от конкретных изменений, касающихся формирования и расторжения связей.

13.1.1.1. Создание сети для имитационного моделирования

Чтобы приступить к созданию и тестированию нашей имитационной модели, у нас должна быть сеть, с которой мы будем работать. Кроме того, нам нужно задать некоторые базовые характеристики сети и параметры модели, которые будут использоваться в процессе. Мы начнем с простой случайной сети, состоящей из 25 участников.

```
library(igraph)
N <- 25
netdum <- erdos.renyi.game(N, p=0.10)
graph.density(netdum)
mean(degree(netdum))

## [1] 0.1
## [1] 2.4
```

Кроме того, сеть должна включать характеристику узла, которая будет задавать изменения сети. Это абстрактное поведение (*Bh*) может принимать значение

от 0 до 1. Для упрощения интерпретации также вычисляется категориальная характеристика узла (`BhCat`). Категориальная переменная включает пять уровней физической активности участников сети: «очень низкий», «низкий», «средний», «высокий» и «очень высокий».

```
Bh <- runif(N, 0, 1)
BhCat <- cut(Bh, breaks=5, labels = FALSE)
V(netdum)$Bh <- Bh
V(netdum)$BhCat <- BhCat
table(V(netdum)$BhCat)

##
## 1 2 3 4 5
## 8 5 2 4 6
```

Вот как выглядит сеть после того, как мы задали палитру, назначающую цвета пяти уровням `BhCat`. (См. главу 5 для получения дополнительной информации о том, как работают палитры цветов.)

```
library(RColorBrewer)
my_pal <- brewer.pal(5, "PiYG")
V(netdum)$color <- my_pal[V(netdum)$BhCat]
crd_save <- layout.auto(netdum)
plot(netdum, layout = crd_save)
```

13.1.1.2. Создание функции изменения

Чтобы запустить процесс имитационного моделирования, нужно начинать изнутри и двигаться наружу. То есть мы начинаем с того, что задаем внутренние механизмы, которые позволяют сети меняться, и затем создаем платформу имитационного моделирования вокруг них. Ядро модели динамической сети позволяет сети меняться со временем. В данном контексте время является довольно абстрактным или размытым понятием, но, по сути, у нас должен быть способ изменять сеть и наблюдать эти изменения. Начать нужно с того, чтобы задать функцию, которая изменяет структуру сети, в данном случае речь идет о формировании или расторжении связей между двумя узлами.

Прежде чем браться за написание функции, мы можем вручную настроить процесс формирования новой связи или расторжения уже существующей связи. Проще начать с удаления связей. Во-первых, нам нужен способ, с помощью которого можно определить все имеющиеся связи для конкретного узла. В пакете `igraph` существует несколько равнозначных способов извлечь список смежности для узла, который является списком его прямых связей. Ниже приводятся узлы, которые связаны с узлом 24 в объекте `netdum`. (Чтобы сэкономить немного места и обезопасить себя от случайных изменений данных, сначала скопируем сеть.)

```
g <- netdum
get.adjlist(g) [24]
```

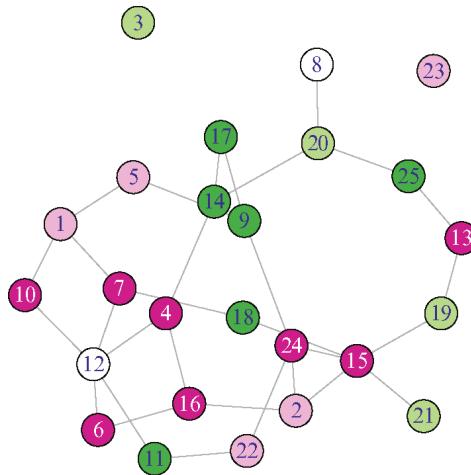
```

## [[1]]
## + 4/25 vertices:
## [1] 2 9 15 22

g[[24,]]

## [[1]]
## + 4/25 vertices:
## [1] 2 9 15 22

```



*Рис. 13.1. Случайная тестовая сеть
с пятью обозначенными уровнями поведения*

Возвращаясь к рис. 13.1, можно увидеть, что узел 24 связан с четырьмя узлами (2, 9, 15 и 22). Синтаксис `get.adjlist()` позволяет понять легче, чем ярлык с двойными квадратными скобками, поэтому далее будем использовать его.

В нашей модели нам нужны изменения в связях, обусловленные характеристикой узла (`Bh`). В частности, при построении обоснованной модели можно предположить, что дружеские связи с большей вероятностью будут расторгнуты, если два участника стали сильнее отличаться друг от друга по какой-то характеристике или поведению. Чтобы смоделировать это, нам нужно сравнить уровень поведения конкретного участника сети с поведением всех его друзей. Это легко сделать, используя вышеприведенный синтаксис. В нем используется функция-экстрактор вершин `V()` пакета `igraph`. Кроме того, функция `get.adjlist()` возвращает список, таким образом, функция `unlist()` используется для получения простого числового вектора. Наконец, сохраненный список смежности применяется для фильтрации сети, чтобы вывести значения поведенческой характеристики лишь для узлов, смежных с узлом 24. Похоже, что узел 24 имеет низкий уровень физической активности, который схож с уровнем физической активности узла 15. Узел 24 сильнее всего отличается от узла 9, который имеет очень высокий уровень физической активности.

```
V(g) [24] $Bh
## [1] 0.192
V_adj <- unlist(get.adjlist(g) [24])
V(g) [V_adj]$Bh
## [1] 0.389 0.952 0.114 0.325
```

Всю эту информацию можно записать в простой вектор различий, который измеряет абсолютные разности между значениями физической активности (Bh) для узла 24 и его смежных узлов.

```
BhDiff <- abs(V(g) [V_adj]$Bh - V(g) [24]$Bh)
BhDiff
## [1] 0.1966 0.7604 0.0783 0.1327
```

Затем используем эту информацию, чтобы выбрать связь, которую нужно удалить из сети. Это можно сделать вручную, определив два узла и присвоив им значение FALSE (и снова сначала сделаем копию):

```
gdum <- g
gdum[24,9] <- FALSE
get.adjlist(gdum) [24]
## [[1]]
## + 3/25 vertices:
## [1] 2 15 22
```

Более эффективный способ отобрать связи для удаления состоит в том, чтобы найти пару узлов, наиболее сильно отличающихся между собой. Это можно сделать с помощью индексной фильтрации (рис. 13.2).

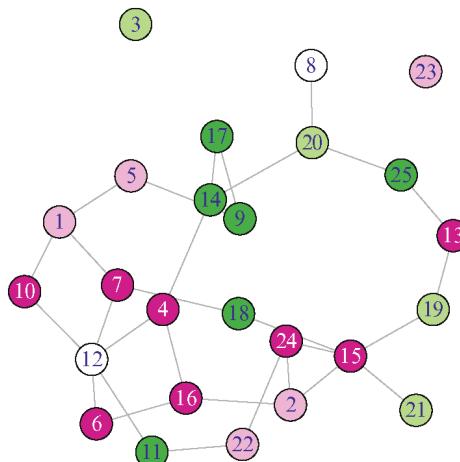


Рис. 13.2. Тестовая сеть с одной удаленной связью (24-9)

```

gdum <- g
V_sel <- V_adj[BhDiff == max(BhDiff)]
gdum[24,V_sel] <- FALSE
get.adjlist(gdum) [24]

## [[1]]
## + 3/25 vertices:
## [1] 2 15 22

plot(gdum, layout = crd_save)

```

Однако применительно к нашей модели нам не нужно удалять связь из самой непохожей пары узлов. Вместо этого нам нужно случайным образом удалить связи, при этом вероятность удаления взвешивается по степени различия между узлами. Это вносит в модель определенную случайность и гетерогенность. Получив вектор различий, его можно использовать для случайного отбора связи.

```

gdum <- g
V_sel <- sample(V_adj,1,prob=BhDiff)
gdum[24,V_sel] <- FALSE
get.adjlist(gdum) [24]

## [[1]]
## + 3/25 vertices:
## [1] 2 15 22

```

Функция `sample` отбирает один узел из списка смежных узлов с вероятностью, взвешенной по вектору различий. Чем сильнее непохожа пара узлов, тем с большей вероятностью узел будет выбран для удаления. Чтобы убедиться в том, что отбор работает должным образом, мы можем многократно повторить отбор и посмотреть на его результаты. Они показывают, что узел 9 выбирается чаще всего, а узел 15 реже всего, что соответствует нашим ожиданиям, исходя из значений характеристики `Bh`.

```

smplCheck <- sample(V_adj,500,replace=TRUE,prob=BhDiff)
table(smplCheck)

## smplCheck
##   2   9   15  22
##   91  327   35   47

```

Добавление новой связи, которая соединяет конкретный узел с любым другим узлом, осуществляется аналогичным способом. Однако есть два основных отличия. Во-первых, вместо отбора наиболее различающихся пар вершин нам нужно выбрать пару узлов, которые схожи между собой по характеристике `Bh`. Во-вторых, поскольку мы хотим добавить новую связь, нам нужно отобрать все несмежные узлы (т. е. узлы, которые не связаны напрямую с интересующим узлом).

Несмежные узлы можно отобрать путем удаления смежных узлов, а также идентификационного номера интересующей вершины из списка всех узлов. Узлам в пакете *igraph* присваиваются номера начиная с 1. Если нас интересует узел 24, программный код, приведенный ниже, находит все несмежные узлы. Он использует индексацию вектора для удаления значений с помощью знака минуса.

```
vtx <- 24
nodes <- 1:vcount(g)
V_nonadj <- nodes[-c(vtx,V_adj)]
V_nonadj

## [1] 1 3 4 5 6 7 8 10 11 12 13 14 16 17 18
## [16] 19 20 21 23 25
```

Следуя той же логике, что и прежде, мы сейчас можем случайным образом создать новую связь, основываясь на схожести двух узлов. Поскольку теперь мы вычисляем значения, обратные абсолютным разностям, в вектор *BhDiff2* записываются значения сходства.

```
BhDiff2 <- 1-abs(V(g)[V_nonadj]$Bh - V(g)[vtx]$Bh)
BhDiff2

## [1] 0.912 0.546 0.956 0.771 0.906 0.967 0.712
## [8] 0.900 0.207 0.663 0.859 0.309 0.997 0.194
## [15] 0.305 0.480 0.433 0.486 0.820 0.249

Sel_V <- sample(V_nonadj,1,prob=BhDiff2)
gnew <- g
gnew[vtx,Sel_V] <- TRUE
get.adjlist(gnew)[vtx]

## [[1]]
## + 5/25 vertices:
## [1] 2 9 10 15 22
```

Программный код, приведенный ниже, присваивает особый цвет (*darkred*) недавно добавленной связи, чтобы ее легче было заметить на графике (рис. 13.3).

```
E(gnew)$color <- "grey"
E(gnew, P = c(vtx, Sel_V))$color <- "darkred"
plot(gnew, layout = crd_save)
```

Все это является подготовкой к созданию простой функции изменения, которую можно будет вызвать в ходе имитационного моделирования сети большего размера. Функция, которая приводится ниже, принимает в качестве аргументов объект-сеть *igraph(g)* и интересующую нас вершину (*vtx*). Сначала она проверяет, не является ли переданная вершина изолированным узлом, если это так, функция просто возвращает сеть без изменений (потому что нельзя удалить связь у изолированного узла). Если вершина не является изолированным узлом, функция

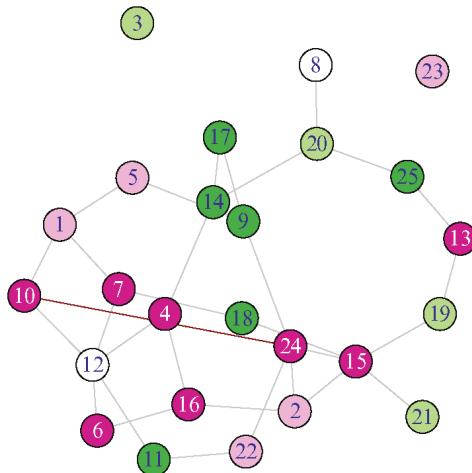


Рис. 13.3. Тестовая сеть с одной новой связью, добавленной к узлу 24

ция случайным образом удаляет существующую связь, используя вероятность, взвешенную по вектору различий между всеми связанными парами узлов. Затем она добавляет новую связь, используя вероятность, взвешенную по вектору сходств между всеми несвязанными парами узлов. Эти две операции объединены в одну функцию, чтобы возвращенный объект-сеть имел ту же самую плотность (т. е. общее количество связей), что и первоначальная сеть. Это позволит упростить интерпретацию будущей имитационной модели. Обратите внимание на то, что эта функция использует объект `igraph` с уже заданным атрибутом вершин `Bh`.

```
Sel_update <- function(g,vtx) {
  V_adj <- neighbors(g,vtx)
  if(length(V_adj)==0) return(g)
  BhDiff1 <- abs(V(g)[V_adj]$Bh - V(g)[vtx]$Bh)
  Sel_V <- sample(V_adj,1,prob=BhDiff1)
  g[vtx,Sel_V] <- FALSE
  nodes <- 1:vcount(g)
  V_nonadj <- nodes[-c(vtx,V_adj)]
  BhDiff2 <- 1-abs(V(g)[V_nonadj]$Bh - V(g)[vtx]$Bh)
  Sel_V <- sample(V_nonadj,1,prob=BhDiff2)
  g[vtx,Sel_V] <- TRUE
  g
}
```

Чтобы протестировать функцию, передаем в нее объект `igraph` вместе с вершиной, для которой нужно изменить связи.

```
gtst <- g
node <- 24
```

```

gnew <- Sel_update(g, node)
neighbors(gtst, node)

## + 4/25 vertices:
## [1] 2 9 15 22

neighbors(gnew, node)

## + 4/25 vertices:
## [1] 2 7 15 22

```

13.1.1.3. Построение простой имитационной модели социальной селекции

Теперь, создав функцию изменения, которая случайным образом добавляет и исключает связи в сети дружеских отношений, можно построить динамическую имитационную модель социальной селекции. Имитационная модель, приведенная ниже, является простой, но при этом ей присущи все элементы модели динамической сети. Она работает с сетью, вносит изменения с течением времени, и эти изменения можно наблюдать.

В динамической модели время может быть как вполне реальным, так и довольно абстрактным понятием. Для модели социальной селекции, представленной здесь, используется абстрактное понятие времени. В частности, узлы, которые будут изменены, выбираются случайным образом, и мы предполагаем, что между изменениями проходит определенный период времени. Однако никаких конкретных характеристик времени мы здесь не задаем.

Функция `Sel_sim` инкапсулирует имитационную модель социальной селекции. Функция принимает в качестве аргументов объект-сеть `igraph(g)` и заданное число изменений. Она начинает работу с того, что задает список, который будет использоваться для хранения измененных сетей. Затем внутри цикла, который выполняет заданное число изменений, выбирается случайный узел, и вызывается функция, которая удаляет уже существующую связь и добавляет новую. Измененная сеть сохраняется в списке после каждого шага, и по завершении цикла возвращается полный список сетей.

```

Sel_sim <- function(g, upd) {
  g_lst <- lapply(1:(upd+1), function(i) i)
  g_lst[[1]] <- g
  for (i in 1:upd) {
    gnew <- g_lst[[i]]
    node <- sample(1:vcount(g), 1)
    gupd <- Sel_update(gnew, node)
    g_lst[[i+1]] <- gupd
  }
  g_lst
}

```

Эта функция имитационного моделирования неэффективна по нескольким причинам. Во-первых, цикл можно вполне заменить векторизованной функцией.

Это может ускорить выполнение функции, хотя и с некоторой потерей удобочитаемости. Что еще более важно, по завершении каждого шага изменения функция сохраняет сеть полностью. Это приведет к тому, что функция вернет очень большие объекты в зависимости от размера сети и количества изменений. На ранних этапах разработки имитационной модели лучше сохранять сети полностью, чтобы их можно было исследовать. Однако на более поздних этапах обычно функцию настраивают так, чтобы возвратить лишь конкретную информацию о сетях, а не сами сети.

Следующий шаг заключается в построении случайной сети большего размера, которая будет использоваться в качестве вводной информации для имитационной модели социальной селекции.

```
N <- 100
netdum <- erdos.renyi.game(N, p=0.10)
graph.density(netdum)

## [1] 0.0949

mean(degree(netdum))

## [1] 9.4

Bh <- runif(N, 0, 1)
BhCat <- cut(Bh, breaks=5, labels = FALSE)
V(netdum)$Bh <- Bh
V(netdum)$BhCat <- BhCat
table(V(netdum)$BhCat)

##
## 1 2 3 4 5
## 13 19 32 13 23
```

Сейчас, когда стартовая сеть создана, мы запускаем фактическое имитационное моделирование и результаты сохраняем в списке объектов-сетей. В данном случае имитационная модель в качестве стартовой сети использует объект-сеть netdum и выполняет 500 изменений. Возвращенный список объектов-сетей содержит исходную сеть в первоначальном состоянии, а также 500 дополнительных сетей, которые соответствуют каждому изменению состояния сети в имитационной модели.

```
set.seed(999)
g_lst <- Sel_sim(netdum, 500)
length(g_lst)

## [1] 501

summary(g_lst[[1]])

## IGRAPH U--- 100 470 -- Erdos renyi (gnp) graph
## + attr: name (g/c), type (g/c), loops (g/l),
## | p (g/n), Bh (v/n), BhCat (v/n)
```

13.1.1.4. Интерпретация результатов имитационного моделирования

В первую очередь полученные результаты должны ответить на вопрос, было ли выполнено имитационное моделирование должным образом, затем нужно изучить соответствующие характеристики сетей, чтобы посмотреть, какие паттерны были выделены в результате имитационного моделирования. После этого мы можем сделать вывод о том, подтверждают ли полученные результаты наши исследовательские гипотезы касательно сетевой динамики.

Самый простой способ проверить качество нашей имитационной модели – изучить плотность имитированных сетей. Если имитационное моделирование выполнено правильно, плотность имитированных сетей постоянна. При этом паттерны прямых связей для каждого узла сети должны меняться. (Обратите внимание, что паттерны связей будут различными только в том случае, если узел был выбран и изменен в ходе имитационного моделирования. Это одна из причин, в силу которой количество прогонов должно многократно превышать размер сети, чтобы паттерны связей для всех или, по крайней мере, для большинства узлов были изменены.)

```
graph.density(g_lst[[1]])
## [1] 0.0949

graph.density(g_lst[[501]])
## [1] 0.0949

neighbors(g_lst[[1]], 1)
## + 5/100 vertices:
## [1] 16 33 51 65 72

neighbors(g_lst[[501]], 1)
## + 3/100 vertices:
## [1] 4 65 66
```

Убедившись в том, что имитационное моделирование выполнено правильно, мы можем сделать более существенные выводы. Согласно основной гипотезе этого примера, со временем степень гомофилии в сети нарастает. Это вызвано тем, что изменения связей отчасти обусловлены сходством узлов по абстрактной поведенческой характеристике. В данном случае важным показателем является модулярность сети (см. главу 8 для получения дополнительной информации о модулярности).

```
modularity(g_lst[[1]], BhCat)
## [1] -0.0221

modularity(g_lst[[501]], BhCat)
## [1] 0.168
```

Здесь мы видим, что для первоначальной сети была характерна более низкая модулярность, по сравнению с итоговой измененной сетью. Более высокое значение модулярности в итоговой сети говорит нам о том, что связи между участниками с одинаковым уровнем физической активности (`BhCat`) устанавливаются с большей вероятностью, чем связи между участниками с различными уровнями физической активности.

Этот аргумент звучит еще более убедительно, если мы приведем более подробную информацию, полученную в ходе имитационного моделирования. Графики показывают, что наблюдается существенный разброс значений модулярности по шагам моделирования. Что еще более важно, со временем модулярность растет практически вплоть до последнего шага имитационного моделирования (рис. 13.4).

```
sim_stat <- unlist(lapply(g_lst, function(u)
modularity(u,V(u)$BhCat)))
op <- par(mfrow=(c(1,2)))
plot(density(sim_stat),main="",xlab="Modularity")
plot(0:500,sim_stat,type="l",
      xlab="Simulation Step",ylab="Modularity")
par(op)
```

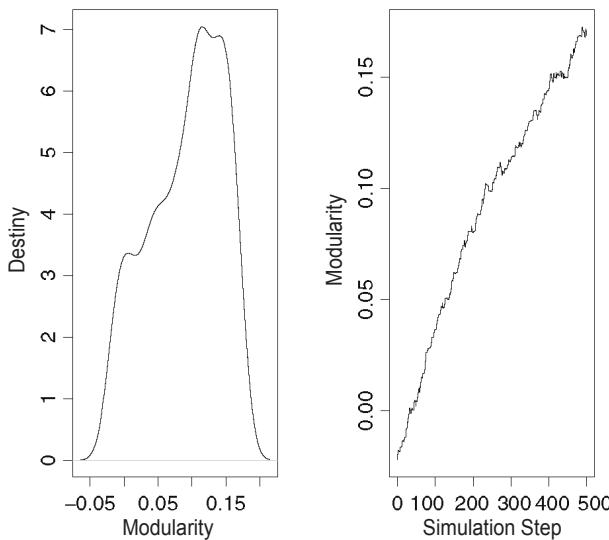


Рис. 13.4. Изменение модулярности со временем по результатам имитационного моделирования социальной селекции

13.1.2. Имитационное моделирование социального влияния

Следующий пример сосредоточен на втором процессе сетевой динамики, объясняющем нарастание гомофилии в социальных сетях, а именно на социальном влиянии. Социальное влияние – это процесс, в ходе которого поведение (или от-

ношение, мнение и т. д.) конкретного человека определяется поведением других людей, тесно связанных с ним внутри социальной сети. В данном случае мы разработаем простую модель социального влияния. Согласно этой модели, абстрактное поведение (B_h) конкретного человека в социальной сети определяется усредненным поведением всех участников, с которыми он непосредственно связан. Она представляет собой простую модель социального влияния сверстников. Чтобы сделать ее немного более реалистичной (и интересной), мы также дополним модель таким понятием, как область допуска. У каждого участника сети есть диапазон допуска (T_1). Если смежный участник имеет значение характеристики B_h , выходящее за пределы этого диапазона, влияние этого человека не будет учитываться. Так, например, если под B_h снова подразумевается уровень физической активности, то в модели, приведенной ниже, уровень физической активности участника будет определяться уровнем физической активности его друзей, но только в том случае, если уровень активности друзей примерно совпадает с его собственным.

13.1.2.1. Создание сети для имитационного моделирования

Процесс построения модели аналогичен предыдущему примеру, поэтому мы можем обойтись меньшим количеством иллюстраций. Первый шаг заключается в создании сети, которая будет использоваться для примера. Единственное отличие здесь заключается в том, что мы добавляем новую характеристику вершин T_1 или диапазон допуска для каждого участника сети. Для начала предположим, что каждый участник имеет одинаковый диапазон допуска 0,20. (Имейте в виду, что в силу случайности процесса имитационного моделирования значения вашей сети будут отличаться от нижеприведенных значений.)

```
N <- 25
netdum <- erdos.renyi.game(N, p=0.10)
Bh <- runif(N,0,1)
BhCat <- cut(Bh, breaks=5, labels = FALSE)
V(netdum)$Bh <- Bh
V(netdum)$BhCat <- BhCat
V(netdum)$T1 <- 0.20
V(netdum)$T1[1:10]

## [1] 0.2 0.2 0.2 0.2 0.2 0.2 0.2 0.2 0.2 0.2
```

13.1.2.2. Создание функции изменения

На первом шаге моделирования мы должны снова задать базовую функцию изменения. В данном случае вместо связей изменяем атрибут вершин B_h .

```
g <- netdum
V_adj <- neighbors(g,24)
V_adj

## + 4/25 vertices:
## [1] 2 9 15 22
```

```
V(g) [24] $Bh
## [1] 0.192
V(g) [V_adj] $Bh
## [1] 0.389 0.952 0.114 0.325
```

Для узла 24 начальное значение B_h является довольно низким (0,19). Значения B_h для четырех соседей узла 24 варьируют от 0,11 до 0,95.

Самый простой способ изменить значение B_h для узла 24 заключается в том, чтобы взять начальное значение B_h для узла 24, прибавить к нему усредненное значение B_h по всем четырем узлам-соседям, а затем полученный результат умножить на 0,5. Новое значение B_h равно 0,32, однако теперь оно скорректировано с учетом значений B_h для всех четырех узлов-соседей. Сильнее всего на узел 24 влияет узел 9 со значением B_h , равным 0,95.

```
newval <- .5*(V(g)$Bh[24] + mean(V(g)[V_adj]$Bh))
newval
## [1] 0.318
```

Для исключения узлов, у которых значения B_h выходят за пределы допустимого диапазона, можно использовать диапазон допуска. Создаем вектор V_{Bh} со значением B_h для узла 24 и вектор N_{Bh} со значениями B_h для узлов-соседей. Затем, если абсолютная разность между значением B_h для узла-соседа и значением B_h для узла 24 превышает диапазон допуска 0,20, данное значение B_h для узла-соседа не рассматриваем.

```
V_Bh <- V(g)[24]$Bh
V_Bh
## [1] 0.192
N_Bh <- V(g)[V_adj]$Bh
N_Bh
## [1] 0.389 0.952 0.114 0.325
N_Bh[abs(N_Bh-V_Bh) < .20]
## [1] 0.389 0.114 0.325
```

Теперь, удалив экстремально высокое значение для узла 9, выходящее за пределы диапазона допуска, можно вычислить изменившееся значение B_h для узла 24. Мы видим, что в данном случае значение B_h для узла 24 изменилось совсем не так, как прежде.

```
newval2 <- .5*(V(g)$Bh[24] +
mean(N_Bh[abs(N_Bh-V_Bh) < .20]))
newval2
## [1] 0.234
```

Этот подход, основанный на абсолютных разностях, закладывает основу функции изменения для будущей модели социального влияния. Эта функция возвращает измененное значение B_h для отобранный вершины. Если у отобранный вершины нет соседей со значениями B_h , находящимися внутри диапазона допуска, значение B_h возвращается без изменений. И снова эта функция предполагает, что объект-сеть уже имеет атрибуты вершин B_h и T_1 .

```
Inf_update <- function(g, vtx) {
  TL <- V(g)[vtx]$T1
  V_adj <- neighbors(g, vtx)
  V_Bh <- V(g)[vtx]$Bh
  N_Bh <- V(g)[V_adj]$Bh
  ifelse(length(N_Bh[abs(N_Bh-V_Bh)<TL]) > 0,
    new_Bh <- .5*(V_Bh +
      mean(N_Bh[abs(N_Bh-V_Bh) < TL])),
    new_Bh <- V_Bh
  )
  new_Bh
}
```

Тестируя новую функцию изменения, видим, что она возвращает правильное значение для узла 24.

```
newval3 <- Inf_update(g, 24)
newval3
## [1] 0.234
```

13.1.2.3. Построение имитационной модели социального влияния

Теперь, когда функция изменения социального влияния создана, ее можно поместить в функцию, которая запускает модель динамической сети. Она аналогична модели социальной селекции из предыдущего раздела с одной большой разницей. Логично предположить, что в один и тот же момент времени влияние испытывают все узлы, поскольку социальное влияние является в большей степени непрерывным процессом. Это означает, что вместо случайного отбора и изменения узлов мы будем изменять все узлы в каждом имитационном прогоне. (И снова эффективность функции, представленной здесь, можно повысить несколькими способами.)

```
Inf_sim <- function(g, runs) {
  g_lst <- lapply(1:(runs+1), function(i) i)
  g_lst[[1]] <- g
  for (i in 1:runs) {
    gnew <- g_lst[[i]]
    for (j in 1:length(V(g))) {
      V(gnew)[j]$Bh <- Inf_update(g=gnew, vtx=j)
    }
    g_lst[[i+1]] <- gnew
  }
}
```

```

}
g_lst
}

```

Программный код, приведенный ниже, создает ту же самую случайную стартовую сеть и затем строит имитационную модель, выполнив 50 прогонов по этой сети. В данном случае количество имитационных прогонов не должно быть таким же большим, как для модели селекции, потому что в каждом прогоне модели влияния изменяются все узлы.

```

N <- 100
netdum <- erdos.renyi.game(N, p=0.10)
Bh <- runif(N, 0,1)
V(netdum)$T1 <- .20
V(netdum)$Bh <- Bh
V(netdum)$BhCat <- BhCat
set.seed(999)
g_lst <- Inf_sim(netdum, 50)

```

13.1.2.4. Интерпретация результатов имитационного моделирования

В ходе имитационного моделирования мы можем наблюдать уменьшение разброса значений Bh из-за того, как участники сети корректируют свое поведение в зависимости от усредненного поведения их соседей (рис. 13.5).

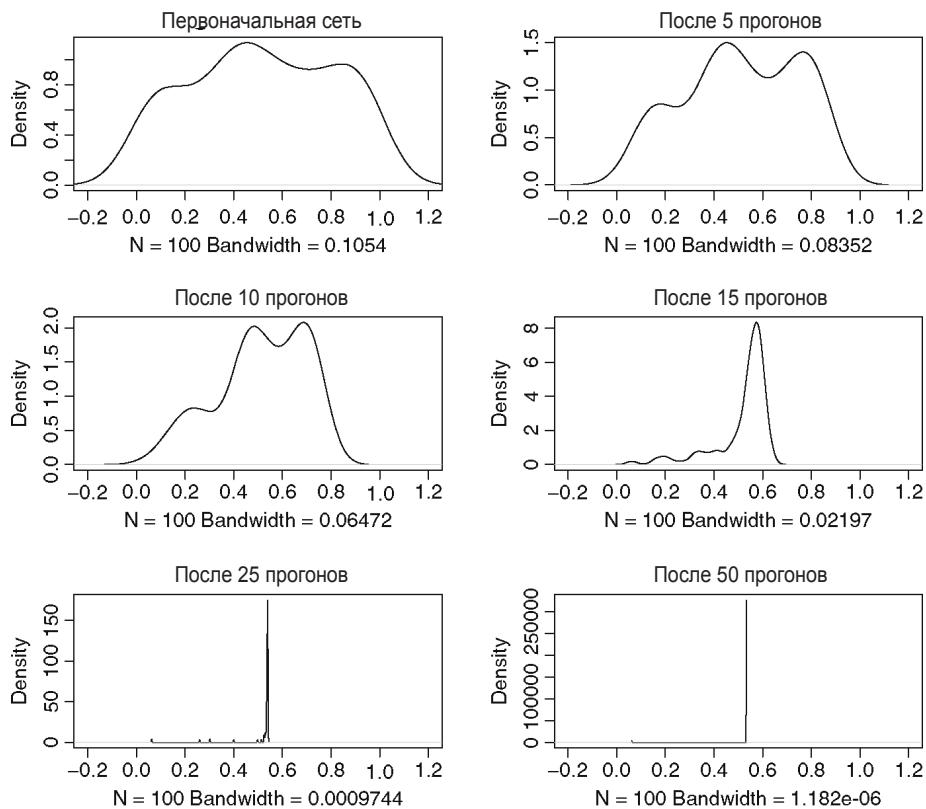
```

op <- par(mfrow=(c(3,2)))
plot(density(V(g_lst[[1]])$Bh), xlim=c(-.2,1.2),
      main="Первоначальная сеть")
plot(density(V(g_lst[[6]])$Bh), xlim=c(-.2,1.2),
      main='После 5 прогонов')
plot(density(V(g_lst[[11]])$Bh), xlim=c(-.2,1.2),
      main='После 10 прогонов')
plot(density(V(g_lst[[16]])$Bh), xlim=c(-.2,1.2),
      main='После 15 прогонов')
plot(density(V(g_lst[[26]])$Bh), xlim=c(-.2,1.2),
      main='После 25 прогонов')
plot(density(V(g_lst[[51]])$Bh), xlim=c(-.2,1.2),
      main='После 50 прогонов')
par(op)

```

Графики показывают нам несколько интересных вещей. Во-первых, потребовалось несколько прогонов модели, чтобы разброс значений поведенческой характеристики стал меняться. Однако процессу гомогенизации не потребовалось 50 прогонов, уже к 25-му прогону почти все узлы изменили свое поведение так, чтобы соответствовать узлам со средним уровнем физической активности.

Кроме того, мы можем наблюдать, что увеличилась гомофиля сети. Рисунок 13.6 показывает, что к 25-му имитационному прогону большинство узлов попало в среднюю категорию характеристики Bh , тогда как изначально они были равномерно распределены по пяти категориям.

Рис. 13.5. Уменьшение разброса значений Bh со временем

```

V(g_lst[[1]])$BhCat <- cut(V(g_lst[[1]])$Bh,
  breaks=c(0,.2,.4,.6,.8,1), labels = FALSE)
V(g_lst[[26]])$BhCat <- cut(V(g_lst[[26]])$Bh,
  breaks=c(0,.2,.4,.6,.8,1), labels = FALSE)
V(g_lst[[51]])$BhCat <- cut(V(g_lst[[51]])$Bh,
  breaks=c(0,.2,.4,.6,.8,1), labels = FALSE)
V(g_lst[[1]])$color <- my_pal[V(g_lst[[1]])$BhCat]
V(g_lst[[26]])$color <- my_pal[V(g_lst[[26]])$BhCat]
op <- par(mfrow=c(1,2),mar=c(0,0,2,0))
plot(g_lst[[1]],vertex.label=NA,
  main="Первоначальная сеть")
plot(g_lst[[26]],vertex.label=NA,
  main="Сеть после 25-го прогона")
par(op)

```

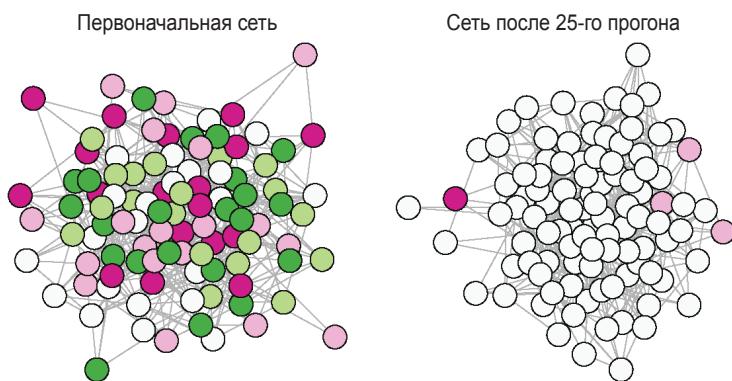


Рис. 13.6. Увеличение гомофилии со временем

Эти примеры имитационного моделирования демонстрируют возможности R по исследованию сетевой и поведенческой динамики. Их можно дополнить различным образом, чтобы не только строить аналогичные имитационные модели, но и также применять их для решения более серьезных научных задач. Существует, по крайней мере, два простых способа дополнить примеры, представленные здесь. Во-первых, при имитационном моделировании социального влияния, вместо того чтобы всем участникам сети назначать одинаковый диапазон допуска (0,20), можно исследовать эффекты различных значений допуска на характеристики социального влияния. (Или можно исследовать эффекты уменьшения или увеличения уровней допуска.) Во-вторых, примеры, представленные здесь, рассматривают процессы социальной селекции и социального отбора по отдельности. Эти две имитационные модели можно объединить для исследования характеристик одновременно протекающих процессов селекции и влияния. (Об этом рассказывалось в главе 12 с точки зрения статистического моделирования.)

Библиография

- Barabási A. L. (2007). Network medicine from obesity to the diseasesome. *N Engl J Med* // <http://www.nejm.org/doi/full/10.1056/nejme078114>.
- Barabási A. L., Albert R. (1999). Emergence of scaling in random networks. *Science* // <http://www.sciencemag.org/content/286/5439/509.short>.
- Broder A., Kumar R., Maghoul F. (2000). Graph structure in the web. *Computer Netw* // <http://www.sciencedirect.com/science/article/pii/S1389128600000839>.
- Butts C. T. (2008). Network: a package for managing relational data in R. *J Stat Softw* // <http://cran.repo.bppt.go.id/web/packages/network/vignettes/networkVignette.pdf>.
- Freeman L. C. (2004). The development of social network analysis: a study in the sociology of science. Empirical Press, p 205. ISBN:1594577145 // <https://books.google.com/books?id=VcxqQgAACAAJ&pgis=1>.
- Fruchterman T. M. J., Reingold E. M. (1991). Graph drawing by force-directed placement. *Softw Pract Exp* // ftp://132.180.22.143/axel/papers/reingold:graph_drawing_by_force_directed_placement.pdf.
- Galaskiewicz J. (1985). The influence of corporate power, social status, and market position on corporate interlocks in a regional network. *Social Forces* // <http://sf.oxfordjournals.org/content/64/2/403.abstract>.
- Gentleman R., Lang D. T. (2007). Statistical analyses and reproducible research. *J Comput Graph Stat* // <http://www.jstor.org/stable/27594227>.
- Goodreau S. M. (2007). Advances in exponential random graph (p^*) models applied to a large social network. *Soc Netw* 29 (2): 231–248. ISSN: 03788733. doi:10.1016/j.socnet.2006.08.001.
- Granovetter M. S. (1973). The strength of weak ties. *Am J Sociol* // <http://www.jstor.org/stable/2776392>.
- Handcock M. S. et al. (2008). Statnet: software tools for the representation, visualization, analysis and simulation of network data. *J Stat Softw* 24 (1): 1–11. ISSN: 1548–7660.
- Harris J. K. (2013). An introduction to exponential random graph modeling. SAGE, p. 136. ISBN: 148332205X // <https://books.google.com/books?hl=en&lr=&id=lkYXBAAAQBAJ&pgis=1>.
- Harris J. K., Luke D. A. (2009). Forty years of secondhand smoke research: the gap between discovery and delivery. *Am J Prev Med* // <http://www.sciencedirect.com/science/article/pii/S0749379709001548>.
- Holland P. W., Leinhardt S. (1978). An omnibus test for social structure using triads. *Sociol Methods Res* // <http://smr.sagepub.com/content/7/2/227.short>.
- Hunter D. R. et al. (2008). Ergm: a package to fit, simulate and diagnose exponential-family models for networks. *J Stat Softw* 24 (3): nihpa54860. ISSN: 1548-7660 // <http://www.ncbi.nlm.nih.gov/pmc/articles/PMC2743438/> tool=pmc entrez&rendertype=abstract.

- Knoke D., Burt R. S. (1983). Prominence. *Appl Netw Anal* // https://scholar.google.com/scholar?q=knoke+burt+prominence&btnG=&hl=en&as_sdt=0%2C26#0.
- Kolaczyk E. D. (2009). Statistical analysis of network data: methods and models. Springer, p. 398. ISBN: 0387881468 // <https://books.google.com/books?id=Q-GNLsqq7QwC&pgis=1>.
- Krebs V. E. (2002). Uncloaking terrorist networks // <http://firstmonday.org/ojs/index.php/fm/article/view/941/863>.
- Leischow S. J., Luke D. A., et al. (2010). Mapping US government tobacco control leadership: networked for success? *Nicotine Tob Res* // <http://ntr.oxfordjournals.org/content/12/9/888.short>.
- Liljeros F., Edling C. R., Amaral L. A. N. (2001). The web of human sexual contacts. *Nature* // <http://www.nature.com/nature/journal/v411/n6840/full/411907a0.html>.
- Luke D. A., Harris J. K. (2007). Network analysis in public health: history, methods, and applications. *Annu Rev Public Health* 28: 69–93. ISSN: 0163-7525. doi:10.1146/annurev.publhealth.28.021406.144132.
- Luke D. A., Stamatakis K. A. (2012). Systems science methods in public health: dynamics, networks, and agents. *Annu Rev Public Health* // <http://www.ncbi.nlm.nih.gov/pmc/articles/PMC3644212/>.
- Luke D. A., Wald L. M. (2013). Network influences on dissemination of evidence-based guidelines in state tobacco control programs. *Health Educ Behav* // http://heb.sagepub.com/content/40/1_suppl/33S.short.
- Luke D. A., Harris J. K., Shelton S. (2010). Systems analysis of collaboration in 5 national tobacco control networks. *Am J Public Health* // <http://www.ncbi.nlm.nih.gov/pmc/articles/PMC2882404/>.
- McPherson M., Smith-Lovin L., Cook J. M. (2001). Birds of a feather: homophily in social networks. *Annu Rev Sociol* // <http://www.jstor.org/stable/2678628>.
- Morris M., Handcock M. S., Hunter D. R. (2008). Specification of exponential-family random graph models: terms and computational aspects. *J Stat Softw* 24 (4): 1548–7660. ISSN: 1548–7660 // <http://www.ncbi.nlm.nih.gov/articlerender.fcgi?artid=2481518&tool=pmcentrez&rendertype=abstract>.
- Murrell P. (2005). R graphics. Taylor & Francis, p. 328. ISBN: 158488486X // <https://books.google.com/books?id=fJUVNgEACAAJ&pgis=1>.
- Newman M. E. J. (2006). Modularity and community structure in networks. *Proc Natl Acad Sci USA* // <http://www.pnas.org/content/103/23/8577.short>.
- Newman M. (2010). Networks: an introduction. Oxford University Press, Oxford, p. 784. ISBN: 0191500704 // <https://books.google.com/books?id=LrFaU4XCscUoC&pgis=1>.
- Newman M. E. J., Girvan M. (2004). Finding and evaluating community structure in networks. *Phys Rev E Stat Nonlinear Soft Matter Phys* 69 (2): 1–15. ISSN: 1063651X. doi:10.1103/PhysRevE.69.026113. arXiv: 0308217 [cond-mat].
- Newman M., Barabási A. L., Watts D. J. (2006). The structure and dynamics of networks. Princeton University Press, p. 582. ISBN: 0691113572 // <https://books.google.com/books?id=0FNQ1LYKTMwC&pgis=1>.

- Rogers E. M. (2003). *Diffusion of innovations*, 5th edn. Simon and Schuster, p. 576. ISBN: 0743258231 // <https://books.google.com/books?id=9U1K5LjUOwEC&pgis=1>.
- Scott J. (2012). Social network analysis (3rd Ed.) SAGE Publications.
- Scott J., Carrington P. J. (2011). *The SAGE handbook of social network analysis*. SAGE Publications.
- Snijders T. A. B., Pattison P. E. (2006). New specifications for exponential random graph models. *Sociol Methodol* // <http://smx.sagepub.com/content/36/1/99.short>.
- Snijders T. A. B., Van de Bunt G. G., Steglich C. E. G. (2010). Introduction to stochastic actor-based models for network dynamics. *Soc Netw* // <http://www.sciencedirect.com/science/article/pii/S0378873309000069>.
- De Solla Price D. J. (1976). A general theory of bibliometric and other cumulative advantage process. *J Am Soc Info Sci* // https://scholar.google.com/scholar?q=price+1976+bibliometric&btnG=&hl=en&as_sdt=0%2C26#4.
- Sporns O. (2012). Discovering the human connectome. MIT, p. 232. ISBN: 026017903 // <https://books.google.com/books?id=u0Nf2x0J8LMC&pgis=1>.
- Tufte E. R. (1990). Envisioning information, vol. 914. Graphics Press, p. 126 // <https://books.google.com/books?id=1uloAAAAIAAJ&pgis=1>.
- Tufte E. R. (2001). The visual display of quantitative information. Graphics Press, p. 197. ISBN: 0961392142 // <https://books.google.com/books?id=GTd5oQEACAAJ&pgis=1>.
- Tukey J. W. (1977). Exploratory data analysis. Addison-Wesley, p. 688. ISBN: 0201076160 // <https://books.google.com/books?id=UT9dAAAAIAAJ&pgis=1>.
- Valente T. W. (2010). Social networks and health: models, methods, and applications. Oxford University Press, Oxford, p. 296. ISBN: 0199719721 // <https://books.google.com/books?id=xnMzd1-7iGgC&pgis=1>.
- Wasserman S., Faust K. (1994). Social network analysis: methods and applications, vol. 25. Cambridge University Press, p. 825. ISBN: 0521387078 // <https://books.google.com/books?id=CAm2DplqRUIC&pgis=1>.
- Watts D. J., Strogatz S. H. (1998). Collective dynamics of 'small-world' networks. *Nature* // <http://www.nature.com/nature/journal/v393/n6684/abs/393440a0.html>.

Книги издательства «ДМК Пресс» можно заказать в торгово-издательском холдинге «Планета Альянс» наложенным платежом, выслав открытку или письмо по почтовому адресу:
115487, г. Москва, 2-й Нагатинский пр-д, д. 6А.

При оформлении заказа следует указать адрес (полностью),
по которому должны быть высланы книги; фамилию, имя и отчество получателя.

Желательно также указать свой телефон и электронный адрес.

Эти книги вы можете заказать и в интернет-магазине: www.alians-kniga.ru.

Оптовые закупки: тел. (499) 782-38-89.

Электронный адрес: books@alians-kniga.ru.

Дуглас А. Люк

Анализ сетей (графов) в среде R. Руководство пользователя

Главный редактор *Мовчан Д. А.*
dmkpress@gmail.com

Перевод *Груздев А. В.*

Корректор *Синяева Г. И.*

Верстка *Чапнова А. А.*

Дизайн обложки *Мовчан А. Г.*

Формат 70×100 1/16.

Гарнитура «Петербург». Печать офсетная.

Усл. печ. л. 23,25. Тираж 200 экз.

Веб-сайт издательства: www.dmk.ru